

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104378-115323

**Mobilná aplikácia na ovládanie výrobnéj linky s
využitím jedinečného identifikátora**

Diplomová práca

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104378-115323

Mobilná aplikácia na ovládanie výrobnéj linky s využitím jedinečného identifikátora

Diplomová práca

Študijný program:	Aplikovaná mechatronika a elektromobilita
Študijný odbor:	Kybernetika
Školiace pracovisko:	Ústav automobilovej mechatroniky (FEI)
Školiteľ:	Ing. Lukáš Beňo PhD.



ZADANIE BAKALÁRSKEJ PRÁCE

Študent: **Meno Priezvisko**
ID študenta: 012345
Študijný program: jadrové a fyzikálne inžinierstvo
Študijný odbor: elektrotechnika
Vedúci práce: tituly, Meno Priezvisko, tituly
Vedúci pracoviska: tituly Meno Priezvisko, tituly
Miesto vypracovania: Ústav jadrového a fyzikálneho inžinierstva

Názov práce: **Rozšírená šablóna záverečnej práce na FEI STU v Bratislave
v systéme LaTeX**

Jazyk, v ktorom sa práca vypracuje: slovenský jazyk

Špecifikácia zadania:

- Vytvorte šablónu záverečnej práce pre študentov bakalárskeho a inžinierskeho štúdia na FEI STU v Bratislave.
- Napište návod na písanie záverečnej práce s použitím vytvorenej šablóny.
- Vytvorte prehľad najpoužívanejších typov citovaných zdrojov a zdokumentujte ich tak, aby boli v súlade s normou ISO 690.

Zoznam odbornej literatúry:

- Zákon č. 131/2002 Z. z. z 21. februára 2002 o vysokých školách a o zmene a doplnení niektorých zákonov [online]. [cit. 2024-09-01]. Dostupné na https://www.slov-lex.sk/static/pdf/2002/131/ZZ_2002_131_20240901.pdf
- Vyhláška č. 233/2011 Z. z. Ministerstva školstva, vedy, výskumu a športu Slovenskej republiky z 1. júla 2011, ktorou sa vykonávajú niektoré ustanovenia zákona č. 131/2002 Z. z. o vysokých školách a o zmene a doplnení niektorých zákonov v znení neskorších predpisov [online]. [cit. 2024-09-01]. Dostupné na https://www.slov-lex.sk/static/pdf/2011/233/ZZ_2011_233_20201015.pdf

3. Metodické usmernenie Ministerstva školstva, vedy, výskumu a športu SR č. 56/2011 o náležitostiach záverečných prác, ich bibliografickej registrácii, kontrole originality, uchovávaní a sprístupňovaní č. 2011-11513/31015:4-071 [online]. [cit. 2024-09-24]. Dostupné na <http://www.minedu.sk/metodicke-usmernenie-c-562011-o-nalezitostiach-zaverecných-prac-ich-bibliografickej-registrácii-uchovavani-a-sprístupnovani/>.
4. STN ISO 214: 1998. Dokumentácia. Abstrakty (referáty) pre publikácie a dokumentáciu. Bratislava: Slovenský ústav technickej normalizácie. Bratislava. Úrad pre metrológiu a skúšobníctvo Slovenskej republiky.
5. STN ISO 690: 2022. Dokumentácia – Bibliografické odkazy – Obsah, forma a štruktúra. Bratislava. Úrad pre metrológiu a skúšobníctvo Slovenskej republiky.
6. STN 01 6910: 2023. Pravidlá písania a úpravy písomností. Bratislava. Úrad pre metrológiu a skúšobníctvo Slovenskej republiky.
7. STN ISO 2145: 1997. Dokumentácia. Číslovanie oddielov a pododdielov písaných dokumentov. Bratislava. Úrad pre metrológiu a skúšobníctvo Slovenskej republiky.
8. STN ISO EN 80 000-1: 2022. Veličiny a jednotky. Bratislava. Úrad pre metrológiu a skúšobníctvo Slovenskej republiky.
9. LICHNEROVÁ, L. a B. BELLÉROVÁ. Nové pravidlá citovania podľa ISO 690 z roku 2021. *ITlib. Informačné technológie a knižnice*, 3–4/2023, 10 – 22. [cit. 2024-09-06]. Dostupné na <http://doi.org/10.52036/1335793X.2023.3-4.10-22>.
10. HOFTICH, M. ISO 690 biblatex style [online]. [cit. 2024-09-30]. Dostupné na <https://mirrors.ibiblio.org/CTAN/macros/latex/contrib/biblatex-contrib/biblatex-iso690/biblatex-iso690.pdf>.

Termín odovzdania bakalárskej práce: 31. 05. 2025

Dátum schválenia zadania bakalárskej práce: 28. 02. 2025

Zadanie bakalárskej práce schválil: tituly Meno Priezvisko, tituly – garant študijného programu

Podakovanie

Na tomto mieste by som sa rád poďakoval Ing. Lukášovi Beňovi PhD. za cenné rady a pomoc pri písaní diplomovej práce.

Abstrakt

Príručka pre študentov Fakulty elektrotechniky a informatiky STU v Bratislave obsahuje rady a návody, ako z formálneho hľadiska pristupovať k vypracovaniu záverečnej práce vysokoškolského štúdia. Dokument zároveň môže slúžiť ako šablóna práce v systéme na sadzbu textu $\text{\LaTeX}$. Detailne sa zaoberá pravidlami sadzby matematických rovníc, číslovania plávajúcich objektov a odkazovaním na ne. Podrobne sa venuje aj spôsobu citovania externých literárnych zdrojov.

Kľúčové slová

Ovládanie výrobnéj linky, mobilná aplikácia, jedinečný identifikátor, AI asistent

Abstract

The manual for students of the Faculty of Electrical Engineering and Information Technology at Slovak University of Technology in Bratislava provides advice and guidelines on how to approach the formal aspects of writing a final thesis for university studies. The document can also serve as a template for the thesis in the $\text{\LaTeX}$ typesetting system. It covers in detail the rules for typesetting mathematical equations, numbering floating objects, and referencing them. It also thoroughly addresses the method of citing external literary sources.

Keywords

Production line control, mobile application, unique identifier, AI assistant

Obsah

Úvod	1
1 Analýza existujúcich riešení	3
1.1 Siemens WinCC Unified	3
1.2 Ignition Perspective	4
1.3 Tulip	5
1.4 AVEVA InTouch Edge HMI	6
2 Prehľad technológií pre vývoj aplikácií a priemyselnú komunikáciu	9
2.1 Frontendové technológie	9
2.2 Backendové frameworky	10
2.3 Kontajnerizácia a Edge architektúra	10
2.3.1 Docker a Docker Compose	11
2.4 Priemyselné komunikačné protokoly	11
2.4.1 OPC UA	11
2.4.2 S7 Protokol	12
2.4.3 MQTT	12
2.4.4 Modbus TCP	13
3 Prehľad technológií pre inteligentných asistentov	14
3.1 Veľké jazykové modely a možnosti nasadenia	14
3.2 Retrieval-Augmented Generation	14
3.3 AI asistenti v priemyselnom prostredí	15
4 Typy identifikátorov a ich použitie	16
4.1 QR kódy	16
4.2 Fiduciálne markery – AprilTag, ArUco, STag	16
4.3 3D identifikátory	16
4.3.1 Princíp a štruktúra	17
5 Špecifikácia požiadaviek systému	18
5.1 Prehľad systému	18
5.2 Popis používateľských rolí	19
5.3 Use-case scenáre	19
5.4 Funkcionálne požiadavky	21
5.5 Nefunkcionálne požiadavky	22
5.6 Doménové požiadavky	23

6	Voľba technológií	24
6.1	Komunikácia s PLC – S7 protokol	24
6.2	Komunikačná middleware vrstva – Node-RED	24
6.3	Transportný protokol – MQTT	25
6.4	Backend – FastAPI	25
6.5	Frontend – Flutter	26
6.6	Výber identifikátora – ArUco	26
7	Experimentálne porovnanie a výber jazykových modelov	28
7.1	Popis testovaných modelov	28
7.2	Metodika testovania	29
7.3	Výsledky porovnania	30
7.4	Analýza výsledkov a výber modelu	30
7.4.1	Overenie na cloudovom hardvéri	31
7.4.2	Záverečné rozhodnutie o architektúre AI asistenta	32
8	Návrh architektúry systému	33
8.1	Architektúra komponentov systému	33
8.2	Fyzická topológia systému	33
8.3	Štruktúra MQTT tém	35
9	Implementácia backendu	36
9.1	Autentifikácia a RBAC	36
9.2	API endpointy	37
9.3	Mechanizmus relácií	38
9.4	Command lifecycle	38
9.5	Idempotencia príkazov	38
9.6	Generátor ArUco + STL export	38
10	Implementácia AI asistenta	39
10.1	RAG pipeline diagram	39
10.2	Embedovací model	39
10.3	System prompt	39
10.4	Správa konverzácie	39
10.5	KB management	39
11	Implementácia frontendu	40
11.1	Stavový manažment	40
11.2	ArUco skenovanie	40

11.3 WebSocket pripojenie	40
11.4 Role based UI	40
12 Aplikácia a jej funkcionality	41
12.1 Skener ArUco identifikátorov	41
12.2 Generátor ArUco identifikátorov	41
12.3 Monitoring a ovládanie zariadení	41
12.4 Virtuálny asistent PLE XO	41
12.5 Správa používateľov	42
12.6 Správa zariadení	42
12.7 Správa znalostnej bázy	42
12.8 Nastavenia	42
13 Testovanie a meranie	44
13.1 Overenie splnenia špecifikácie	44
13.2 Latencia vykonania príkazov	44
13.3 ArUco detekcia	44
13.4 Kvalita odpovedí asistenta	44
Záver	45
Literatúra	47
Použitie nástrojov umelej inteligencie	49
A Algoritmus	50
B Výpis dlhého kódu	51
C Slovníček pojmov	55

Zoznam značiek a skratiek

AI	Artificial Intelligence (slovensky „umelá inteligencia“)
API	Application Programming Interface (slovensky „aplikačné programové rozhranie“)
ASGI	Asynchronous Server Gateway Interface (slovensky „asynchrónne rozhranie serverovej brány“)
CPU	Central Processing Unit (slovensky „centrálna procesorová jednotka“)
GPU	Graphics Processing Unit (slovensky „grafická procesorová jednotka“)
HMI	Human-Machine Interface (slovensky „rozhranie človek-stroj“)
HTML	HyperText Markup Language (slovensky „hypertextový značkovací jazyk“)
HTTP	HyperText Transfer Protocol (slovensky „hypertextový prenosový protokol“)
IIoT	Industrial Internet of Things (slovensky „priemyselný internet vecí“)
IoT	Internet of Things (slovensky „internet vecí“)
IT	Information Technology (slovensky „informačné technológie“)
JSON	JavaScript Object Notation (slovensky „JavaScriptová objektová notácia“)
KB	Knowledge Base (slovensky „znalostná báza“)
LLM	Large Language Model (slovensky „veľký jazykový model“)
ML	Machine Learning (slovensky „strojové učenie“)
MQTT	Message Queuing Telemetry Transport (slovensky „protokol na prenos telemetrických správ“)
OPC UA	Open Platform Communications Unified Architecture (slovensky „zjednotená architektúra otvorenej platformovej komunikácie“)

OT	Operational Technology (slovensky „prevádzkové technológie“)
PLC	Programmable Logic Controller (slovensky „programovateľný logický automat“)
Pub/Sub	Publish-Subscribe (slovensky „publikovanie-odberanie“)
QoS	Quality of Service (slovensky „kvalita služieb“)
QR	Quick Response (slovensky „rýchla odozva“)
RAG	Retrieval-Augmented Generation (slovensky „generovanie rozšírené o vyhľadávanie“)
RAM	Random Access Memory (slovensky „pamäť s náhodným prístupom“)
REST	Representational State Transfer (slovensky „prezentačný prenos stavu“)
SaaS	Software as a Service (slovensky „softvér ako služba“)
SCADA	Supervisory Control and Data Acquisition (slovensky „dohľadové riadenie a zber dát“)
SQL	Structured Query Language (slovensky „štruktúrovaný dotazovací jazyk“)
TCP	Transmission Control Protocol (slovensky „protokol riadenia prenosu“)
UI	User Interface (slovensky „používateľské rozhranie“)
VRAM	Video Random Access Memory (slovensky „video pamäť s náhodným prístupom“)

Zoznam algoritmov

1	Vypočítaj $y = x^n$	50
---	-------------------------------	----

Zoznam výpisov kódov

1	Závislosti pre kontrolu rolí	36
2	Ukážka výpisu kódu programu načítaného z externého súboru pomocou makra <code>\lstinputlisting</code>	51

Úvod

Písanie záverečnej práce je nevyhnutnou súčasťou štúdia na vysokej škole. Študenti sa s touto činnosťou často stretávajú po prvýkrát na konci bakalárskeho štúdia. Príprava obsiahlejšieho textu je náročná úloha, ktorá zväčša trvá niekoľko týždňov alebo mesiacov. Pri finalizácii a formátovaní do výslednej podoby často panuje neistota a medzi študentami sa šíria protichodné informácie. Tento dokument slúži ako odporúčaná šablóna pre všetkých študentov FEI STU. Môžu ju využiť v plnej miere, alebo len ako inšpiráciu vytvorenia vlastnej výslednej podoby. Zároveň obsahuje návody a rady, ako sa vysporiadať s problémami, ktoré sa môžu pri písaní práce vyskytnúť.

Dokument je vytvorený v systéme na sadzbu textu $\text{\LaTeX}$ použitím upravenej verzie obľúbenej šablóny `FEIstyle`, verzia 2.0.0. Príručka je po formálnej a vizuálnej stránke navrhnutá tak, aby zodpovedala požiadavkám kladeným na záverečnú prácu vrátane poradia jednotlivých častí. Niektoré časti sú povinné (napr. obálka, titulný list, abstrakt), iné sú voliteľné (zoznam obrázkov, tabuliek, poďakovanie). Odporúčame študentom prečítať si aspoň prvú kapitolu tejto príručky, aby získali istotu pri začatí práce.

Jedným zo zámerov tohto manuálu je, aby jeho zdrojové súbory slúžili ako šablóna, do ktorej študenti vložia obsah vlastnej práce. Okrem definície rozmerov, okrajov, číslovania strán, štýlov a znakov, šablóna `FEIstyle.cls` obsahuje množstvo makier a príkazov na generovanie zoznamov obrázkov, tabuliek, výpisov kódov, algoritmov alebo obsahu. Zoznam a opis všetkých funkcií šablóny nájdete v priloženom dokumente `tutorial.pdf`.

Je žiadúce, aby študenti ovládali prácu s $\text{\LaTeX}$ -om na pokročilej užívateľskej úrovni. Je vhodné, ak si pred začiatkom písania preštudujú základné príručky. Veľmi vhodná je kniha Jiřího Rybyčku $\text{\LaTeX}$ pro začátečníky z roku 2003 [**Rybicka2003Latex**]. Ide síce o staršiu publikáciu v českom jazyku, patrí však k vyhľadávaným didaktickým textom a je oceňovaná všetkými používateľmi $\text{\LaTeX}$ -u najmä pri zvládaní prvých krokov. Prehľadnou a príťažlivou formou je tiež spracovaný tutoriál pre používateľov internetovej služby Overleaf.¹ Je to bezplatný výkonný online kompilátor $\text{\LaTeX}$ -u podporovaný mnohými vedeckými vydavateľstvami.

V texte tejto rozšírenej šablóny nájdeme okrem iného aj poznámky k jazykovej stránke textu záverečných prác, písaniu matematických vzorcov, vytváraniu a formátovaniu grafov, tabuliek, či výpisu kódov programov.

V závere ?? kapitoly rozoberieme aktuálnu problematiku používania umelej inteligencie pri tvorbe akademických prác.

¹www.overleaf.com/learn

Citáciám a bibliografickým zdrojom venujeme celú kapitolu ??, pretože práca s externými zdrojmi je pri akademických textoch veľmi dôležitá. Záverečná práca má byť samostatné dielo študenta, ktorý čerpá poznatky z iných zdrojov, spracováva ich a spája do nových súvislostí, čím vytvára novú kvalitu. Veríme, že tento dokument študentom pomôže lepšie sa orientovať, dodá im istotu pri písaní, zabezpečí kvalitný výsledok, estetický vzhľad a hodnotný obsah. Táto príručka nie je komplexným nástrojom na všetky aspekty záverečnej práce, no poskytuje pevný základ úspešného písania a efektívnej práce s literatúrou.

Naším cieľom bolo vytvoriť materiál, ktorý vedie študenta pri hľadaní ďalších zdrojov v literatúre a na internete, aby sa vedel orientovať v terminológii a získal základný prehľad. Prajeme úspešné písanie a dosiahnutie všetkých stanovených cieľov.

1 Analýza existujúcich riešení

Trh s priemyselnými softvérovými platformami ponúka viacero riešení umožňujúcich vizualizáciu a ovládanie výrobných zariadení. Väčšina z nich vychádza z tradičného modelu SCADA/HMI a postupne sa rozširuje o mobilný prístup, cloudovú konektivitu a v niektorých prípadoch aj o prvky umelej inteligencie. Nasledujúci prehľad analyzuje štyri významné komerčné platformy z pohľadu funkcionalít relevantných pre mobilné ovládanie priemyselných liniek: mobilný prístup k zariadeniam, identifikácia fyzických zariadení, nasadenie na edge vrstvu, otvorenosť platformy a integrácia inteligentného asistenta schopného pracovať s technickou dokumentáciou.

1.1 Siemens WinCC Unified

SCADA systém *SIMATIC WinCC Unified PC* od spoločnosti Siemens je vizualizačná platforma integrovaná do prostredia TIA Portal, navrhnutá na zjednotenie OT a IT dát v rámci jedného konzistentného systému [1]. Platforma je škálovateľná — od jednotlivého stroja až po rozsiahle distribuované systémy s prakticky neobmedzeným počtom dátových bodov — a používa rovnakú inžiniersku bázu ako panely radu Unified, čo štandardizuje vývoj naprieč typmi zariadení.

Prístup k prevádzkovým dátam je zabezpečený cez webové rozhranie HTML5, ktoré umožňuje vzdialené monitorovanie z prehliadača bez inštalácie klienta. Platforma obsahuje vstavaný SQL archív pre dlhodobé ukladanie dát a podporuje redundanciu pre vysokú dostupnosť systému.

Siemens v rámci TIA Portal ekosystému ponúka aj nástroj *Engineering Copilot TIA Standard* [2] — generatívneho AI asistenta pripojeného priamo k TIA Portal. Tento nástroj dokáže generovať kód PLC v jazyku SCL, vytvárať testovacie prípady, konfigurovať HMI obrazovky a odpovedať na inžinierske otázky na základe dokumentácie TIA Portal. Jeho zameranie je však výlučne na fázu návrhu a pomáha automatizačnému inžinierovi pri programovaní a konfigurácii, nie operátorovi počas prevádzky.

Z pohľadu tejto práce sú kľúčové tieto body:

- **Mobilný prístup:** Webové rozhranie je dostupné cez prehliadač, nie je to natívna mobilná aplikácia. Interakcia nie je optimalizovaná pre dotykové ovládanie v teréne.
- **Identifikácia zariadení:** Platforma nepodporuje skenovanie unikátnych identifikátorov (napr. ArUco, QR); operátor naviguje manuálne cez menu obrazoviek.

- **AI asistent pre obsluhu:** Engineering Copilot je nástroj pre inžiniera, nie pre operátora. Neposkytuje kontextovú pomoc na základe znalostnej bázy zariadení počas prevádzky.
- **Licenčný model:** Proprietárny, viazaný na ekosystém Siemens; vyžaduje TIA Portal licencie.

1.2 Ignition Perspective

Ignition SCADA od spoločnosti Inductive Automation je modulárna platforma postavená na otvorených IT štandardoch — SQL, Python, MQTT a OPC UA [3]. Jej kľúčovou vlastnosťou je licenčný model bez obmedzenia počtu tagov, klientov ani pripojení, čo ju odlišuje od väčšiny konkurenčných riešení účtujúcich za každý bod alebo reláciu.

Platforma komunikuje s PLC radu Allen-Bradley, Siemens, Mitsubishi, Modbus a ďalšími prostredníctvom vstavaných ovládačov a zabudovaného OPC UA servera. Ignition Gateway beží na štandardnom serveri (Windows, Linux, macOS) a škálovateľnosť je riešená architektúrou hub-and-spoke, kde centrálny Gateway koordinuje viaceré odlahčené inštancie.

Modul *Perspective* poskytuje plnohodnotné webové rozhranie na báze HTML5, prístupné z akéhokoľvek zariadenia bez inštalácie klienta. Vizualizačné komponenty sú responzívne a optimalizované pre dotykové ovládanie na tabletoch a smartfónoch. K dispozícii je aj natívna mobilná aplikácia *Ignition Perspective App*.

Pre nasadenie na okrajových zariadeniach (edge) Inductive Automation ponúka *Ignition Edge* [4]. Odlahčenú verziu so vstavaným archívom (35 dní lokálneho ukladania), podporou MQTT Sparkplug pre synchronizáciu dát na centrálny Gateway a možnosťou behu skriptov a tvorby REST API priamo na edge zariadení. Ignition Edge teda plní úlohu inteligentného priemyselného mosta medzi fyzickými zariadeniami a vyššími systémovými vrstvami.

Z pohľadu tejto práce sú kľúčové tieto body:

- **Mobilný prístup:** Modul Perspective poskytuje responzívne webové rozhranie aj natívnu mobilnú aplikáciu; dotykové ovládanie je plne podporované.
- **Identifikácia zariadení:** Platforma natívne nepodporuje skenovanie unikátnych identifikátorov. Navigácia cez QR kódy je technicky realizovateľná vlastnými Pythonskými skriptmi, avšak nejde o štandardnú funkciu platformy.
- **Edge nasadenie:** Ignition Edge umožňuje distribuované nasadenie priamo na priemyselných zariadeniach s lokálnou historizáciou a synchronizáciou dát.

- **AI asistent:** Platforma neobsahuje vstavanú funkciu inteligentného asistenta ani správu znalostnej bázy. Skriptovacie rozhranie v Pythone by technicky umožnilo volanie externých LLM API, avšak bez natívnej podpory.
- **Licenčný model:** Licencia na Gateway bez obmedzenia počtu klientov a tagov; jednotlivé moduly (Perspective, Alarming, Reporting) sa licencujú samostatne.

1.3 Tulip

Tulip je cloudová no-code platforma pre frontline operácie vo výrobnom sektore, ktorá umožňuje vytvárať priemyselné aplikácie prostredníctvom vizuálneho drag-and-drop editora bez nutnosti programovania [5]. Platforma je orientovaná na digitalizáciu manuálnych výrobných procesov — sledovanie výrobných krokov, zber dát z pracovísk, kontrolu kvality, vizuálne pracovné inštrukcie a sledovateľnosť výroby.

Licenčný model Tulip je odlišný od tradičných SCADA systémov — účtuje sa per interface (zariadenie spúšťajúce Tulip Player), nie per používateľ. Základný plán *Essentials* zahŕňa aplikácie na mobiloch, tabletoch, dotykových obrazovkách a nositeľných zariadeniach, pričom vyššie plány (*Professional*, *Enterprise*) pridávajú edge konektivitu, pokročilú správu rolí a integrácie cez HTTP a SQL konektory.

Pripojenie k priemyselným zariadeniam je realizované cez doplnkový modul *Machine Monitoring* s podporou OPC UA, MQTT a Node-RED. Aplikácie bežia vo webovom prehliadači (Tulip Player) na tabletoch a iných zariadeniach umiestnených na pracoviskách.

V roku 2024 Tulip uzavrel strategickú spoluprácu s Amazon Web Services a predstavil funkciu *Frontline Copilot* [6], postavenú na platforme Amazon Bedrock. Frontline Copilot umožňuje operátorom diagnostikovať výrobné dáta, hľadať v nich vzory a vytvárať aplikácie bez kódu s pomocou generatívnej AI. Systém pracuje s reálnymi výrobnými dátami zozbieranými v rámci platformy.

Z pohľadu tejto práce sú kľúčové tieto body:

- **Mobilný prístup:** Aplikácie sú webové a responzívne, spustiteľné na mobiloch, tabletoch aj dotykových obrazovkách.
- **Identifikácia zariadení:** Platforma podporuje skenovanie čiarových kódov a QR kódov pre identifikáciu materiálov a produktov, avšak nie pre priame spárovanie s konkrétnym zariadením výrobnéj linky.
- **Edge nasadenie:** Edge konektivita (OPC UA, MQTT, Node-RED) je dostupná ako platený doplnok; aplikačná logika a dáta sú hostované v cloude.

- **AI asistent:** Frontline Copilot poskytuje generatívnu AI na analýzu výrobných dát a asistenciu operátorom. Nejde však o asistenta s vlastnou znalostnou bázou technickej dokumentácie zariadení — funkcia pracuje primárne s dátami nazbieranými v rámci platformy Tulip.
- **Licenčný model:** SaaS model účtovaný mesačne per interface; cloudová závislosť môže byť problematická v prostrediach s prísnyimi požiadavkami na lokalizáciu dát.

1.4 AVEVA InTouch Edge HMI

AVEVA Edge je HMI/SCADA platforma od spoločnosti AVEVA, člen skupiny Schneider Electric, navrhnutá pre nasadenie na priemyselných zariadeniach, priemyselných PC a edge zariadeniach s minimálnymi hardvérovými nárokmi [7]. Kľúčovým princípom platformy je heslo „develop once, deploy everywhere“. Aplikácia sa navrhne raz v prostredí AVEVA Edge Studio a nasadí na Windows alebo Linux, od malých embedded zariadení až po plnohodnotné SCADA systémy.

Platforma je interoperabilná s väčšinou priemyselných zariadení prostredníctvom vstavaných ovládačov a natívnej podpory OPC UA. Vzdialený prístup je zabezpečený webovým publikovaním na báze HTML5, čo umožňuje sledovanie a ovládanie aplikácie zo smartfónov, tabletov a priemyselných panelov bez inštalácie klienta.

V oblasti priemyselnej AI AVEVA rozvíja samostatnú platformu *Industrial AI for Operations* [8], ktorá využíva živé aj historické dáta naprieč prevádzkou, dodávateľským reťazcom a plánovaním na odhaľovanie skrytých neefektív a predikciu výpadkov. Platforma bola uznaná v rebríčkoch Gartner a Verdantix v roku 2025. Táto AI vrstva je však cieľená na podnikovú úroveň — optimalizáciu procesov a prediktívnu údržbu — nie na kontextovú asistenciu obsluhy priamo pri zariadení.

Z pohľadu tejto práce sú kľúčové tieto body:

- **Mobilný prístup:** HTML5 webové rozhranie prístupné zo smartfónov a tabletov; nie je to natívna mobilná aplikácia.
- **Identifikácia zariadení:** Platforma nepodporuje skenovanie unikátnych identifikátorov pre spárovanie operátora so zariadením.
- **Edge nasadenie:** Natívna podpora; AVEVA Edge je priamo navrhnutý pre beh na edge zariadeniach vrátane Linux-based embedded systémov s malou pamäťovou stopou.

- **AI asistent:** Industrial AI for Operations je analytická platforma na podnikovej úrovni zameraná na prediktívnu údržbu a optimalizáciu procesov. Neposkytuje kontextovú asistenciu obsluhy na základe znalostnej bázy dokumentácie konkrétnych zariadení.
- **Licenčný model:** Proprietárny; licencie sa aktivujú cez AVEVA web portál na základe sériového čísla a hardvérového identifikátora.

Zhrnutie analýzy

Tabuľka 2 sumarizuje kľúčové vlastnosti porovnávaných platforiem vzhľadom na mobilný prístup, identifikáciu zariadení, edge nasadenie a integráciu AI asistenta s vlastnou znalostnou bázou.

Tabuľka 2: Porovnanie existujúcich riešení

Vlastnosť	WinCC Unified	Ignition Perspective	Tulip	AVEVA InTouch
Natívna mobilná aplikácia	Nie	Áno	Nie*	Nie
Identifikácia zariadení	Nie	Nie	Čiastočne**	Nie
Edge nasadenie	Áno	Áno	Čiastočne	Áno
AI asistent s vlastnou KB	Nie	Nie	Nie	Nie
Otvorená platforma	Nie	Čiastočne	Nie	Nie

* Webová aplikácia optimalizovaná pre tablety. ** QR/čiarové kódy pre materiály, nie pre zariadenia linky.

Z porovnania vyplýva, že existujúce komerčné platformy poskytujú rôznu mieru mobilného prístupu k priemyselným systémom, avšak ani jedna z nich neintegruje inteligentného asistenta schopného odpovedať na otázky obsluhy na základe vlastnej znalostnej bázy technickej dokumentácie. Väčšina platforiem sa orientuje na vizualizáciu a vzdialený prístup k procesným dátam. Pričom podpora operátora, teda schopnosť systému aktívne pomáhať pri riešení prevádzkových situácií prostredníctvom práce s dokumentáciou, zostáva nepokrytou oblasťou.

Rovnako identifikácia fyzických zariadení prostredníctvom vizuálnych markerov s automatickým načítaním kontextu pre dané zariadenie nie je štandardnou funkciou žiadnej z analyzovaných platforiem. Operátori sú naďalej odkázaní na manuálnu navigáciu cez menu a obrazovky, čo spomaľuje prístup k informáciám a zvyšuje pravdepodobnosť interakcie s nesprávnym zariadením.

Tieto identifikované medzery v súčasnej ponuke komerčných riešení tvoria základ pre návrh systému prezentovaného v ďalších kapitolách tejto práce.

2 Prehľad technológií pre vývoj aplikácií a priemyselnú komunikáciu

Moderné priemyselné aplikácie nestoja na jednej technológii. Sú výsledkom starostlivo zvolenej skladačky nástrojov, kde každá vrstva plní svoju úlohu: mobilné rozhranie reaguje na pokyny operátora a backendová vrstva spracúva množstvo súbežných udalostí z výrobných linky.

Kľúčovou výzvou je pritom premostenie dvoch oddelených svetov. OT označuje svet priemyselného riadenia a teda PLC automaty, senzory, pohony a výrobné linky, ktoré fyzicky ovládajú stroje v reálnom čase. IT je naopak svet softvéru, sietí a aplikácií určených na spracovanie a prenos informácií. Tieto dva svety dlho fungovali oddelene, každý s vlastnými protokolmi a prioritami. Priemyselné aplikácie v kontexte Industry 4.0 ich spájajú práve prostredníctvom komunikačnej vrstvy, napríklad pomocou protokolov MQTT alebo OPC UA.

Nasledujúci prehľad mapuje najpoužívannejšie technológie v každej z týchto vrstiev a ich typické uplatnenie v priemyselnom prostredí.

2.1 Frontendové technológie

Výber frameworku pre mobilnú aplikáciu patrí k zásadným architektonickým rozhodnutiam. Podľa prehľadu moderných frameworkov [9] nie je voľba len technická, ale priamo ovplyvňuje rýchlosť vývoja, výkon aplikácie, dlhodobé náklady na údržbu a dostupnosť vývojárov. Nasledujúci prehľad stručne charakterizuje najrozšírenejšie prístupy.

Natívny vývoj (Swift/SwiftUI pre iOS, Kotlin pre Android) poskytuje maximálny výkon a priamy prístup k hardvérovým funkciám zariadenia. Jeho nevýhodou je nutnosť paralelného vývoja a údržby dvoch samostatných kódových základní, čo zvyšuje celkové náklady na vývoj.

React Native od spoločnosti Meta umožňuje zdieľanie logiky aplikácie medzi platformami pomocou JavaScriptu, pričom UI vykresľuje cez natívne komponenty systému. Prístup má silný ekosystém, avšak pri výkonnostne náročných operáciách môžu nastať obmedzenia spôsobené prechodom cez natívne rozhranie.

Flutter od spoločnosti Google využíva jednotnú kódovú základňu v jazyku Dart a vlastný vykresľovací engine, ktorý zaručuje konzistentné vizuálne výstupy na všetkých platformách bez závislosti na systémových komponentoch. Dosahuje výkon blízky natívnym aplikáciám vďaka AOT kompilácii.

Webové frameworky (React, Angular, Vue) umožňujú prístup z ľubovoľného zariadenia s prehliadačom bez inštalácie. Pre priemyselné aplikácie je ich hlavným

obmedzením bezpečnostný sandbox prehliadača, ktorý sťažuje priamu komunikáciu s lokálnym hardvérom a priemyselnými rozhraniami.

2.2 Backendové frameworky

Backend tvorí jadro systému, spracúva požiadavky, komunikuje s databázami a sprostredkováva tok dát medzi PLC a klientskymi aplikáciami. Výber frameworku závisí od požiadaviek na výkon, dostupnosť AI/ML knižníc a dlhodobú udržiateľnosť [10].

Django je framework s filozofiou „batteries included“ obsahuje vstavaný admin panel, správu relácií a ORM vrstvu. Je vhodný pre dátovo náročné aplikácie a rýchly vývoj, avšak jeho monolitická architektúra ho robí menej vhodným pre mikroslužby.

Node.js s **Express** / **NestJS** umožňuje použiť JavaScript aj pre backend. Node.js vyniká pri aplikáciách s vysokou frekvenciou krátkych I/O operácií, avšak nie je vhodný pre výpočtovo náročné úlohy blokujúce event loop. NestJS nadstavba pridáva štruktúru TypeScript pre väčšie projekty.

Python s frameworkmi **Flask** / **FastAPI** dominuje v oblasti AI a ML vďaka bohatému ekosystému knižníc ako PyTorch, Scikit-learn, LangChain. Flask je minimalistický a flexibilný, FastAPI využíva asynchrónne ASGI a automaticky generuje OpenAPI dokumentáciu na základe typových anotácií.

Go s **Gin** / **Fiber** je kompilovaný jazyk s vstavanou podporou konkurencie, nízkymi nárokmi na RAM a CPU a predvídateľnou latenciou. Je vhodný pre mikroslužby, edge nasadenia a výkonnostne kritické systémy, avšak jeho ekosystém pre AI/ML je výrazne menší oproti Pythonu.

Tabuľka 3: Backendové frameworky podľa scenára nasadenia [10]

Scenár použitia	Odporúčaný framework
MVP / Startup	Node.js, Django, FastAPI
Podnikové mikroslužby	Spring Boot, Go, NestJS
Aplikácie s AI	Django, FastAPI, Node.js
Vysoká záťaž / real-time	Gin, Fiber, Node.js

2.3 Kontajnerizácia a Edge architektúra

Cloudové spracovanie dát, kde sa všetky informácie odosielajú na vzdialené servery, čelí rastúcim obmedzeniam v podobe latencie, zataženia siete a bezpečnostných rizík pri prenose citlivých dát [11]. Ako alternatíva sa presadzuje model *edge computing*, kde sa dáta spracúvajú priamo pri zdroji a teda na lokálnom zariadení alebo v blízkosti

výrobnej linky. Edge zariadenia dokážu filtrovať a vyhodnocovať dáta lokálne, do cloudu sa odosielať len relevantné výsledky, čo znižuje spotrebu prenosového pásma a zvyšuje odolnosť systému pri výpadku pripojenia.

Edge computing a cloud sa navzájom nevylučujú, ale spolupracujú v hybridnom modeli, kde edge zabezpečuje real-time spracovanie a cloud poskytuje dlhodobé ukladanie dát, pokročilú analytiku a globálnu koordináciu.

2.3.1 Docker a Docker Compose

Docker je otvorená platforma pre vývoj, distribúciu a spúšťanie aplikácií [12]. Umožňuje baliť aplikáciu spolu so všetkými jej závislosťami do prenositeľného kontajnera, ktorý beží rovnako v každom prostredí – na vývojárskom počítači, v testovacom prostredí aj na priemyselnom PC v prevádzke. Kontajnery využívajú izoláciu na úrovni jadra Linuxu, sú výrazne ľahšie ako virtuálne stroje a umožňujú spúšťať viacero izolovaných aplikácií na jednom hostovom systéme súčasne.

Zmena v kóde si vyžaduje prenos len zmenenej vrstvy obrazu, nie celého systému, čo je kľúčové pri aktualizáciách cez obmedzené priemyselné pripojenia. Docker Compose rozširuje tento koncept na celý aplikačný stack: backend, MQTT broker, vektorová databáza a ďalšie služby sú definované v jednom konfiguračnom súbore a spúšťajú sa jedným príkazom.

2.4 Priemyselné komunikačné protokoly

2.4.1 OPC UA

OPC UA (OPC Unified Architecture) je platformovo nezávislá, servisne orientovaná architektúra vydaná v roku 2008, ktorá integruje funkcionality predchádzajúcich OPC Classic špecifikácií do jedného rozšíriteľného rámca [13]. Štandard beží na rôznych hardvérových platformách, od priemyselných PC a PLC až po mikrokontroléry a cloudovú infraštruktúru. Podporuje operačné systémy Windows, Linux, Android a ďalšie.

Informačný model OPC UA je objektovo-orientovaný: dáta sú reprezentované hierarchicky ako uzly, objekty a premenné s plnou sémantickou popisnosťou. Prístup k dátam zahŕňa čítanie a zápis, odoberanie zmien, notifikácie udalostí a volanie metód. Komunikácia je možná v modeli klient-server aj publish-subscribe (Pub/Sub).

Bezpečnosť je súčasťou návrhu štandardu: OPC UA podporuje šifrovanie správ, podpisovanie, X.509 certifikáty pre autentifikáciu, sekvenčné pakety proti replay útokom a auditný log aktivít.

- **Výhody:** Vstavaná kybernetická bezpečnosť, sémantický popis dát, podpora klient-server aj Pub/Sub komunikácie, spätná kompatibilita a platformová nezávislosť.
- **Nevýhody:** Vysoká komplexnosť stacku a nároky na RAM/CPU limitujú nasaďenie na jednoduchších PLC.

2.4.2 S7 Protokol

S7 komunikácia je proprietárny protokol spoločnosti Siemens určený na výmenu dát medzi PLC rady SIMATIC [14]. Ide o natívny komunikačný mechanizmus ekosystému TIA Portal, ktorý pracuje nad sieťami PROFINET alebo PROFIBUS DP. Na rozdiel od otvorených štandardov nie je S7 protokol verejne špecifikovaný a zariadenia tretích strán ho implementujú reverzným inžinierstvom.

Komunikácia prebieha na princípe klient-server s jednosmerne konfigurovanými alebo obojstranne konfigurovanými spojeniami.

- **Výhody:** Jednoduchá konfigurácia v prostredí TIA Portal, natívna podpora v celom ekosystéme SIMATIC, nízka latencia v homogénnych Siemens sieťach.
- **Nevýhody:** Uzavretý, neštandardizovaný protokol bez verejnej špecifikácie; obmedzená interoperabilita so zariadeniami iných výrobcov.

2.4.3 MQTT

MQTT, Message Queuing Telemetry Transport je ľahký, otvorený protokol typu klient-server s modelom publish/subscribe, navrhnutý pre jednoduché použitie v obmedzených prostrediach ako IoT a komunikácia medzi strojmi [15]. Protokol beží nad TCP/IP a poskytuje obojsmerný tok správ s minimálnou réžiou.

Správy sa neposielajú priamo medzi zariadeniami. Klienti publikujú správy na témy (topics) na brokeri, ostatní klienti sa môžu na tieto témy prihlásiť (subscribe) a dostávať správy bez potreby poznať ich pôvod.

Protokol definuje tri úrovne QoS pre doručenie správ:

- **QoS 0** — správa je doručená najviac raz, bez potvrdenia
- **QoS 1** — správa je doručená aspoň raz, môžu nastať duplikáty
- **QoS 2** — správa je doručená práve raz, s plným handshake protokolom

Ďalšou vlastnosťou je mechanizmus „Last Will and Testament“, správa, ktorú broker automaticky odošle ostatným klientom v prípade neštandardného odpojenia klienta. Verzia MQTT 5.0 pridáva rozšírené vlastnosti ako expirácia správ, aliasy tém a zlepšené hlásenie chýb.

- **Výhody:** Minimálna réžia (2-bajtová pevná hlavička), tri úrovne QoS, podpora „Last Will“, vhodnosť pre zariadenia s obmedzeným výkonom a sieťou.
- **Nevýhody:** Nutnosť udržiavať bežiaci broker ako centrálny bod zlyhania.

2.4.4 Modbus TCP

Modbus je komunikačný protokol vyvinutý spoločnosťou Modicon (dnes Schneider Electric) v roku 1979 pre potreby priemyselných programovateľných automatov. Dnes je de facto štandardom v priemyselnej automatizácii s odhadovaných 7 miliónmi nasadených uzlov [16]. Modbus TCP/IP prenáša správy protokolu Modbus zabalené do TCP/IP rámcov na porte 502, čím umožňuje nasadenie v štandardných ethernetových sieťach bez potreby špeciálneho hardvéru.

Protokol pracuje na princípe klient-server. Klient iniciuje požiadavky a server odpovedá. Dáta sú organizované do štyroch základných typov registrov:

- **Coils** — jednobitové, čítanie aj zápis (digitálne výstupy)
- **Discrete Inputs** — jednobitové, iba čítanie (digitálne vstupy)
- **Holding Registers** — 16-bitové, čítanie aj zápis (analogové veličiny, nastavenia)
- **Input Registers** — 16-bitové, iba čítanie (analogové vstupy)
- **Výhody:** Jednoduchý a otvorený štandard bez licenčných poplatkov, rozšírená podpora zariadení, minimálne nároky na zdroje, jednoduché ladenie.
- **Nevýhody:** Chýba zabudovaná autentifikácia a šifrovanie, obmedzený dátový model, žiadny mechanizmus notifikácie, teda klient musí aktívne dopytovať server.

3 Prehľad technológií pre inteligentných asistentov

3.1 Veľké jazykové modely a možnosti nasadenia

Veľké jazykové modely (LLM) sú kategóriou modelov hlbokého učenia trénovaných na obrovských množstvách textových dát, vďaka čomu sú schopné porozumieť prirodzenému jazyku a generovať text pre široké spektrum úloh [17]. Ich základom je architektúra transformer s mechanizmom seba-pozornosti, ktorý modelu umožňuje zachytiť vzťahy a závislosti medzi slovami na rôznych miestach v texte.

Trénovanie prebieha na miliardách slov z kníh, článkov a webových stránok. Text je rozdelený na tokeny, každý token je zakódovaný ako vektor čísel tzv. embedding a sieť sa iteratívne učí predpovedať nasledujúci token v sekvencii. Výsledkom je model, ktorý si osvojil gramatické pravidlá, faktické znalosti aj štruktúry uvažovania.

Z hľadiska nasadenia existujú dve základné možnosti [18]. Prvou sú **cloudové modely prístupné cez API** (napr. GPT-4o, Claude, Gemini) — ide o platené služby, kde poskytovateľ spravuje celú infraštruktúru a model je dostupný okamžite bez nutnosti vlastného hardvéru. Druhou možnosťou sú **open-source modely nasadené lokálne** (napr. Llama 3, Mistral), kde organizácia prevádzkuje model na vlastných serveroch alebo zariadeniach. Lokálne nasadenie je vhodné najmä v prostrediach s obmedzeným internetovým pripojením, prísnyimi požiadavkami na ochranu dát alebo potrebou prevádzky bez závislosti od externých služieb.

3.2 Retrieval-Augmented Generation

LLM modely sú obmedzené na znalosti zachytené počas trénovania a nemajú prístup k aktuálnym ani doménovým informáciám. Retrieval-Augmented Generation (RAG) tento nedostatok rieši prepojením modelu s externou znalostnou bázou bez nutnosti opätovného trénovania [19].

Princíp fungovania je taký, že pri každej otázke používateľa retrieval model vyhľadá v znalostnej báze relevantné úseky dokumentov, tie sa vložia do kontextu LLM spolu s pôvodnou otázkou a model na ich základe vygeneruje odpoveď. Znalostná báza je typicky uložená vo vektorovej databáze, kde sú dokumenty reprezentované ako číselné vektory (embeddingy) umožňujúce rýchle sémantické vyhľadávanie. Jednou z populárnych open-source vektorových databáz je ChromaDB. Lhká databáza licencovaná pod Apache 2.0, ktorú možno prevádzkovať lokálne na jednom zariadení aj v cloudovom prostredí a je priamo integrovaná s frameworkmi LangChain a LlamaIndex [20].

Hlavné prínosy RAG oproti čistému LLM sú zníženie halucinácií ukotvením odpovedí v konkrétnych zdrojoch, prístup k aktuálnym a doménovým dátam a možnosť odkazovať na zdroj informácie priamo v odpovedi.

3.3 AI asistenti v priemyselnom prostredí

Priemyselné podniky čelia rastúcemu nedostatku kvalifikovaných pracovníkov a potrebe rýchleho prenosu znalostí na novú generáciu zamestnancov. Generatívni AI asistenti predstavujú riešenie tohto problému. Fungujú ako virtuálni mentori priamo na výrobnnej linke, kde pracovníkom poskytujú okamžité odpovede v prirodzenom jazyku na otázky o postupoch, riešení porúch alebo špecifikáciách zariadení [21].

Systém prepája viaceré zdroje dát ako podnikové systémy, tréningové databázy, prevádzkové dáta a syntetizuje z nich kontextovo relevantnú odpoveď. Technická dokumentácia je tak prekladaná do zrozumiteľných pokynov prispôbených skúsenostiam konkrétného pracovníka. Výsledkom je skrátenie času zaškoľovania, zníženie závislosti od tzv. kmeňových znalostí a vyššia adaptabilita pracovníkov pri zavádzaní nových technológií.

4 Typy identifikátorov a ich použitie

4.1 QR kódy

QR kódy sú dvojrozmerné maticové identifikátory optimalizované pre rýchle čítanie a vysokú hustotu dát. V kontexte priemyselnej automatizácie sa využívajú najmä na statickú identifikáciu objektov, kde sa vyžaduje uloženie komplexnejších informácií napr. URL adresy, sériové čísla alebo konfiguračné parametre. Ich výhodou je silná korekcia chyby, ktorá umožňuje prečítať kód aj pri čiastočnom poškodení alebo znečistení povrchu.

4.2 Fiduciálne markery – AprilTag, ArUco, STag

Fiduciálne markery sú špeciálne navrhnuté pre potreby počítačového videnia a robotiky. Na rozdiel od QR kódov nie je ich primárnym cieľom prenos veľkého objemu dát, ale presná lokalizácia v 3D priestore.

Tieto identifikátory sa vyznačujú predovšetkým vysokou mierou interoperability s modernými robotickými riešeniami. Vďaka existujúcim knižniciam napr. OpenCV, ROS je ich integrácia štandardom pri vývoji:

- **Autonómnych upratovacích robotov:** Kde markery umiestnené v prostredí slúžia ako pevné referenčné body pre rekalibráciu lokalizácie a elimináciu kumulatívnej chyby v mapách.
- **Dronov v skladoch:** Kde umožňujú presné pristávanie na nabíjaciach staniciach alebo navigáciu v priestoroch bez signálu GPS, pričom dron dokáže v reálnom čase určiť svoju polohu a náklon voči markeru.
- **Kolaboratívnych robotov:** Pri navádzaní na presnú pozíciu.

Identifikátory ako AprilTag a ArUco sú robustné voči zmenám osvetlenia a perspektívnemu skresleniu, zatiaľ čo STag prináša zvýšenú stabilitu a presnosť pri určovaní orientácie.

4.3 3D identifikátory

V prostrediach priemyselných podnikov a logistických reťazcov, kde sú si entity tvarovo a rozmerovo blízke, sa ako perspektívne riešenie javia unikátne 3D identifikátory. Na Fakulte elektrotechniky a informatiky STU bol vyvinutý systém programaticky generovaných 3D identifikátorov, ktoré sú optimalizované pre systémy zmiešanej a rozšírenej reality.

4.3.1 Princíp a štruktúra

Navrhnutý 3D identifikátor má tvar kocky, ktorá je vnútorne vyskladaná z menších, unikátnych geometrických elementov. Tieto elementy sú usporiadané v originálnej štruktúre, ktorá v sebe nesie zakódované informácie.

Hlavné technické výhody tohto riešenia sú:

- **Všesmerová detekcia:** Na rozdiel od 2D QR kódov je možné tieto 3D objekty v systémoch zmiešanej reality spoľahlivo snímať z akéhokoľvek uhla.
- **Odolnosť voči falšovaniu:** Vďaka komplexnej vnútornej členitosti a 3D geometrii sú tieto identifikátory výrazne náročnejšie na replikáciu než bežné 2D identifikátory.
- **Využitie vlastného tvaru:** Sledovanie sa nespolieha len na vizuálny vzor, ale na obrys a priestorovú charakteristiku 3D modelu, čo zvyšuje stabilitu v AR aplikáciách.

5 Špecifikácia požiadaviek systému

Práca predstavuje moderný prístup k priemyselnému internetu vecí (IIoT), kde mobilná aplikácia slúži ako primárne rozhranie pre obsluhu výrobnnej linky, prepojené s riadiacim systémom prostredníctvom edge computing zariadenia umiestneného priamo v prevádzke.

5.1 Prehľad systému

V moderných priemyselných prevádzkach narastá tlak na flexibilitu a mobilitu obsluhy výrobných zariadení. Tradičné riešenia sú spravidla viazané na pevne umiestnené operátorské panely alebo stolové počítače, čo obmedzuje pohyblivosť obsluhy a zvyšuje reakčný čas pri riešení prevádzkových udalostí. Mobilné zariadenia ponúkajú možnosť prístupu k výrobným systémom odkiaľkoľvek v rámci areálu závodu. Ich použitie v kombinácii s jednoznačnou identifikáciou zariadení otvára cestu k bezpečnému a intuitívnemu ovládaniu výrobnnej linky.

Kľúčovou výzvou pri takomto prístupe je spoľahlivé a jednoznačné spárovanie mobilného zariadenia s konkrétnou fyzickou časťou výrobnnej linky. Skenovaním vizuálneho identifikátora umiestneného priamo pri zariadení operátor okamžite nadviaže spojenie a systém presne vie, kto a ktoré zariadenie ovláda. Toto spojenie je základom pre bezpečné riadenie, auditovanie operácií a správu prístupu viacerých používateľov k rovnakému zariadeniu.

Ďalšou dôležitou oblasťou je správa prístupu pracovníkov s rôznymi rolami. Operátor potrebuje priamy prístup k riadeniu linky, manažér vyžaduje prehľad o výkonnosti a vyťaženosť, údržbár musí mať garantovaný exkluzívny, neprepisovateľný prístup pri servisnom zásahu a administrátor spravuje celý systém vrátane registrácie nových používateľov. Bez jasne definovaného mechanizmu riadenia prístupu by mohlo dôjsť ku konfliktom príkazov alebo neoprávnenému zásahu do výrobného procesu.

Celá komunikačná vrstva od PLC až po mobilnú aplikáciu prebieha cez štandardné priemyselné a webové protokoly. Backendová infraštruktúra je plne kontajnerizovaná a to umožňuje rýchle nasadenie na ďalšie uzly v rámci továrne. Ovládanie linky je obmedzené výhradne na lokálnu sieť továrne a cloudová vrstva slúži len na vzdialený reporting a zálohovanie agregovaných dát.

Neoddeliteľnou súčasťou systému je inteligentný technický asistent. Asistent odpovedá na technické otázky obsluhy výhradne na základe dokumentácie a manuálov nahratých pre konkrétne zariadenie, čím znižuje závislosť od papierových príručiek a skracaje čas potrebný na riešenie prevádzkových problémov.

5.2 Popis používateľských rolí

Systém implementuje riadenie prístupu založené na rolách (*Role-Based Access Control*, RBAC). Každý nový používateľ sa musí zaregistrovať a pred prvým prihlásením čaká na schválenie administrátorom, ktorý mu zároveň priradí príslušnú rolu. Sú definované štyri roly:

Operátor: Základná obsluha výrobnjej linky. Prihlasuje sa na konkrétnu linku skenovaním ArUco kódu, odosiela riadiace príkazy, upravuje prevádzkové parametre a sleduje aktuálny stav zariadenia v reálnom čase. Nemá prístup k reportom, správe vedomostnej bázy ani správe používateľov. Môže v prípade potreby využiť AI asistenta.

Manažér: Zameriava sa na sledovanie výkonnostných ukazovateľov. Má prístup k histórii prihlásení jednotlivých operátorov, dennému reportu o vyťaženosti a agregovaným štatistikám pre všetky zariadenia. Linku priamo neovláda.

Údržbár: Má exkluzívnu ochranu relácie a žiadny iný používateľ ho nemôže odhlásiť z prihláseného zariadenia, čo zaručuje bezpečnosť počas servisného zásahu. Spravuje vedomostnú bázu (KB) pre jednotlivé zariadenia, pričom KB tvorí znalostný zdroj pre AI asistenta.

Administrátor: Spravuje celý systém, schvaľuje nové registrácie, priraduje roly, edituje a odstraňuje používateľské kontá (s výnimkou hlavného admina). Má prístup ku všetkým logom a taktiež spravuje vedomostnú bázu.

5.3 Use-case scenáre

ID	UC-01: Registrácia a prihlásenie
Aktér	Všetky roly
Popis	Používateľ sa zaregistruje zadaním údajov. Kým administrátor neschváli konto, aplikácia zobrazí informáciu o čakaní na schválenie. Po schválení sa používateľ prihlási a získa JWT token.

ID	UC-02: Skenovanie ArUco kódu a spárovanie linky
Aktér	Operátor, údržbár
Popis	Používateľ naskenuje ArUco kód pri zariadení. Ak je linka voľná, po potvrdení dialógu sa vytvorí relácia. Ak je obsadená, zobrazí sa identita a rola prihláseného. Reláciu neprítomného operátora je možné prevziať; reláciu údržbára prevziať nie je povolené.

ID	UC-03: Ovládanie linky v reálnom čase
Aktér	Operátor
Popis	Operátor odosiela príkazy z ovládacieho panelu. Každý príkaz má unikátny identifikátor a prechádza stavmi: <i>queued</i> → <i>sent</i> → <i>acknowledged</i> → <i>applied</i> (resp. <i>failed</i> / <i>timeout</i>). Pri <i>timeout</i> aplikácia upozorní používateľa s možnosťou opakovania príkazu.
ID	UC-04: Monitorovanie stavu linky
Aktér	Operátor, manažér
Popis	Dashboard zobrazuje procesné dáta z PLC v reálnom čase cez WebSocket. Stavý sú farebne kódované podľa normy IEC 60073.
ID	UC-05: Prezeranie logov a reportov
Aktér	Manažér, admin
Popis	Po výbere zariadenia zo zoznamu sa zobrazí história prihlásení, denný report o vyťažnosti operátorov a prehľad udalostí.
ID	UC-06: Správa vedomostnej bázy
Aktér	Údržbár, admin
Popis	Prostredníctvom CRUD rozhrania sa nahrávajú, upravujú a odstraňujú dokumenty KB (texty a obrázky) pre každé zariadenie.
ID	UC-07: AI asistent (RAG chatbot)
Aktér	Všetky roly
Popis	Tlačidlom v pravom hornom rohu každej obrazovky (okrem prihlasovacej) sa spustí chatbot. Odpovedá výhradne na základe KB daného zariadenia; ak informácia chýba, prizná to. Rozhranie aj odpovede sú lokalizované v SK a EN.
ID	UC-08: Správa používateľov
Aktér	Admin
Popis	Admin schvaľuje registrácie, priraduje roly, upravuje a odstraňuje kontá. Hlavného admina nie je možné odstrániť ani upraviť inou cestou.
ID	UC-09: Nastavenia aplikácie
Aktér	Všetky roly
Popis	V nastaveniach je možné zmeniť jazyk (SK / EN) a vlastné heslo. Jazyk je dostupný aj na prihlasovacej obrazovke.

ID	UC-10: Cloudová synchronizácia
Aktér	Systém (automaticky)
Popis	Agregované dáta sú periodicky synchronizované do cloudu. Vzdialený prístup slúži výhradne na čítanie reportov a riadiace príkazy sú povolené iba v lokálnej sieti závodu.

5.4 Funkcionálne požiadavky

- FP1:** Aplikácia musí umožniť načítanie unikátneho identifikátora na automatické spárovanie mobilného zariadenia s konkrétnou časťou výrobnéj linky.
- FP2:** Používateľ musí mať možnosť odosielať riadiace príkazy a modifikovať prevádzkové parametre v riadenom systéme.
- FP3:** Systém musí implementovať verifikáciu kritických príkazov. Po odoslaní požiadavky musí aplikácia čakať na potvrdenie z PLC a vizuálne indikovať úspešné vykonanie zmeny.
- FP4:** Zobrazovanie aktuálnych stavov z PLC.
- FP5:** Implementácia chatbota využívajúceho metódu *Retrieval-Augmented Generation*. Chatbot musí odpovedať na technické otázky výhradne na základe poskytnutej vedomostnej bázy.
- FP6:** Plná lokalizácia používateľského rozhrania a odpovedí chatbota v dvoch jazykoch: slovenský (SK) a anglický (EN).
- FP7:** Agregované štatistické dáta musia byť periodicky zálohované z lokálnej databázy do cloudu pre potreby vzdialeného prístupu.
- FP8:** Aplikácia musí implementovať mechanizmus exkluzívnej relácie pre ovládanie konkrétnej výrobnéj linky. Po úspešnom prihlásení a spárovaní linky sa vytvorí aktívna relácia viazaná na používateľa. Relácia musí byť udržiavaná periodickým *heartbeat* signálom a automaticky ukončená pri odhlásení alebo po prekročení časového limitu neaktivity.
- FP9:** Pri pokuse o spárovanie linky, ktorá je už obsadená aktívnou reláciou, musí aplikácia používateľovi zobraziť informáciu o existujúcej relácii (identifikátor používateľa/rola). Nútené ukončenie resp. prevzatie relácie musí byť umožnené v prípade neodhlásenia sa už neprítomnej obsluhy.

FP10: Systém musí podporovať prihlásenie používateľov pomocou autentifikácie založenej na JWT. Aplikácia musí implementovať *Role-Based Access Control* (RBAC) s rolami: operátor, manažér, údržbár, admin.

FP11: Každý odoslaný riadiaci príkaz musí mať unikátny identifikátor (*command_id*) a systém musí poskytovať stav príkazu minimálne v úrovniach: *queued*, *sent*, *acknowledged*, *applied*, *failed*, *timeout*. Aplikácia musí tieto stavy používateľovi vizualizovať.

FP12: Systém musí ukladať základný log operácií obsahujúci minimálne: čas vykonania, identifikátor používateľa, identifikátor linky, typ akcie/príkazu a výsledok vykonania. Log musí byť dostupný pre roly *manažér* a *admin*.

5.5 Nefunkcionálne požiadavky

Definujú kvalitatívne atribúty, technologické obmedzenia a nároky na bezpečnosť.

NFP1: Celá backendová infraštruktúra musí byť kontajnerizovaná pomocou nástroja Docker a spustená na edge zariadení.

NFP2: Prenos správ v edge infraštruktúre musí prebiehať cez MQTT s QoS 1 alebo QoS 2.

NFP3: Latencia riadiaceho cyklu nesmie presiahnuť 250 ms.

NFP4: Odpovede AI asistenta musia byť striktne viazané na poskytnutý kontext. Ak informácia v materiáloch chýba, model musí túto skutočnosť priznať.

NFP5: Lokálna databáza musí byť konfigurovaná na zachovanie integrity dát aj v prípade náhleho prerušenia napájania edge zariadenia.

NFP6: Využitie Docker Compose musí umožňovať rýchle nasadenie identického stacku na iné edge uzly v rámci továrne.

NFP7: Systém musí zabrániť viacnásobnému vykonaniu toho istého príkazu v prípade opakovaného doručenia správy. Každý príkaz musí obsahovať unikátny identifikátor a backend musí zabezpečiť, že príkaz s rovnakým identifikátorom bude spracovaný najviac raz.

NFP8: Pri nedoručení potvrdenia (ACK) do 1.5 s musí aplikácia označiť príkaz ako *timeout* a informovať používateľa o neúspechu vykonania s možnosťou opakovania požiadavky. Systém musí logovať dôvod zlyhania, ak je dostupný.

NFP9: Ovládacie príkazy z externých sietí mimo lokálnej siete závodu nesmú byť povolené. Vzdialený prístup (mimo LAN) môže byť použitý výhradne na prehliadanie agregovaných dát a reportov v cloude.

NFP10: Backendové služby musia poskytovať štruktúrované logy a základné prevádzkové metriky (napr. latencia riadiaceho cyklu, počet neúspešných príkazov, stav pripojenia k PLC) pre účely diagnostiky.

5.6 Doménové požiadavky

Požiadavky plynúce z priemyselného prostredia a použitých technológií.

DP1: Komunikácia s hardvérom PLC musí prebiehať cez natívny protokol S7.

DP2: Grafické rozhranie musí dodržiavať priemyselné štandardy pre farebnú indikáciu stavov podľa normy IEC 60073.

DP3: Systém musí pracovať v hybridnom režime – plná funkčnosť ovládania v lokálnej sieti aj pri výpadku pripojenia k internetu.

6 Voľba technológií

Výber použitých technológií bol výsledkom posúdenia viacerých faktorov. Medzi kľúčové kritériá patrili kompatibilita s existujúcim hardvérom, jednoduchá integrácia, nízka latencia a schopnosť fungovať v priemyselnom prostredí s omezenými zdrojmi. V neposlednom rade bola dôležitá aj dostupnosť knižníc a predchádzajúca skúsenosť s jednotlivými technológiami, čo zásadne urýchlilo vývoj.

6.1 Komunikácia s PLC – S7 protokol

Riadiaci systém výrobnéj linky je PLC od firmy Siemens, konkrétne model S7-1200, pre ktorý je natívnym komunikačným protokolom S7. Práve to bolo primárnym dôvodom jeho výberu. S7 protokol umožňuje priame čítanie a zápis dátových blokov bez nutnosti zložitej konfigurácie alebo dodatočných licencií.

Alternatívou by bolo aktivovanie servera OPC UA priamo v S7-1200, čo je síce technicky možné, avšak prináša niekoľko nevýhod. Tými sú vyšší nápor na výpočtové zdroje PLC s obmedzenou pamäťou, potrebu licencie a výrazne komplexnejší konfiguračný proces. S7 protokol cez knižnicu `node-red-contrib-s7` poskytuje priamy a jednoduchý prístup k dátam PLC bez týchto obmedzení.

- **Výhody:** Natívna podpora pre Siemens S7-1200, priamy prístup k dátovým blokom, nízke vyťažovanie prostriedkov, jednoduchá konfigurácia v Node-RED.
- **Nevýhody:** Viazanosť na platformu Siemens, absencia štandardizovaného informačného modelu v porovnaní s OPC UA.

6.2 Komunikačná middleware vrstva – Node-RED

Spojenie medzi PLC a zvyškom systému zabezpečuje Node-RED, nástroj na programovanie s využitím minima kódu, ktorý beží ako Docker kontajner priamo na edge zariadení v prevádzke. Node-RED periodicky číta hodnoty z PLC prostredníctvom S7 protokolu a publikuje ich do MQTT brokera, čím spája svet OT (PLC, S7) a IT (MQTT, backend).

Táto vrstva bola zvolená z niekoľkých dôvodov. Disponuje natívnym uzlom `node-red-contrib-s7` pre priamu komunikáciu so Siemens PLC a rovnako natívnou podporou MQTT. Toto riešenie bez potreby písať rozsiahly kód, čo výrazne skracuje čas konfigurácie. Node-RED tiež dobre zvláda periodické dotazovanie (polling) PLC a podmienené spúšťanie akcií.

- **Výhody:** Minimum kódu, natívna S7 a MQTT podpora, jednoduchý deployment v Dockeri, aktívna komunita s rozsiahlou knižnicou uzlov.

- **Nevýhody:** Nie je vhodný pre komplexnú biznis logiku, vizuálne toky môžu byť pri väčšom projekte ťažšie udržiavateľné.

6.3 Transportný protokol – MQTT

Pre transport dát medzi edge vrstvou a backendom bol zvolený protokol MQTT. Kľúčovým argumentom je jeho nenáročnosť. Protokol bol navrhnutý pre zariadenia s obmedzenými zdrojmi a nestabilné siete.

OPC UA je komplexný štandard s bohatým informačným modelom, vstavanou bezpečnosťou a sémantickým popisom dát. Pre scenár, kde Node-RED číta hodnoty zo Siemens PLC a odovzdáva ich ďalej na spracovanie, táto komplexnosť nepredstavuje pridanú hodnotu, ale zbytočnú záťaž. MQTT broker nasadený v Dockeri zvládne rovnakú úlohu s minimálnou pamäťovou a CPU náročnosťou.

- **Výhody MQTT:** Nízke nároky na zdroje, jednoduchá architektúra pub/sub, výborná podpora v Node-RED aj Pythone, QoS úrovne pre spoľahlivosť doručenia.
- **Kedy by bol OPC UA lepšou voľbou:** Pri požiadavke na štandardizovaný sémantický popis dát, pri integrácii viacerých zariadení od rôznych výrobcov alebo pri prísnych bezpečnostných požiadavkách.

6.4 Backend – FastAPI

Backend aplikácie bol implementovaný v Pythone s využitím frameworku FastAPI. Tvorí API pre celú mobilnú aplikáciu. Oddelené API obsluhuje AI asistenta vrátane RAG pipeline. Voľba Pythonu bola prirodzená, pretože knižnice LangChain, ChromaDB a Ollama sú súčasťou python ekosystému a ich integrácia je bezproblémová.

FastAPI bolo zvolené z niekoľkých praktických dôvodov. Asynchrónna architektúra (ASGI) umožňuje súbežne obsluhovať požiadavky mobilnej aplikácie aj dlhotrvajúce volania jazykového modelu bez vzájomného blokovania. Automaticky generovaná OpenAPI dokumentácia uľahčuje ladenie API počas vývoja. Validácia vstupov cez Pydantic redukuje množstvo pomocného kódu. Rolu zohrali aj predchádzajúce skúsenosti s týmto frameworkom v bakalárskej práci, čo výrazne urýchlilo vývoj a umožnilo sa sústrediť na implementáciu biznis logiky a integráciu s AI knižnicami.

- **Výhody:** Asynchrónne spracovanie požiadaviek, automatická OpenAPI dokumentácia, Pydantic validácia, priama integrácia s AI knižnicami, rýchly vývoj.
- **Nevýhody:** Interpretovaný Python je pomalší oproti kompilovaným jazykom pri CPU-intenzívnych operáciách.

6.5 Frontend – Flutter

Pre mobilnú aplikáciu bol zvolený framework Flutter od spoločnosti Google. Primárnou cieľovou platformou je Android, avšak Flutter umožňuje z jednej kódovej základne generovať aj webovú aplikáciu, čo otvára možnosť implementácie administrátorského panelu bez nutnosti udržiavať samostatný projekt.

Oproti natívnemu vývoju v Kotlin, Flutter ponúka výrazne rýchlejší vývojový cyklus vďaka funkciám hot reload a hot restart. Vlastný vykreslovací engine Impeller zaručuje vizuálnu konzistenciu rozhrania naprieč zariadeniami a operačnými systémami. Bohatá štandardná knižnica widgetov pokrýva väčšinu potrieb priemyselného ovládacieho rozhrania vrátane dynamických grafov, stavových indikátorov a formulárov.

- **Výhody:** Jedna kódová základňa pre Android, iOS aj web, rýchly vývojový cyklus, konzistentné UI, silná podpora od Google.
- **Nevýhody:** Väčšia veľkosť výslednej aplikácie oproti natívnym riešeniam, pri požiadavke na plnohodnotnú iOS aplikáciu by bolo potrebné doplniť testovanie na Apple zariadeniach.

6.6 Výber identifikátora – ArUco

Pre jednoznačnú identifikáciu zariadení bolo v rámci práce spočiatku investované značné množstvo času do experimentovania s 3D identifikátormi navrhnutými študentom FEI. Tieto identifikátory sa spočiatku javili ako vhodné riešenie, pretože poskytovali vizuálne unikátny vzor, ktorý by teoreticky mohol byť rozpoznaný pomocou počítačového videnia.

Preto bolo otestovaných niekoľko prístupov k ich rozpoznávaniu:

- **Template matching a hashing** – porovnanie snímaného povrchu s uloženými referenčnými vzormi metódami pHash, SSIM a klasický template matching.
- **Extrakcia príznakov ORB s FLANN matcher** – rotačne invariantné príznaky s rýchlym vyhľadávaním v databáze, testované na rôznych vzdialenostiach a uhloch.
- **Analýza mriežky jamiek** – priama detekcia binárneho vzoru v 19×19 mriežke a porovnanie matíc.
- **Porovnávanie histogramov** – identifikácia na základe distribúcie intenzít po perspektívnej korekcii.
- **Siamese network** – ľahká CNN extrahujúca 128-dimenzionálne príznakové vektory, identifikácia na základe cosine similarity.

- **Transfer learning s MobileNet V3-Small** – klasifikátor exportovaný do TFLite pre nasadenie v mobilnej aplikácii Flutter, trénovaný s augmentáciou rotácií a variáciou osvetlenia.

Napriek rozsiahlemu experimentovaniu žiadna z týchto metód neposkytovala dostatočne spoľahlivé výsledky v reálnych podmienkach. Systém si vzory vzájomne zamieňal, pri zmenách osvetlenia alebo pohľadového uhla klesala istota rozpoznávania pod použiteľnú hranicu, a príprava každej novej triedy identifikátora vyžadovala opätovné zbieranie dát a doladenie modelu.

Z týchto dôvodov bolo prijaté rozhodnutie použiť štandardizovaný fiduciálny marker **ArUco**. Markery ArUco sú binárne štvorcové vzory s kódovanou číselnou identitou a orientáciou, ktoré sú navrhnuté priamo pre spoľahlivú detekciu počítačovým videním za rôznych svetelných podmienok. Knižnica ArUco je súčasťou OpenCV a poskytuje robustné algoritmy detekcie s korekciou perspektívy. V priemyselnom prostredí majú ArUco markery silné zastúpenie, využívajú ich napríklad automaticky riadené vozidlá (AGV), upratovacie autonómne roboty a aj výskumné robotické platformy. Táto rozšírenosť je ďalším argumentom v prospech voľby ArUco oproti 3D identifikátorom, ktoré by vyžadovali vlastnú infraštruktúru rozpoznávania. Prípadne by bolo možné použitie frameworku ako Vuforia, čo by ale značne zvýšilo závislosť implementácie a údržby.

7 Experimentálne porovnanie a výber jazykových modelov

7.1 Popis testovaných modelov

Na účely porovnania bolo vybraných päť lokálne spustiteľných jazykových modelov dostupných prostredníctvom platformy Ollama. Modely boli zámerne zvolené tak, aby pokrývali tri veľkostné kategórie: modely do 10 miliárd parametrov, modely v rozsahu 10 až 15 miliárd parametrov a model s 24 miliardami parametrov. Cieľom tohto rozloženia bolo analyzovať vzťah medzi veľkosťou modelu, kvalitou odpovedí a časom odozvy.

1. llama3.2:3b

Kompaktný model od spoločnosti Meta s 3 miliardami parametrov zo série Llama 3.2, ktorá zahŕňa predtrénované aj inštrukčne doladené generatívne modely vo veľkostiach 1B a 3B parametrov. Inštrukčne doladené varianty sú optimalizované pre multijazyčné konverzačné úlohy vrátane agentického vyhľadávania a sumarizácie. Podľa oficiálnej dokumentácie model prekonáva modely Gemma 2 2.6B a Phi 3.5-mini v úlohách ako sledovanie inštrukcií, sumarizácia, prepis promptov a používanie nástrojov [22]. Do testovania bol zaradený ako zástupca najmenej veľkostnej kategórie s predpokladom najrýchlejšej odozvy.

2. gemma4:e4b

Model od spoločnosti Google zo série Gemma 4 s 4 miliardami parametrov v kvantizovanej verzii (e4b označuje efektívnu 4-bitovú kvantizáciu). Série Gemma 4 predstavuje najnovšiu generáciu otvorených modelov Google, navrhnutú s dôrazom na multimodálne schopnosti a efektívne nasadenie na bežnom spotrebiteľskom hardvéri. Model podporuje dlhé kontextové okno a je optimalizovaný pre inštrukčné úlohy vrátane multijazyčných konverzačných scenárov [23]. Do testovania bol zaradený ako zástupca strednej veľkostnej kategórie s priaznivým pomerom výkonu a pamätevej náročnosti.

3. mistral-nemo:12b

Model s 12 miliardami parametrov vyvinutý spoločnosťami Mistral AI a NVIDIA. Disponuje kontextovým oknom až 128 000 tokenov a podľa oficiálnej dokumentácie dosahuje v svojej veľkostnej kategórii špičkové výsledky v oblasti uvažovania, znalosti sveta a presnosti generovania kódu. Vďaka štandardnej architektúre je plnohodnotnou náhradou modelu Mistral 7B v existujúcich systémoch [24]. Do testovania bol zaradený ako zástupca kategórie 10–15 miliárd parametrov.

4. **phi4:14b**

Model od spoločnosti Microsoft s 14 miliardami parametrov a kontextovým oknom 16 000 tokenov. Je trénovaný na kombinácii syntetických dátových sád, filtrovaných verejne dostupných webových zdrojov a akademických kníh a dátových sád otázok a odpovedí. Prešiel procesom doladenia pomocou supervised fine-tuningu a direct preference optimization s dôrazom na presné sledovanie inštrukcií a bezpečnosť. Podľa oficiálnej dokumentácie je určený pre prostredia s obmedzenými výpočtovými zdrojmi, scenáre s požiadavkami na nízku latenciu a úlohy vyžadujúce uvažovanie a logiku [25]. Do testovania bol zaradený ako druhý zástupca kategórie 10–15 miliárd parametrov.

5. **mistral-small:24b**

Model od spoločnosti Mistral AI s 24 miliardami parametrov a kontextovým oknom 32 000 tokenov, ktorý stanovuje nový benchmark v kategórii modelov do 70B parametrov. Podľa oficiálnej dokumentácie dosahuje výkon porovnateľný s modelmi trojnásobnej veľkosti a proprietárnym modelom GPT-4o mini naprieč úlohami v oblasti kódu, matematiky, všeobecných znalostí a sledovania inštrukcií [26]. Model vyniká multijazyčnou podporou, natívnym volaním funkcií, JSON výstupom a silnou adherenciou k systémovým promptom. Vďaka kompaktnej veľkosti je nasaditeľný lokálne na bežnom spotrebiteľskom hardvéri a je licencovaný pod Apache 2.0.

7.2 Metodika testovania

Testovanie prebiehalo formou automatizovaného benchmarku implementovaného v jazyku Python s využitím knižníc LangChain, ChromaDB a Ollama. Znalostná báza asistenta vo formáte `.txt` bola rozdelená na sekcie podľa markerov `-- NÁZOV DOKUMENTU:` a uložená do vektorovej databázy ChromaDB s využitím embedding modelu `nomic-embed-text`. Pre každú testovú otázku boli z vektorovej databázy vytiahnuté tri najrelevantnejšie dokumenty, ktoré boli spolu s otázkou odovzdané modelu ako kontext.

Každý model bol otestovaný na sade 14 testovacích otázok rozdelených do troch kategórií:

- **Faktické otázky** (10 otázok) – odpoveď je priamo obsiahnutá v znalostnej báze. 6 otázok v slovenskom a 4 otázky v anglickom jazyku.
- **Otázky vyžadujúce syntézu** (2 otázky) – správna odpoveď vyžaduje kombináciu informácií z viacerých dokumentov znalostnej bázy.

- **Otázky mimo rozsahu** (2 otázky) – otázky, ktorých odpoveď sa v znalostnej báze nenachádza a model by mal odpovedať odmietnutím a odkazom na technika.

Na rozdiel od automatických metrík ako ROUGE, ktoré vykazujú nízku spoľahlivosť pri jazykoch, kde sa využíva skloňovanie, ako je slovenčina, bolo hodnotenie kvality realizované manuálne. Každá odpoveď bola ohodnotená podľa nasledujúcich kritérií:

- **Relevancia** (škála 1–5) – miera, do akej odpoveď zodpovedá položenej otázke.
- **Úplnosť** (škála 1–5) – pokrytie všetkých dôležitých bodov správnej odpovede.
- **Zrozumiteľnosť** (škála 1–5) – zrozumiteľnosť formulácie odpovede.
- **Jazyková správnosť** (škála 1–3) – či model odpovedal v rovnakom jazyku, v akom bola položená otázka.
- **Odmietnutie otázky mimo rozsahu** (áno/nie) – či model správne odmietol odpovedať na otázku, ktorá nie je pokrytá znalostnou bázou.

Celkové skóre bolo vypočítané ako vážený priemer jednotlivých kritérií: relevancia (30 %), úplnosť (25 %), zrozumiteľnosť (20 %) a jazyková správnosť (25 %).

Okrem kvalitatívnych metrík bol pre každú odpoveď zaznamenaný čas odozvy v milisekundách. Testovanie prebiehalo na notebookovom hardvéri (CPU AMD Ryzen 5 5600H, RAM 32 GB, GPU NVIDIA RTX 3060 6 GB VRAM). Keďže väčšina testovaných modelov presahuje kapacitu VRAM, modely bežali čiastočne alebo úplne na systémovej RAM, čo predstavuje hardvérovú limitáciu meraní. V produkčnom nasadení, na dedikovanom serveri s dostatočnou VRAM, by časy odozvy boli výrazne nižšie.

7.3 Výsledky porovnania

Výsledky hodnotenia všetkých piatich modelov sú zhrnuté v tabuľke 4.

7.4 Analýza výsledkov a výber modelu

Z výsledkov testovania vyplýva, že model **gemma4:e4b** dosiahol najvyššie celkové skóre 4,92/5,0 spomedzi všetkých testovaných modelov. Model vykazoval konzistentne vysokú kvalitu odpovedí naprieč všetkými typmi otázok aj oboma testovacími jazykmi, pričom jeho priemerný čas odozvy 11 165 ms bol v podmienkach notebookového hardvéru prijateľný a takmer trojnásobne nižší v porovnaní s modelom mistral-small:24b.

Prekvapivým zistením je, že modely phi4:14b a mistral-small:24b opakovane odmietali odpovedať na otázky, ktorých odpovede boli v znalostnej báze jednoznačne

Tabuľka 4: Výsledky porovnania jazykových modelov

Model	Priem. čas [ms]	Relev. (1–5)	Úplnosť (1–5)	Zrozum. (1–5)	Jazyk (1–3)	OOS odmiet.	Celk. skóre
llama3.2:3b	4 536	2,29	2,21	2,50	2,14	100 %	2,63
gemma4:e4b	11 165	4,86	4,86	5,00	3,00	100 %	4,92
mistral-nemo:12b	15 217	4,07	4,07	4,29	2,86	100 %	4,29
phi4:14b	20 039	2,00	2,00	2,07	2,79	100 %	2,68
mistral-small:24b	35 801	1,86	1,86	1,86	3,00	100 %	2,65

Tabuľka 5: Priemerná relevancia podľa typu otázky a jazyka

Model	Faktická otázka	Syntéza	Mimo rozsahu	SK	EN
llama3.2:3b	1,70	2,50	5,00	2,12	2,50
gemma4:e4b	5,00	4,00	5,00	4,88	4,83
mistral-nemo:12b	4,20	2,50	5,00	4,62	3,33
phi4:14b	1,40	2,00	5,00	2,00	2,00
mistral-small:24b	1,40	1,00	5,00	2,00	1,67

obsiahnuté. Tento jav naznačuje, že RAG pipeline nepodal týmto modelom dostatočne relevantný kontext, čo mohlo byť spôsobené odlišnou citlivosťou modelov na formát vstupného kontextu.

Všetky testované modely dosiahli 100 % úspešnosť pri odmietaní otázok mimo rozsahu znalostnej bázy, čo potvrdzuje správne fungovanie systémového promptu z hľadiska bezpečnosti systému.

7.4.1 Overenie na cloudovom hardvéri

V nadväznosti na merania realizované lokálne bolo vybrané testovanie vykonaných aj na platforme RunPod.io, ktorá poskytuje prístup k výkonným GPU serverom formou platby za využitý čas. Cieľom bolo overiť, do akej miery hardvérová limitácia skresľuje závery o reálnej použiteľnosti modelov v produkcii.

Výsledky potvrdili predpoklad, na dedikovanom serverovom hardvéri s dostatočnou VRAM klesol priemerný čas odozvy na menej ako 8 sekúnd, čo je pre interaktívne použitie výrazne prijateľnejšia hodnota. Kvalita odpovedí pritom zostala nezmenená,

čo je v súlade s očakávaním. Model generuje rovnaký výstup nezávisle od hardvéru, rozdiel sa prejaví iba v latencii.

7.4.2 Záverečné rozhodnutie o architektúre AI asistenta

Napriek tomu, že výsledky testovania lokálnych modelov boli z kvalitatívneho hľadiska uspokojivé, cloudové overenie odhalilo zásadné ekonomické obmedzenie tohto prístupu. Modely, ktoré dosahujú dostatočnú kvalitu odpovedí, si pre produkčné nasadenie vyžadujú dedikovaný GPU server s dostatočnou VRAM. Prevádzkové náklady takéhoto riešenia nie sú pre projekt tohto rozsahu rentabilné.

V prípade väčších organizácií s vyšším objemom požiadaviek by mohlo byť zmysluplné investovať do vlastného serverového hardvéru. Stále však bude výhodnosť vlastného servera s GPU závislá od konkrétneho objemu požiadaviek. Pre nízky až stredný objem požiadaviek, je určite ekonomicky výhodnejšie využívať cloudové API s modelom per-token, kde náklady sú priamoúmerné skutočnému využitiu a nevyžadujú si vysokú počiatočnú investíciu.

Z týchto dôvodov bolo rozhodnuté opustiť prístup lokálnych LLM a prejsť na volanie externého API. Na výber je niekoľko poskytovateľov ako OpenAI, Google, Anthropic a iní veľkí hráči v oblasti AI. My sme zvolili API od spoločnosti Anthropic, nakoľko v poslednej dobe zaznamenali výraznejší pokrok v porovnaní s konkurenciou. Tento prístup zabezpečuje prístup k výkonným jazykovým modelom bez nutnosti prevádzkovať vlastný server, pričom náklady sa platia priamoúmerne skutočnému využitiu. RAG pipeline a znalostná báza zostávajú zachované v pôvodnej podobe. Kontextové dokumenty sú naďalej vyhľadávané lokálne z vektorovej databázy a odovzdávané modelu ako súčasť promptu. Mení sa iba vrstva generovania odpovede, ktorá prechádza z lokálne bežiacieho modelu na cloudové API.

8 Návrh architektúry systému

Systém je navrhnutý ako distribuovaná aplikácia skladajúca sa z viacerých vzájomne prepojených vrstiev. Každá vrstva plní špecifickú úlohu a komunikuje so susednými vrstvami prostredníctvom jasne definovaných rozhraní. Jadro systému beží na edge zariadení umiestenom priamo v prevádzke a zabezpečuje plnú funkčnosť aj bez pripojenia k internetu. Mobilná aplikácia komunikuje výhradne v rámci lokálnej siete závodu a v súčasnosti sa pripojenie na internet využíva len pre účely AI asistenta. Ak by sme využívali lokálne spustiteľný jazykový model, komunikácia s AI asistentom by prebiehala výhradne v rámci lokálnej siete a celý systém by bol izolovaný. Nasledujúce podkapitoly popisujú celkovú štruktúru systému, spôsob nasadenia jednotlivých komponentov, ich vzájomnú komunikáciu a formát ukladania dát.


8.1 Architektúra komponentov systému

Systém sa skladá z piatich hlavných komponentov. Prvým je mobilná aplikácia Flutter, ktorá slúži ako primárne rozhranie pre obsluhu. Druhým je backendová vrstva tvorená dvoma službami FastAPI. Hlavnou službou zabezpečujúcou autentifikáciu, správu relácií, riadenie zariadení a samostatnou službou AI asistenta s RAG pipeline. Tretím komponentom je MQTT broker Mosquitto, ktorý sprostredkúva asynchrónnu komunikáciu medzi backendom a Node-RED. Štvrtým je Node-RED, ktorý premostuje svet priemyselnej komunikácie so svetom IT a periodicky číta dáta z PLC prostredníctvom S7 protokolu. Posledným komponentom je samotné PLC Siemens S7-1200, ktoré fyzicky ovláda zariadenia na výrobnéj linke. Všetky tieto komponenty okrem mobilnej aplikácie bežia ako Docker kontajnery na edge zariadení. Jediné externé volanie smeruje z AI služby na rozhranie Anthropic API.

Mobilná aplikácia komunikuje s hlavnou FastAPI službou cez REST API a prijíma aktualizácie stavu zariadení cez WebSocket. Príkazy odoslané z aplikácie putujú cez backend do MQTT brokera a ďalej do Node-RED, ktorý ich zapíše do PLC. Spätná väzba prechádza tou istou cestou v opačnom smere. Dáta zo senzorov PLC číta Node-RED periodicky a publikuje ich do príslušných MQTT tém, odkiaľ ich backend preposiela pripojeným klientom cez WebSocket.


8.2 Fyzická topológia systému

Fyzická topológia systému vychádza z požiadavky na lokálnu prevádzku bez závislosti od externej infraštruktúry. Celá komunikácia prebieha v rámci lokálnej siete medzi



Obr. 1: Diagram architektúry systému a komunikácia medzi komponentmi

mobilnými zariadeniami, edge zariadením a riadiacimi systémami výrobných liniek. Schéma fyzickej architektúry je znázornená na obrázku 2.




Obr. 2: Fyzická topológia systému

Mobilné zariadenia sa pripájajú k edge zariadeniu bezdrôtovo cez WiFi. Voľba bezdrôtového pripojenia vychádza z charakteru práce operátora, ktorý sa pohybuje po výrobnej hale a potrebuje mať prístup k systému kdekoľvek v jej dosahu. Edge zariadenie je prepojené s Ethernet switchom, na ktorý sú napojené riadiace systémy

výrobných liniek. Edge zariadenie plní úlohu centrálného uzla, beží na ňom backend aj AI asistent a všetka logika spracovania príkazov sa vykonáva lokálne (okrem LLM, v práci sme zvolili externé API). Architektúra počíta s pripojením viacerých riadiacich systémov, čo umožňuje rozšírenie na ďalšie výrobné linky bez zmeny základnej topológie. V súčasnej implementácii je na switch napojený jeden riadiaci systém Siemens S7-1200.

8.3 Štruktúra MQTT tém

Komunikácia medzi backend službou, Node-RED a zariadeniami prebieha cez štruktúrované MQTT témy. Všetky témy zdieľajú spoločný prefix `plc`, za ktorým nasleduje identifikátor zariadenia vo formáte `device_{id}`, kde `id` zodpovedá ArUco identifikátoru fyzického zariadenia. Táto štruktúra umožňuje systému jednoznačne smerovať správy na konkrétne zariadenie a zároveň odberateľom filtrovať témy.



Tabuľka 6: Prehľad MQTT tém

Téma	Vydavateľ	Odberateľ	Popis
<code>plc/device_{id}/data</code>	Node-RED	Backend	Aktuálne hodnoty premenných zariadenia
<code>plc/device_{id}/status</code>	Node-RED	Backend	Stav pripojenia zariadenia (online/offline)
<code>plc/device_{id}/commands/#</code>	Backend	Node-RED	Riadiaci príkaz smerovaný na zariadenie

Backend pri štarte subscribuje na tému `plc/#`, čím prijíma správy zo všetkých zariadení naraz. Node-RED subscribuje selektívne len na témy `commands` pre zariadenia, ktoré spravuje. Príkazy sú publikované s QoS 1, čím je zaručené doručenie aspoň raz.

9 Implementácia backendu

Backend systému tvorí dvojica nezávislých FastAPI služieb bežiacich v prostredí Docker. Hlavná služba zabezpečuje autentifikáciu, správu zariadení a spracovanie príkazov. Druhá služba je určená výhradne pre AI asistenta. Obe služby komunikujú s mobilnou aplikáciou cez REST API, pričom hlavná služba poskytuje navyše WebSocket kanál pre aktualizácie stavu zariadení. V nasledujúcich podkapitolách popisujeme implementáciu jednotlivých funkcionálít backendu, začínajúc autentifikáciou a RBAC, cez API endpoiny, mechanizmus relácií, command lifecycle, idempotenciu príkazov až po generátor ArUco identifikátorov a export identifikátorov vo formáte STL vhodnom pre 3D tlač.

9.1 Autentifikácia a RBAC

Systém používa autentifikáciu pomocou JWT tokenov podľa štandardu OAuth2. Po úspešnom prihlásení server vygeneruje token podpísaný zdieľaným tajným kľúčom algoritmom HS256. Token obsahuje identifikátor používateľa a čas vypršania platnosti. Heslá sú uložené výhradne ako bcrypt hash.

Registrácia je verejne dostupná, avšak nový účet je predvolene neaktívny. Prístup do systému získa až po schválení administrátorom, ktorý zároveň priradí rolu. Táto dvojfázová registrácia zabraňuje neoprávnenému vstupu do systému.

Oprávnenia sú riadené štyrmi rolami. Každý chránený endpoint deklaruje požadovanú rolu ako FastAPI závislosť, čo umožňuje jednotnú kontrolu prístupu bez duplicitnej logiky.

```
async def get_line_operator(user: User = Depends(get_current_user)):  
    _ensure_role(user, {"operator", "admin", "maintenance"})  
    return user  
  
async def get_manager_or_admin(user: User = Depends(get_current_user)):  
    _ensure_role(user, {"manager", "admin"})  
    return user
```

Výpis kódu 1: Závislosti pre kontrolu rolí

Funkcia	Operátor	Manažér	Údržbár	Admin
Dashboard, nastavenia, AI asistent	✓	✓	✓	✓
ArUco skenovanie a ovládanie linky	✓		✓	✓
Zoznam a správa zariadení		✓	✓	✓
Log príkazov		✓	✓	✓
Znalostná báza		✓	✓	✓
Správa používateľov		✓		✓

9.2 API endpointy

Backend poskytuje REST API rozdelené do šiestich skupín podľa funkčnej oblasti. Endpointy pre AI asistenta sú dostupné na samostatnej službe počúvajúcej na porte 8100, ostatné na porte 8000. Okrem REST komunikácie poskytuje backend WebSocket endpoint pre real-time aktualizácie stavu zariadenia.

Tabuľka 7: Prehľad API endpointov

Metóda	Endpoint	Popis	Rola
<i>Autentifikácia — /auth</i>			
POST	/auth/login	Prihlásenie, vracia JWT token	—
POST	/auth/register	Registrácia nového účtu	—
GET	/auth/me	Aktuálny prihlásený používateľ	všetci
PUT	/auth/me	Úprava mena a priezviska	všetci
POST	/auth/change-password	Zmena hesla	všetci
<i>Zariadenia — /plc</i>			
GET	/plc/devices	Zoznam zariadení	všetci
POST	/plc/devices	Vytvorenie zariadenia	admin, údržbár
GET	/plc/devices/{id}	Detail zariadenia	všetci
PUT	/plc/devices/{id}	Úprava zariadenia	admin, údržbár
DELETE	/plc/devices/{id}	Vymazanie zariadenia	admin, údržbár
POST	/plc/devices/{id}/command/{cmd}	Odoslanie príkazu	admin, údržbár, operátor
GET	/plc/stats	Dashboard štatistiky	všetci
WS	/plc/ws/{id}	Real-time stav + príkazy	všetci
<i>Relácie — /device-sessions</i>			
POST	/device-sessions/{id}/join	Prihlásenie na zariadenie	admin, údržbár, operátor
POST	/device-sessions/{id}/leave	Odhlásenie zo zariadenia	všetci
<i>Logy — /command-logs</i>			
GET	/command-logs	Logy s filtrami	admin, manažér, údržbár
GET	/command-logs/device/{id}	Logy zariadenia	admin, manažér, údržbár
<i>Používatelia — /users</i>			
GET	/users	Zoznam používateľov	admin, manažér
POST	/users/{id}/approve	Schválenie + rola	admin, manažér
PUT	/users/{id}	Úprava účtu	admin, manažér
POST	/users/{id}/reset-password	Reset hesla	admin, manažér
DELETE	/users/{id}	Vymazanie účtu	admin, manažér
<i>ArUco — /aruco</i>			
GET	/aruco/next-id	Nasledujúce voľné ID	všetci
GET	/aruco/preview/{id}	Náhľad markera	všetci
GET	/aruco/png/{id}	Stiahnutie markera ako PNG	všetci
GET	/aruco/stl/{id}	Stiahnutie markera ako STL	všetci
<i>AI asistent — port 8100</i>			
POST	/chat	Správa AI asistentovi	všetci
GET	/kb	Zoznam záznamov znalostnej bázy	admin, manažér, údržbár
POST	/kb	Pridanie záznamu	admin, manažér, údržbár
POST	/kb/upload	Nahratie súboru do KB	admin, manažér, údržbár
DELETE	/kb/{id}	Vymazanie záznamu	admin, manažér, údržbár

9.3 Mechanizmus relácií

Pred ovládaním zariadenia sa musí používateľ na neho prihlásiť. Relácia je väzba medzi používateľom a zariadením, ktorá zabraňuje súčasnému ovládaniu jedného zariadenia viacerými používateľmi. Na každom zariadení môže byť aktívna práve jedna relácia.

Prihlásenie prebieha volaním `POST /devices/{id}/login`. Backend overí, či je zariadenie voľné. Ak áno, vytvorí novú reláciu. Ak je zariadenie obsadené, správanie závisí od parametra `force` a od roly aktuálneho držiteľa relácie. Zariadenie obsadené používateľom s rolou údržbára nemôže byť prebraté žiadnym iným používateľom. Táto ochrana zabraňuje prerušeniu servisného zásahu operátorom. Vlastnú reláciu môže ukončiť prihlásený používateľ odhlásením sa. Cudziu reláciu môže ukončiť výhradne administrátor.

9.4 Command lifecycle

Príkaz prechádza niekoľkými vrstvami systému, kým sa prejaví na fyzickom zariadení. Používateľ ho môže odoslať dvoma cestami: cez REST endpoint alebo cez WebSocket spojenie.

Pri WebSocket ceste backend príkaz najskôr overí voči konfigurácii zariadenia. Kontroluje sa existencia príkazu a pre numerické a výčtové typy aj platnosť hodnoty. Ak zariadenie nemá konfiguráciu definovanú, validácia sa preskočí. REST endpoint validáciu nevykonáva a príkaz odošle priamo.

Po validácii backend publikuje správu na MQTT tému `plc/device_{id}/commands/{cmd}`. Mosquitto broker správu doručí Node-RED, ktorý ju preloží do S7 protokolu a zapíše príslušnú premennú v PLC. Volajúci dostane späť potvrdenie `command_ack` s príznakom úspechu doručenia na broker. Toto potvrdenie nezaručuje vykonanie príkazu na PLC. Skutočná zmena stavu sa prejaví v ďalšom cykle čítania, keď Node-RED publikuje aktualizované hodnoty na tému `plc/device_{id}/data` a backend ich pošle cez WebSocket do aplikácie.

Každý príkaz je bez ohľadu na výsledok zaznamenávaný do tabuľky `command_logs` s identifikátorom používateľa, zariadenia, zdrojovým kanálom a príznakom úspechu doručenia.

9.5 Idempotencia príkazov

9.6 Generátor ArUco + STL export

10 Implementácia AI assistenta

10.1 RAG pipeline diagram

10.2 Embedovací model

10.3 System prompt

10.4 Správa konverzácie

10.5 KB management

11 Implementácia frontendu

11.1 Stavový manažment

11.2 ArUco skenovanie

11.3 WebSocket pripojenie

11.4 Role based UI

12 Aplikácia a jej funkcionality

12.1 Skener ArUco identifikátorov

Dostupné pre: operátor, technik, manažér, administrátor

Skener ArUco identifikátorov slúži ako primárny spôsob prihlásenia sa na konkrétne zariadenie. Používateľ namieri kameru mobilného zariadenia na ArUco identifikátor umiestnený priamo na fyzickom zariadení a systém ho automaticky identifikuje. Po úspešnom naskenovaní je používateľ priradený k danému zariadeniu a získava prístup k jeho monitorovaniu a ovládaniu. Tento prístup eliminuje manuálne vyhľadávanie zariadení a zabezpečuje, že používateľ pracuje s tým správnym zariadením.

12.2 Generátor ArUco identifikátorov

Dostupné pre: technik, manažér, administrátor

Pri zakladaní nového zariadenia v systéme aplikácia automaticky vygeneruje unikátny ArUco identifikátor, ktorý jednoznačne identifikuje dané zariadenie. Identifikátor je možné exportovať vo formáte PNG pre bežnú tlač alebo vo formáte STL ako trojrozmerný model vhodný na 3D tlač, pričom biela časť kódu je vystúpená a čierna zapustená. Fyzická značka sa následne umiestni na zariadenie, čím sa prepojí záznam v systéme s reálnym zariadením v prevádzke.

12.3 Monitoring a ovládanie zariadení

Dostupné pre: operátor, technik, administrátor

Monitoring a ovládanie zariadení predstavuje hlavnú funkcionality aplikácie. Po prihlásení na zariadenie má používateľ k dispozícii prehľad aktuálneho stavu zariadenia v reálnom čase. Môže sledovať stavy senzorov, aktuálny režim prevádzky, stav v ktorom sa zariadenie nachádza, a iné. Okrem sledovania stavu môže používateľ zariadenie aj priamo ovládať, napríklad spustiť alebo zastaviť cyklus, zmeniť smer pohybu či vykonať reset. Všetky zmeny sa prejavia rádo v desiatkach milisekúnd, čo umožňuje rýchlu reakciu na aktuálnu situáciu v prevádzke. Systém zároveň zaznamenáva históriu vykonaných príkazov pre potreby kontroly a auditu.

12.4 Virtuálny asistent PLEXO

Dostupné pre: operátor, technik, manažér, administrátor

Virtuálny asistent PLEXO je inteligentný pomocník dostupný priamo v aplikácii. Používatelia môžu klásť otázky prirodzeným jazykom, napríklad o aktuálnom stave

zariadenia, postupe pri riešení poruchy alebo pokynoch na údržbu. Asistent odpovedá na základe znalostnej bázy vytvorenej pre konkrétne zariadenia a prevádzku. Vďaka tomu má operátor alebo technik potrebné informácie vždy po ruke, bez nutnosti listovať v technickej dokumentácii. Asistent komunikuje v jazyku nastavenom používateľom v nastaveniach aplikácie.

12.5 Správa používateľov

Dostupné pre: manažér, administrátor

Správa používateľov poskytuje oprávneným osobám nástroje na riadenie prístupu do systému. Manažér alebo administrátor môže vytvárať nové používateľské účty, upravovať existujúce, prideliť príslušné roly podľa pracovného zaradenia a v prípade potreby účty odstrániť resp. deaktivovať. Systém rolí zabezpečuje, že každý používateľ vidí a môže vykonávať iba tie akcie, ktoré zodpovedajú jeho pracovnej pozícii, čím sa minimalizuje riziko neoprávneného zásahu do prevádzky.

12.6 Správa zariadení

Dostupné pre: technik, manažér, administrátor

Správa zariadení umožňuje udržiavať databázu zariadení aktuálnu a v súlade so skutočným stavom prevádzky. Oprávnený používateľ môže do systému pridať nové zariadenie, nastaviť jeho parametre a vygenerovať preň ArUco identifikátor. Existujúce zariadenia je možné upravovať, resp. meniť, čo sa zobrazuje v ovládacom paneli zariadenia. Taktiež je možné ich zo systému odstrániť, ak boli vyradené z prevádzky. Vďaka tejto funkcionalite systém vždy odráža reálny stav zariadení v podniku.

12.7 Správa znalostnej bázy

Dostupné pre: technik, manažér, administrátor

Znalostnú bázu tvorí súbor informácií, z ktorých čerpá virtuálny asistent PLEKO pri odpovedaní na otázky používateľov. Oprávnení používatelia môžu obsah znalostnej bázy priebežne pridávať nové dokumenty, upravovať existujúce záznamy alebo odstraňovať zastarané informácie. Kvalita a aktuálnosť znalostnej bázy priamo ovplyvňuje relevantnosť a presnosť odpovedí asistenta, preto je jej pravidelná údržba dôležitou súčasťou prevádzky systému.

12.8 Nastavenia

Dostupné pre: operátor, technik, manažér, administrátor

Každý používateľ má možnosť prispôbiť si aplikáciu podľa vlastných preferencií. V nastaveniach môže zmeniť jazyk rozhrania, ktorý sa automaticky uplatní aj na komunikáciu s virtuálnym asistentom PLEXO. Zároveň má možnosť zmeniť si svoje prístupové heslo. Tieto nastavenia sú viazané na konkrétny používateľský účet a zostávajú zachované aj po opätovnom prihlásení.

13 Testovanie a meranie

13.1 Overenie splnenia špecifikácie

13.2 Latencia vykonania príkazov

13.3 ArUco detekcia

13.4 Kvalita odpovedí asistenta

Záver

„V tejto príručke sme sa snažili poskytnúť praktické pokyny pre vypracovanie záverečných prác na Fakulte elektrotechniky a informatiky STU v Bratislave. Obsahuje dôležité informácie o formálnej stránke dokumentu, ktoré sú nevyhnutné pre zabezpečenie jasnej štruktúry a správneho formátovania práce. Naša príručka kladie dôraz na dodržiavanie základných pravidiel, ktoré pomáhajú minimalizovať chyby a zlepšujú celkovú kvalitu predkladaných dokumentov.

Rovnakú pozornosť venujeme aspektom, ako sú formátovanie textu, zarovnávanie, riadkovanie a použitie preddefinovaných štýlov, ktoré prispievajú k profesionálnemu vzhľadu dokumentu. Dôkladné spracovanie matematických rovníc a grafov je ďalším dôležitým prvkom, ktorý môže ovplyvniť hodnotenie práce. Práca s týmito aspektmi zaisťuje, že obsah je prehľadný a presne odráža zamýšľané myšlienky.

V neposlednom rade sa naša príručka zameriava na význam citovania externých zdrojov, čo je zásadné pre zachovanie integrity a etických štandardov pri písaní akademických textov. Správne citovanie nielenže posilňuje argumentáciu, ale tiež pomáha predchádzať plagiátorstvu, ktoré môže mať vážne následky na akademickú kariéru.

Dodržiavanie týchto pokynov umožňuje vyhnúť sa bežným chybám a zvyšuje kvalitu záverečných prác, čím sa zlepšuje celkový dojem z akademických schopností. Dobre vypracovaná práca môže viesť k pozitívnemu hodnoteniu a uznaniu zo strany hodnotiteľov, čo je cieľom každého študenta.

Celkovo je príručka navrhnutá ako cenný nástroj na podporu pri písaní záverečných prác. Poskytnuté informácie a odporúčania prispievajú k dosiahnutiu akademických cieľov a pomôžu vypracovať kvalitné a odborné dokumenty, ktoré budú spĺňať štandardy fakulty.“

(ChatGPT 3, 2024)

Poznámka autora: Časť záveru vygenerovala umelá inteligencia na základe analýzy obsahu verzie dokumentu pre práce písané v MS Word. Konkrétne išlo o aplikáciu ChatGPT 3 dňa 29. 9. 2024. Rukopis umelej inteligencie je z textu cítiť aj napriek tomu, že celá komunikácia vedúca k tejto forme záveru trvala približne 40 minút. Parafrázujúc ľudové príslovie konštatujeme, že umelá inteligencia je možno dobrý sluha, ale zlý pán. Používajme ju s rozumom.

Pripomíname, že takýto spôsob tvorby obsahu je v záverečnej práci, ako aj v iných akademických textoch, neprípustný. Autorské dielo nesmie obsahovať odseky vytvorené generatívnou umelou inteligenciou. Preto sme ho formátovali ako citovaný text.

Literatúra

1. SIEMENS AG. *SIMATIC WinCC Unified PC* [online]. Siemens, 2025 [cit. 2026-04-07]. Dostupné z: <https://www.siemens.com/en-us/products/simatic-hmi/wincc-unified-software/>.
2. SIEMENS AG. *Engineering Copilot TIA Standard (Managed Service)* [online]. Siemens, 2025 [cit. 2026-04-07]. Dostupné z: <https://www.siemens.com/en-us/products/tia-portal/engineering-copilot-tia-standard/>.
3. INDUCTIVE AUTOMATION. *Ignition SCADA Software* [online]. Inductive Automation, 2026 [cit. 2026-04-07]. Dostupné z: <https://inductiveautomation.com/scada-software/>.
4. INDUCTIVE AUTOMATION. *Ignition Edge* [online]. Inductive Automation, 2026 [cit. 2026-04-07]. Dostupné z: <https://inductiveautomation.com/ignition/edge>.
5. TULIP INTERFACES. *Pricing and Plans* [online]. Tulip Interfaces, 2026 [cit. 2026-04-07]. Dostupné z: <https://tulip.co/plans/>.
6. TULIP INTERFACES. *Tulip Signs Strategic Collaboration Agreement With AWS to Build Generative AI Capabilities Empowering Frontline Workers* [online]. Tulip Interfaces, 2024-04-23 [cit. 2026-04-07]. Dostupné z: <https://tulip.co/press/tulip-signs-strategic-collaboration-agreement-with-aws-to-build-generative-ai-capabilities-empowering-frontline-workers/>.
7. AVEVA SOLUTIONS LIMITED. *AVEVA™ Edge* [online]. AVEVA, 2026 [cit. 2026-04-07]. Dostupné z: <https://www.aveva.com/en/products/edge/>.
8. AVEVA SOLUTIONS LIMITED. *Industrial AI for Operations* [online]. AVEVA, 2026 [cit. 2026-04-07]. Dostupné z: <https://www.aveva.com/en/solutions/digital-transformation/artificial-intelligence/industrial-ai-for-operations/>.
9. EITBIZ - EXTROVERT INFORMATION TECHNOLOGY. *Top App Development Frameworks to Build High-Performance Apps in 2026* [online]. Medium, 2025-12-23 [cit. 2026-04-07]. Dostupné z: <https://medium.com/@eitbiz/top-app-development-frameworks-for-high-performance-apps-in-2026-2db28c6c0a33>.
10. NADARAJAN, C. *How to Choose the Best Backend Frameworks in 2026 for AI-Powered Software: A Business Leader's Guide* [online]. ThinkPalm Technologies, 2025-12-01 [cit. 2026-04-07]. Dostupné z: <https://thinkpalm.com/blogs/how-t>

o-choose-the-right-backend-framework-for-ai-powered-software-a-business-leaders-guide/.

11. GARAI, K. *From Cloud to Edge: How Technology Is Redefining Data Processing* [online]. Medium, 2026-03-10 [cit. 2026-04-07]. Dostupné z: <https://medium.com/@kastab/from-cloud-to-edge-how-technology-is-redefining-data-processing-43b66acde782>.
12. DOCKER INC. *Docker Overview* [online]. Docker Documentation, 2026 [cit. 2026-04-07]. Dostupné z: <https://docs.docker.com/get-started/docker-overview/>.
13. OPC FOUNDATION. *OPC Unified Architecture* [online]. OPC Foundation, 2026 [cit. 2026-04-07]. Dostupné z: <https://opcfoundation.org/about/opc-technologies/opc-ua/>.
14. SIEMENS AG. *S7 Communication* [online]. Siemens TIA Portal Documentation, 2026 [cit. 2026-04-09]. Dostupné z: https://docs.tia.siemens.cloud/r/simatic_et_200clean_manual_collection_zhcn_20/function-manuals/communication-function-manuals/communication/s7-communication/s7-communication.
15. OASIS. *MQTT Version 5.0* [online]. OASIS, 2019-03-07 [cit. 2026-04-07]. Dostupné z: <https://docs.oasis-open.org/mqtt/mqtt/v5.0/mqtt-v5.0.html>.
16. MODBUS ORGANIZATION. *Modbus FAQ* [online]. Modbus Organization, 2026 [cit. 2026-04-07]. Dostupné z: <https://www.modbus.org/faq.php>.
17. STRYKER, C. *What are large language models (LLMs)?* [online]. IBM Think, 2025 [cit. 2026-04-11]. Dostupné z: <https://www.ibm.com/think/topics/large-language-models>.
18. ULLAH, I. *API vs. Self-Hosted LLM: Which Path Is Right for Your Enterprise?* [online]. Medium, 2025-08-28 [cit. 2026-04-11]. Dostupné z: <https://theirfan.medium.com/api-vs-self-hosted-llm-which-path-is-right-for-your-enterprise-82c60a7795fa>.
19. IBM. *What is retrieval augmented generation (RAG)?* [online]. IBM Think, 2025 [cit. 2026-04-11]. Dostupné z: <https://www.ibm.com/think/topics/retrieval-augmented-generation>.
20. RICADELA, A. *What Is Chroma? An Open Source Embedded Database* [online]. Oracle, 2024-04-15 [cit. 2026-04-11]. Dostupné z: <https://www.oracle.com/anz/database/vector-database/chromadb/>.

21. KUNTZ, C. *The New Industrial Evolution: How AI Assistants and Agents Are Transforming Manufacturing Knowledge* [online]. Training Industry, 2025-04-08 [cit. 2026-04-11]. Dostupné z: <https://trainingindustry.com/articles/work-force-development/the-new-industrial-evolution-how-ai-assistants-and-agents-are-transforming-manufacturing-knowledge/>.
22. META AI. *llama3.2* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/llama3.2>.
23. GOOGLE DEEPMIND. *gemma4* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/gemma4>.
24. MISTRAL AI; NVIDIA. *mistral-nemo* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/mistral-nemo>.
25. MICROSOFT. *phi4* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/phi4>.
26. MISTRAL AI. *mistral-small* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/mistral-small>.

Použitie nástrojov umelej inteligencie

OpenAI (2025), ChatGPT 4o, časť ??, generovanie vzorca záznamu použitia AI.

OpenAI (2024), ChatGPT 3, Záver, generovanie textu.

OpenAI (2025), ChatGPT 4o, dodatok B, generovanie kódu programu.

OpenAI (2024), ChatGPT 3, dodatok C, generovanie zoznamu.

Dodatok A: Algoritmus

Algoritmus 1 Vypočítaj $y = x^n$

Require: $n \geq 0 \vee x \neq 0$

Ensure: $y = x^n$

$y \Leftarrow 1$

if $n < 0$ **then**

$X \Leftarrow 1/x$

$N \Leftarrow -n$

else

$X \Leftarrow x$

$N \Leftarrow n$

end if

while $N \neq 0$ **do**

if N is even **then**

$X \Leftarrow X \times X$

$N \Leftarrow N/2$

else $\{N \text{ is odd}\}$

$y \Leftarrow y \times X$

$N \Leftarrow N - 1$

end if

end while

Dodatok B: Výpis dlhého kódu

Dlhšie kódy, prípadne kompletne programy vypisujeme do dodatkov práce. Nasledujúci program v jazyku Python vygeneruje súbor `thesis.tex`, ktorý je funkčne totožný s hlavným súborom tohto dokumentu. Stačí vyplniť prehľadný formulár pri volaní funkcie `generate_thesis_tex` na konci kódu a získate hlavný súbor vašej práce.

```
def generate_thesis_tex(
    author,
    reg_nr,
    title,
    title_en,
    day,
    month,
    year,
    keywords,
    keywords_en,
    study_programme,
    study_programme_en,
    study_field,
    study_field_en,
    training_workplace,
    training_workplace_en,
    supervisor,
    consultant=None,
    thesis_type="bp",
    language="sk",
):

    tex_class_option = thesis_type if thesis_type in ["bp", "dp"] else "bp"
    tex_language_option = "en" if language == "en" else ""

    if tex_language_option:
        document_class = f"\\documentclass[{tex_class_option},{tex_language_option}]{FEIstyle}"
    else:
        document_class = f"\\documentclass[{tex_class_option}]{FEIstyle}"

    tex_content = f"""
{document_class}

% Author of the thesis
\\FEIauthor{{{author}}}
```

```

% Evidence number
\\FEIregNr{{{reg_nr}}}

% Title
\\FEItitle{{{title}}}
\\FEItitleEn{{{title_en}}}

% Date
\\FEIdate{{{day}}}{{{month}}}{{{year}}}

% Keywords
\\FEIkeywords{{{keywords}}}
\\FEIkeywordsEn{{{keywords_en}}}

% Further details
\\FEIstudyProgramme{{{study_programme}}}
\\FEIstudyProgrammeEn{{{study_programme_en}}}
\\FEIstudyField{{{study_field}}}
\\FEIstudyFieldEn{{{study_field_en}}}
\\FEItrainingWorkplace{{{training_workplace}}}
\\FEItrainingWorkplaceEn{{{training_workplace_en}}}

% Supervisor
\\FEIsupervisor{{{supervisor}}}
"""

    if consultant:
        tex_content += f"\n\\FEIconsultant{{{consultant}}}\n"

    tex_content += f"""

% Bibliography database file
\\bibliography{{{includes/bibliography.bib}}}

\\begin{{{document}}}

\\frontmatter
\\FEIpdfInfo
\\FEIcover
\\FEItitlePage
\\includepdf[pages=-]{{{includes/assignment.pdf}}}
\\FEIthanks{{{includes/thanks}}}
\\FEIabstract{{{includes/abstract}}}
\\FEIabstractEn{{{includes/abstractEN}}}

```

```

\\FEIcontent
\\FEImanualListOfGlossaries{{includes/manual_glossary}}
\\FEIlistOfAlgorithms
\\FEIlistOfListings

\\mainmatter
\\FEIintroduction{{includes/introduction}}
\\FEIcore{{includes/core}}
\\FEIconclusion{{includes/conclusion}}
\\FEIbibliography
\\FEIaiDeclaration{{includes/ai_declaration}}
\\backmatter
\\FEIappendix{{Algoritmus\\label{{att:algorithms}}}}{{includes/attachmentA}}
\\FEIappendix{{Výpis dlhého kódu\\label{{att:listings}}}}{{includes/attachmentB}}
\\FEIappendix{{Slovníček pojmov\\label{{att:dictionary}}}}{{includes/attachmentC}}

\\end{{document}}
"""

with open("thesis.tex", "w", encoding="utf-8") as file:
    file.write(tex_content)

print("Súbor thesis.tex bol úspešne vygenerovaný.")

# Testovacie volanie funkcie
generate_thesis_tex(
    author="RNDr. Juraj Chlpík, PhD.",
    reg_nr="FEI-xxxx-xxxx",
    title="Rozšírená šablóna záverečnej práce na FEI STU v Bratislave v systéme LaTeX",
    title_en="Extended thesis template at FEI STU in Bratislava in LaTeX system",
    day="31",
    month="12",
    year="2024",
    keywords="záverečná práca, šablóna, LaTeX, formátovanie textu, citácie",
    keywords_en="Final thesis, template, LaTeX, text formatting, citations",
    study_programme="názov študijného programu",
    study_programme_en="Study program in English",
    study_field="názov študijného odboru",
    study_field_en="Field of the study in English",
    training_workplace="Názov školiaceho pracoviska",
    training_workplace_en="Training Work place",
    supervisor="tituly Meno Priezvisko, tituly",
    consultant="",

```

```
thesis_type="bp", # Možnosti: "bp", "dp"  
language="sk", # Možnosti: "sk" (slovenčina - predvolená), "en" (angličtina)  
)
```

Výpis kódu 2: Ukážka výpisu kódu programu načítaného z externého súboru pomocou makra `\lstinputlisting`

Dodatok C: Slovníček pojmov

Abstrakt – Krátke zhrnutie hlavných bodov dokumentu, vrátane cieľov, metodológie a výsledkov.

Bod (pt) – Jednotka merania veľkosti písma; 1 bod sa rovná približne 0,352 mm.

Bold – Písmo, ktoré je tučné, používané na zvýraznenie dôležitých častí textu a v nadpisoch.

Citácia – Uvedenie zdroja informácií v texte, ktoré umožňuje identifikáciu pôvodného materiálu.

Font – Typ písma, ktorý sa používa na zobrazenie textu. Rôzne fonty majú odlišný štýl a vzhľad.

Graf – Vizualizácia údajov, ktorá zobrazuje vzťah medzi premennými.

Kapitola – Hlavná časť dokumentu, ktorá sa zaoberá konkrétnou témou a je zvyčajne označená číslom alebo názvom.

Korektúra – Proces revízie a opravy textu s cieľom odstrániť chyby.

Kurzíva – Typ písma, ktorý je sklonený doprava a používa sa na zvýraznenie textu, názvov alebo cudzích výrazov.

Metodológia – Opis metód a techník použitých pri výskume alebo analýze.

Normostrana – Základná jednotka pre meranie dĺžky textu, ktorá zvyčajne obsahuje 1 800 znakov vrátane medzier.

Obrázok – Grafický prvok alebo fotografia, ktorá ilustruje text.

Odsadenie – Vzdialenosť prvého riadku odseku od okraja stránky.

Odsek – Základná jednotka textu, ktorá obsahuje súvislé myšlienky. V L^AT_EX-u sa odseky oddeľujú prázdny riadkom v zdrojovom texte.

Plagiátorstvo – Prezenterovanie cudzej práce alebo myšlienok ako vlastných bez riadneho citovania.

Rez písma – Variant typu písma, ktorý určuje štýlové úpravy, ako sú normálny, tučný (bold), kurzíva (italic) alebo podčiarknutie.

Riadkovanie – Vzdialenosť medzi jednotlivými riadkami textu.

Sadzba – Proces usporiadania textu a grafiky na stránke.

Súbor – Elektronický dokument, ktorý obsahuje text alebo dáta.

Šablóna – Prednastavené formátovanie pre rôzne typy textu, ktoré zabezpečuje jednotný vzhľad.

Tabuľka – Usporiadanie údajov do riadkov a stĺpcov.

Titulný list – Prvá stránka dokumentu, ktorá obsahuje základné informácie, ako je názov práce a meno autora.

Typografia – Umenie a technika usporiadania textu tak, aby bol esteticky príťažlivý a čitateľný.

Úvod – Prvá časť dokumentu, ktorá predstavuje tému a ciele výskumu.

Vedecká práca – Akademický dokument, ktorý prezentuje výsledky výskumu, analýzy alebo diskusie o špecifickej téme.

Zdroje primárne a sekundárne – Primárne zdroje sú originálne dokumenty; sekundárne zdroje interpretujú alebo analyzujú primárne zdroje.