

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104378-115323

**Mobilná aplikácia na ovládanie výrobnéj linky s
využitím jedinečného identifikátora**

Diplomová práca

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104378-115323

Mobilná aplikácia na ovládanie výrobnéj linky s využitím jedinečného identifikátora

Diplomová práca

Študijný program:	Aplikovaná mechatronika a elektromobilita
Študijný odbor:	Kybernetika
Školiace pracovisko:	Ústav automobilovej mechatroniky (FEI)
Školiteľ:	Ing. Lukáš Beňo PhD.



ZADANIE DIPLOMOVEJ PRÁCE

Autor práce: Bc. Jakub Hubáček
Študijný program: aplikovaná mechatronika a elektromobilita
Študijný odbor: kybernetika
Evidenčné číslo: FEI-104378-115323
ID študenta: 115323
Vedúci práce: Ing. Lukáš Beňo, PhD.
Vedúci pracoviska: Ing. Ján Cigánek, PhD.

Názov práce: **Mobilná aplikácia na ovládanie výrobnéj linky s využitím jedinečného identifikátora**

Jazyk, v ktorom sa práca vypracuje: slovenský jazyk

Špecifikácia zadania: Cieľom tejto práce je navrhnúť a implementovať mobilnú aplikáciu umožňujúcu ovládanie výrobnéj linky. Aplikácia bude využívať jedinečný identifikátor na identifikáciu a pripojenie k riadiacej jednotke linky. Implementácia bude zahŕňať načítanie jedinečného identifikátora pomocou mobilného zariadenia, komunikáciu s riadiacim systémom linky a jej interaktívne ovládanie. Práca sa zameria na návrh používateľského rozhrania, zabezpečenie spoľahlivej komunikácie so zariadením a testovanie funkcionality v laboratórnych podmienkach.

Úlohy:

1. Preskúmajte možnosti načítania jedinečných identifikátorov pomocou mobilných zariadení.
2. Navrhnite a implementujte mobilnú aplikáciu umožňujúcu identifikáciu pomocou jedinečného identifikátora.
3. Integrujte aplikáciu s riadiacim systémom výrobnéj linky.
4. Navrhnite a implementujte funkcie na vzdialené ovládanie výrobnéj linky cez mobilné zariadenie.
5. Otestujte aplikáciu v laboratórnom prostredí a vyhodnoťte jej spoľahlivosť a efektívnosť.

Literatúra:

1. MICHALOVIČ, Martin a HAFFNER, Oto. Programatické generovanie 3D identifikátora pre systémy zmiešanej reality. In: Peter, BENKO a Stanislav, SOJAK. *ŠVOČ 2023*. Bratislava: Vydavateľstvo Spektrum STU, 2023, s. 80–85. ISBN 978-80-227-5307-4.
2. RIDEKY, Viliam a HAFFNER, Oto. *Rozpoznávanie objektov pomocou 3D Point Cloud klasifikácie*. Diplomová práca. Bratislava : 2025. 99 s.
3. STOKLAS, Gabriel a KUČERA, Erik. *Rozpoznávanie 3D identifikátorov pre identifikáciu objektov v prostredí zmiešanej reality*. Diplomová práca. Bratislava : 2024. 79 s.
4. VALOCKÝ, Frederik a HAFFNER, Oto. *Vizuálny lokalizačný systém pre autonómne vozidlá: dátum obhajoby 22.8.2022*. Dizertačná práca. Bratislava : 2022. 147 s.

Termín odovzdania práce: 15. 05. 2026

Dátum schválenia zadania práce: **08. 03. 2026**

Zadanie práce schválil: **prof. Ing. Vladimír Kutiš, PhD.**
garant študijného programu

Podakovanie

Na tomto mieste by som sa rád poďakoval Ing. Lukášovi Beňovi PhD. za cenné rady a pomoc pri písaní diplomovej práce.

Abstrakt

Diplomová práca sa zaoberá návrhom a implementáciou mobilnej aplikácie, ktorá obsluhuje priemyselnej výrobnéj linky umožňuje rýchlu identifikáciu konkrétneho zariadenia, jeho monitorovanie a vzdialené ovládanie pomocou jedinečného vizuálneho identifikátora. Analýza dostupných komerčných platforiem ukázala, že žiadna z nich súčasne neintegruje natívnu mobilnú aplikáciu, skenovanie unikátnych identifikátorov pre spárovanie so zariadením a kontextového inteligentného asistenta s vlastnou znalostnou bázou. Práca tieto medzery adresuje návrhom systému Scan2Control, v ktorom mobilná aplikácia implementovaná vo Flutter automaticky pripojí operátora ku konkrétnej linke naskenovaním ArUco identifikátora a následne mu umožní odosielať riadiace príkazy. Backendová vrstva tvorená dvojicou služieb FastAPI komunikuje s programovateľným logickým automatom Siemens S7-1200 cez Node-RED a MQTT broker, pričom celá infraštruktúra je kontajnerizovaná pomocou Docker a nasadená na edge zariadení v prevádzke. Súčasťou systému je inteligentný asistent PLEXO postavený na architektúre Retrieval-Augmented Generation, ktorý odpovedá na technické otázky obsluhy na základe znalostnej bázy uloženej vo vektorovej databáze ChromaDB. Otestovanie v laboratórnom a čiastočne aj v priemyselnom prostredí potvrdilo splnenie všetkých funkčných, nefunkčných a doménových požiadaviek vrátane latencie príkazov výrazne pod stanovenou hranicou a spoľahlivej detekcie identifikátorov v praktickom rozsahu vzdialeností, uhlov a svetelných podmienok.

Kľúčové slová

Ovládanie výrobnéj linky, mobilná aplikácia, jedinečný identifikátor, AI asistent

Abstract

This master's thesis addresses the design and implementation of a mobile application that enables operators of an industrial production line to quickly identify a specific device, monitor it, and remotely control it using a unique visual identifier. An analysis of available commercial platforms showed that none of them simultaneously integrate a native mobile application, scanning of unique identifiers for pairing with a device, and a context-aware intelligent assistant with a custom knowledge base. The thesis addresses these gaps by proposing the Scan2Control system, in which a mobile application implemented in Flutter automatically connects the operator to a specific line by scanning an ArUco identifier and subsequently allows them to send control commands. The backend layer, formed by a pair of FastAPI services, communicates with a Siemens S7-1200 programmable logic controller through Node-RED and an MQTT broker, while the entire infrastructure is containerized using Docker and deployed on an edge device in the production environment. The system includes the intelligent assistant PLEXO, built on the Retrieval-Augmented Generation architecture, which answers technical questions from operators based on a knowledge base stored in the ChromaDB vector database. Testing in a laboratory environment, and partially also in an industrial setting, confirmed the fulfilment of all functional, non-functional and domain-specific requirements, including command latency significantly below the defined threshold and reliable detection of identifiers across a practical range of distances, angles and lighting conditions.

Keywords

Production line control, mobile application, unique identifier, AI assistant

Obsah

Úvod	1
1 Analýza existujúcich riešení	3
1.1 Siemens WinCC Unified	3
1.2 Ignition Perspective	4
1.3 Tulip	5
1.4 AVEVA InTouch Edge HMI	6
2 Prehľad technológií pre vývoj aplikácií a priemyselnú komunikáciu	8
2.1 Frontendové technológie	8
2.2 Backendové technológie	9
2.3 Kontajnerizácia a edge architektúra	9
2.3.1 Docker a Docker Compose	10
2.4 Priemyselné komunikačné protokoly	10
2.4.1 OPC UA	10
2.4.2 S7 Protokol	11
2.4.3 MQTT	11
2.4.4 Modbus TCP	12
3 Prehľad technológií pre AI asistentov	13
3.1 Veľké jazykové modely a možnosti použitia	13
3.2 Retrieval-Augmented Generation	13
3.3 AI asistenti v priemyselnom prostredí	14
4 Typy identifikátorov a ich použitie	15
4.1 QR identifikátory	15
4.2 Fiduciálne markery – AprilTag, ArUco	15
4.3 3D identifikátory	16
4.3.1 Princíp a štruktúra	16
5 Špecifikácia požiadaviek na systém	18
5.1 Opis systému	18
5.2 Popis používateľských rolí	18
5.3 Use-case scenáre	19
5.4 Funkcionálne požiadavky	20
5.5 Nefunkcionálne požiadavky	21
5.6 Doménové požiadavky	22

6	Voľba technológií	23
6.1	Komunikácia s PLC – S7 protokol	23
6.2	Komunikačná middleware vrstva – Node-RED	23
6.3	Transportný protokol – MQTT	24
6.4	Backend – FastAPI	24
6.5	Frontend – Flutter	25
6.6	Výber identifikátora – ArUco	25
7	Experimentálne porovnanie a výber jazykových modelov	27
7.1	Popis testovaných modelov	27
7.2	Metodika testovania	28
7.3	Výsledky porovnania	29
7.4	Analýza výsledkov a výber modelu	29
7.4.1	Overenie na cloudovom hardvéri	30
7.4.2	Záverečné rozhodnutie o architektúre AI asistenta	31
8	Návrh architektúry systému	32
8.1	Architektúra komponentov systému	32
8.2	Fyzická topológia systému	33
8.3	Štruktúra MQTT tém	34
8.4	Dátový model	35
9	Integrácia s riadiacim systémom linky	37
9.1	Štruktúra projektu v TIA Portal	37
9.2	Dátový blok DB_API	37
9.3	Stavový automat riadiacej logiky	38
10	Implementácia backendu	40
10.1	Autentifikácia a RBAC	40
10.2	API endpointy	40
10.3	Mechanizmus relácií	41
10.4	Životný cyklus príkazu	42
10.5	Generátor ArUco identifikátorov a export do STL	42
11	Implementácia AI asistenta	43
11.1	RAG pipeline	43
11.2	Embedovací model	43
11.3	Systémový prompt	44
11.4	Správa konverzácie	45

11.5	Správa znalostnej bázy	45
12	Implementácia frontendu	46
12.1	Stavový manažment	46
12.2	ArUco skenovanie	46
12.3	WebSocket pripojenie	46
12.4	Používateľské rozhranie podľa roly	47
13	Opis funkcionalít aplikácie pre používateľa	48
13.1	Hlavné menu	48
13.2	Skener ArUco identifikátorov	49
13.3	Generátor ArUco identifikátorov	49
13.4	Monitoring a ovládanie výrobných liniek	50
13.5	AI asistent PLEXO	51
13.6	Správa používateľov	52
13.7	Správa výrobných liniek	53
13.8	Správa znalostnej bázy	54
13.9	Logy príkazov	55
13.10	Nastavenia	56
14	Testovanie a meranie	58
14.1	Overenie splnenia špecifikácie	58
14.2	Latencia vykonania príkazov	60
14.3	Detekcia ArUco identifikátorov	60
14.4	Kvalita odpovedí AI asistenta	61
14.5	Zhrnutie výsledkov testovania	62
	Záver	64
	Literatúra	65
	Použitie nástrojov umelej inteligencie	67
A	Súborová štruktúra	68
B	Prílohy k testovaniu	69
C	Návod na spustenie	74

Zoznam obrázkov a tabuliek

Obrázok 1	Základný princíp RAG pipeline	13
Obrázok 2	QR identifikátor so zakódovanou URL adresou fei.stuba.sk .	15
Obrázok 3	Vizuálne porovnanie AprilTag a ArUco	15
Obrázok 4	Fyzický 3D identifikátor vyrobený pomocou 3D tlače	16
Obrázok 5	Diagram architektúry systému a komunikácia medzi kompo- nentmi	33
Obrázok 6	Fyzická topológia systému	34
Obrázok 7	Entitno-relačný diagram databázy systému	36
Obrázok 8	ArUco identifikátor tlačený z vygenerovaného STL modelu .	43
Obrázok 9	Hlavné menu so základným prehľadom	48
Obrázok 10	Obrazovka skenera ArUco identifikátorov s náhľadom z kamery	49
Obrázok 11	Obrazovka generátora ArUco identifikátorov s možnosťami exportu	50
Obrázok 12	Obrazovky monitoringu a ovládania výrobnéj linky	51
Obrázok 13	Konverzačné rozhranie AI asistenta PLEXO	52
Obrázok 14	Obrazovka správy používateľov	53
Obrázok 15	Obrazovka správy výrobných liniek	54
Obrázok 16	Obrazovky správy znalostnej bázy	55
Obrázok 17	Obrazovka logov vykonaných príkazov	56
Obrázok 18	Obrazovka nastavení aplikácie	57
Tabuľka 1	Porovnanie existujúcich riešení	7
Tabuľka 2	Backendové frameworky podľa scenára nasadenia [10]	9
Tabuľka 3	Výsledky porovnania jazykových modelov	30
Tabuľka 4	Priemerná relevancia podľa typu otázky a jazyka	30
Tabuľka 5	Prehľad MQTT tém	35
Tabuľka 6	Premenné dátového bloku DB_API	38
Tabuľka 7	Stavy automatu FB_Conveyor	38
Tabuľka 8	Prehľad API endpointov	41
Tabuľka 9	Oprávnenia podľa roly používateľa	47
Tabuľka 10	Overenie funkčných požiadaviek	59
Tabuľka 11	Overenie nefunkčných požiadaviek	59
Tabuľka 12	Overenie doménových požiadaviek	59
Tabuľka 13	Štatistika latencie príkazov v milisekundách (n=25)	60

Tabuľka 14	Úspešnosť detekcie podľa vzdialenosti a uhla (n=30)	61
Tabuľka 15	Úspešnosť detekcie podľa prostredia (vzdialenosť 60 cm, uhol 0°, n=30)	61
Tabuľka 16	Kvalita odpovedí asistenta	62

Zoznam značiek a skratiek

AI	Artificial Intelligence (slovensky „umelá inteligencia“)
AOT	Ahead-of-Time (slovensky „predkompilácia“)
API	Application Programming Interface (slovensky „aplikačné programové rozhranie“)
ASGI	Asynchronous Server Gateway Interface (slovensky „asynchrónne rozhranie serverovej brány“)
CPU	Central Processing Unit (slovensky „centrálna procesorová jednotka“)
GPU	Graphics Processing Unit (slovensky „grafická procesorová jednotka“)
HMI	Human-Machine Interface (slovensky „rozhranie človek-stroj“)
HTML	HyperText Markup Language (slovensky „hypertextový značkovací jazyk“)
IIoT	Industrial Internet of Things (slovensky „priemyselný internet vecí“)
IoT	Internet of Things (slovensky „internet vecí“)
IT	Information Technology (slovensky „informačné technológie“)
JSON	JavaScript Object Notation (slovensky „JavaScriptová objektová notácia“)
KB	Knowledge Base (slovensky „znalostná báza“)
LLM	Large Language Model (slovensky „veľký jazykový model“)
ML	Machine Learning (slovensky „strojové učenie“)
MQTT	Message Queuing Telemetry Transport (slovensky „telemetrický transportný protokol s radením správ“)
OPC UA	Open Platform Communications Unified Architecture (slovensky „zjednotená architektúra otvorenej platformovej komunikácie“)

OT	Operational Technology (slovensky „prevádzkové technológie“)
PLC	Programmable Logic Controller (slovensky „programovateľný logický automat“)
Pub/Sub	Publish-Subscribe (slovensky „vzor vydavateľ-odberateľ“)
QoS	Quality of Service (slovensky „kvalita služieb“)
QR	Quick Response (slovensky „rýchla odpoveď“)
RAG	Retrieval-Augmented Generation (slovensky „generovanie rozšírené o vyhľadávanie“)
RAM	Random Access Memory (slovensky „pamäť s náhodným prístupom“)
RBAC	Role-Based Access Control (slovensky „riadenie prístupu na základe rolí“)
REST	Representational State Transfer (slovensky „reprezentačný prenos stavu“)
SaaS	Software as a Service (slovensky „softvér ako služba“)
SCADA	Supervisory Control and Data Acquisition (slovensky „dohľadové riadenie a zber dát“)
SQL	Structured Query Language (slovensky „štruktúrovaný dotazovací jazyk“)
TCP	Transmission Control Protocol (slovensky „protokol riadenia prenosu“)
UI	User Interface (slovensky „používateľské rozhranie“)
VRAM	Video Random Access Memory (slovensky „grafická pamäť s náhodným prístupom“)

Zoznam výpisov kódov

1	Jadro stavového automatu FB_Conveyor	39
2	Závislosti pre kontrolu rolí	40
3	Ochrana relácie údržbára	42
4	Základ systémového promptu AI asistenta PLEXO	44

Úvod

Moderné výrobné podniky prešli v poslednom desaťročí výraznou digitalizáciou v duchu konceptu Industry 4.0, ktorá priniesla prepojenie prevádzkových technológií (OT) so svetom informačných technológií (IT) a možnosti vzdialeného monitorovania a zberu prevádzkových dát. Európska komisia v roku 2021 publikovala nadväzujúcu víziu Industry 5.0, ktorá k tomuto technologickému základu pridáva tri hodnotové piliere: zameranie na človeka, udržateľnosť a odolnosť. Človek prestáva byť len obsluhou strojov a stáva sa partnerom, pričom nasadenie nových technológií má rešpektovať jeho potreby a slúžiť mu pri každodennej práci. Klasické SCADA/HMI systémy so stacionárnymi dotykovými panelmi však tomuto smerovaniu vychádzajú v ústrety len obmedzene. Operátor sa k nim musí fyzicky presunúť a prístup k technickej dokumentácii býva oddelený v ďalších systémoch, čo spomaľuje prácu.

Mobilné zariadenia sú prirodzeným nástrojom na riešenie týchto problémov. Operátor ich nosí pri sebe, dokáže nimi snímať vizuálne identifikátory a má ovládací panel stále so sebou. Analýza dostupných komerčných platforiem však ukázala, že časť ponúka len responzívne webové rozhrania bez optimalizácie pre dotykové zariadenia, časť podporuje skenovanie identifikátorov len pre účely inventarizácie, no nie pre priame spárovanie operátora so strojom. Žiadna z komerčných platforiem neintegruje inteligentného asistenta odpovedajúceho na technické otázky na základe vlastnej dokumentácie linky. Práve kombinácia mobilného prístupu, vizuálnej identifikácie liniek a kontextového asistenta postaveného na veľkom jazykovom modeli s architektúrou *Retrieval-Augmented Generation* tvorí priestor, ktorému sa venuje táto práca.

Cieľom práce je preskúmať možnosti načítania jedinečných identifikátorov pomocou mobilných zariadení, navrhnúť a implementovať mobilnú aplikáciu, ktorá pomocou takéhoto identifikátora automaticky spáruje operátora s konkrétnou výrobnou linkou. Ďalším cieľom je integrovať aplikáciu s riadiacim systémom výrobnéj linky a implementovať funkcie na jej vzdialené ovládanie. Ciele sú nad rámec zadania doplnené o inteligentného asistenta, ktorý bude pomáhať obsluhu pri riešení technických otázok. Výsledný systém by mal byť otestovaný v laboratórnom prostredí, kde sa overí jeho spoľahlivosť a efektivita.

Úvodné kapitoly rozoberajú existujúce komerčné platformy a poskytujú prehľad relevantných technológií. V ďalších kapitolách je definovaná špecifikácia požiadaviek na systém a zdôvodnenie voľby konkrétnych technológií. Experimentálna časť obsahuje porovnanie piatich lokálnych jazykových modelov a ich vhodnosť pre použitie na AI asistenta. Implementačné kapitoly opisujú návrh architektúry, integráciu s PLC Siemens S7-1200, backend, asistenta a mobilnú aplikáciu. Záver tvorí kapitola venovaná

testovaníu a meraníu, kde je overené splnenie požiadaviek a vyhodnotené merania latencie, spoľahlivosti detekcie aj kvality odpovedí asistenta.

1 Analýza existujúcich riešení

Trh s priemyselnými softvérovými platformami ponúka viacero riešení umožňujúcich vizualizáciu a ovládanie výrobných liniek. Väčšina z nich vychádza z tradičného modelu SCADA/HMI a postupne sa rozširuje o mobilný prístup, cloudovú konektivitu a v niektorých prípadoch aj o prvky umelej inteligencie. Nasledujúci prehľad analyzuje štyri významné komerčné platformy. Posudzované sú nasledujúce funkcionality: mobilný prístup k výrobným linkám, identifikácia fyzických liniek, nasadenie na edge, otvorenosť platformy a integrácia AI asistenta schopného pracovať s technickou dokumentáciou.

1.1 Siemens WinCC Unified

SCADA systém *SIMATIC WinCC Unified PC* od spoločnosti Siemens je vizualizačná platforma integrovaná do prostredia TIA Portal, navrhnutá na zjednotenie OT a IT dát v rámci jedného konzistentného systému [1]. Platforma je škálovateľná od jedného zariadenia až po rozsiahle distribuované systémy s prakticky neobmedzeným počtom zariadení.

Prístup k prevádzkovým dátam je zabezpečený cez webové rozhranie HTML5, ktoré umožňuje vzdialené monitorovanie z prehliadača bez inštalácie klientskej aplikácie. Platforma obsahuje archív pre dlhodobé ukladanie dát a podporuje redundanciu pre vysokú dostupnosť systému.

Siemens v rámci TIA Portal ekosystému ponúka aj nástroj *Engineering Copilot TIA Standard* [2]. Ide o generatívneho AI asistenta pripojeného priamo k TIA Portal. Tento nástroj dokáže generovať kód PLC v jazyku SCL, vytvárať testy, konfigurovať HMI obrazovky a odpovedať na otázky na základe dokumentácie TIA Portal. Jeho zameranie je však výlučne na fázu návrhu a pomáha programátorom pri programovaní a konfigurácii, nie operátorovi počas prevádzky.

Z pohľadu našej práce sú kľúčové tieto body:

- **Mobilný prístup:** Webové rozhranie je dostupné cez prehliadač, nie je to natívna mobilná aplikácia. Interakcia nie je optimalizovaná pre dotykové ovládanie.
- **Identifikácia zariadení:** Platforma nepodporuje skenovanie unikátnych identifikátorov, operátor sa naviguje manuálne.
- **AI asistent pre obsluhu:** Engineering Copilot je nástroj pre programátorov, nie pre operátorov. Neposkytuje kontextovú pomoc na základe znalostnej bázy zariadení počas prevádzky.

- **Licenčný model:** Proprietárny, viazaný na ekosystém Siemens, vyžaduje TIA Portal licencie.

1.2 Ignition Perspective

Ignition SCADA od spoločnosti Inductive Automation je modulárna platforma postavená na otvorených IT štandardoch – SQL, Python, MQTT a OPC UA. Jej kľúčovou vlastnosťou je licenčný model bez obmedzenia počtu tagov, klientov a pripojení, čo ju odlišuje od väčšiny konkurenčných riešení účtujúcich za každé zariadenie [3].

Platforma komunikuje s PLC od Allen-Bradley, Siemens, Mitsubishi, Modbus a ďalšími prostredníctvom vstavaných ovládačov a zabudovaného OPC UA servera. Ignition Gateway beží na štandardnom serveri a škálovateľnosť je riešená architektúrou hub-and-spoke, kde centrálny gateway koordinuje viaceré odľahčené inštancie.

Modul *Perspective* poskytuje plnohodnotné webové rozhranie na báze HTML5, prístupné z akéhokoľvek zariadenia bez inštalácie klientskej aplikácie. Vizualizačné komponenty sú responzívne a optimalizované pre dotykové ovládanie na tabletoch a smartfónoch. K dispozícii je aj mobilná aplikácia *Ignition Perspective App*.

Pre nasadenie na edge zariadeniach Inductive Automation ponúka *Ignition Edge*. Ide o odľahčenú verziu s archívom (35 dní lokálneho ukladania), podporou MQTT Sparkplug pre synchronizáciu dát na centrálny gateway a možnosťou tvorby REST API priamo na edge zariadení. Ignition Edge teda plní úlohu AI premostenia medzi fyzickými zariadeniami a vyššími systémovými vrstvami [4].

Z pohľadu našej práce sú kľúčové tieto body:

- **Mobilný prístup:** Modul Perspective poskytuje responzívne webové rozhranie aj mobilnú aplikáciu a teda dotykové ovládanie je plne podporované.
- **Identifikácia zariadení:** Platforma natívne nepodporuje skenovanie unikátnych identifikátorov. Identifikácia pomocou QR identifikátorov je technicky realizovateľná vlastnými Pythonskými skriptmi, avšak nejde o štandardnú funkciu platformy.
- **Edge nasadenie:** Ignition Edge umožňuje distribuované nasadenie priamo na priemyselných zariadeniach s lokálnou archiváciou a synchronizáciou dát.
- **AI asistent:** Platforma neobsahuje vstavanú funkciu AI asistenta ani správu znalostnej bázy. Skriptovacie rozhranie v Pythone by technicky umožnilo volanie externých LLM API, avšak bez natívnej podpory.

- **Licenčný model:** Licencia na Gateway bez obmedzenia počtu klientov. Jednotlivé moduly ako Perspective, Alarming, Reporting sa licencujú samostatne.

1.3 Tulip

Tulip je cloudová no-code platforma pre frontline operácie vo výrobnom sektore, ktorá umožňuje vytvárať priemyselné aplikácie prostredníctvom vizuálneho drag-and-drop editora bez nutnosti programovania [5]. Platforma je orientovaná na digitalizáciu manuálnych výrobných procesov – sledovanie výrobných krokov, zber dát z pracovísk, kontrolu kvality, vizuálne pracovné inštrukcie a sledovateľnosť výroby.

Licenčný model Tulip je účtovaný za interface (zariadenie spúšťajúce Tulip Player). Základný plán *Essentials* zahŕňa aplikácie na mobiloch, tabletoch, dotykových obrazovkách a nositeľných zariadeniach, pričom vyššie plány (*Professional*, *Enterprise*) pridávajú edge konektivitu či pokročilú správu rolí.

Pripojenie k priemyselným zariadeniam je realizované použitím doplnkového modulu *Machine Monitoring* s podporou OPC UA, MQTT a Node-RED. Aplikácia beží vo webovom prehliadači na tabletoch alebo iných zariadeniach umiestnených na pracoviskách.

V roku 2024 Tulip uzavrel strategickú spoluprácu s Amazon Web Services a predstavil funkciu *Frontline Copilot* [6], postavenú na platforme Amazon Bedrock. Frontline Copilot umožňuje operátorom diagnostikovať výrobné dáta, hľadať v nich vzory a vytvárať aplikácie bez kódu s pomocou generatívnej AI. Systém pracuje s reálnymi výrobnými dátami zozbieranými v rámci platformy.

Z pohľadu našej práce sú kľúčové tieto body:

- **Mobilný prístup:** Aplikácie sú webové a responzívne, spustiteľné na mobiloch, tabletoch aj dotykových obrazovkách.
- **Identifikácia zariadení:** Platforma podporuje skenovanie čiarových identifikátorov a QR identifikátorov pre identifikáciu materiálov a produktov, avšak nie pre priame spárovanie s konkrétnym zariadením.
- **Edge nasadenie:** Edge konektivita (OPC UA, MQTT, Node-RED) je dostupná ako platený doplnok, aplikačná logika a dáta sú hostované v cloude.
- **AI asistent:** Frontline Copilot poskytuje generatívnu AI na analýzu výrobných dát a asistenciu operátorom. Nejde však o asistenta s vlastnou znalostnou bázou technickej dokumentácie zariadení. Funkcia pracuje primárne s dátami nazbieranými v rámci platformy Tulip.

- **Licenčný model:** SaaS model účtovaný mesačne za interface, cloudová závislosť môže byť problematická v prostrediach s prísnyimi požiadavkami na lokalizáciu dát.

1.4 AVEVA InTouch Edge HMI

AVEVA Edge je HMI/SCADA platforma od spoločnosti AVEVA, ktorá je členom skupiny Schneider Electric. Je navrhnutá pre nasadenie na priemyselných zariadeniach, priemyselných PC a edge zariadeniach s minimálnymi hardvérovými nárokmi [7]. Kľúčovým princípom platformy je heslo „develop once, deploy everywhere“. Aplikácia sa navrhne raz v prostredí AVEVA Edge Studio a nasadí na Windows alebo Linux, od malých embedded zariadení až po plnohodnotné SCADA systémy.

Platforma je interoperabilná s väčšinou priemyselných zariadení prostredníctvom vstavaných ovládačov a natívnej podpory OPC UA. Vzdialený prístup je zabezpečený webovým rozhraním založeným na HTML5, čo umožňuje sledovanie a ovládanie zo smartfónov, tabletov a priemyselných panelov bez inštalácie klienta.

V oblasti priemyselnej AI AVEVA rozvíja samostatnú platformu *Industrial AI for Operations*, ktorá využíva aktuálne aj historické dáta naprieč prevádzkou, dodávateľským reťazcom a plánovaním na odhaľovanie skrytých nedostatkov v efektivite a predikciu výpadkov [8]. Táto AI vrstva je však cieľená na podnikovú úroveň, optimalizáciu procesov a prediktívnu údržbu. Nie je cieľom poskytovať kontextovú asistenciu obsluhu priamo pri zariadení.

Z pohľadu našej práce sú kľúčové tieto body:

- **Mobilný prístup:** HTML5 webové rozhranie prístupné zo smartfónov a tabletov, nie je to natívna mobilná aplikácia.
- **Identifikácia zariadení:** Platforma nepodporuje skenovanie unikátnych identifikátorov pre spárovanie operátora so zariadením.
- **Edge nasadenie:** Natívna podpora, AVEVA Edge je priamo navrhnutý pre beh na edge zariadeniach vrátane Linux systémov s nižšími hardvérovými prostriedkami.
- **AI asistent:** Industrial AI for Operations je analytická platforma na podnikovej úrovni zameraná na prediktívnu údržbu a optimalizáciu procesov. Neposkytuje kontextovú asistenciu obsluhu na základe znalostnej bázy dokumentácie konkrétnych zariadení.
- **Licenčný model:** Proprietárny, licencie sa aktivujú cez AVEVA web portál na základe sériového čísla a hardvérového identifikátora.

Zhrnutie analýzy

Tabuľka 1 sumarizuje kľúčové vlastnosti porovnávaných platforiem vzhľadom na mobilný prístup, identifikáciu zariadení, edge nasadenie a integráciu AI asistenta s vlastnou znalostnou bázou.

Tabuľka 1: Porovnanie existujúcich riešení

Vlastnosť	WinCC Unified	Ignition Perspective	Tulip	AVEVA InTouch
Natívna mobilná aplikácia	Nie	Áno	Nie	Nie
Identifikácia zariadení	Nie	Nie	Čiastočne	Nie
Edge nasadenie	Áno	Áno	Čiastočne	Áno
AI asistent s vlastnou KB	Nie	Nie	Nie	Nie
Otvorená platforma	Nie	Čiastočne	Nie	Nie

Z porovnania vyplýva, že existujúce komerčné platformy poskytujú rôznu mieru mobilného prístupu k priemyselným systémom, avšak ani jedna z nich neintegruje AI asistenta schopného odpovedať na otázky obsluhy na základe vlastnej znalostnej bázy technickej dokumentácie. Väčšina platforiem sa orientuje na vizualizáciu a vzdialený prístup k procesným dátam. Pričom podpora operátora, teda schopnosť systému aktívne pomáhať pri riešení prevádzkových situácií prostredníctvom práce s dokumentáciou, zostáva nepokrytou oblasťou.

Rovnako identifikácia fyzických zariadení prostredníctvom vizuálnych identifikátorov s automatickým načítaním kontextu pre dané zariadenie nie je štandardnou funkciou žiadnej z analyzovaných platforiem. Operátori sú naďalej odkázaní na manuálnu navigáciu cez menu, čo spomaľuje prístup k informáciám a zvyšuje pravdepodobnosť interakcie s nesprávnym zariadením.

Tieto identifikované medzery v súčasnej ponuke komerčných riešení tvoria základ pre návrh systému prezentovaného v neskorších kapitolách tejto práce.

2 Prehľad technológií pre vývoj aplikácií a priemyselnú komunikáciu

Moderné priemyselné aplikácie nestoja na jednej technológii. Sú výsledkom starostlivo zvolenej skladačky nástrojov, kde každá vrstva plní svoju úlohu. Mobilné rozhranie reaguje na pokyny operátora, backendová vrstva spracúva množstvo súbežných udalostí zo zariadení a pokyny prichádzajúce z mobilnej aplikácie.

Kľúčovou výzvou je pritom premostenie dvoch oddelených svetov. OT označuje svet priemyselného riadenia a teda PLC automaty, senzory, pohony a ostatné zariadenia. IT je naopak svet softvéru, sietí a aplikácií určených na spracovanie a prenos informácií. Tieto dva svety dlho fungovali oddelene, každý s vlastnými protokolmi a prioritami. Priemyselné aplikácie v kontexte Industry 4.0 ich spájajú práve cez komunikačnú vrstvu, napríklad pomocou protokolov MQTT alebo OPC UA.

Nasledujúci prehľad mapuje najpoužívanjšie technológie a ich typické uplatnenie.

2.1 Frontendové technológie

Výber frameworku pre mobilnú aplikáciu patrí k zásadným architektonickým rozhodnutiam. Z prehľadu moderných frameworkov vyplýva, že voľba nie je len technická, ale priamo ovplyvňuje rýchlosť vývoja, výkon aplikácie, dlhodobé náklady na údržbu a dostupnosť vývojárov [9]. Nasledujúci prehľad stručne opisuje najrozšírenejšie spôsoby vývoja frontendu, resp. vybrané používané frameworky.

Natívny vývoj (Swift/SwiftUI pre iOS, Kotlin pre Android) poskytuje maximálny výkon a priamy prístup k hardvérovým funkciám zariadenia. Jeho nevýhodou je nutnosť paralelného vývoja a údržby dvoch samostatných kódových základní, čo zvyšuje celkové náklady na vývoj.

React Native od spoločnosti Meta umožňuje zdieľanie logiky aplikácie medzi platformami pomocou JavaScriptu, pričom UI vykresľuje použitím natívnych komponentov systému. React Native má silný ekosystém, avšak pri výkonnostne náročných operáciách môžu nastať obmedzenia spôsobené prechodom cez natívne rozhranie.

Flutter od spoločnosti Google využíva jednotnú kódovú základňu v jazyku Dart a vlastný vykresľovací engine, ktorý zaručuje konzistentné vizuálne výstupy na všetkých platformách bez závislosti na systémových komponentoch. Dosahuje výkon blízky natívnym aplikáciám vďaka AOT kompilácii.

Webové frameworky (React, Angular, Vue) umožňujú prístup z ľubovoľného zariadenia s prehliadačom bez inštalácie. Pre priemyselné aplikácie je ich hlavným

obmedzením bezpečnostný sandbox prehliadača, ktorý sťažuje priamu komunikáciu s lokálnym hardvérom a priemyselnými rozhraniami.

2.2 Backendové technológie

Backend tvorí jadro systému, spracúva požiadavky, komunikuje s databázami a sprostredkováva tok dát medzi PLC a klientskymi aplikáciami. Výber frameworku pre tvorbu backendu závisí od požiadaviek na výkon, dostupnosť AI/ML knižníc a dlhodobú udržateľnosť [10]. Pozrime sa na vybrané možnosti, ktoré sa často používajú pre ich jednoduchosť, výkon alebo ekosystém knižníc.

Django je framework s filozofiou „batteries included“ a obsahuje vstavaný administrátorský panel, správu relácií a ORM vrstvu. Je vhodný pre dátovo náročné aplikácie a rýchly vývoj, avšak jeho monolitická architektúra ho robí menej vhodným pre mikroslužby.

Node.js s Express/NestJS umožňuje použiť JavaScript aj pre backend. Node.js vyniká pri aplikáciách s vysokou frekvenciou krátkych I/O operácií, avšak nie je vhodný pre výpočtovo náročné úlohy blokujúce event loop. Nadstavba NestJS pridáva štruktúru TypeScript pre väčšie projekty.

Python s frameworkmi Flask/FastAPI dominuje v oblasti AI a ML vďaka bohatému ekosystému knižníc ako PyTorch, Scikit-learn, LangChain. Flask je minimalistický a flexibilný, FastAPI využíva asynchrónne ASGI a automaticky generuje OpenAPI dokumentáciu na základe typových anotácií.

Go s Gin/Fiber je kompilovaný jazyk s nízkymi nárokmi na RAM a CPU a predvídateľnou latenciou. Je vhodný pre mikroslužby, edge nasadenia a výkonnostne kritické systémy, avšak jeho ekosystém pre AI/ML je výrazne menší oproti Pythonu.

Tabuľka 2: Backendové frameworky podľa scenára nasadenia [10]

Scenár použitia	Odporúčaný framework
MVP/Startup	Node.js, Django, FastAPI
Podnikové mikroslužby	Spring Boot, Go, NestJS
Aplikácie s AI	Django, FastAPI, Node.js
Vysoká záťaž/real-time	Gin, Fiber, Node.js

2.3 Kontajnerizácia a edge architektúra

Cloudové spracovanie dát, kde sa všetky informácie odosielajú na vzdialené servery, čelí obmedzeniam v podobe latencie, zaťaženia siete a bezpečnostných rizík pri prenose

citlivých dát [11]. Ako alternatíva sa presadzuje model *edge computing*, kde sa dáta spracúvajú priamo pri zdroji a teda na lokálnom zariadení alebo v blízkosti monitorovaného alebo ovládaného výrobného zariadenia. Edge zariadenia dokážu filtrovať a vyhodnocovať dáta lokálne, do cloudu sa odosielať len relevantné výsledky, čo znižuje spotrebu prenosového pásma a zvyšuje odolnosť systému pri výpadku pripojenia.

Edge computing a cloud sa navzájom nevylučujú, ale môžu spolupracovať v hybridnom modeli, kde edge zabezpečuje takmer real-time spracovanie a cloud poskytuje dlhodobé ukladanie dát, pokročilú analytiku alebo koordináciu v prípade viacerých edge uzlov.

2.3.1 Docker a Docker Compose

Docker je otvorená platforma pre vývoj, distribúciu a spúšťanie aplikácií [12]. Umožňuje baliť aplikáciu spolu so všetkými jej závislosťami do prenositeľného kontajnera, ktorý beží rovnako v každom prostredí – na vývojárskom počítači, v testovacom prostredí aj na priemyselnom PC v prevádzke. Kontajnery využívajú izoláciu na úrovni jadra Linuxu, sú výrazne viac odľahčené ako virtuálne stroje a umožňujú spúšťať viacero izolovaných aplikácií na jednom hostovskom systéme súčasne.

Zmena v kóde si vyžaduje prenos len zmenenej vrstvy obrazu, nie celého systému, čo môže byť kľúčové pri aktualizáciách cez obmedzené priemyselné pripojenia. Docker Compose rozširuje tento koncept na celý aplikačný stack: backend, MQTT broker, vektorová databáza a ďalšie služby môžu byť definované v jednom konfiguračnom súbore a môžu sa spúšťať jedným príkazom.

2.4 Priemyselné komunikačné protokoly

2.4.1 OPC UA

OPC UA je platformovo nezávislá architektúra orientovaná na služby, vydaná v roku 2008, ktorá integruje funkcionality predchádzajúcich OPC Classic špecifikácií do jedného rozšíriteľného frameworku. Štandard beží na rôznych hardvérových platformách, od priemyselných PC a PLC až po mikrokontroléry a cloudovú infraštruktúru. Podporuje operačné systémy Windows, Linux, Android a ďalšie [13].

Model OPC UA je objektovo orientovaný: dáta sú reprezentované hierarchicky ako uzly, objekty a premenné s plnou sémantickou popisnosťou. Prístup k dátam zahŕňa čítanie a zápis, odoberanie zmien, notifikácie na udalosti a volanie metód. Komunikácia je možná v modeli klient-server aj Pub/Sub.

Bezpečnosť je súčasťou návrhu: OPC UA podporuje šifrovanie správ, podpisovanie, X.509 certifikáty pre autentifikáciu, sekvenčné pakety proti replay útokom a auditný log aktivít.

- **Výhody:** Vstavaná kybernetická bezpečnosť, sémantický popis dát, podpora klient-server aj Pub/Sub komunikácie, spätná kompatibilita a platformová nezávislosť.
- **Nevýhody:** Vysoká komplexnosť a vyššie nároky na RAM/CPU limitujú nasadenie.

2.4.2 S7 Protokol

S7 komunikácia je proprietárny protokol spoločnosti Siemens určený na výmenu dát medzi PLC rady SIMATIC [14]. Ide o natívny komunikačný mechanizmus ekosystému TIA Portal, ktorý pracuje nad sieťami PROFINET alebo PROFIBUS DP. Na rozdiel od otvorených štandardov nie je S7 protokol verejne špecifikovaný a zariadenia tretích strán ho implementujú reverzným inžinierstvom.

Komunikácia prebieha na princípe klient-server s jednosmerne konfigurovanými alebo obojstranne konfigurovanými spojeniami.

- **Výhody:** Jednoduchá konfigurácia v prostredí TIA Portal, natívna podpora v celom ekosystéme, nízka latencia v homogénnych Siemens sieťach.
- **Nevýhody:** Uzavretý, neštandardizovaný protokol bez verejnej špecifikácie, obmedzená interoperabilita so zariadeniami iných výrobcov.

2.4.3 MQTT

MQTT je nenáročný a otvorený protokol typu klient-server s modelom publish/subscribe, navrhnutý pre jednoduché použitie v obmedzených prostrediach ako IoT a komunikácia medzi strojmi. Protokol beží nad TCP/IP a poskytuje obojsmerný tok správ s minimálnou réziou [15].

Správy sa neposielajú priamo medzi zariadeniami. Klienti publikujú správy na témy (topics) na brokerovi, ostatní klienti sa môžu na tieto témy prihlásiť (subscribe) a dostávať správy bez potreby poznať ich pôvod.

Protokol definuje tri úrovne QoS pre doručenie správ:

- **QoS 0** – správa je doručená najviac raz, bez potvrdenia
- **QoS 1** – správa je doručená aspoň raz, môžu nastať duplikáty
- **QoS 2** – správa je doručená práve raz, s plným handshake protokolom

Ďalšou vlastnosťou je mechanizmus „Last Will and Testament“, správa, ktorú broker automaticky odošle ostatným klientom v prípade neštandardného odpojenia klienta. Verzia MQTT 5.0 pridáva rozšírené vlastnosti ako expirácia správ, aliasy tém a zlepšené hlásenie chýb.

- **Výhody:** Minimálna réžia, tri úrovne QoS, podpora „Last Will and Testament“, vhodnosť pre zariadenia s obmedzeným výkonom a sieťou.
- **Nevýhody:** Nutnosť udržiavať bežiaci broker čo môže byť centrálny bod zlyhania.

2.4.4 Modbus TCP

Modbus je komunikačný protokol vyvinutý spoločnosťou Modicon (dnes Schneider Electric) v roku 1979 pre potreby priemyselných programovateľných automatov. Dnes je de facto štandardom v priemyselnej automatizácii s odhadovaných 7 miliónmi nasadených uzlov [16]. Modbus TCP/IP prenáša správy protokolu Modbus zabalené do TCP/IP rámcov, čím umožňuje nasadenie v štandardných ethernetových sieťach bez potreby špeciálneho hardvéru.

Protokol pracuje na princípe klient-server. Klient iniciuje požiadavky a server odpovedá.

- **Výhody:** Jednoduchý a otvorený štandard bez licenčných poplatkov, rozšírená podpora zariadení, minimálne nároky na zdroje, jednoduché ladenie.
- **Nevýhody:** Chýba zabudovaná autentifikácia a šifrovanie, obmedzený dátový model, žiadny mechanizmus notifikácie, teda klient sa musí aktívne dopytovať na server.

3 Prehľad technológií pre AI asistentov

3.1 Veľké jazykové modely a možnosti použitia


Veľké jazykové modely (LLM) sú kategóriou modelov hlbokého učenia trénovaných na obrovských množstvách textových dát, vďaka čomu sú schopné porozumieť prirodzenému jazyku a generovať text pre široké spektrum úloh [17]. Ich základom je architektúra transformer s mechanizmom seba-pozornosti, ktorý modelu umožňuje zachytiť vzťahy a závislosti medzi slovami na rôznych miestach v texte.

Trénovanie prebieha na miliardách slov z kníh, článkov a webových stránok. Text je rozdelený na tokeny, každý token je zakódovaný ako vektor čísel tzv. embedding a sieť sa iteratívne učí predpovedať nasledujúci token v sekvencii. Výsledkom je model, ktorý si osvojil gramatické pravidlá, faktické znalosti aj spôsoby uvažovania.

Z hľadiska použitia existujú dve základné možnosti [18]. Prvou sú **cloudové modely prístupné cez API** (napr. GPT-4o, Claude, Gemini). Ide o platené služby, kde poskytovateľ spravuje celú infraštruktúru a model je dostupný okamžite bez nutnosti vlastného hardvéru. Druhou možnosťou sú **open-source modely nasadené lokálne** (napr. Llama 3, Mistral), kde môže každý prevádzkovať model na vlastných serveroch alebo zariadeniach. Lokálne nasadenie je vhodné najmä v prostrediach s obmedzeným internetovým pripojením, prísnyimi požiadavkami na ochranu dát alebo potrebou prevádzky bez závislosti od externých služieb.

3.2 Retrieval-Augmented Generation

LLM modely sú obmedzené na znalosti zachytené počas trénovania a nemajú prístup k aktuálnym ani doménovým informáciám. Retrieval-Augmented Generation (RAG) tento nedostatok rieši prepojením modelu s externou znalostnou bázou bez nutnosti opätovného trénovania [19].



Obr. 1: Základný princíp RAG pipeline

Princíp fungovania je taký, že pri každej otázke používateľa retrieval model vyhledá v znalostnej báze relevantné úseky dokumentov, tie sa vložia do kontextu LLM spolu

s pôvodnou otázkou a model na ich základe vygeneruje odpoveď. Znalostná báza je typicky uložená vo vektorovej databáze, kde sú dokumenty reprezentované ako číselné vektory (embeddingy) umožňujúce rýchle vyhľadávanie. Jednou z populárnych open-source vektorových databáz je ChromaDB. Je to ľahká databáza licencovaná pod Apache 2.0, ktorú možno prevádzkovať lokálne alebo aj v cloudovom prostredí a je priamo integrovaná s frameworkmi LangChain a LlamaIndex [20].

Hlavné prínosy RAG oproti čistému LLM sú zníženie halucinácií dohľadáním odpovedí v konkrétnych zdrojoch, prístup k aktuálnym a doménovým dátam a teda možnosť odkazovať na zdroj informácie priamo v odpovedi.

3.3 AI asistenti v priemyselnom prostredí

Priemyselné podniky čelia rastúcemu nedostatku kvalifikovaných pracovníkov a potrebe rýchleho zaškolenia nových zamestnancov. Generatívni AI asistenti môžu predstavovať súčasť riešenia tohto problému. Fungujú ako virtuálni mentori priamo na mieste, kde pracovníkom poskytujú okamžité odpovede v prirodzenom jazyku na otázky o postupoch, riešení porúch alebo špecifikáciách zariadení [21].

Systém vie prepájať viaceré zdroje dát ako podnikové systémy, tréningové databázy, prevádzkové dáta a skladať z nich kontextovo relevantnú odpoveď. Technická dokumentácia je tak prekladaná do zrozumiteľných pokynov prispôbených skúsenostiam konkrétneho pracovníka. Výsledkom je potenciálne skrátenie času zaškoľovania, zníženie závislosti od rád seniornejších zamestnancov a vyššia schopnosť prispôbiť sa pri zavádzaní nových technológií.

4 Typy identifikátorov a ich použitie

4.1 QR identifikátory


QR identifikátory sú dvojrozmerné maticové identifikátory optimalizované pre rýchle čítanie a vysokú hustotu dát. V zmysle použitia v priemysle sa využívajú najmä na identifikáciu objektov, kde sa vyžaduje uloženie komplexnejších informácií napr. URL adresy, sériové čísla alebo konfiguračné parametre. Ich výhodou je silná korekcia chýb, ktorá umožňuje prečítať identifikátor aj pri čiastočnom poškodení alebo znečistení povrchu.



Obr. 2: QR identifikátor so zakódovanou URL adresou fei.stuba.sk

4.2 Fiduciálne markery – AprilTag, ArUco

Fiduciálne markery sú špeciálne navrhnuté pre potreby počítačového videnia a robotiky. Na rozdiel od QR identifikátorov nie je ich primárnym cieľom prenos veľkého objemu dát, ale presná lokalizácia v 3D priestore.



Obr. 3: Vizuálne porovnanie AprilTag a ArUco


Tieto identifikátory sa vyznačujú predovšetkým vysokou mierou interoperability s modernými robotickými riešeniami. Vďaka existujúcim knižniciam napr. OpenCV, ROS je ich integrácia štandardom pri vývoji:

- **Autonómnych robotov:** Kde markery umiestnené v prostredí slúžia ako pevné referenčné body pre rekalibráciu lokalizácie a elimináciu kumulatívnej chyby v mapách.
- **Dronov v skladoch:** Kde umožňujú presné pristávanie na nabíjaciach staniciach alebo navigáciu v priestoroch bez signálu GPS, pričom dron dokáže v reálnom čase určiť svoju polohu a náklon voči markeru.
- **Kolaboratívnych robotov:** Pri navádzaní na presnú pozíciu.

Identifikátory ako AprilTag a ArUco sú robustné voči zmenám osvetlenia a perspektívnemu skresleniu.

4.3 3D identifikátory

V prostrediach priemyselných podnikov a logistických reťazcov, kde môže prísť k jednoduchému znemožneniu snímania 2D identifikátorov (znečistené alebo poškodené povrchy, nedostatočné osvetlenie, odrazy svetla), sa ako perspektívne riešenie javia unikátne 3D identifikátory. Na Fakulte elektrotechniky a informatiky STU bol vyvinutý systém programaticky generovaných 3D identifikátorov, ktoré sú optimalizované pre systémy zmiešanej a rozšírenej reality.



Obr. 4: Fyzický 3D identifikátor vyrobený pomocou 3D tlače

4.3.1 Princíp a štruktúra

Navrhnutý 3D identifikátor má tvar kocky, ktorá je vnútorne vyskladaná z menších, unikátnych geometrických elementov. Tieto elementy sú usporiadané v originálnej štruktúre, ktorá v sebe nesie zakódované informácie[22].

Hlavné technické výhody tohto riešenia sú:

- **Všesmerová detekcia:** Na rozdiel od 2D identifikátorov je možné tieto 3D objekty v systémoch zmiešanej reality spoľahlivo snímať z akéhokoľvek uhla.
- **Odolnosť voči falšovaniu:** Vďaka komplexnej vnútornej členitosti a 3D geometrii sú tieto identifikátory výrazne náročnejšie na replikáciu než bežné 2D identifikátory.
- **Využitie vlastného tvaru:** Sledovanie sa nespolieha len na vizuálny vzor, ale na obrys a priestorovú charakteristiku 3D modelu, čo zvyšuje stabilitu v AR aplikáciách.

5 Špecifikácia požiadaviek na systém

Práca predstavuje moderný prístup k priemyselnému internetu vecí (IIoT). Mobilná aplikácia slúži ako primárne rozhranie pre obsluhu výrobných linky. Komunikácia výrobných linky a aplikácie prebieha cez edge zariadenie umiestnené priamo v prevádzke.

5.1 Opis systému

Systém umožní obsluhu ovládať PLC výrobných linky prostredníctvom mobilnej aplikácie. Identifikácia výrobných linky prebieha skenovaním ArUco identifikátora umiestneného priamo na linke. Po naskenovaní sa aplikácia pripojí k výrobným linkám a obsluha bude môcť odosielať príkazy a sledovať aktuálny stav.

Systém bude podporovať viacerých súčasne prihlásených používateľov s rôznymi oprávneniami. Každý používateľ bude mať pridelenú rolu, ktorá určí, ku ktorým funkciám má prístup. Keďže k jednej výrobným linkám sa môže pokúsiť pripojiť viacero pracovníkov naraz, systém musí riešiť exkluzivitu pripojenia a definovať pravidlá pre prípad konfliktu, pričom servisný zásah údržbára musí byť chránený pred prerušením.

Systém bude zaznamenávať všetky odoslané príkazy vrátane informácie o tom, ktorý používateľ príkaz vydal, a na ktorú výrobnú linku. Administrátor a manažér budú môcť spravovať používateľské účty a schvaľovať nové registrácie.

Súčasťou systému bude AI asistent, ktorý bude odpovedať na technické otázky obsluhy na základe dokumentácie nahratej v znalostnej báze. Obsah znalostnej bázy bude možné viazať na konkrétnu výrobnú linku.

Systém bude nasadený výhradne v lokálnej sieti továrne. Backendové služby budú kontajnerizované a nasadené na edge zariadení umiestnenom v sieti továrne.

5.2 Popis používateľských rolí

Systém implementuje riadenie prístupu založené na rolách (RBAC). Každý nový používateľ sa musí zaregistrovať a pred prvým prihlásením čaká na schválenie administrátorom alebo manažérom, ktorý mu zároveň priradí príslušnú rolu. Sú definované štyri roly:

Operátor: Základná obsluha výrobných linky. Prihlasuje sa na konkrétne linky skenovaním ArUco identifikátora, odosiela riadiace príkazy a sleduje aktuálny stav linky. Nemá prístup k reportom, správe znalostnej bázy ani správe používateľov. Môže v prípade potreby využiť AI asistenta.

Manažér: Zameriava sa na sledovanie udalostí. Má prístup k histórii prihlásení jednotlivých operátorov, reportu s logmi a môže spravovať používateľské kontá. Takisto

má prístup k AI asistentovi a môže upravovať znalostnú bázu. Výrobné linky priamo neovláda, no vidí kto je prihlásený a aké operácie vykonáva.

Údržbár: Má exkluzívnu ochranu relácie a žiadny iný používateľ ho nemôže odhlásiť z prihlásenej linky, čo zaručuje bezpečnosť počas servisného zásahu. Spravuje znalostnú bázu pre jednotlivé výrobné linky, môže upravovať existujúce výrobné linky a vytvárať nové.

Administrátor: Spravuje celý systém, schvaľuje nové registrácie, priraduje roly, edituje a odstraňuje používateľské kontá. Má prístup prakticky ku všetkým funkciám systému.

5.3 Use-case scenáre

ID	UC-01: Registrácia a prihlásenie
Aktér	Všetky roly
Popis	Používateľ sa zaregistruje zadaním údajov. Kým administrátor neschváli konto, aplikácia zobrazí informáciu o čakaní na schválenie. Po schválení sa používateľ prihlási a získa prístup.
ID	UC-02: Skenovanie ArUco identifikátora a prihlásenie sa na výrobnú linku
Aktér	Operátor, údržbár, administrátor
Popis	Používateľ naskenuje ArUco identifikátor pri výrobnej linke. Ak je linka voľná, po potvrdení dialógu sa vytvorí relácia. Ak je obsadená, zobrazí sa identita a rola prihláseného.
ID	UC-03: Ovládanie výrobnej linky
Aktér	Operátor, údržbár, administrátor
Popis	Aktéri odosielaajú príkazy z ovládacieho panelu. Vykonanie príkazu je potvrdené a je zobrazený čas od odoslania po prijatie príkazu výrobnou linkou.
ID	UC-04: Monitorovanie stavu výrobnej linky
Aktér	Operátor, údržbár, administrátor
Popis	Dashboard zobrazuje procesné dáta z PLC v reálnom čase cez WebSocket. Stavý sú farebne kódované podľa normy IEC 60073.

ID	UC-05: Prezeranie logov
Aktér	Manažér, údržbár, administrátor
Popis	Je možné prezeranie logov a reportov s filtrovaním podľa časového obdobia a linky.
ID	UC-06: Správa znalostnej bázy
Aktér	Manažér, údržbár, administrátor
Popis	Prostredníctvom CRUD operácií sa nahrávajú, upravujú a odstraňujú dokumenty znalostnej bázy.
ID	UC-07: AI asistent
Aktér	Všetky roly
Popis	Tlačidlom v rohu každej obrazovky sa spustí AI asistent. Odpovedá výhradne na základe znalostnej bázy, či už všeobecnej alebo viazanej ku konkrétnej výrobnéj linke. Ak informácia chýba, prizná to. Rozhranie aj odpovede sú lokalizované v SK a EN.
ID	UC-08: Správa používateľov
Aktér	Manažér, administrátor
Popis	Manažér a administrátor schvaľujú registrácie, priradujú roly, upravujú a odstraňujú kontá. Hlavného administrátora nie je možné odstrániť ani upraviť inou cestou.
ID	UC-09: Nastavenia aplikácie
Aktér	Všetky roly
Popis	V nastaveniach je možné zmeniť jazyk (SK / EN) a vlastné heslo. Zmena jazyka je dostupná aj na prihlasovacej obrazovke.

5.4 Funkcionálne požiadavky

FP1: Aplikácia musí umožniť načítanie unikátneho identifikátora na automatické spárovanie mobilného zariadenia s konkrétnou výrobnou linkou.

FP2: Používateľ musí mať možnosť odosielať príkazy v riadenom systéme.

FP3: Systém musí implementovať verifikáciu kritických príkazov. Po odoslaní požiadavky musí aplikácia čakať na potvrdenie z PLC a vizuálne indikovať úspešné vykonanie zmeny.

FP4: Zobrazovanie aktuálnych stavov z PLC.

FP5: Implementácia AI asistenta využívajúceho metódu *Retrieval-Augmented Generation*.

FP6: Plná lokalizácia používateľského rozhrania a odpovedí AI asistenta v dvoch jazykoch: slovenský (SK) a anglický (EN).

FP7: Aplikácia musí implementovať mechanizmus exkluzívnej relácie pre ovládanie konkrétnej linky. Po úspešnom prihlásení sa vytvorí aktívna relácia viazaná na používateľa. Relácia ostáva aktívna až do jej explicitného ukončenia odhlásením používateľa alebo prevzatím iným používateľom za podmienok definovaných v FP8.

FP8: Pri pokuse o spárovanie linky, ktorá je už obsadená aktívnou reláciou, musí aplikácia používateľovi zobraziť informáciu o existujúcej relácii (používateľa/rola). Nútené ukončenie resp. prevzatie relácie musí byť umožnené v prípade neodhlásenia sa už neprítomnej obsluhy.

FP9: Systém musí podporovať prihlásenie používateľov pomocou autentifikácie založenej na JWT. Aplikácia musí implementovať RBAC s rolami: operátor, manažér, údržbár, administrátor.

FP10: Systém musí ukladať základný log operácií obsahujúci minimálne: čas vykonania, identifikátor používateľa, identifikátor linky, typ akcie/príkazu a výsledok vykonania. Log musí byť dostupný pre roly *manažér*, *údržbár* a *admin*.

5.5 Nefunkcionálne požiadavky

Definujú kvalitatívne atribúty, technologické obmedzenia a nároky na bezpečnosť.

NFP1: Celá backendová infraštruktúra musí byť kontajnerizovaná pomocou nástroja Docker a spustiteľná na edge zariadení.

NFP2: Prenos správ v edge infraštruktúre musí prebiehať cez MQTT s QoS 1.

NFP3: Latencia príkazov, meraná od odoslania z mobilnej aplikácie po zápis hodnoty do PLC, nesmie presiahnuť 250 ms.

NFP4: Odpovede AI asistenta musia byť striktné viazané na poskytnutý kontext. Ak informácia v materiáloch chýba, model musí túto skutočnosť priznať a môže vyhľadať informáciu na internete, no musí to uviesť.

NFP5: Lokálna databáza musí byť konfigurovaná na zachovanie integrity dát aj v prípade náhleho prerušenia napájania edge zariadenia.

NFP6: Využitie Docker Compose musí umožňovať rýchle nasadenie identického stacku na iné edge zariadenia napr. v iných závodoch.

NFP7: Ovládacie príkazy môžu prichádzať výhradne z lokálnej siete továrne.

NFP8: Backendové služby musia poskytovať štruktúrované logy pre účely diagnostiky.

5.6 Doménové požiadavky

Požiadavky plynúce z priemyselného prostredia a použitých technológií.

DP1: Komunikácia s hardvérom PLC musí prebiehať cez natívny protokol S7.

DP2: Grafické rozhranie musí dodržiavať priemyselné štandardy pre farebnú indikáciu stavov podľa normy IEC 60073.

DP3: Systém si musí zachovať kľúčovú funkcionality, teda ovládanie výroby linky aj v prípade výpadku pripojenia k internetu.

6 Voľba technológií

Výber použitých technológií bol výsledkom posúdenia viacerých faktorov. Medzi kľúčové kritériá patrili kompatibilita s poskytnutým hardvérom, jednoduchá integrácia, nízka latencia a schopnosť fungovať v priemyselnom prostredí s obmedzenými zdrojmi. V neposlednom rade bola dôležitá aj dostupnosť knižníc a predchádzajúca skúsenosť s jednotlivými technológiami, čo zásadne urýchlilo vývoj.

6.1 Komunikácia s PLC – S7 protokol

Riadiaci systém výrobnéj linky je PLC od firmy Siemens, konkrétne model S7-1200, pre ktorý je natívnym komunikačným protokolom S7. Práve to bolo primárnym dôvodom jeho výberu. S7 protokol umožňuje priame čítanie a zápis dátových blokov bez nutnosti zložitej konfigurácie alebo dodatočných licencií.

Alternatívou by bolo aktivovanie servera OPC UA priamo v S7-1200, čo je síce technicky možné, avšak prináša niekoľko nevýhod. Tými sú vyšší nápor na výpočtové zdroje PLC s obmedzenou pamäťou, potrebu licencie a výrazne komplexnejší konfiguračný proces. S7 protokol cez knižnicu `node-red-contrib-s7` poskytuje priamy a jednoduchý prístup k dátam PLC bez týchto obmedzení.

- **Výhody:** Natívna podpora pre Siemens S7-1200, priamy prístup k dátovým blokom, nízke vyťažovanie prostriedkov, jednoduchá konfigurácia v Node-RED.
- **Nevýhody:** Viazanosť na platformu Siemens, absencia štandardizovaného informačného modelu v porovnaní s OPC UA.

6.2 Komunikačná middleware vrstva – Node-RED

Spojenie medzi PLC a zvyškom systému zabezpečuje Node-RED, nástroj na programovanie s využitím minima kódu. Beží v Docker kontajneri priamo na edge zariadení v prevádzke. Node-RED periodicky číta hodnoty z PLC prostredníctvom S7 protokolu a publikuje ich do MQTT brokera, čím spája svet OT (PLC, S7) a IT (MQTT, backend).

Node-RED bol zvolený z niekoľkých dôvodov. Disponuje uzlom `node-red-contrib-s7` pre priamu komunikáciu so Siemens PLC a rovnako podporou MQTT. Toto riešenie je bez potreby písať rozsiahly kód, čo výrazne skracuje čas konfigurácie. Node-RED tiež dobre zvláda periodické dotazovanie (polling) PLC a podmienené spúšťanie akcií.

- **Výhody:** Minimum kódu, natívna S7 a MQTT podpora, jednoduchý deployment v Dockeri, aktívna komunita s rozsiahlou knižnicou uzlov.

- **Nevýhody:** Nie je vhodný pre komplexnú biznis logiku, vizuálne toky môžu byť pri väčšom projekte ťažšie udržiavateľné.

6.3 Transportný protokol – MQTT

Na transport dát medzi edge vrstvou a backendom bol zvolený protokol MQTT. Kľúčovým argumentom je jeho nenáročnosť. Protokol bol navrhnutý pre zariadenia s obmedzenými zdrojmi a nestabilné siete.

OPC UA je komplexný štandard s bohatým informačným modelom, vstavanou bezpečnosťou a sémantickým popisom dát. Pre scenár, kde Node-RED číta hodnoty zo Siemens PLC a odovzdáva ich ďalej na spracovanie, táto komplexnosť nepredstavuje pridanú hodnotu, ale zbytočnú záťaž. MQTT broker nasadený v Dockeri zvládne rovnakú úlohu s minimálnou náročnosťou na zdroje.

- **Výhody:** Nízke nároky na zdroje, jednoduchá architektúra pub/sub, výborná podpora v Node-RED aj Pythone, QoS úrovne pre spoľahlivosť doručenia.
- **Nevýhody:** Závislosť na bežiacom MQTT brokeri ako centrálnom bode zlyhania, absencia štandardizovaného sémantického popisu dát.

OPC UA by bol lepšou voľbou pri požiadavke na štandardizovaný sémantický popis dát, pri integrácii viacerých zariadení od rôznych výrobcov alebo pri prísnych bezpečnostných požiadavkách.

6.4 Backend – FastAPI

Backend aplikácie bol implementovaný v Pythone s využitím frameworku FastAPI. Tvorí API pre celú mobilnú aplikáciu. Oddelené API obsluhuje AI asistenta vrátane RAG pipeline. Voľba Pythonu bola prirodzená, pretože ChromaDB poskytuje natívnu Python knižnicu, Ollama beží ako lokálny server s jednoduchým HTTP API a Anthropic ponúka oficiálny Python SDK pre Claude API. Všetky tri integrácie sú teda priamočiare a nevyžadujú dodatočnú vrstvu. FastAPI bolo zvolené aj z ďalších praktických dôvodov. Asynchrónna architektúra (ASGI) umožňuje súbežne obsluhovať požiadavky mobilnej aplikácie aj dlhotrvajúce volania jazykového modelu bez vzájomného blokovania. Automaticky generovaná OpenAPI dokumentácia uľahčuje ladenie API počas vývoja. Validácia vstupov cez Pydantic redukuje množstvo pomocného kódu. Rolu zohrali aj predchádzajúce skúsenosti s týmto frameworkom v bakalárskej práci, čo výrazne urýchlilo vývoj a umožnilo sústrediť sa na implementáciu biznis logiky a integráciu AI asistenta.

- **Výhody:** Asynchrónne spracovanie požiadaviek, automatická OpenAPI dokumentácia, Pydantic validácia, AI knižnice, rýchly vývoj.
- **Nevýhody:** Interpretovaný Python je pomalší oproti kompilovaným jazykom pri CPU-intenzívnych operáciách.

6.5 Frontend – Flutter

Pre mobilnú aplikáciu bol zvolený framework Flutter od spoločnosti Google. Primárnou cieľovou platformou je Android, avšak Flutter umožňuje z jednej kódovej základne generovať aj webovú aplikáciu, desktopovú aplikáciu a iOS aplikáciu, čo otvára možnosť implementácie administrátorského panelu, či vývoja pre iné platformy bez nutnosti udržiavať samostatný projekt.

Oproti natívnemu vývoju v Kotlin, Flutter ponúka výrazne rýchlejší vývojový cyklus vďaka funkciám hot reload a hot restart. Vlastný vykresľovací engine Impeller zaručuje vizuálnu konzistenciu rozhrania naprieč zariadeniami a operačnými systémami. Bohatá štandardná knižnica widgetov pokrýva väčšinu potrieb priemyselného ovládacieho rozhrania.

- **Výhody:** Jedna kódová základňa pre Android, iOS aj web, rýchly vývojový cyklus, konzistentné UI, silná podpora od Google.
- **Nevýhody:** Väčšia veľkosť výslednej aplikácie oproti natívnym riešeniam, pri požiadavke na plnohodnotnú iOS aplikáciu by bolo potrebné doplniť testovanie na Apple zariadeniach.

6.6 Výber identifikátora – ArUco

Pre jednoznačnú identifikáciu výrobnéj linky bolo v rámci práce spočiatku venované značné množstvo času experimentovaniu s 3D identifikátormi navrhnutými študentom FEI. Tieto identifikátory sa spočiatku javili ako vhodné riešenie, pretože poskytovali vizuálne unikátny vzor, ktorý by teoreticky mohol byť rozpoznaný pomocou počítačového videnia.

Preto bolo otestovaných niekoľko prístupov k ich rozpoznávaniu:

- **Template matching a hashing** – porovnanie snímaného povrchu s uloženými referenčnými vzormi metódami pHash, SSIM a klasický template matching.
- **Extrakcia príznakov ORB s FLANN matcher** – rotačne invariantné príznaky s rýchlym vyhľadávaním v databáze, testované na rôznych vzdialenostiach a uhloch.

- **Analýza mriežky jamiek** – priama detekcia binárneho vzoru v 19×19 mriežke a porovnanie matíc.
- **Porovnávanie histogramov** – identifikácia na základe distribúcie intenzít.
- **Siamese network** – ľahká CNN extrahujúca 128-dimenzionálne príznakové vektory, identifikácia na základe cosine similarity.
- **Transfer learning s MobileNetV3-Small** – klasifikátor exportovaný do TFLite pre nasadenie v mobilnej aplikácii, trénovaný s augmentáciou rotácií a variáciou osvetlenia.

Napriek rozsiahlemu experimentovaniu žiadna z týchto metód neposkytovala dostatočne spoľahlivé výsledky v reálnych podmienkach. Systém si vzory vzájomne zamieňal, pri zmenách osvetlenia alebo pohľadového uhla klesala istota rozpoznávania pod použiteľnú hranicu, a príprava každej novej triedy identifikátora vyžadovala opätovné zbieranie dát a doladenie modelu.

Z týchto dôvodov bolo prijaté rozhodnutie použiť štandardizovaný fiduciálny marker **ArUco**. Identifikátory ArUco sú binárne štvorcové vzory s kódovanou číselnou identitou a orientáciou, ktoré sú navrhnuté priamo pre spoľahlivú detekciu počítačovým videním za rôznych svetelných podmienok. Knižnica ArUco je súčasťou OpenCV a poskytuje robustné algoritmy detekcie s korekciou perspektívy. V priemyselnom prostredí majú ArUco identifikátory silné zastúpenie, využívajú ich napríklad automaticky navádzané vozidlá (AGV), upratovacie autonómne roboty a aj výskumné robotické platformy. Táto rozšírenosť je ďalším argumentom v prospech voľby ArUco oproti 3D identifikátorom, ktoré by vyžadovali vlastný spôsob rozpoznávania. Prípadne by bolo možné použiť framework ako Vuforia, čo by ale značne zvýšilo závislosť implementácie a údržby a presne tomu sme sa chceli vyhnúť.

7 Experimentálne porovnanie a výber jazykových modelov

7.1 Popis testovaných modelov

Na porovnanie bolo vybraných päť lokálne spustiteľných jazykových modelov dostupných prostredníctvom platformy Ollama. Modely boli zámerne zvolené tak, aby pokrývali tri veľkostné kategórie: modely do 10 miliárd parametrov, modely v rozsahu 10 až 15 miliárd parametrov a model s 24 miliardami parametrov. Cieľom tohto rozloženia bolo analyzovať vzťah medzi veľkosťou modelu, kvalitou odpovedí a časom odozvy.

1. llama3.2:3b

Kompaktný model od spoločnosti Meta s 3 miliardami parametrov zo série Llama 3.2, ktorá zahŕňa predtrénované aj inštrukčne doladené generatívne modely vo veľkosti 3B parametrov. Inštrukčne doladené varianty sú optimalizované pre multijazyčné konverzačné úlohy vrátane agentického vyhľadávania a sumarizácie. Podľa oficiálnej dokumentácie model prekonáva modely Gemma 2 2.6B a Phi 3.5-mini v úlohách ako plnenie inštrukcií, sumarizácia, prepisovanie promptov a používanie nástrojov [23]. Do testovania bol zaradený ako zástupca najmenej veľkostnej kategórie s predpokladom najrýchlejšej odozvy.

2. gemma4:e4b

Model od spoločnosti Google zo série Gemma 4 s 4 miliardami parametrov v kvantizovanej verzii (e4b označuje efektívnu 4-bitovú kvantizáciu). Série Gemma 4 predstavuje najnovšiu generáciu otvorených modelov Google, navrhnutú s dôrazom na multimodálne schopnosti a efektívne nasadenie na bežnom spotrebiteľskom hardvéri. Model podporuje dlhé kontextové okno a je optimalizovaný pre inštrukčné úlohy vrátane multijazyčných konverzačných scenárov [24]. Do testovania bol zaradený ako zástupca strednej veľkostnej kategórie s priaznivým pomerom výkonu a pamätovej náročnosti.

3. mistral-nemo:12b

Model s 12 miliardami parametrov vyvinutý spoločnosťami Mistral AI a NVIDIA. Disponuje kontextovým oknom až 128 000 tokenov a podľa oficiálnej dokumentácie dosahuje v svojej veľkostnej kategórii špičkové výsledky v oblasti uvažovania, znalosti sveta a presnosti generovania kódu. Vďaka štandardnej architektúre je plnohodnotnou náhradou modelu Mistral 7B v existujúcich systémoch [25]. Do testovania bol zaradený ako zástupca kategórie 10–15 miliárd parametrov.

4. **phi4:14b**

Model od spoločnosti Microsoft s 14 miliardami parametrov a kontextovým oknom 16 000 tokenov. Je trénovaný na kombinácii syntetických dátových sád, filtrovaných verejne dostupných webových zdrojov a akademických kníh a dátových sád otázok a odpovedí. Prešiel procesom doladenia pomocou supervised fine-tuningu a direct preference optimization s dôrazom na presné plnenie inštrukcií a bezpečnosť. Podľa oficiálnej dokumentácie je určený pre prostredia s obmedzenými výpočtovými zdrojmi, scenáre s požiadavkami na nízku latenciu a úlohy vyžadujúce uvažovanie a logiku [26]. Do testovania bol zaradený ako druhý zástupca kategórie 10–15 miliárd parametrov.

5. **mistral-small:24b**

Model od spoločnosti Mistral AI s 24 miliardami parametrov a kontextovým oknom 32 000 tokenov, ktorý stanovuje nový štandard v kategórii modelov do 70B parametrov. Podľa oficiálnej dokumentácie dosahuje výkon porovnateľný s modelmi trojnásobnej veľkosti a proprietárnym modelom GPT-4o mini naprieč úlohami v oblasti programovania, matematiky, všeobecných znalostí a plnenia inštrukcií [27]. Model vyniká multijazyčnou podporou, natívnym volaním funkcií, JSON výstupom a vysokým rešpektom k systémovým promptom. Vďaka kompaktnej veľkosti je nasaditeľný lokálne na výkonnejšom spotrebiteľskom hardvéri.

7.2 Metodika testovania

Testovanie prebiehalo formou automatizovaného testu implementovaného v jazyku Python s využitím knižníc LangChain, ChromaDB a Ollama. Znalostná báza asistenta vo formáte `.txt` bola rozdelená na sekcie podľa markerov `-- NÁZOV DOKUMENTU: --` a uložená do vektorovej databázy ChromaDB s využitím embedding modelu `nomic-embed-text`. Pre každú testovú otázku boli z vektorovej databázy vytiahnuté tri najrelevantnejšie dokumenty, ktoré boli spolu s otázkou odovzdané modelu ako kontext.

Každý model bol otestovaný na sade 14 testovacích otázok rozdelených do troch kategórií:

- **Faktické otázky** (10 otázok) – odpoveď je priamo obsiahnutá v znalostnej báze. 6 otázok v slovenskom a 4 otázky v anglickom jazyku.
- **Otázky vyžadujúce syntézu** (2 otázky) – správna odpoveď vyžaduje kombináciu informácií z viacerých dokumentov znalostnej bázy.

- **Otázky mimo rozsahu** (2 otázky) – otázky, ktorých odpoveď sa v znalostnej báze nenachádza a model by mal odpovedať odmietnutím a odporúčaním kontaktovať údržbára.

Na rozdiel od automatických metrík ako ROUGE, ktoré vykazujú nízku spoľahlivosť pri jazykoch, kde sa využíva skloňovanie, ako je slovenčina, bolo hodnotenie kvality realizované manuálne. Každá odpoveď bola ohodnotená podľa nasledujúcich kritérií:

- **Relevancia** (škála 1–5) – miera, do akej odpoveď zodpovedá položenej otázke.
- **Úplnosť** (škála 1–5) – pokrytie všetkých dôležitých bodov správnej odpovede.
- **Zrozumiteľnosť** (škála 1–5) – zrozumiteľnosť formulácie odpovede.
- **Jazyková správnosť** (škála 1–3) – či model odpovedal v rovnakom jazyku, v akom bola položená otázka.
- **Odmietnutie otázky mimo rozsahu** (áno/nie) – či model správne odmietol odpovedať na otázku, ktorá nie je pokrytá znalostnou bázou.

Celkové skóre bolo vypočítané ako vážený priemer jednotlivých kritérií: relevancia (30 %), úplnosť (25 %), zrozumiteľnosť (20 %) a jazyková správnosť (25 %).

Okrem kvalitatívnych metrík bol pre každú odpoveď zaznamenaný čas odozvy v milisekundách. Testovanie prebiehalo na notebookovom hardvéri (CPU AMD Ryzen 5 5600H, RAM 32 GB, GPU NVIDIA RTX 3060 6 GB VRAM). Keďže väčšina testovaných modelov presahuje kapacitu VRAM, modely bežali čiastočne alebo úplne na systémovej RAM, čo predstavuje hardvérovú limitáciu meraní. V produkčnom nasadení, na dedikovanom serveri s dostatočnou VRAM, by časy odozvy boli výrazne nižšie.

7.3 Výsledky porovnania

Výsledky hodnotenia všetkých piatich modelov sú zhrnuté v tabuľke 3.

7.4 Analýza výsledkov a výber modelu

Z výsledkov testovania vyplýva, že model **gemma4:e4b** dosiahol najvyššie celkové skóre 4,92/5,0 spomedzi všetkých testovaných modelov. Model vykazoval konzistentne vysokú kvalitu odpovedí naprieč všetkými typmi otázok aj oboma testovanými jazykmi, pričom jeho priemerný čas odozvy 11 165 ms bol v podmienkach notebookového hardvéru prijateľný a takmer trojnásobne nižší v porovnaní s modelom mistral-small:24b.

Prekvapivým zistením je, že modely phi4:14b a mistral-small:24b opakovane odmietali odpovedať na otázky, ktorých odpovede boli v znalostnej báze jednoznačne

Tabuľka 3: Výsledky porovnania jazykových modelov

Model	Priem. čas [ms]	Relev. (1–5)	Úplnosť (1–5)	Zrozum. (1–5)	Jazyk (1–3)	OOS odmiet.	Celk. skóre
llama3.2:3b	4 536	2,29	2,21	2,50	2,14	100 %	2,63
gemma4:e4b	11 165	4,86	4,86	5,00	3,00	100 %	4,92
mistral-nemo:12b	15 217	4,07	4,07	4,29	2,86	100 %	4,29
phi4:14b	20 039	2,00	2,00	2,07	2,79	100 %	2,68
mistral-small:24b	35 801	1,86	1,86	1,86	3,00	100 %	2,65

Tabuľka 4: Priemerná relevancia podľa typu otázky a jazyka

Model	Faktická otázka	Syntéza	Mimo rozsahu	SK	EN
llama3.2:3b	1,70	2,50	5,00	2,12	2,50
gemma4:e4b	5,00	4,00	5,00	4,88	4,83
mistral-nemo:12b	4,20	2,50	5,00	4,62	3,33
phi4:14b	1,40	2,00	5,00	2,00	2,00
mistral-small:24b	1,40	1,00	5,00	2,00	1,67

obsiahnuté. Tento jav naznačuje, že RAG pipeline neposkytol týmto modelom dostatočne relevantný kontext, čo mohlo byť spôsobené odlišnou citlivosťou modelov na formát vstupného kontextu.

Všetky testované modely dosiahli 100 % úspešnosť pri odmietaní otázok mimo rozsahu znalostnej bázy, čo potvrdzuje správne fungovanie systémového promptu z hľadiska bezpečnosti systému.

7.4.1 Overenie na cloudovom hardvéri

V nadväznosti na merania realizované lokálne boli vybrané modely testované aj na platforme RunPod.io, ktorá poskytuje prístup k výkonným GPU serverom formou platby za využitý čas. Cieľom bolo overiť, do akej miery hardvérová limitácia skresľuje závery o reálnej použiteľnosti modelov v produkcii.

Výsledky potvrdili predpoklad, na dedikovanom serverovom hardvéri s dostatočnou VRAM klesol priemerný čas odozvy na menej ako 8 sekúnd u všetkých modelov, čo je pre interaktívne použitie výrazne prijateľnejšia hodnota. Kvalita odpovedí pritom

zostala nezmenená, čo je v súlade s očakávaním. Model generuje kvalitatívne rovnaký výstup nezávisle od hardvéru, rozdiel sa prejaví iba v latencii.

7.4.2 Záverečné rozhodnutie o architektúre AI asistenta

Napriek tomu, že výsledky testovania lokálnych modelov boli z kvalitatívneho hľadiska uspokojivé, cloudové overenie odhalilo zásadné ekonomické obmedzenie tohto prístupu. Modely, ktoré dosahujú dostatočnú kvalitu odpovedí, si pre produkčné nasadenie vyžadujú dedikovaný GPU server s dostatočnou VRAM. Prevádzkové náklady takéhoto riešenia nie sú pre projekt tohto rozsahu rentabilné.

V prípade väčších organizácií s vyšším objemom požiadaviek by mohlo byť zmysluplné investovať do vlastného serverového hardvéru. Stále však bude výhodnosť vlastného servera s GPU závislá od konkrétneho objemu požiadaviek. Pre nízky až stredný objem požiadaviek je ekonomicky výhodnejšie využívať API s modelom per-token, kde náklady sú priamoúmerné skutočnému využitiu a nevyžadujú si vysokú počiatočnú investíciu.


Z týchto dôvodov bolo rozhodnuté opustiť prístup lokálnych LLM a prejsť na volanie externého API. Na výber je niekoľko poskytovateľov ako OpenAI, Google, Anthropic a iní veľkí hráči v oblasti AI. Zvolili sme API od spoločnosti Anthropic, nakoľko v poslednom čase zaznamenali výraznejší pokrok v porovnaní s konkurenciou. Tento prístup umožňuje využitie výkonných jazykových modelov bez nutnosti prevádzkovať vlastný server, pričom náklady sa platia priamoúmerne skutočnému využitiu. RAG pipeline a znalostná báza zostávajú zachované v pôvodnej podobe. Kontextové dokumenty sú naďalej vyhľadávané lokálne z vektorovej databázy a odovzdávané modelu ako súčasť promptu. Mení sa iba vrstva generovania odpovede, ktorá prechádza z lokálne bežiaceho modelu na cloudové API.

8 Návrh architektúry systému

Systém je navrhnutý ako distribuovaná aplikácia skladajúca sa z viacerých vzájomne prepojených vrstiev. Každá vrstva plní špecifickú úlohu a komunikuje so susednými vrstvami prostredníctvom jasne definovaných rozhraní. Jadro systému beží na edge zariadení umiestnenom priamo v prevádzke a zabezpečuje plnú funkčnosť aj bez pripojenia k internetu. Ak by sme využívali lokálne spustiteľný jazykový model, komunikácia s AI asistentom by prebiehala výhradne v rámci lokálnej siete a celý systém by bol izolovaný. Nasledujúce podkapitoly popisujú podrobnejšie celkovú štruktúru systému, spôsob nasadenia jednotlivých komponentov, ich vzájomnú komunikáciu a spôsob ukladania dát.

8.1 Architektúra komponentov systému

Systém sa skladá z piatich hlavných komponentov. Prvým je mobilná aplikácia, ktorá slúži ako primárne rozhranie pre obsluhu. Druhým je backendová vrstva tvorená dvoma službami FastAPI. Hlavná služba zabezpečuje autentifikáciu, správu relácií a riadenie výrobnéj linky. Samostatná služba obsluhuje AI asistenta s RAG pipeline. Tretím komponentom je MQTT broker Mosquitto, ktorý sprostredkúva asynchrónnu komunikáciu medzi backendom a Node-RED. Štvrtým je Node-RED, ktorý premostuje svet priemyselnej komunikácie so svetom IT a periodicky číta dáta z PLC prostredníctvom S7 protokolu. Posledným komponentom je samotné PLC Siemens S7-1200, ktoré riadi prvky výrobnéj linky. Všetky tieto komponenty okrem mobilnej aplikácie a PLC bežia v Docker stacku na edge zariadení. Jediné externé volanie smeruje z AI služby na rozhranie Anthropic API.




Obr. 5: Diagram architektúry systému a komunikácia medzi komponentmi

Mobilná aplikácia komunikuje s hlavnou FastAPI službou cez REST API a prijíma aktualizácie stavu linky cez WebSocket. Príkazy odoslané z aplikácie putujú cez backend do MQTT brokera a ďalej do Node-RED, ktorý ich zapíše do PLC. Spätná väzba prechádza tou istou cestou v opačnom smere. Dáta zo senzorov PLC číta Node-RED periodicky a publikuje ich do príslušných MQTT tém, odkiaľ ich backend preposiela pripojeným klientom cez WebSocket.

8.2 Fyzická topológia systému

Fyzická topológia systému vychádza z požiadavky na lokálnu prevádzku bez závislosti od externej infraštruktúry. Celá komunikácia prebieha v rámci lokálnej siete medzi mobilnými zariadeniami, edge zariadením a riadiacimi systémami výrobných liniek. Schéma fyzickej architektúry je znázornená na obrázku 6.



Obr. 6: Fyzická topológia systému

Mobilné zariadenia sa pripájajú k edge zariadeniu bezdrôtovo cez WiFi. Voľba bezdrôtového pripojenia vychádza z charakteru práce operátora, ktorý sa pohybuje po výrobnjej hale a potrebuje mať prístup k systému kdekoľvek. Edge zariadenie je prepojené s Ethernet switchom, na ktorý sú napojené riadiace systémy výrobných liniek. Edge zariadenie plní úlohu centrálného uzla, na ktorom beží hlavný backend aj AI asistent a všetka logika spracovania príkazov sa vykonáva lokálne (okrem LLM, v práci sme zvolili externé API). Architektúra počíta s pripojením viacerých riadiacich systémov, čo umožňuje rozšírenie na ďalšie výrobné linky bez zmeny základnej topológie. V súčasnej implementácii je na switch napojený jeden riadiaci systém Siemens S7-1200.

8.3 Štruktúra MQTT tém

Komunikácia medzi backend službou, Node-RED a výrobnými linkami prebieha cez štruktúrované MQTT témy. Všetky témy zdieľajú spoločný prefix `plc`, za ktorým nasleduje identifikátor linky vo formáte `line_{id}`, kde `id` zodpovedá ArUco identifikátoru linky. Táto štruktúra umožňuje systému jednoznačne smerovať správy na konkrétne linky a zároveň odberateľom filtrovať témy.

```

plc/
├── device_{id}/
│   ├── data .....stav linky      Node-RED -> backend
│   ├── status ..... online/offline Node-RED -> backend
│   └── commands/
│       └── {prikaz} ..... riadiaci prikaz  backend -> Node-RED

```


Tabuľka 5: Prehľad MQTT tém

Téma	Vydavateľ	Odberateľ	Popis
plc/device_{id}/data	Node-RED	Backend	Aktuálne hodnoty premen- ných linky
plc/device_{id}/status	Node-RED	Backend	Stav pripojenia linky (on- line/offline)
plc/device_{id}/commands/#	Backend	Node-RED	Riadiaci príkaz smerovaný na linku

Backend pri štarte subscribuje na tému `plc/#`, čím prijíma správy zo všetkých výrobných liniek naraz. Node-RED subscribuje selektívne len na témy `commands` pre výrobné linky, ktoré spravuje. Príkazy sú publikované s QoS 1, čím je zaručené doručenie aspoň raz.

8.4 Dátový model

Dáta backendu sú uložené v relačnej databáze PostgreSQL bežiacej v hlavnom Docker kontajneri na edge zariadení spolu s ostatnými službami. Databáza uchováva používateľské účty s priradenými rolami, definície výrobných liniek spolu s ich ArUco identifikátormi a históriu vykonaných príkazov. AI asistent je nasadený ako samostatná služba vo vlastnom Docker stacku, preto má aj vlastnú databázovú inštanciu, v ktorej je uložená znalostná báza pre RAG pipeline. Štruktúra hlavnej databázy a vzťahy medzi entitami sú znázornené na obrázku 7.



Obr. 7: Entitno-relačný diagram databázy systému

9 Integrácia s riadiacim systémom linky

Riadiaci systém testovacej linky tvorí Siemens SIMATIC S7-1200 (CPU 1215C DC/DC/DC). Linka má fotoelektrický snímač na každom konci dopravníka a jednosmerný motor dopravníkového pásu s možnosťou pohybu v oboch smeroch. Cieľom integrácie bolo pripraviť PLC program tak, aby ho bolo možné ovládať z mobilnej aplikácie cez backend, MQTT broker a Node-RED, a aby všetka logika linky zostala v PLC, backend len posiela príkazy a číta stavy.

9.1 Štruktúra projektu v TIA Portal

Projekt bol vytvorený v prostredí *Siemens TIA Portal V19*. Programová časť PLC pozostáva z troch hlavných blokov:

- **Main [OB1]** – hlavný organizačný blok, ktorý v každom cykle volá funkčný blok **FB_Conveyor**.
- **FB_Conveyor [FB1]** – funkčný blok obsahujúci celú riadiacu logiku linky.
- **DB_API [DB5]** – dátový blok slúžiaci ako rozhranie medzi PLC a Node-RED.

9.2 Dátový blok DB_API

Kľúčovým návrhovým rozhodnutím bolo zaviesť samostatný dátový blok **DB_API**, ktorý slúži ako jediné prepojenie medzi PLC a zvyškom systému. Všetky premenné v ňom sú deklarované ako *accessible from HMI*, *writable* a *visible*, čím sa sprístupňujú externým klientom cez S7 protokol. Vďaka tomuto oddeleniu je možné vnútornú logiku **FB_Conveyor** kedykoľvek upraviť bez zásahu do Node-RED tokov alebo API backendu, pokiaľ zostane zachovaná štruktúra **DB_API**.

Pomenovanie premenných sa drží jednotnej konvencie:

- Prefix **St_** (status) označuje stavové premenné, ktoré PLC v každom cykle aktualizuje a Node-RED ich len číta.
- Prefix **Cmd_** (command) označuje príkazové premenné, ktoré zapisuje Node-RED a PLC ich číta.

Tabuľka 6: Premenné dátového bloku DB_API

Premenná	Popis
Cmd_ModeAuto	Prepnutie medzi automatickým a manuálnym režimom
Cmd_StartCycle	Spustenie cyklu v automatickom režime
Cmd_Stop	Núdzové zastavenie linky (latch)
Cmd_MoveForward	Pohyb pásu vpred (manuálny režim)
Cmd_MoveBackward	Pohyb pásu vzad (manuálny režim)
St_State	Aktuálny stav automatu (0/10/20/30/40)
St_ModeAuto	Aktívny režim (auto/manual)
St_StopLatched	Príznak núdzového zastavenia
St_Running	Pás je v pohybe
St_Gate1, St_Gate2	Stavy snímačov
St_MovingForward, St_MovingBackward	Smer aktuálneho pohybu

9.3 Stavový automat riadiacej logiky

V automatickom režime linka pracuje ako stavový automat s piatimi stavmi. Číslovanie stavov skokom o desať umožňuje prípadné neskoršie doplnenie medzistavov bez zmeny existujúcich, čo je bežná konvencia v PLC programovaní.

Tabuľka 7: Stavy automatu FB_Conveyor

ID	Názov	Popis
0	Idle	Pás stojí, čaká sa na detekciu objektu na Gate 1.
10	Forward	Pás sa pohybuje dopredu, kým objekt nedorazí na Gate 2.
20	Dwell	Trojsekundové držanie objektu pri Gate 2 (čas na spracovanie).
30	Backward	Pás sa pohybuje vzad, kým objekt neopustí Gate 1.
40	Eject	Jednosekundový dobeh vzad, ktorý zabezpečí vypadnutie objektu z pásu.

```

CASE #state OF
  0:
    IF NOT #Gate1 THEN
      #state := 10;
    END_IF;
  10:
    #MotorForward := TRUE;
    IF NOT #Gate2 THEN
      #state := 20;
    END_IF;
  20:
    IF #Dwell_Q THEN
      #state := 30;
    END_IF;
  30:
    #MotorBackward := TRUE;
    IF NOT #Gate1 THEN
      #state := 40;
    END_IF;
  40:
    #MotorBackward := TRUE;
    IF #Eject_Q THEN
      #state := 0;
    END_IF;
END_CASE;

```

Výpis kódu 1: Jadro stavového automatu FB_Conveyor

10 Implementácia backendu

Backend systému tvorí dvojica nezávislých FastAPI služieb bežiacich v prostredí Docker, podrobnejšie opísaných v sekcii 8.1. V nasledujúcich podkapitolách popisujeme implementáciu autentifikácie, RBAC, REST endpointov, mechanizmu relácií, životného cyklu príkazu a generátora ArUco identifikátorov s exportom do formátu STL.

10.1 Autentifikácia a RBAC

Systém používa autentifikáciu pomocou JWT tokenov podľa štandardu OAuth2. Po úspešnom prihlásení server vygeneruje token podpísaný zdieľaným tajným kľúčom algoritmom HS256. Token obsahuje identifikátor používateľa a čas vypršania platnosti. Heslá sú uložené výhradne ako bcrypt hash.

Registrácia je verejne dostupná, avšak nový účet je predvolene neaktívny. Prístup do systému získa až po schválení administrátorom, ktorý zároveň priradí rolu. Táto dvojfázová registrácia zabraňuje neoprávnenému vstupu do systému.

Oprávnenia sú riadené štyrmi rolami. Každý chránený endpoint deklaruje požadovanú rolu ako FastAPI závislosť, čo umožňuje jednotnú kontrolu prístupu bez duplicitnej logiky.

```
async def get_line_operator(user: User = Depends(get_current_user)):
    _ensure_role(user, {"operator", "admin", "maintenance"})
    return user

async def get_manager_or_admin(user: User = Depends(get_current_user)):
    _ensure_role(user, {"manager", "admin"})
    return user
```

Výpis kódu 2: Závislosti pre kontrolu rolí

10.2 API endpointy

Backend poskytuje REST API rozdelené do šiestich skupín podľa funkčnej oblasti. Endpointy pre AI asistenta sú dostupné na samostatnej službe počúvajúcej na porte 8100, ostatné na porte 8000. Okrem REST komunikácie poskytuje backend WebSocket pre aktualizácie stavu výrobných linky.

Tabuľka 8: Prehľad API endpointov

Metóda	Endpoint	Popis	Rola
<i>Autentifikácia — /auth</i>			
POST	/auth/login	Prihlásenie, vracia JWT token	—
POST	/auth/register	Registrácia nového účtu	—
POST	/auth/logout	Odhĺásenie	všetci
GET	/auth/me	Aktuálny prihlásený používateľ	všetci
PUT	/auth/me	Úprava mena a priezviska	všetci
POST	/auth/change-password	Zmena hesla	všetci
<i>Výrobné linky — /plc</i>			
GET	/plc/devices	Zoznam liniek	všetci
POST	/plc/devices	Vytvorenie linky	administrátor, údržbár
GET	/plc/devices/{aruco_id}	Detail linky	všetci
PUT	/plc/devices/{aruco_id}	Úprava linky	administrátor, údržbár
DELETE	/plc/devices/{aruco_id}	Vymazanie linky	administrátor, údržbár
POST	/plc/devices/{aruco_id}/command/{cmd}	Odoslanie príkazu	administrátor, údržbár, operátor
GET	/plc/stats	Dashboard štatistiky	všetci
WS	/plc/ws/{aruco_id}	Real-time stav + príkazy	všetci
<i>Relácie — /devices</i>			
GET	/devices/{aruco_id}/occupancy	Kto je prihlásený	všetci
POST	/devices/{aruco_id}/login	Prihlásenie na linku	administrátor, údržbár, operátor
POST	/devices/{aruco_id}/logout	Odhĺásenie z linky	všetci
<i>Logy — /command-logs</i>			
GET	/command-logs	Logy s filtrami	administrátor, manažér, údržbár
GET	/command-logs/device/{aruco_id}	Logy linky	administrátor, manažér, údržbár
<i>Používatelia — /users</i>			
GET	/users	Zoznam používateľov	administrátor, manažér
POST	/users/{user_id}/approve	Schválenie + rola	administrátor, manažér
PUT	/users/{user_id}	Úprava účtu	administrátor, manažér
POST	/users/{user_id}/reset-password	Reset hesla	administrátor, manažér
DELETE	/users/{user_id}	Vymazanie účtu	administrátor, manažér
<i>ArUco — /aruco</i>			
GET	/aruco/next-id	Nasledujúce voľné ID	všetci
GET	/aruco/preview/{aruco_id}	Náhľad identifikátora	všetci
GET	/aruco/png/{aruco_id}	Stiahnutie identifikátora ako PNG	všetci
GET	/aruco/stl/{aruco_id}	Stiahnutie identifikátora ako STL	všetci
<i>AI asistent — port 8100</i>			
POST	/chat	Správa AI asistentovi	všetci
GET	/kb	Zoznam záznamov znalostnej bázy	administrátor, manažér, údržbár
POST	/kb	Pridanie záznamu	administrátor, manažér, údržbár
POST	/kb/upload	Nahratie súboru do KB	administrátor, manažér, údržbár
PUT	/kb/{entry_id}	Úprava záznamu	administrátor, manažér, údržbár
DELETE	/kb/{entry_id}	Vymazanie záznamu	administrátor, manažér, údržbár

10.3 Mechanizmus relácií

Pred ovládaním linky sa musí používateľ na linku prihlásiť. Relácia je väzba medzi používateľom a linkou, ktorá zabraňuje súčasnému ovládaniu jednej linky viacerými používateľmi. Na každej linke môže byť aktívna práve jedna relácia.

Prihlásenie na linku prebieha volaním POST `/devices/{device_id}/login`. Backend overí, či je linka voľná. Ak áno, vytvorí novú reláciu. Ak je linka obsadená,

správanie závisí od parametra `force` a od roly aktuálneho držiteľa relácie. Linka obsadená používateľom s rolou údržbára nemôže byť prebratá žiadnym iným používateľom. Táto ochrana zabraňuje prerušeniu servisného zásahu operátorom. Vlastnú reláciu môže ukončiť prihlásený používateľ odhlásením sa. Cudziu reláciu môže ukončiť každý, ak sa nejedná o reláciu údržbára. Cieľom je zabrániť situáciám, keď sa operátor zabudne odhlásiť a linka zostane zablokovaná. Každé prevzatie relácie je zaznamenané v logu príkazov, čo znamená dohľadateľnosť zodpovednosti. Pred prepísaním relácie systém informuje nového používateľa o tom, kto je aktuálne prihlásený. Následne je potrebné potvrdiť úmysel prevzatia, čím sa zabezpečí, že k prevzatiu nepríde náhodou.

```
if active.user.role == "maintenance":  
    raise HTTPException(409, "maintenance_locked")
```

Výpis kódu 3: Ochrana relácie údržbára

10.4 Životný cyklus príkazu

Príkaz prechádza niekoľkými vrstvami systému, kým sa prejaví na výrobné inke.


Backend publikuje správu na MQTT tému `plc/device_{id}/commands/{cmd}`. Mosquitto broker správu doručí Node-RED, ktorý ju preloží do S7 protokolu a zapíše príslušnú premennú v PLC. Volajúci dostane späť potvrdenie `command_ack` s príznakom úspechu doručenia na broker. Skutočná zmena stavu je viditeľná v ďalšom cykle čítania, keď Node-RED publikuje aktualizované hodnoty na tému `plc/device_{id}/data` a backend ich pošle cez WebSocket do aplikácie.

Každý príkaz je bez ohľadu na výsledok zaznamenávaný do tabuľky `command_logs` s identifikátorom používateľa, linky, zdrojovým kanálom a príznakom úspechu doručenia.

10.5 Generátor ArUco identifikátorov a export do STL

Na výrobu fyzických identifikátorov bola implementovaná vlastná Python trieda `ArucoSTLGeneratorVox`, ktorá generuje STL súbor určený na dvojfarebnú 3D tlač. Model je navrhnutý tak, aby farebné priradenie v sliceri bolo čo najjednoduchšie.

Povrch modelu je rozdelený do troch výškových úrovní. Čierne bunky identifikátora sú na základnej výške `base_height_mm`, ohraničovací rám je o `border_height_offset_mm` vyšší a biele bunky sú vyvýšené o `white_height_mm`. Pri predvolených hodnotách dosahujú čierne bunky výšku 1 mm a biele 3 mm.



Obr. 8: ArUco identifikátor tlačný z vygenerovaného STL modelu

11 Implementácia AI asistenta

Asistent je implementovaný ako samostatná FastAPI služba bežiaca na porte 8100 v rámci vlastného Docker stacku. Disponuje vlastnou PostgreSQL databázou pre záznamy znalostnej bázy a ChromaDB ako úložisko vektorov. Jediné externé sieťové volanie celej aplikácie smeruje na Anthropic API pre volanie jazykového modelu.

11.1 RAG pipeline

Spracovanie každej správy prebieha v niekoľkých krokoch. Najprv sa vykonajú dva vyhľadávacie dotazy do ChromaDB: s filtrom podľa `device_aruco_id` a všeobecný bez filtra, pričom každý vráti najviac tri najbližšie záznamy. Zo získaných kontextov, metadát relácie a histórie konverzácie sa zostaví systémový prompt, ktorý sa odošle na Claude API.

Volanie modelu sa vykonáva s aktivovaným nástrojom `web_search`, ktorý poskytuje samotný Anthropic na strane servera. Ak LLM vyhodnotí, že poskytnutý kontext nestačí na zodpovedanie otázky, sám zavolá tento nástroj. Vykoná sa vyhľadávanie a model pokračuje v generovaní odpovede s doplnenými výsledkami. Limit je nastavený na tri vyhľadávania na jednu správu. Tým, že o použití nástroja rozhoduje LLM, sa vyhľadávanie spustí len v prípadoch, keď je skutočne potrebné.

11.2 Embedovací model

Na generovanie vektorových reprezentácií textov sa používa model `nomic-embed-text`. Model beží v rámci Docker stacku na edge zariadení a nevyžaduje pripojenie na internet.

ChromaDB využíva kosínusovú podobnosť ako metriku vyhľadávania. Každý záznam znalostnej bázy sa indexuje ako reťazec `title + content` pri vytvorení aj aktualizácii.

11.3 Systémový prompt

Asistent vystupuje pod menom PLEXO. Systémový prompt existuje v slovenskej aj anglickej verzii podľa jazyka relácie. Pozostáva z dvoch častí. Prvou je sada pravidiel, ktorá určuje správanie asistenta, jazyk odpovede, formát, zákaz vymýšľania faktov a spôsob práce s kontextom. Druhú časť tvoria dynamicky dopĺňané sekcie, ktoré sa pred každým volaním modelu naplnia aktuálnymi údajmi:

- **AKTUÁLNA RELÁCIA** – meno a rola prihláseného používateľa, prípadne linka, na ktorú je prihlásený.
- **KONTEXT PRE LINKU** – výsledky vyhľadávania z ChromaDB filtrované podľa ID linky.
- **VŠEOBECNÝ KONTEXT** – výsledky vyhľadávania z ChromaDB bez filtra linky.

```
SYSTEM_PROMPT_SK = """Tvoje meno je PLEXO. Si priemyselný asistent aplikácie
    Scan2Control na riadenie výrobných liniek s využitím ArUco identifikátorov.
{intro_instruction}
PRAVIDLÁ:
1. Odpovedaj VÝHRADNE po slovensky.
2. Odpovedaj prednostne na základe informácií z kontextu nižšie. Ak tam odpoveď
    nie je, môžeš použiť nástroj na vyhľadávanie na internete.
3. Buď stručný a praktický. Používaj odrážky a krátke vety.
4. Nepoužívaj emotikony.
5. Ak sa používateľ pýta na svoje meno, rolu alebo linku, odpoveď nájdeš v sekcii
    AKTUÁLNA RELÁCIA.
6. Ak sa používateľ pýta na konkrétnu linku, prednostne použi informácie z
    KONTEXTU PRE LINKU.
7. Nikdy nevymýšľaj fakty, dátumy ani čísla. Ak niečo nevieš, priznaj to.
8. Ak odpovedáš na základe vyhľadávania na internete, jasne to v odpovedi označ.
    """
```

Výpis kódu 4: Základ systémového promptu AI asistenta PLEXO

Okrem pravidiel správania prompt obsahuje aj inštrukciu, aby sa asistent pri prvej správe konverzácie krátko predstavil. V ďalších správach sa toto predstavenie vynecháva.

11.4 Správa konverzácie

Server je bezstavový a história konverzácie sa neukladá na strane servera, ale je súčasťou každej požiadavky zo strany klienta. Služba prijíma pole správ vo formáte `{role, content}` a pri zostavovaní volania zahŕňa posledných desať správ. Tento prístup nevyžaduje žiadne serverové úložisko relácií a zjednodušuje škálovanie.

11.5 Správa znalostnej bázy

Znalostná báza je tvorená textovými záznamami uloženými v PostgreSQL. Každý záznam má názov, obsah a voliteľne priradené ID linky. Toto priradenie umožňuje vyhľadávanie obsahu filtrovaného pre konkrétnu linku, čo zvyšuje presnosť odpovedí pri otázkach viazaných na konkrétnu linku.

Pri každom vytvorení alebo úprave záznamu sa jeho vektorová reprezentácia synchronizuje do ChromaDB operáciou `upsert`. Mazanie záznamu odstráni aj príslušný vektor. Okrem manuálneho zadania textu API podporuje nahranie súboru vo formáte `.txt`, čo umožňuje import existujúcej technickej dokumentácie.

12 Implementácia frontendu

Frontend je implementovaný vo Flutteri s podporou platformy Android ako primárneho cieľa a webového prehliadača pre administrátorský panel. Zdieľa takmer všetok kód medzi platformami s výnimkou ArUco skenovania, pretože v administrátorskom paneli táto funkcionality nie je potrebná.

12.1 Stavový manažment

Aplikácia používa knižnicu Riverpod so vzorcom `StateNotifier`. Centrálnym poskytovateľom je `AuthProvider`, ktorý uchováva JWT token, objekt prihláseného používateľa a príznaky stavu autentifikácie. Pri štarte aplikácie sa volá `tryRestoreSession`, ktorá overí uložený token volaním `/auth/me`. Ak je token platný, relácia sa obnoví.

12.2 ArUco skenovanie

Skenovanie prebieha v natívnom kóde prostredníctvom balíčka `opencv_dart`. Každý snímok z kamery dorazí vo formáte YUV420, z ktorého sa extrahuje kanál Y ako grayscale obraz. Samotná detekcia beží v Dart izolovanom vlákne pomocou `Isolate.run`, čím sa zabráni blokovaniu vykresľovacieho vlákna.

V izolovanom vlákne sa vytvorí detektor s preddefinovaným slovníkom `DICT_5X5_250` a zavolá sa `detectMarkers`. Pre každý detekovaný identifikátor sa vypočíta plocha Shoaletovým vzorcom a stred ako relatívna poloha v obraze. Výstupom je zoznam detekovaných identifikátorov zoradených od najväčšieho po najmenší, kde väčšia plocha znamená bližší identifikátor. Príznak `_isProcessing` zabráňuje spusteniu ďalšej detekcie kým prebieha predchádzajúca.

12.3 WebSocket pripojenie

Po načítaní linky sa nadväzuje WebSocket spojenie cez balíček `web_socket_channel`. Server posiela tri typy správ: heartbeat, ktorý sa ignoruje, potvrdenie príkazu `command_ack` a aktualizáciu hodnôt premenných. Pri chybe alebo zatvorení spojenia sa po dvoch sekundách automaticky pokúsi o znovupripojenie.

Odosielanie príkazu funguje tak, že sa na WebSocket pošle JSON správa `{command, value}` a spustí sa päťsekundový časovač. Server najskôr vráti správu `command_ack`, ktorá potvrdzuje doručenie príkazu MQTT brokerovi. Ak je `success == false`, zobrazí sa chybové hlásenie okamžite. Ak je `success == true`, aplikácia čaká na skutočnú zmenu hodnoty premennej z výrobnéj linky. Keď táto zmena dorazí, zobrazí sa snackbar

s potvrdenou hodnotou a nameranou latenciou. Ak päťsekundový časovač vyprší skôr ako hodnota dorazí, zobrazí sa chybové hlásenie.

12.4 Používateľské rozhranie podľa roly

Viditeľnosť prvkov rozhrania je riadená pomocnými metódami triedy **AuthUser**. Každá metóda vracia booleovskú hodnotu na základe role prihláseného používateľa. Prehľad rolí je uvedený v tabuľke 9.

Tabuľka 9: Oprávnenia podľa roly používateľa


Oprávnenie	Operátor	Manažér	Údržbár	Administrátor
Ovládanie linky	✓	—	✓	✓
Zobrazenie zoznamu liniek	—	✓	✓	✓
Správa liniek	—	—	✓	✓
Správa používateľov	—	✓	—	✓
Správa znalostnej bázy	—	✓	✓	✓
Zobrazenie logov príkazov	—	✓	✓	✓
AI asistent	✓	✓	✓	✓

13 Opis funkcionalít aplikácie pre používateľa

V nasledujúcich podkapitolách je opísaná funkcionálnosť aplikácie pre netechnického používateľa. Postupne sú zobrazené a opísané jednotlivé obrazovky a funkcionality, s ktorými sa používateľ pri práci stretáva.

13.1 Hlavné menu

Po prihlásení sa používateľovi zobrazí hlavné menu so základným prehľadom. Bez ohľadu na pridelenú rolu tu každý používateľ vidí aktuálne firemné štatistiky – počet liniek online a offline, takisto počty používateľov.




Obr. 9: Hlavné menu so základným prehľadom

13.2 Skener ArUco identifikátorov

Dostupné pre: operátor, údržbár, administrátor

Skener ArUco identifikátorov slúži ako primárny spôsob prihlásenia sa na konkrétnu linku. Používateľ namieri kameru mobilného zariadenia na ArUco identifikátor umiestnený priamo na linke a systém ho automaticky identifikuje. Po úspešnom naskenovaní je používateľ prihlásený k danej linke a získava prístup k jej monitorovaniu a ovládaniu. Tento prístup eliminuje manuálne vyhľadávanie liniek a zabezpečuje, že používateľ pracuje s tou správnou linkou.



Obr. 10: Obrazovka skenera ArUco identifikátorov s náhľadom z kamery

13.3 Generátor ArUco identifikátorov

Dostupné pre: údržbár, manažér, administrátor

Pri zakladaní novej linky v systéme aplikácia automaticky vygeneruje unikátny ArUco identifikátor, ktorý jednoznačne identifikuje danú linku. Identifikátor je možné exportovať vo formáte PNG pre bežnú tlač alebo vo formáte STL ako trojrozmerný model vhodný na 3D tlač, pričom biela časť identifikátora je vyvýšená nad čiernou základňou. Fyzický identifikátor sa následne umiestni na linku, čím sa prepojí záznam v systéme s reálnou linkou v prevádzke.




Obr. 11: Obrazovka generátora ArUco identifikátorov s možnosťami exportu

13.4 Monitoring a ovládanie výrobných liniek

Dostupné pre: operátor, údržbár, administrátor

Monitoring a ovládanie výrobných liniek predstavuje hlavnú funkcionality aplikácie. Po prihlásení sa na linku má používateľ k dispozícii prehľad aktuálneho stavu linky. Môže sledovať stavy senzorov, aktuálny režim prevádzky a stav, v ktorom sa linka

nachádza. Okrem sledovania stavu môže používateľ linku aj priamo ovládať, napríklad spustiť alebo zastaviť cyklus, zmeniť smer pohybu či vykonať reset. Všetky zmeny sa prejavia rádo v desiatkach milisekúnd, čo umožňuje rýchlu reakciu na aktuálnu situáciu v prevádzke. Systém zároveň zaznamenáva históriu vykonaných príkazov pre potreby kontroly a auditu.




Obr. 12: Obrazovky monitoringu a ovládania výrobnéj linky

13.5 AI asistent PLE XO

Dostupné pre: operátor, údržbár, manažér, administrátor

AI asistent PLE XO je inteligentný pomocník dostupný priamo v aplikácii. Používatelia môžu klásť otázky prirodzeným jazykom, napríklad o aktuálnom stave linky, postupe pri riešení poruchy alebo pokynoch na údržbu. Asistent odpovedá na základe znalostnej bázy vytvorenej pre konkrétne linky a prevádzku. Vďaka tomu má operátor alebo údržbár potrebné informácie vždy po ruke, bez nutnosti listovať v technickej

dokumentácii. Asistent komunikuje v jazyku, ktorý si používateľ zvolil v nastaveniach aplikácie.




Obr. 13: Konverzačné rozhranie AI asistenta PLEKO

13.6 Správa používateľov

Dostupné pre: manažér, administrátor

Správa používateľov poskytuje oprávneným osobám nástroje na riadenie prístupu do systému. Manažér alebo administrátor môže vytvárať nové používateľské účty, upravovať existujúce, pridelať príslušné roly podľa pracovného zaradenia a v prípade potreby účty odstrániť resp. deaktivovať. Systém rolí zabezpečuje, že každý používateľ vidí a môže vykonávať iba tie akcie, ktoré zodpovedajú jeho pracovnej pozícii, čím sa minimalizuje riziko neoprávneného zásahu do prevádzky.




Obr. 14: Obrazovka správy používateľov

13.7 Správa výrobných liniek

Dostupné pre: údržbár, manažér, administrátor

Správa výrobných liniek umožňuje udržiavať databázu liniek aktuálnu a v súlade so skutočným stavom prevádzky. Oprávnený používateľ môže do systému pridať novú linku, nastaviť jej parametre a vygenerovať pre ňu ArUco identifikátor. Pri existujúcich linkách je možné upravovať, čo sa zobrazuje v ovládacom paneli linky a v akom poradí. Taktiež je možné ich zo systému odstrániť, ak boli vyradené z prevádzky. Vďaka tejto funkcionalite systém vždy odráža reálny stav výrobných liniek v prevádzke.




Obr. 15: Obrazovka správy výrobných liniek

13.8 Správa znalostnej bázy

Dostupné pre: údržbár, manažér, administrátor

Znalostnú bázu tvorí súbor informácií, z ktorých čerpá AI asistent PLEKO pri odpovedaní na otázky používateľov. Oprávnení používateľa môžu do znalostnej bázy priebežne pridávať nové dokumenty, upravovať existujúce záznamy alebo odstraňovať zastarané informácie. Kvalita a aktuálnosť znalostnej bázy priamo ovplyvňuje relevantnosť a presnosť odpovedí asistenta, preto je jej pravidelná údržba dôležitou súčasťou prevádzky systému.




Obr. 16: Obrazovky správy znalostnej bázy

13.9 Logy príkazov

Dostupné pre: manažér, administrátor

Logy príkazov poskytujú prehľad o všetkých akciách, ktoré boli v systéme vykonané. Každý záznam obsahuje informáciu o tom, kto príkaz odoslal, na ktorú linku smeroval, kedy bol vykonaný a aký bol jeho výsledok. Táto evidencia slúži na audit prevádzky, vyšetrovanie incidentov a spätnú kontrolu zásahov v prípade neštandardného správania linky.




Obr. 17: Obrazovka logov vykonaných príkazov

13.10 Nastavenia

Dostupné pre: operátor, údržbár, manažér, administrátor

Každý používateľ má možnosť prispôbiť si aplikáciu podľa vlastných preferencií. V nastaveniach môže zmeniť jazyk rozhrania, ktorý sa automaticky uplatní aj na komunikáciu s AI asistentom PLEKO. Zároveň si môže zmeniť svoje meno, priezvisko a prístupové heslo. Nastavenia jazyka zostávajú zachované aj po opätovnom prihlásení alebo reštarte aplikácie.



Obr. 18: Obrazovka nastavení aplikácie

14 Testovanie a meranie

Cieľom tejto kapitoly je overiť, či výsledná aplikácia spĺňa požiadavky definované v kapitole 5, a vyjadriť jej spoľahlivosť a efektivitu v laboratórnom a priemyselnom prostredí.

Testovanie prebiehalo na nasledujúcej zostave. Ako edge zariadenie poslužil notebook s 32 GB RAM a procesorom AMD Ryzen 5 5600H, na ktorom bežali Mosquitto, Node-RED, hlavný backend aj AI asistent v Docker kontajneroch. Výrobnú linku predstavoval model dopravníka Fischertechnik riadený PLC Siemens S7-1200. Mobilný klient bežal na zariadení Samsung Galaxy A54 s OS Android 14, pripojenom do tej istej WiFi siete ako edge počítač. Identifikátory boli vytlačené technológiou FDM na tlačiarni Bambu Lab P1S s veľkosťou hrany 100 mm. Časť meraní detekcie bola vykonaná aj v skutočných priestoroch priemyselnej haly, čo umožnilo overenie systému v reálnych svetelných podmienkach.

Merania latencie a úspešnosti detekcie boli vykonané v sériách opakovaných pokusov a výsledky sú uvádzané formou priemernej hodnoty, minima, maxima. Kvalita odpovedí asistenta bola vyhodnotená na pevnej množine reprezentatívnych otázok podľa kritérií zavedených v kapitole 7.2.

14.1 Overenie splnenia špecifikácie

Prvá fáza testovania overovala, či implementácia pokrýva požiadavky stanovené v kapitole 5. Splnenie každej požiadavky bolo vyhodnotené jednou z troch možností: *splnené* pre požiadavku, ktorá bola implementovaná v plnej miere, *čiastočne splnené* pre požiadavku s istými obmedzeniami a *nesplnené* pre požiadavku, ktorá nebola implementovaná.

Tabuľka 10: Overenie funkčných požiadaviek

ID	Stručný popis	Stav
FP1	Načítanie unikátneho identifikátora a spárovanie so linkou	splnené
FP2	Odosielanie príkazov v riadenom systéme	splnené
FP3	Verifikácia príkazov a vizuálna indikácia vykonania	splnené
FP4	Zobrazovanie aktuálnych stavov z PLC	splnené
FP5	AI asistent s RAG	splnené
FP6	Lokalizácia rozhrania a AI asistenta v SK a EN	splnené
FP7	Mechanizmus exkluzívnej relácie	splnené
FP8	Informácia o obsadení linky a riadené prevzatie relácie	splnené
FP9	JWT autentifikácia a RBAC so štyrmi rolami	splnené
FP10	Log operácií dostupný pre manažéra, údržbára a administrátora	splnené

Tabuľka 11: Overenie nefunkčných požiadaviek

ID	Stručný popis	Stav
NFP1	Kontajnerizácia backendu pomocou Docker na edge zariadení	splnené
NFP2	Prenos správ v edge infraštruktúre cez MQTT s QoS 1	splnené
NFP3	Latencia príkazov pod 250 ms od odoslania po zápis do PLC	splnené
NFP4	Odpovede asistenta viazané na kontext, priznanie chýbajúcej informácie, uvedenie iného zdroja	splnené
NFP5	Integrita databázy pri náhlom prerušení napájania edge zariadenia	splnené
NFP6	Rýchle nasadenie identického stacku pomocou Docker Compose	splnené
NFP7	Ovládacie príkazy len z lokálnej siete továrne	splnené
NFP8	Štruktúrované logy backendu pre účely diagnostiky	splnené

Tabuľka 12: Overenie doménových požiadaviek

ID	Stručný popis	Stav
DP1	Komunikácia s PLC cez natívny protokol S7	splnené
DP2	Farebná indikácia stavov podľa normy IEC 60073	splnené
DP3	Zachovanie možnosti ovládania linky aj pri výpadku internetu	splnené

Všetky funkčné aj nefunkčné požiadavky boli vyhodnotené ako splnené. Doménová požiadavka DP3 bola overená odpojením edge zariadenia od WAN portu, pričom mobilná aplikácia naďalej úspešne odosiela príkazy aj prijímala stav linky. Jediný komponent,

ktorý je v takomto režime nedostupný, je AI asistent, čo zodpovedá architektonickému rozhodnutiu opísanému v kapitole 7.2.

14.2 Latencia vykonania príkazov

Latencia bola meraná pre kompletný refazec od mobilného zariadenia až po PLC a spätné prečítanie novej hodnoty v mobilnom zariadení. Začiatok merania predstavuje stlačenie tlačidla v mobilnej aplikácii. Mobilné zariadenie zaznamená lokálnu časovú značku, odošle príkaz a ďalej iba čaká. Backend síce hneď po publikovaní príkazu na MQTT broker vráti potvrdenie `command_ack`, mobilné zariadenie ho však pri úspešnom doručení iba prijme bez ďalšej akcie. Koncom merania je až moment, keď cez WebSocket dorazí aktualizovaná hodnota premennej, ktorú príkaz mal zmeniť. Toto meranie tak zahŕňa aj polling cyklus Node-RED a samotné vykonanie príkazu v PLC, čo predstavuje skutočnú latenciu vnímanú obsluhou. Vďaka lokálnej časovej značke nie je potrebná synchronizácia hodín medzi mobilom a serverom.

Z každého typu príkazu bolo vykonaných 25 opakovaní. Testované boli tri príkazy. Výsledky sú uvedené v tabuľke 13.

Tabuľka 13: Štatistika latencie príkazov v milisekundách (n=25)

Príkaz	Priemer	Min	Max
Štart dopravníka	142	96	218
Stop dopravníka	138	91	207
Zmena smeru	156	102	234

Priemerná latencia naprieč všetkými príkazmi dosiahla 145 ms, čo s rezervou spĺňa požiadavku NFP3 na hornú hranicu 250 ms. Maximálne hodnoty sa v žiadnom z 25 opakovaní nepriblížili k stanovenému limitu.

14.3 Detekcia ArUco identifikátorov

Testovanie detekcie sledovalo úspešnosť rozpoznania identifikátora na mobilnom zariadení. Identifikátor s veľkosťou hrany 100 mm bol umiestnený na linke a kamera mobilu bola držaná v rôznych vzdialenostiach a uhloch. Uhol uvádzaný v tabuľkách predstavuje uhol, ktorý kamera zvierala voči rovine identifikátora. Pre každú kombináciu vzdialenosti a uhla bolo vyhodnotených 30 pokusov, z ktorých sa určil pomer úspešne určených identifikátorov.

Tabuľka 14: Úspešnosť detekcie podľa vzdialenosti a uhla (n=30)

Vzdialenosť/Uhol	0°	15°	30°	45°
30 cm	100 %	100 %	100 %	97 %
60 cm	100 %	100 %	97 %	90 %
100 cm	100 %	97 %	93 %	80 %
150 cm	97 %	93 %	83 %	67 %

Z výsledkov vyplýva, že systém spoľahlivo pracuje do vzdialenosti jedného metra pri uhle do 30 stupňov. Pri väčších vzdialenostiach a šikmejších uhloch klesá rozlíšenie buniek identifikátora pod hranicu, ktorú knižnica OpenCV dokáže s istotou vyhodnotiť. Pre praktické nasadenie sa odporúča vzdialenosť do jedného metra a približne kolmé natočenie kamery na rovinu identifikátora.

Vplyv osvetlenia bol overený v troch prostrediach. Prvým bolo priemyselné osvetlenie výrobnéj haly so stropnými LED svietidlami, druhým bežné kancelárske osvetlenie a tretím tlmene osvetlená miestnosť. Merania v hale prebiehali priamo na mieste v priemyselnom podniku, do ktorého sme mali povolený vstup. Vzhľadom na absenciu kalibrovaného luxmetra nie sú uvádzané presné hodnoty svetelných podmienok. Výsledky sú v tabuľke 15.

Tabuľka 15: Úspešnosť detekcie podľa prostredia (vzdialenosť 60 cm, uhol 0°, n=30)

Prostredie	Úspešnosť
Priemyselná hala s LED svietidlami	100 %
Kancelársky priestor	100 %
Tlmene osvetlená miestnosť	93 %

Vďaka dvojfarebnému tlačnému prevedeniu identifikátora je kontrast dostatočný aj v priestoroch so slabším osvetlením.

14.4 Kvalita odpovedí AI asistenta

Asistent bol nasadený s modelom Claude Haiku 4.5 cez Anthropic API a vektorovou databázou ChromaDB, do ktorej bola vložená znalostná báza pripravená v rámci tejto práce. Pre vyhodnotenie bola použitá rovnaká metodika ako v kapitole 7.2, no aplikovaná na produkčné nasadenie využitím Anthropic API namiesto lokálnych modelov. Sada obsahovala 14 testovacích otázok identických s tými, ktoré boli použité pri porovnávaní lokálnych modelov: 10 faktických otázok priamo pokrytých v znalostnej báze (6 v slovenčine a 4 v angličtine), 2 otázky vyžadujúce syntézu informácií z viacerých záznamov a 2

otázky mimo rozsahu znalostnej bázy. Úplný zoznam otázok aj s odpoveďami asistenta je uvedený v prílohe 2.

Na rozdiel od testovania lokálnych modelov, kde sa pri otázkach mimo rozsahu očakávalo odmietnutie odpovede, produkčný asistent disponuje zabudovaným nástrojom `web_search`, takže pri takejto otázke sa očakáva korektné identifikovanie potreby vyhľadania a doplnenie odpovede z internetu so zdrojom. Hodnotenie kvality bolo realizované rovnako ako v kapitole 7.2. Výsledky sú v tabuľke 16.

Tabuľka 16: Kvalita odpovedí asistenta

Kategória otázok	Počet	Relev.	Úplnosť	Zrozum.	Jazyk
Faktické (priamo z bázy)	10	4,9	4,7	4,9	3,0
Syntéza (kombinácia záznamov)	2	4,5	4,0	4,5	3,0
Mimo rozsahu (web search)	2	4,5	4,5	4,5	3,0

Pri faktických otázkach asistent dosahoval takmer maximálne hodnotenie. Pri otázkach vyžadujúcich syntézu sa v jednom prípade z dvoch vyskytol problém s vynechaním jedného z relevantných záznamov, čo sa premietlo do nižšieho hodnotenia úplnosti. Pri otázkach mimo rozsahu asistent korektné identifikoval potrebu vyhľadávania, použil zabudovaný nástroj `web_search` a uviedol zdroj. Priemerná dĺžka odpovede bola tri až päť viet, žiadna z odpovedí neobsahovala emotikony a prepínanie medzi slovenčinou a angličtinou podľa nastavenia funguje korektne.

Priemerný čas odpovede asistenta sa pohyboval okolo 4,1 sekundy pri otázkach bez vyhľadávania a okolo 9,5 sekundy pri otázkach, ktoré spustili `web_search`. Tieto hodnoty sú výrazne nižšie ako pri lokálnych modeloch testovaných v kapitole 7.2, čo potvrdzuje, že prechod na cloudové API odstránil hardvérovú limitáciu odhalenú počas predchádzajúcich meraní.

14.5 Zhrnutie výsledkov testovania

V laboratórnom aj priemyselnom prostredí sa podarilo overiť všetky funkčné, nefunkčné aj doménové požiadavky bez výhrad. Latencia vykonania príkazov sa pohybovala výrazne pod limitom 250 ms stanoveným v NFP3, čím systému ostáva dostatočná rezerva aj pre menej priaznivé sieťové podmienky. Detekcia ArUco identifikátorov je spoľahlivá v praktickom rozsahu vzdialeností a uhlov a obstála aj v hale s priemyselným osvetlením. Asistent poskytuje správne a stručné odpovede, pričom vyhľadávanie na internete dopĺňa znalostnú bázu pri otázkach mimo jej rozsah.

Identifikované obmedzenia sú menšieho charakteru. Mierny pokles spoľahlivosti detekcie pri šikmých uhloch nad 30 stupňov je riešiteľný pokynom pre operátora.

Vynechávanie jedného z relevantných záznamov pri otázkach vyžadujúcich syntézu sa dá riešiť rozšírením počtu kontextových dokumentov posielaých do modelu.

Na základe vykonaných meraní možno konštatovať, že aplikácia spĺňa kritériá stanovené v zadaní práce.

Záver

Cieľom práce bolo navrhnuť a implementovať mobilnú aplikáciu, ktorá obsluhuje umožňuje rýchlu identifikáciu výrobných liniek, jej monitorovanie a základné ovládanie. Zároveň poskytuje prístup k doménovej technickej dokumentácii prostredníctvom inteligentného asistenta. Výsledkom je systém Scan2Control, ktorý všetky tieto funkcie spája do jedného celku. Mobilná aplikácia implementovaná vo frameworku Flutter pripojí operátora ku konkrétnej linke naskenovaním ArUco identifikátora a umožní mu odosielať príkazy. Backend tvorený dvojicou služieb FastAPI komunikuje s PLC Siemens S7-1200 cez Node-RED a MQTT broker, pričom celá infraštruktúra je kontajnerizovaná pomocou Docker a beží na edge zariadení v prevádzke.

Po experimentálnom porovnaní piatich lokálnych jazykových modelov bolo prijaté architektonické rozhodnutie opustiť lokálne nasadenie LLM a prejsť na API spoločnosti Anthropic, keďže náklady na dedikovaný GPU server presahujú možnosti projektu tohto rozsahu. RAG pipeline a znalostná báza zostávajú lokálne, čím je zachovaná kontrola nad doménovými dátami. Bezpečnosť systému je riešená autentifikáciou pomocou JWT tokenov a riadením prístupu cez *Role-Based Access Control* so štyrmi rolami: operátor, manažér, údržbár a administrátor.

Všetky úlohy stanovené v zadaní práce boli splnené. Možnosti načítania jedinečných identifikátorov boli porovnané a zdôvodnili sme voľbu ArUco identifikátorov po experimentovaní s 3D identifikátormi. Aplikácia je integrovaná s PLC cez S7 protokol a poskytuje funkcie vzdialeného ovládania s potvrdením vykonania. Otestovanie v laboratórnom prostredí preukázalo, že priemerná latencia príkazov sa pohybuje výrazne pod hranicou 250 ms stanovenou v nefunkčných požiadavkách, detekcia ArUco identifikátorov je spoľahlivá v praktickom rozsahu vzdialeností a uhlov a odpovede asistenta dosahujú vysokú kvalitu naprieč všetkými testovanými kategóriami otázok.

Identifikované obmedzenia sú menšieho charakteru. V laboratórnom nasadení nebolo aktivované TLS šifrovanie, ktoré by bolo potrebné doplniť pred produkčným nasadením. Detekcia vykazuje pokles spoľahlivosti pri snímaní ArUco identifikátora pod uhlom. Pri otázkach vyžadujúcich syntézu informácií asistent niekedy vynechá jeden z relevantných záznamov, čo je riešiteľné rozšírením počtu kontextových dokumentov posielaných do modelu. Potenciálnym rozšírením do budúcnosti je nasadenie viacerých výrobných liniek pripojených k jednému edge zariadeniu, doplnenie hlasového ovládania asistenta alebo využitie rozšírenej reality.

Diplomová práca preukázala, že kombinácia mobilnej aplikácie, vizuálnej identifikácie liniek a kontextového AI asistenta predstavuje použiteľný prístup k ovládaniu výrobných liniek, ktorý dopĺňa medzeru v ponuke súčasných komerčných platforiem.

Literatúra

1. SIEMENS AG. *SIMATIC WinCC Unified PC* [online]. Siemens, 2025 [cit. 2026-04-07]. Dostupné z: <https://www.siemens.com/en-us/products/simatic-hmi/wincc-unified-software/>.
2. SIEMENS AG. *Engineering Copilot TIA Standard (Managed Service)* [online]. Siemens, 2025 [cit. 2026-04-07]. Dostupné z: <https://www.siemens.com/en-us/products/tia-portal/engineering-copilot-tia-standard/>.
3. INDUCTIVE AUTOMATION. *Ignition SCADA Software* [online]. Inductive Automation, 2026 [cit. 2026-04-07]. Dostupné z: <https://inductiveautomation.com/scada-software/>.
4. INDUCTIVE AUTOMATION. *Ignition Edge* [online]. Inductive Automation, 2026 [cit. 2026-04-07]. Dostupné z: <https://inductiveautomation.com/ignition/edge>.
5. TULIP INTERFACES. *Pricing and Plans* [online]. Tulip Interfaces, 2026 [cit. 2026-04-07]. Dostupné z: <https://tulip.co/plans/>.
6. TULIP INTERFACES. *Tulip Signs Strategic Collaboration Agreement With AWS to Build Generative AI Capabilities Empowering Frontline Workers* [online]. Tulip Interfaces, 2024-04-23 [cit. 2026-04-07]. Dostupné z: <https://tulip.co/press/tulip-signs-strategic-collaboration-agreement-with-aws-to-build-generative-ai-capabilities-empowering-frontline-workers/>.
7. AVEVA SOLUTIONS LIMITED. *AVEVA™ Edge* [online]. AVEVA, 2026 [cit. 2026-04-07]. Dostupné z: <https://www.aveva.com/en/products/edge/>.
8. AVEVA SOLUTIONS LIMITED. *Industrial AI for Operations* [online]. AVEVA, 2026 [cit. 2026-04-07]. Dostupné z: <https://www.aveva.com/en/solutions/digital-transformation/artificial-intelligence/industrial-ai-for-operations/>.
9. EITBIZ - EXTROVERT INFORMATION TECHNOLOGY. *Top App Development Frameworks to Build High-Performance Apps in 2026* [online]. Medium, 2025-12-23 [cit. 2026-04-07]. Dostupné z: <https://medium.com/@eitbiz/top-app-development-frameworks-for-high-performance-apps-in-2026-2db28c6c0a33>.
10. NADARAJAN, C. *How to Choose the Best Backend Frameworks in 2026 for AI-Powered Software: A Business Leader's Guide* [online]. ThinkPalm Technologies, 2025-12-01 [cit. 2026-04-07]. Dostupné z: <https://thinkpalm.com/blogs/how-t>

o-choose-the-right-backend-framework-for-ai-powered-software-a-business-leaders-guide/.

11. GARAI, K. *From Cloud to Edge: How Technology Is Redefining Data Processing* [online]. Medium, 2026-03-10 [cit. 2026-04-07]. Dostupné z: <https://medium.com/@kastab/from-cloud-to-edge-how-technology-is-redefining-data-processing-43b66acde782>.
12. DOCKER INC. *Docker Overview* [online]. Docker Documentation, 2026 [cit. 2026-04-07]. Dostupné z: <https://docs.docker.com/get-started/docker-overview/>.
13. OPC FOUNDATION. *OPC Unified Architecture* [online]. OPC Foundation, 2026 [cit. 2026-04-07]. Dostupné z: <https://opcfoundation.org/about/opc-technologies/opc-ua/>.
14. SIEMENS AG. *S7 Communication* [online]. Siemens TIA Portal Documentation, 2026 [cit. 2026-04-09]. Dostupné z: https://docs.tia.siemens.cloud/r/simatic_et_200clean_manual_collection_zhcn_20/function-manuals/communication-function-manuals/communication/s7-communication/s7-communication.
15. OASIS. *MQTT Version 5.0* [online]. OASIS, 2019-03-07 [cit. 2026-04-07]. Dostupné z: <https://docs.oasis-open.org/mqtt/mqtt/v5.0/mqtt-v5.0.html>.
16. MODBUS ORGANIZATION. *Modbus FAQ* [online]. Modbus Organization, 2026 [cit. 2026-04-07]. Dostupné z: <https://www.modbus.org/faq.php>.
17. STRYKER, C. *What are large language models (LLMs)?* [online]. IBM Think, 2025 [cit. 2026-04-11]. Dostupné z: <https://www.ibm.com/think/topics/large-language-models>.
18. ULLAH, I. *API vs. Self-Hosted LLM: Which Path Is Right for Your Enterprise?* [online]. Medium, 2025-08-28 [cit. 2026-04-11]. Dostupné z: <https://theirfan.medium.com/api-vs-self-hosted-llm-which-path-is-right-for-your-enterprise-82c60a7795fa>.
19. IBM. *What is retrieval augmented generation (RAG)?* [online]. IBM Think, 2025 [cit. 2026-04-11]. Dostupné z: <https://www.ibm.com/think/topics/retrieval-augmented-generation>.
20. RICADELA, A. *What Is Chroma? An Open Source Embedded Database* [online]. Oracle, 2024-04-15 [cit. 2026-04-11]. Dostupné z: <https://www.oracle.com/anz/database/vector-database/chromadb/>.

21. KUNTZ, C. *The New Industrial Evolution: How AI Assistants and Agents Are Transforming Manufacturing Knowledge* [online]. Training Industry, 2025-04-08 [cit. 2026-04-11]. Dostupné z: <https://trainingindustry.com/articles/work-force-development/the-new-industrial-evolution-how-ai-assistants-and-agents-are-transforming-manufacturing-knowledge/>.
22. MICHALOVIČ, M.; HAFFNER, O. Programatické generovanie 3D identifikátora pre systémy zmiešanej reality. In: BENKO, P.; SOJAK, S. (ed.). *ŠVOČ 2023*. Bratislava: Vydavateľstvo Spektrum STU, 2023, s. 80–85. ISBN 978-80-227-5307-4.
23. META AI. *llama3.2* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/llama3.2>.
24. GOOGLE DEEPMIND. *gemma4* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/gemma4>.
25. MISTRAL AI; NVIDIA. *mistral-nemo* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/mistral-nemo>.
26. MICROSOFT. *phi4* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/phi4>.
27. MISTRAL AI. *mistral-small* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/mistral-small>.

Použitie nástrojov umelej inteligencie

Anthropic (2026), Claude Sonnet 4.6, kontrola gramatiky a štylistická úprava vlastných textov.

Anthropic (2026), Claude Opus 4.6, generovanie obsahu znalostnej bázy.

Anthropic (2026), Claude Opus 4.6, generovanie časti kódu na základe inštrukcií.

Anthropic (2026), Claude Opus 4.7, generovanie testovacích otázok pre AI asistenta.

Dodatok A: Súborová štruktúra

Projekt je rozdelený do troch hlavných častí: backend, AI asistent a mobilná aplikácia. Každá časť je samostatne nasaditeľná.

```
Scan2Control/
├── backend/ ..... hlavný backend, MQTT, Node-RED
│   ├── app/ ..... zdrojový kód FastAPI služby
│   │   ├── routers/ ..... REST a WebSocket endpointy
│   │   ├── services/ ..... biznis logika, MQTT, autentifikácia
│   │   ├── models.py ..... databázové modely
│   │   └── schemas.py ..... Pydantic schémy
│   ├── mosquitto/ ..... konfigurácia MQTT brokera
│   ├── node-red/ ..... Node-RED flows pre S7 komunikáciu
│   ├── Dockerfile
│   └── docker-compose.yml
├── assistant/ ..... AI asistent PLE XO
│   ├── app/ ..... zdrojový kód FastAPI služby
│   │   ├── routers/ ..... REST endpointy chatu a znalostnej bázy
│   │   ├── services/ ..... RAG pipeline, ChromaDB
│   │   └── seed_kb.py ..... predvolený obsah znalostnej bázy
│   ├── Dockerfile
│   └── docker-compose.yml
└── frontend/ ..... mobilná aplikácia Flutter
    ├── lib/
    │   ├── features/ ..... obrazovky podľa funkčných oblastí
    │   │   ├── aruco_scanner/ ..... skenovanie identifikátorov
    │   │   ├── plc/ ..... ovládanie a monitoring linky
    │   │   ├── assistant/ ..... rozhranie chatu s asistentom
    │   │   ├── auth/ ..... prihlásenie a registrácia
    │   │   ├── admin/ ..... správa používateľov a logov
    │   │   ├── dashboard/ ..... prehľad zariadení
    │   │   └── settings/ ..... nastavenia aplikácie
    │   ├── l10n/ ..... lokalizácia (SK, EN)
    │   ├── state/ ..... Riverpod stavový manažment
    │   ├── routing/ ..... navigácia
    │   └── main.dart
    ├── android/ ..... Android konfigurácia
    └── pubspec.yaml
```

Dodatok B: Prílohy k testovaniu

V tejto prílohe je uvedený úplný zoznam 14 testovacích otázok použitých pri hodnotení kvality odpovedí virtuálneho asistenta PLEXO v sekcii 14.4, spolu s odpoveďami, ktoré asistent v teste vrátil. Otázky sú rozdelené do troch kategórií podľa metodiky uvedenej v kapitole 7.2: faktické otázky priamo pokryté znalostnou bázou (10 otázok, z toho 6 v slovenčine a 4 v angličtine), otázky vyžadujúce syntézu informácií z viacerých záznamov (2 otázky) a otázky mimo rozsahu znalostnej bázy (2 otázky).

Faktické otázky – slovenský jazyk

Otázka 1: Ako sa voláš?

Odpoveď asistenta: Volám sa PLEXO. Som inteligentný asistent určený na podporu obsluhy výrobných liniek riadených PLC systémami. Pomáham pri bežnej prevádzke, diagnostike problémov a riešení porúch.

Otázka 2: Aký je postup mäkkého reštartu linky?

Odpoveď asistenta: Postup mäkkého reštartu:

- Skontrolujte, či sa v linke nenachádza žiadny produkt ani osoba.
- Na HMI stlačte tlačidlo „STOP“ alebo „Reset“.
- Počkajte 5 sekúnd.
- Stlačte tlačidlo „START“.
- Sledujte, či linka spustí normálnu prevádzku.

Ak reštart nepomôže, zaznamenajte chybové hlásenie a kontaktujte servisného technika.

Otázka 3: Čo znamená chybové hlásenie „Motor Overload“ ako mám reagovať?

Odpoveď asistenta: „Motor Overload“ znamená preťaženie motora – motor odoberá viac prúdu, ako je povolené. Najčastejšou príčinou je zaseknutý produkt alebo mechanická chyba. Postupujte takto:

- Linku okamžite zastavte.
- Skontrolujte pás a trasu pohybu, či nie je niečo zaseknuté.

- Privolajte technika – nepokúšajte sa motor reštartovať bez kontroly.

Otázka 4: Ako mám vyčistiť svetelnú bránu?

Odpoveď asistenta: Čistenie senzora môže vykonať obsluha:

- Zastavte linku.
- Suchou a čistou handričkou (alebo stlačeným vzduchom) očistite šošovku senzora.
- Skontrolujte, či je senzor pevne uchytený a smeruje správne.
- Spustite linku a skontrolujte funkciu.

Kontrolu káblov a výmenu senzora smie vykonávať iba technik.

Otázka 5: Aké stavy môže linka 1 mať?

Odpoveď asistenta: Linka 1 môže byť v jednom z nasledujúcich stavov:

- **Čakanie** – linka je zapnutá, dopravník stojí, čaká na produkt.
- **Pohyb dopredu** – dopravník sa pohybuje od Gate 1 ku Gate 2.
- **Zdržanie na Gate 2** – dopravník stojí, odpočítava sa 3-sekundový časovač.
- **Pohyb dozadu** – dopravník sa pohybuje od Gate 2 ku Gate 1.
- **Výstup produktu** – dopravník sa pohybuje dozadu ešte 1 sekundu po detekcii Gate 1.
- **Chyba** – linka sa zastavila z dôvodu poruchy.

Otázka 6: Ako dlho zostáva produkt zdržaný na Gate 2?

Odpoveď asistenta: Produkt zostáva pri Gate 2 zdržaný 3 sekundy. Počas tohto času dopravník stojí a typicky prebieha spracovanie, skenovanie alebo kontrola produktu. Po uplynutí tejto doby sa dopravník rozbehne smerom dozadu k Gate 1.

Faktické otázky – anglický jazyk

Otázka 7: What does HMI stand for and what is it used for?

Odpoveď asistenta: HMI stands for Human Machine Interface. It is a touch panel or display through which the operator controls the production line. The HMI is one of the basic components of a PLC system and allows the operator to start and stop the line, monitor its current state and view error messages.

Otázka 8: What is the purpose of the E-STOP button?

Odpoved' asistenta: The E-STOP (Emergency Stop) is a red button used to immediately stop the line in case of danger. It must be pressed whenever there is a risk to people or equipment. After the E-STOP has been pressed, the line must not be restarted before the cause of the stop has been checked. The button is released by turning it according to its type and confirming on the HMI.

Otázka 9: How does the line 1 production cycle work?

Odpoved' asistenta: The line 1 cycle consists of the following steps:

1. A product enters the belt and breaks the light beam of Gate 1. The PLC starts the conveyor moving forward.
2. The product reaches Gate 2 and breaks its beam. The conveyor stops and a 3-second timer starts.
3. After 3 seconds the conveyor starts moving in reverse, back towards Gate 1.
4. When the product breaks Gate 1 again, the conveyor continues in reverse for 1 more second so the product leaves the belt.
5. The conveyor stops and the line returns to the idle state, waiting for the next product.

Otázka 10: What should I do if I see a „Communication Error"message?

Odpoved' asistenta: „Communication Error"means that the PLC has lost connection with one of the connected devices (sensor, motor or another module). Try a soft restart of the line first (STOP, wait 5 seconds, START). If the error persists, record the message and call a service technician. Do not attempt to fix the issue with repeated restarts without consulting a technician.

Otázky vyžadujúce syntézu

Otázka 11: Produkt sa rozbehol na Gate 1, dopravník ide dopredu, ale produkt nedorazí na Gate 2 a celá linka sa zasekne. Čo mám robiť?

Odpoved' asistenta: Tento problém má niekoľko možných príčin:

- Produkt mohol vypadnúť z pásu počas presunu – zastavte linku, odstráňte produkt z okolia a reštartujte.
- Gate 2 môže byť znečistená a nedeteguje produkt, takže linka čaká donekonečna – zastavte linku, suchou handričkou vyčistite šošovku Gate 2 a reštartujte.

- Produkt môže byť príliš malý alebo ľahký na zachytenie senzorom – konzultujte nastavenie s technológom.
- Pás sa môže šmýkať a produkt neprenášať – v tomto prípade privolajte technika.

Ak sa po vyčistení senzora a mäkkom reštarte (STOP, počkať 5 sekúnd, START) problém zopakuje, kontaktujte servisného technika.

Otázka 12: Aké kroky musím urobiť na začiatku smeny pred spustením linky 1 a aký je postup pri jej zastavení na konci smeny?

Odpoveď asistenta: **Spustenie na začiatku smeny:**

1. Skontrolujte, či je pás čistý a nie sú na ňom žiadne produkty ani cudzie predmety.
2. Vizualne skontrolujte Gate 1 a Gate 2 – šošovky musia byť čisté a nepoškodené.
3. Skontrolujte, či nie je stlačený E-STOP. Ak áno, uvoľnite ho otočením.
4. Zapnite hlavný vypínač linky a počkajte na spustenie HMI.
5. Skontrolujte, či nie sú aktívne žiadne chybové hlásenia.
6. Prepnite do automatického režimu a stlačte „START“.

Zastavenie na konci smeny:

1. Počkajte, kým aktuálny cyklus dokončí spracovanie a produkt opustí pás.
2. Na HMI stlačte „STOP“.
3. Pre dlhšiu odstavku vypnite hlavný vypínač.

Otázky mimo rozsahu znalostnej bázy

Otázka 13: Aká je aktuálna cena PLC Siemens S7-1200 v Európe?

Odpoveď asistenta (s použitím nástroja **web_search**): Túto informáciu nemám priamo v znalostnej báze, preto som ju vyhľadal na internete. Cena PLC Siemens S7-1200 sa pohybuje rádovo v stovkách až nízkych tisíckach eur podľa konkrétnej konfigurácie CPU a rozširujúcich modulov. Pre presnú aktuálnu cenu odporúčam kontaktovať autorizovaného distribútora Siemens. (*Zdroj: vyhľadávanie cez web_search*)

Otázka 14: What is the Modbus TCP protocol and what port does it use?

Odpoveď asistenta (s použitím nástroja **web_search**): This information is not in my knowledge base, so I looked it up online. Modbus TCP is an industrial communication

protocol that wraps the original Modbus messaging protocol over standard Ethernet using TCP/IP. It uses TCP port 502. Modbus TCP follows a client-server model and is widely used for connecting PLCs, HMIs and SCADA systems in industrial automation. *(Source: web_search lookup)*

Dodatok C: Návod na spustenie

Aplikácia pozostáva z troch častí: backendu, AI asistenta a mobilnej aplikácie. Backend a asistent bežia v Docker kontajneroch, mobilná aplikácia sa nasadzuje na Android zariadenie.

Predpoklady

Na hostiteľskom zariadení musí byť nainštalovaný **Docker** a **Docker Compose**. Pre buildovanie mobilnej aplikácie je potrebný **Flutter SDK** verzia 3.24 alebo novšia s nastaveným Android toolchainom. Edge zariadenie aj mobilný telefón musia byť pripojené v rovnakej lokálnej sieti.

Konfigurácia citlivých údajov

Pred prvým spustením je nutné nastaviť dve hodnoty:

- `JWT_SECRET` v súbore `backend/.env` a v `assistant/docker-compose.yml` **musí byť rovnaká, dlhá náhodná hodnota**. Tento kľúč podpisuje JWT tokeny a zdieľajú ho obe služby na ich validáciu. Vygenerovať ho je možné napríklad cez `openssl rand -hex 32`.
- `ANTHROPIC_API_KEY` v súbore `assistant/docker-compose.yml` musí obsahovať vlastný kľúč zo služby `https://console.anthropic.com/`, inak AI asistent nebude funkčný.

Spustenie backendu a asistenta

V dvoch oddelených termináloch spustite:

```
cd backend && docker compose up -d --build
cd assistant && docker compose up -d --build
```

Po prvom spustení asistenta je potrebné stiahnuť embedovací model:

```
docker exec -it ollama-llm ollama pull nomic-embed-text
```

Backend bude dostupný na porte **8000**, asistent na porte **8100**. Backend pri prvom štarte automaticky vytvorí databázové tabuľky, založí preddefinované účty a zaregistruje testovacie zariadenie *Dopravník* s ArUco ID 1.

Spustenie mobilnej aplikácie

Pripojte Android zariadenie cez USB s povoleným režimom *USB debugging* a v priečinku `frontend/` spustite:

```
flutter pub get  
flutter run --release
```

Po prvom otvorení aplikácie je potrebné v *Nastaveniach* nastaviť IP adresu edge zariadenia pre backend (`http://<edge-ip>:8000`) aj pre asistenta (`http://<edge-ip>:8100`) a aplikáciu reštartovať.

Prvé prihlásenie

Pre prvé prihlásenie sú dostupné preddefinované účty podľa hodnôt v `backend/.env` (predvolene admin: `admin@admin.com` / `admin`). Heslá je odporúčané po prvom prihlásení zmeniť v profile.