

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104378-115323

**Mobilná aplikácia na ovládanie výrobnéj linky s
využitím jedinečného identifikátora**

Diplomová práca

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104378-115323

Mobilná aplikácia na ovládanie výrobnéj linky s využitím jedinečného identifikátora

Diplomová práca

Študijný program:	Aplikovaná mechatronika a elektromobilita
Študijný odbor:	Kybernetika
Školiace pracovisko:	Ústav automobilovej mechatroniky (FEI)
Školiteľ:	Ing. Lukáš Beňo PhD.



ZADANIE DIPLOMOVEJ PRÁCE

Autor práce: Bc. Jakub Hubáček
Študijný program: aplikovaná mechatronika a elektromobilita
Študijný odbor: kybernetika
Evidenčné číslo: FEI-104378-115323
ID študenta: 115323
Vedúci práce: Ing. Lukáš Beňo, PhD.
Vedúci pracoviska: Ing. Ján Cigánek, PhD.

Názov práce: **Mobilná aplikácia na ovládanie výrobnéj linky s využitím jedinečného identifikátora**

Jazyk, v ktorom sa práca vypracuje: slovenský jazyk

Špecifikácia zadania: Cieľom tejto práce je navrhnúť a implementovať mobilnú aplikáciu umožňujúcu ovládanie výrobnéj linky. Aplikácia bude využívať jedinečný identifikátor na identifikáciu a pripojenie k riadiacej jednotke linky. Implementácia bude zahŕňať načítanie jedinečného identifikátora pomocou mobilného zariadenia, komunikáciu s riadiacim systémom linky a jej interaktívne ovládanie. Práca sa zameria na návrh používateľského rozhrania, zabezpečenie spoľahlivej komunikácie so zariadením a testovanie funkcionality v laboratórnych podmienkach.

Úlohy:

1. Preskúmajte možnosti načítania jedinečných identifikátorov pomocou mobilných zariadení.
2. Navrhnite a implementujte mobilnú aplikáciu umožňujúcu identifikáciu pomocou jedinečného identifikátora.
3. Integrujte aplikáciu s riadiacim systémom výrobnéj linky.
4. Navrhnite a implementujte funkcie na vzdialené ovládanie výrobnéj linky cez mobilné zariadenie.
5. Otestujte aplikáciu v laboratórnom prostredí a vyhodnoťte jej spoľahlivosť a efektívnosť.

Literatúra:

1. MICHALOVIČ, Martin a HAFFNER, Oto. Programatické generovanie 3D identifikátora pre systémy zmiešanej reality. In: Peter, BENKO a Stanislav, SOJAK. *ŠVOČ 2023*. Bratislava: Vydavateľstvo Spektrum STU, 2023, s. 80–85. ISBN 978-80-227-5307-4.
2. RIDEKY, Viliam a HAFFNER, Oto. *Rozpoznávanie objektov pomocou 3D Point Cloud klasifikácie*. Diplomová práca. Bratislava : 2025. 99 s.
3. STOKLAS, Gabriel a KUČERA, Erik. *Rozpoznávanie 3D identifikátorov pre identifikáciu objektov v prostredí zmiešanej reality*. Diplomová práca. Bratislava : 2024. 79 s.
4. VALOCKÝ, Frederik a HAFFNER, Oto. *Vizuálny lokalizačný systém pre autonómne vozidlá: dátum obhajoby 22.8.2022*. Dizertačná práca. Bratislava : 2022. 147 s.

Termín odovzdania práce: 15. 05. 2026

Dátum schválenia zadania práce: **08. 03. 2026**

Zadanie práce schválil: **prof. Ing. Vladimír Kutiš, PhD.**
garant študijného programu

Podakovanie

Na tomto mieste by som sa rád poďakoval Ing. Lukášovi Beňovi PhD. za cenné rady a pomoc pri písaní diplomovej práce.

Abstrakt

TODO: dopisat abstrakt po dokončení celé práce

Klíčové slova

Ovládání výrobní linky, mobilná aplikace, jedinečný identifikátor, AI asistent

Abstract

TODO: vložit preložený abstrakt do angličtiny

Keywords

Production line control, mobile application, unique identifier, AI assistant

Obsah

Úvod	1
1 Analýza existujúcich riešení	2
1.1 Siemens WinCC Unified	2
1.2 Ignition Perspective	3
1.3 Tulip	4
1.4 AVEVA InTouch Edge HMI	5
2 Prehľad technológií pre vývoj aplikácií a priemyselnú komunikáciu	7
2.1 Frontendové technológie	7
2.2 Backendové technológie	8
2.3 Kontajnerizácia a edge architektúra	8
2.3.1 Docker a Docker Compose	9
2.4 Priemyselné komunikačné protokoly	9
2.4.1 OPC UA	9
2.4.2 S7 Protokol	10
2.4.3 MQTT	10
2.4.4 Modbus TCP	11
3 Prehľad technológií pre inteligentných asistentov	12
3.1 Veľké jazykové modely a možnosti použitia	12
3.2 Retrieval-Augmented Generation	12
3.3 AI asistenti v priemyselnom prostredí	13
4 Typy identifikátorov a ich použitie	14
4.1 QR identifikátory	14
4.2 Fiduciálne markery – AprilTag, ArUco	14
4.3 3D identifikátory	15
4.3.1 Princíp a štruktúra	15
5 Špecifikácia požiadaviek na systém	17
5.1 Opis systému	17
5.2 Popis používateľských rolí	17
5.3 Use-case scenáre	18
5.4 Funkcionálne požiadavky	19
5.5 Nefunkcionálne požiadavky	20
5.6 Doménové požiadavky	21

6	Voľba technológií	22
6.1	Komunikácia s PLC – S7 protokol	22
6.2	Komunikačná middleware vrstva – Node-RED	22
6.3	Transportný protokol – MQTT	23
6.4	Backend – FastAPI	23
6.5	Frontend – Flutter	24
6.6	Výber identifikátora – ArUco	24
7	Experimentálne porovnanie a výber jazykových modelov	26
7.1	Popis testovaných modelov	26
7.2	Metodika testovania	27
7.3	Výsledky porovnania	28
7.4	Analýza výsledkov a výber modelu	28
7.4.1	Overenie na cloudovom hardvéri	29
7.4.2	Záverečné rozhodnutie o architektúre AI asistenta	30
8	Návrh architektúry systému	31
8.1	Architektúra komponentov systému	31
8.2	Fyzická topológia systému	32
8.3	Štruktúra MQTT tém	33
9	Implementácia backendu	35
9.1	Autentifikácia a RBAC	35
9.2	API endpointy	35
9.3	Mechanizmus relácií	36
9.4	Životný cyklus príkazu	37
9.5	Generátor ArUco identifikátorov a export do STL	37
10	Implementácia AI asistenta	38
10.1	RAG pipeline	38
10.2	Embedovací model	38
10.3	Systémový prompt	39
10.4	Správa konverzácie	40
10.5	Správa znalostnej bázy	40
11	Implementácia frontendu	41
11.1	Stavový manažment	41
11.2	ArUco skenovanie	41
11.3	WebSocket pripojenie	41

11.4 Používateľské rozhranie podľa roly	42
12 Opis funkcionalít aplikácie pre používateľa	43
12.1 Skener ArUco identifikátorov	43
12.2 Generátor ArUco identifikátorov	43
12.3 Monitoring a ovládanie liniek	43
12.4 Virtuálny asistent PLE XO	43
12.5 Správa používateľov	44
12.6 Správa liniek	44
12.7 Správa znalostnej bázy	44
12.8 Nastavenia	45
13 Testovanie a meranie	46
13.1 Overenie splnenia špecifikácie	46
13.2 Latencia vykonania príkazov	48
13.3 Detekcia ArUco identifikátorov	48
13.4 Kvalita odpovedí AI asistenta	49
13.5 Zhre nutie výsledkov testovania	50
Záver	52
Literatúra	53
Použitie nástrojov umelej inteligencie	55
A Súborová štruktúra	56
B Prílohy k testovaniu	57
C Návod na spustenie	58
D Opis funkcionalít aplikácie	59

Zoznam obrázkov a tabuliek

Obrázok 1	Základný princíp RAG pipeline	12
Obrázok 2	QR identifikátor so zakódovanou URL adresou fei.stuba.sk .	14
Obrázok 3	Vizuálne porovnanie AprilTag a ArUco	14
Obrázok 4	Fyzický 3D identifikátor vyrobený pomocou 3D tlače	15
Obrázok 5	Diagram architektúry systému a komunikácia medzi kompo- nentmi	32
Obrázok 6	Fyzická topológia systému	33
Obrázok 7	ArUco identifikátor tlačený z vygenerovaného STL modelu .	38
Tabuľka 2	Porovnanie existujúcich riešení	6
Tabuľka 3	Backendové frameworky podľa scenára nasadenia [10]	8
Tabuľka 4	Výsledky porovnania jazykových modelov	29
Tabuľka 5	Priemerná relevancia podľa typu otázky a jazyka	29
Tabuľka 6	Prehľad MQTT tém	34
Tabuľka 7	Prehľad API endpointov	36
Tabuľka 8	Oprávnenia podľa roly používateľa	42
Tabuľka 9	Overenie funkčných požiadaviek	47
Tabuľka 10	Overenie nefunkčných požiadaviek	47
Tabuľka 11	Overenie doménových požiadaviek	47
Tabuľka 12	Štatistika latencie príkazov v milisekundách (n=25)	48
Tabuľka 13	Úspešnosť detekcie podľa vzdialenosti a uhla (n=30)	49
Tabuľka 14	Úspešnosť detekcie podľa prostredia (vzdialenosť 60 cm, uhol 0°, n=30)	49
Tabuľka 15	Kvalita odpovedí asistenta	50

Zoznam značiek a skratiek

AI	Artificial Intelligence (slovensky „umelá inteligencia“)
AOT	Ahead-of-Time (slovensky „predkompilácia“)
API	Application Programming Interface (slovensky „aplikačné programové rozhranie“)
ASGI	Asynchronous Server Gateway Interface (slovensky „asynchrónne rozhranie serverovej brány“)
CPU	Central Processing Unit (slovensky „centrálna procesorová jednotka“)
GPU	Graphics Processing Unit (slovensky „grafická procesorová jednotka“)
HMI	Human-Machine Interface (slovensky „rozhranie človek-stroj“)
HTML	HyperText Markup Language (slovensky „hypertextový značkovací jazyk“)
IIoT	Industrial Internet of Things (slovensky „priemyselný internet vecí“)
IoT	Internet of Things (slovensky „internet vecí“)
IT	Information Technology (slovensky „informačné technológie“)
JSON	JavaScript Object Notation (slovensky „JavaScriptová objektová notácia“)
KB	Knowledge Base (slovensky „znalostná báza“)
LLM	Large Language Model (slovensky „veľký jazykový model“)
ML	Machine Learning (slovensky „strojové učenie“)
MQTT	Message Queuing Telemetry Transport (slovensky „telemetrický transportný protokol s radením správ“)
OPC UA	Open Platform Communications Unified Architecture (slovensky „zjednotená architektúra otvorenej platformovej komunikácie“)

OT	Operational Technology (slovensky „prevádzkové technológie“)
PLC	Programmable Logic Controller (slovensky „programovateľný logický automat“)
Pub/Sub	Publish-Subscribe (slovensky „vzor vydavateľ-odberateľ“)
QoS	Quality of Service (slovensky „kvalita služieb“)
QR	Quick Response (slovensky „rýchla odpoveď“)
RAG	Retrieval-Augmented Generation (slovensky „generovanie rozšírené o vyhľadávanie“)
RAM	Random Access Memory (slovensky „pamäť s náhodným prístupom“)
REST	Representational State Transfer (slovensky „prezentačný prenos stavu“)
SaaS	Software as a Service (slovensky „softvér ako služba“)
SCADA	Supervisory Control and Data Acquisition (slovensky „dohľadové riadenie a zber dát“)
SQL	Structured Query Language (slovensky „štruktúrovaný dotazovací jazyk“)
TCP	Transmission Control Protocol (slovensky „protokol riadenia prenosu“)
UI	User Interface (slovensky „používateľské rozhranie“)
VRAM	Video Random Access Memory (slovensky „grafická pamäť s náhodným prístupom“)

Zoznam výpisov kódov

1	Závislosti pre kontrolu rolí	35
2	Ochrana relácie údržbára	37
3	Základ systémového promptu AI asistenta PLEXO	39

Úvod

TODO: dopisat uvodnu kapitolu, ktora bude obsahovat motivaciu, ciele prace a struczny prehlad obsahu jednotlivych kapitol

1 Analýza existujúcich riešení

Trh s priemyselnými softvérovými platformami ponúka viacero riešení umožňujúcich vizualizáciu a ovládanie výrobných liniek. Väčšina z nich vychádza z tradičného modelu SCADA/HMI a postupne sa rozširuje o mobilný prístup, cloudovú konektivitu a v niektorých prípadoch aj o prvky umelej inteligencie. Nasledujúci prehľad analyzuje štyri významné komerčné platformy. Posudzované sú nasledovné funkcionality: mobilný prístup k výrobným linkám, identifikácia fyzických zariadení, nasadenie na edge, otvorenosť platformy a integrácia inteligentného asistenta schopného pracovať s technickou dokumentáciou.

1.1 Siemens WinCC Unified

SCADA systém *SIMATIC WinCC Unified PC* od spoločnosti Siemens je vizualizačná platforma integrovaná do prostredia TIA Portal, navrhnutá na zjednotenie OT a IT dát v rámci jedného konzistentného systému [1]. Platforma je škálovateľná od jedného zariadenia až po rozsiahle distribuované systémy s prakticky neobmedzeným počtom zariadení.

Prístup k prevádzkovým dátam je zabezpečený cez webové rozhranie HTML5, ktoré umožňuje vzdialené monitorovanie z prehliadača bez inštalácie klientskej aplikácie. Platforma obsahuje archív pre dlhodobé ukladanie dát a podporuje redundanciu pre vysokú dostupnosť systému.

Siemens v rámci TIA Portal ekosystému ponúka aj nástroj *Engineering Copilot TIA Standard* [2]. Ide o generatívneho AI asistenta pripojeného priamo k TIA Portal. Tento nástroj dokáže generovať kód PLC v jazyku SCL, vytvárať testy, konfigurovať HMI obrazovky a odpovedať na otázky na základe dokumentácie TIA Portal. Jeho zameranie je však výlučne na fázu návrhu a pomáha programátorom pri programovaní a konfigurácii, nie operátorovi počas prevádzky.

Z pohľadu našej práce sú kľúčové tieto body:

- **Mobilný prístup:** Webové rozhranie je dostupné cez prehliadač, nie je to natívna mobilná aplikácia. Interakcia nie je optimalizovaná pre dotykové ovládanie.
- **Identifikácia zariadení:** Platforma nepodporuje skenovanie unikátnych identifikátorov, operátor sa naviguje manuálne.
- **AI asistent pre obsluhu:** Engineering Copilot je nástroj pre programátorov, nie pre operátorov. Neposkytuje kontextovú pomoc na základe znalostnej bázy zariadení počas prevádzky.

- **Licenčný model:** Proprietárny, viazaný na ekosystém Siemens, vyžaduje TIA Portal licencie.

1.2 Ignition Perspective

Ignition SCADA od spoločnosti Inductive Automation je modulárna platforma postavená na otvorených IT štandardoch – SQL, Python, MQTT a OPC UA. Jej kľúčovou vlastnosťou je licenčný model bez obmedzenia počtu tagov, klientov a pripojení, čo ju odlišuje od väčšiny konkurenčných riešení účtujúcich za každé zariadenie [3].

Platforma komunikuje s PLC od Allen-Bradley, Siemens, Mitsubishi, Modbus a ďalšími prostredníctvom vstavaných ovládačov a zabudovaného OPC UA servera. Ignition Gateway beží na štandardnom serveri a škálovateľnosť je riešená architektúrou hub-and-spoke, kde centrálny gateway koordinuje viaceré odľahčené inštancie.

Modul *Perspective* poskytuje plnohodnotné webové rozhranie na báze HTML5, prístupné z akéhokoľvek zariadenia bez inštalácie klientskej aplikácie. Vizualizačné komponenty sú responzívne a optimalizované pre dotykové ovládanie na tabletoch a smartfónoch. K dispozícii je aj mobilná aplikácia *Ignition Perspective App*.

Pre nasadenie na edge zariadeniach Inductive Automation ponúka *Ignition Edge*. Ide o odľahčenú verziu s archívom (35 dní lokálneho ukladania), podporou MQTT Sparkplug pre synchronizáciu dát na centrálny gateway a možnosťou tvorby REST API priamo na edge zariadení. Ignition Edge teda plní úlohu inteligentného premostenia medzi fyzickými zariadeniami a vyššími systémovými vrstvami [4].

Z pohľadu našej práce sú kľúčové tieto body:

- **Mobilný prístup:** Modul Perspective poskytuje responzívne webové rozhranie aj mobilnú aplikáciu a teda dotykové ovládanie je plne podporované.
- **Identifikácia zariadení:** Platforma natívne nepodporuje skenovanie unikátnych identifikátorov. Navigácia cez QR identifikátory je technicky realizovateľná vlastnými Pythonskými skriptmi, avšak nejde o štandardnú funkciu platformy.
- **Edge nasadenie:** Ignition Edge umožňuje distribuované nasadenie priamo na priemyselných zariadeniach s lokálnou archiváciou a synchronizáciou dát.
- **AI asistent:** Platforma neobsahuje vstavanú funkciu inteligentného asistenta ani správu znalostnej bázy. Skriptovacie rozhranie v Pythone by technicky umožnilo volanie externých LLM API, avšak bez natívnej podpory.
- **Licenčný model:** Licencia na Gateway bez obmedzenia počtu klientov. Jednotlivé moduly ako Perspective, Alarming, Reporting sa licencujú samostatne.

1.3 Tulip

Tulip je cloudová no-code platforma pre frontline operácie vo výrobnom sektore, ktorá umožňuje vytvárať priemyselné aplikácie prostredníctvom vizuálneho drag-and-drop editora bez nutnosti programovania [5]. Platforma je orientovaná na digitalizáciu manuálnych výrobných procesov – sledovanie výrobných krokov, zber dát z pracovísk, kontrolu kvality, vizuálne pracovné inštrukcie a sledovateľnosť výroby.

Licenčný model Tulip je účtovaný za interface (zariadenie spúšťajúce Tulip Player). Základný plán *Essentials* zahŕňa aplikácie na mobiloch, tabletoch, dotykových obrazovkách a nositeľných zariadeniach, pričom vyššie plány (*Professional*, *Enterprise*) pridávajú edge konektivitu či pokročilú správu rolí.

Pripojenie k priemyselným zariadeniam je realizované cez doplnkový modul *Machine Monitoring* s podporou OPC UA, MQTT a Node-RED. Aplikácia beží vo webovom prehliadači na tabletoch alebo iných zariadeniach umiestnených na pracoviskách.

V roku 2024 Tulip uzavrel strategickú spoluprácu s Amazon Web Services a predstavil funkciu *Frontline Copilot* [6], postavenú na platforme Amazon Bedrock. Frontline Copilot umožňuje operátorom diagnostikovať výrobné dáta, hľadať v nich vzory a vytvárať aplikácie bez kódu s pomocou generatívnej AI. Systém pracuje s reálnymi výrobnými dátami zozbieranými v rámci platformy.

Z pohľadu našej práce sú kľúčové tieto body:

- **Mobilný prístup:** Aplikácie sú webové a responzívne, spustiteľné na mobiloch, tabletoch aj dotykových obrazovkách.
- **Identifikácia zariadení:** Platforma podporuje skenovanie čiarových identifikátorov a QR identifikátorov pre identifikáciu materiálov a produktov, avšak nie pre priame spárovanie s konkrétnym zariadením.
- **Edge nasadenie:** Edge konektivita (OPC UA, MQTT, Node-RED) je dostupná ako platený doplnok, aplikačná logika a dáta sú hostované v cloude.
- **AI asistent:** Frontline Copilot poskytuje generatívnu AI na analýzu výrobných dát a asistenciu operátorom. Nejde však o asistenta s vlastnou znalostnou bázou technickej dokumentácie zariadení. Funkcia pracuje primárne s dátami nazbieranými v rámci platformy Tulip.
- **Licenčný model:** SaaS model účtovaný mesačne za interface, cloudová závislosť môže byť problematická v prostrediach s prísnyimi požiadavkami na lokalizáciu dát.

1.4 AVEVA InTouch Edge HMI

AVEVA Edge je HMI/SCADA platforma od spoločnosti AVEVA, ktorá je členom skupiny Schneider Electric. Je navrhnutá pre nasadenie na priemyselných zariadeniach, priemyselných PC a edge zariadeniach s minimálnymi hardvérovými nárokmi [7]. Kľúčovým princípom platformy je heslo „develop once, deploy everywhere“. Aplikácia sa navrhne raz v prostredí AVEVA Edge Studio a nasadí na Windows alebo Linux, od malých embedded zariadení až po plnohodnotné SCADA systémy.

Platforma je interoperabilná s väčšinou priemyselných zariadení prostredníctvom vstavaných ovládačov a natívnej podpory OPC UA. Vzdialený prístup je zabezpečený webovým rozhraním na založeným na HTML5, čo umožňuje sledovanie a ovládanie zo smartfónov, tabletov a priemyselných panelov bez inštalácie klienta.

V oblasti priemyselnej AI AVEVA rozvíja samostatnú platformu *Industrial AI for Operations* [8], ktorá využíva aktuálne aj historické dáta naprieč prevádzkou, dodávateľským reťazcom a plánovaním na odhaľovanie skrytých nedostatkov v efektivite a predikciu výpadkov. Význam platformy bol uznaný v rebríčkoch Gartner a Verdantix v roku 2025. Táto AI vrstva je však cielená na podnikovú úroveň, optimalizáciu procesov a prediktívnu údržbu. Nie je cieľom poskytovať kontextovú asistenciu obsluhu priamo pri zariadení.

Z pohľadu našej práce sú kľúčové tieto body:

- **Mobilný prístup:** HTML5 webové rozhranie prístupné zo smartfónov a tabletov, nie je to natívna mobilná aplikácia.
- **Identifikácia zariadení:** Platforma nepodporuje skenovanie unikátnych identifikátorov pre spárovanie operátora so zariadením.
- **Edge nasadenie:** Natívna podpora, AVEVA Edge je priamo navrhnutý pre beh na edge zariadeniach vrátane Linux systémov s nižšími hardvérovými prostriedkami.
- **AI asistent:** Industrial AI for Operations je analytická platforma na podnikovej úrovni zameraná na prediktívnu údržbu a optimalizáciu procesov. Neposkytuje kontextovú asistenciu obsluhu na základe znalostnej bázy dokumentácie konkrétnych zariadení.
- **Licenčný model:** Proprietárny, licencie sa aktivujú cez AVEVA web portál na základe sériového čísla a hardvérového identifikátora.

Zhrnutie analýzy

Tabuľka 2 sumarizuje kľúčové vlastnosti porovnávaných platforiem vzhľadom na mobilný prístup, identifikáciu zariadení, edge nasadenie a integráciu AI asistenta s vlastnou znalostnou bázou.

Tabuľka 2: Porovnanie existujúcich riešení

Vlastnosť	WinCC Unified	Ignition Perspective	Tulip	AVEVA InTouch
Natívna mobilná aplikácia	Nie	Áno	Nie	Nie
Identifikácia zariadení	Nie	Nie	Čiastočne	Nie
Edge nasadenie	Áno	Áno	Čiastočne	Áno
AI asistent s vlastnou KB	Nie	Nie	Nie	Nie
Otvorená platforma	Nie	Čiastočne	Nie	Nie

Z porovnania vyplýva, že existujúce komerčné platformy poskytujú rôznu mieru mobilného prístupu k priemyselným systémom, avšak ani jedna z nich neintegruje inteligentného asistenta schopného odpovedať na otázky obsluhy na základe vlastnej znalostnej bázy technickej dokumentácie. Väčšina platforiem sa orientuje na vizualizáciu a vzdialený prístup k procesným dátam. Pričom podpora operátora, teda schopnosť systému aktívne pomáhať pri riešení prevádzkových situácií prostredníctvom práce s dokumentáciou, zostáva nepokrytou oblasťou.

Rovnako identifikácia fyzických zariadení prostredníctvom vizuálnych identifikátorov s automatickým načítaním kontextu pre dané zariadenie nie je štandardnou funkciou žiadnej z analyzovaných platforiem. Operátori sú naďalej odkázaní na manuálnu navigáciu cez menu, čo spomaľuje prístup k informáciám a zvyšuje pravdepodobnosť interakcie s nesprávnym zariadením.

Tieto identifikované medzery v súčasnej ponuke komerčných riešení tvoria základ pre návrh systému prezentovaného v neskorších kapitolách tejto práce.

2 Prehľad technológií pre vývoj aplikácií a priemyselnú komunikáciu

Moderné priemyselné aplikácie nestoja na jednej technológii. Sú výsledkom starostlivo zvolenej skladačky nástrojov, kde každá vrstva plní svoju úlohu. Mobilné rozhranie reaguje na pokyny operátora, backendová vrstva spracúva množstvo súbežných udalostí zo zariadení a pokyny prichádzajúce z mobilnej aplikácie.

Kľúčovou výzvou je pritom premostenie dvoch oddelených svetov. OT označuje svet priemyselného riadenia a teda PLC automaty, senzory, pohony a ostatné zariadenia. IT je naopak svet softvéru, sietí a aplikácií určených na spracovanie a prenos informácií. Tieto dva svety dlho fungovali oddelene, každý s vlastnými protokolmi a prioritami. Priemyselné aplikácie v kontexte Industry 4.0 ich spájajú práve cez komunikačnú vrstvu, napríklad pomocou protokolov MQTT alebo OPC UA.

Nasledujúci prehľad mapuje najpoužívanjšie technológie a ich typické uplatnenie.

2.1 Frontendové technológie

Výber frameworku pre mobilnú aplikáciu patrí k zásadným architektonickým rozhodnutiam. Z prehľadu moderných frameworkov vypláva, že voľba nie je len technická, ale priamo ovplyvňuje rýchlosť vývoja, výkon aplikácie, dlhodobé náklady na údržbu a dostupnosť vývojárov [9]. Nasledujúci prehľad stručne opisuje najrozšírenejšie spôsoby vývoja frontendu, resp. vybrané používané frameworky.

Natívny vývoj (Swift/SwiftUI pre iOS, Kotlin pre Android) poskytuje maximálny výkon a priamy prístup k hardvérovým funkciám zariadenia. Jeho nevýhodou je nutnosť paralelného vývoja a údržby dvoch samostatných kódových základní, čo zvyšuje celkové náklady na vývoj.

React Native od spoločnosti Meta umožňuje zdieľanie logiky aplikácie medzi platformami pomocou JavaScriptu, pričom UI vykresľuje cez natívne komponenty systému. React Native má silný ekosystém, avšak pri výkonnostne náročných operáciách môžu nastať obmedzenia spôsobené prechodom cez natívne rozhranie.

Flutter od spoločnosti Google využíva jednotnú kódovú základňu v jazyku Dart a vlastný vykresľovací engine, ktorý zaručuje konzistentné vizuálne výstupy na všetkých platformách bez závislosti na systémových komponentoch. Dosahuje výkon blízky natívnym aplikáciám vďaka AOT kompilácii.

Webové frameworky (React, Angular, Vue) umožňujú prístup z ľubovoľného zariadenia s prehliadačom bez inštalácie. Pre priemyselné aplikácie je ich hlavným

obmedzením bezpečnostný sandbox prehliadača, ktorý sťažuje priamu komunikáciu s lokálnym hardvérom a priemyselnými rozhraniami.

2.2 Backendové technológie

Backend tvorí jadro systému, spracúva požiadavky, komunikuje s databázami a sprostredkováva tok dát medzi PLC a klientskymi aplikáciami. Výber frameworku pre tvorbu backendu závisí od požiadaviek na výkon, dostupnosť AI/ML knižníc a dlhodobú udržateľnosť [10]. Pozrime sa na vybrané možnosti, ktoré sa často používajú pre ich jednoduchosť, výkon alebo ekosystém knižníc.

Django je framework s filozofiou „batteries included“ a obsahuje vstavaný admin panel, správu relácií a ORM vrstvu. Je vhodný pre dátovo náročné aplikácie a rýchly vývoj, avšak jeho monolitická architektúra ho robí menej vhodným pre mikroslužby.

Node.js s Express/NestJS umožňuje použiť JavaScript aj pre backend. Node.js vyniká pri aplikáciách s vysokou frekvenciou krátkych I/O operácií, avšak nie je vhodný pre výpočtovo náročné úlohy blokujúce event loop. NestJS nadstavba pridáva štruktúru TypeScript pre väčšie projekty.

Python s frameworkmi Flask/FastAPI dominuje v oblasti AI a ML vďaka bohatému ekosystému knižníc ako PyTorch, Scikit-learn, LangChain. Flask je minimalistický a flexibilný, FastAPI využíva asynchrónne ASGI a automaticky generuje OpenAPI dokumentáciu na základe typových anotácií.

Go s Gin/Fiber je kompilovaný jazyk s nízkymi nárokmi na RAM a CPU a predvídateľnou latenciou. Je vhodný pre mikroslužby, edge nasadenia a výkonnostne kritické systémy, avšak jeho ekosystém pre AI/ML je výrazne menší oproti Pythonu.

Tabuľka 3: Backendové frameworky podľa scenára nasadenia [10]

Scenár použitia	Odporúčaný framework
MVP/Startup	Node.js, Django, FastAPI
Podnikové mikroslužby	Spring Boot, Go, NestJS
Aplikácie s AI	Django, FastAPI, Node.js
Vysoká záťaž/real-time	Gin, Fiber, Node.js

2.3 Kontajnerizácia a edge architektúra

Cloudové spracovanie dát, kde sa všetky informácie odosielaajú na vzdialené servery, čelí obmedzeniam v podobe latencie, zaťaženia siete a bezpečnostných rizík pri prenose citlivých dát [11]. Ako alternatíva sa presadzuje model *edge computing*, kde sa dáta

spracúvajú priamo pri zdroji a teda na lokálnom zariadení alebo v blízkosti monitorovanej alebo ovládanej výrobnjej linky. Edge zariadenia dokážu filtrovať a vyhodnocovať dáta lokálne, do cloudu sa odosielať len relevantné výsledky, čo znižuje spotrebu prenosového pásma a zvyšuje odolnosť systému pri výpadku pripojenia.

Edge computing a cloud sa navzájom nevylučujú, ale môžu spolupracovať v hybridnom modeli, kde edge zabezpečuje takmer real-time spracovanie a cloud poskytuje dlhodobé ukladanie dát, pokročilú analytiku alebo koordináciu v prípade viacerých edge uzlov.

2.3.1 Docker a Docker Compose

Docker je otvorená platforma pre vývoj, distribúciu a spúšťanie aplikácií [12]. Umožňuje baliť aplikáciu spolu so všetkými jej závislosťami do prenositeľného kontajnera, ktorý beží rovnako v každom prostredí – na vývojárskom počítači, v testovacom prostredí aj na priemyselnom PC v prevádzke. Kontajnery využívajú izoláciu na úrovni jadra Linuxu, sú výrazne viac odľahčené ako virtuálne stroje a umožňujú spúšťať viacero izolovaných aplikácií na jednom hostovskom systéme súčasne.

Zmena v kóde si vyžaduje prenos len zmenenej vrstvy obrazu, nie celého systému, čo môže byť kľúčové pri aktualizáciách cez obmedzené priemyselné pripojenia. Docker Compose rozširuje tento koncept na celý aplikačný stack: backend, MQTT broker, vektorová databáza a ďalšie služby môžu byť definované v jednom konfiguračnom súbore a môžu sa spúšťať jedným príkazom.

2.4 Priemyselné komunikačné protokoly

2.4.1 OPC UA

OPC UA je platformovo nezávislá architektúra orientovaná na služby, vydaná v roku 2008, ktorá integruje funkcionality predchádzajúcich OPC Classic špecifikácií do jedného rozšíriteľného frameworku. Štandard beží na rôznych hardvérových platformách, od priemyselných PC a PLC až po mikrokontroléry a cloudovú infraštruktúru. Podporuje operačné systémy Windows, Linux, Android a ďalšie [13].

Model OPC UA je objektovo orientovaný: dáta sú reprezentované hierarchicky ako uzly, objekty a premenné s plnou sémantickou popisnosťou. Prístup k dátam zahŕňa čítanie a zápis, odoberanie zmien, notifikácie na udalosti a volanie metód. Komunikácia je možná v modeli klient-server aj Pub/Sub.

Bezpečnosť je súčasťou návrhu: OPC UA podporuje šifrovanie správ, podpisovanie, X.509 certifikáty pre autentifikáciu, sekvenčné pakety proti replay útokom a auditný log aktivít.

- **Výhody:** Vstavaná kybernetická bezpečnosť, sémantický popis dát, podpora klient-server aj Pub/Sub komunikácie, spätná kompatibilita a platformová nezávislosť.
- **Nevýhody:** Vysoká komplexnosť a vyššie nároky na RAM/CPU limitujú nasadenie.

2.4.2 S7 Protokol

S7 komunikácia je proprietárny protokol spoločnosti Siemens určený na výmenu dát medzi PLC rady SIMATIC [14]. Ide o natívny komunikačný mechanizmus ekosystému TIA Portal, ktorý pracuje nad sieťami PROFINET alebo PROFIBUS DP. Na rozdiel od otvorených štandardov nie je S7 protokol verejne špecifikovaný a zariadenia tretích strán ho implementujú reverzným inžinierstvom.

Komunikácia prebieha na princípe klient-server s jednosmerne konfigurovanými alebo obojstranne konfigurovanými spojeniami.

- **Výhody:** Jednoduchá konfigurácia v prostredí TIA Portal, natívna podpora v celom ekosystéme, nízka latencia v homogénnych Siemens sieťach.
- **Nevýhody:** Uzavretý, neštandardizovaný protokol bez verejnej špecifikácie, obmedzená interoperabilita so zariadeniami iných výrobcov.

2.4.3 MQTT

MQTT je nenáročný a otvorený protokol typu klient-server s modelom publish/subscribe, navrhnutý pre jednoduché použitie v obmedzených prostrediach ako IoT a komunikácia medzi strojmi. Protokol beží nad TCP/IP a poskytuje obojsmerný tok správ s minimálnou réžiou [15].

Správy sa neposielajú priamo medzi zariadeniami. Klienti publikujú správy na témy (topics) na brokerovi, ostatní klienti sa môžu na tieto témy prihlásiť (subscribe) a dostávať správy bez potreby poznať ich pôvod.

Protokol definuje tri úrovne QoS pre doručenie správ:

- **QoS 0** – správa je doručená najviac raz, bez potvrdenia
- **QoS 1** – správa je doručená aspoň raz, môžu nastať duplikáty
- **QoS 2** – správa je doručená práve raz, s plným handshake protokolom

Ďalšou vlastnosťou je mechanizmus „Last Will and Testament“, správa, ktorú broker automaticky odošle ostatným klientom v prípade neštandardného odpojenia klienta. Verzia MQTT 5.0 pridáva rozšírené vlastnosti ako expirácia správ, aliasy tém a zlepšené hlásenie chýb.

- **Výhody:** Minimálna réžia, tri úrovne QoS, podpora „Last Will and Testament“, vhodnosť pre zariadenia s obmedzeným výkonom a sieťou.
- **Nevýhody:** Nutnosť udržiavať bežiaci broker čo môže byť centrálny bod zlyhania.

2.4.4 Modbus TCP

Modbus je komunikačný protokol vyvinutý spoločnosťou Modicon (dnes Schneider Electric) v roku 1979 pre potreby priemyselných programovateľných automatov. Dnes je de facto štandardom v priemyselnej automatizácii s odhadovaných 7 miliónmi nasadených uzlov [16]. Modbus TCP/IP prenáša správy protokolu Modbus zabalené do TCP/IP rámcov, čím umožňuje nasadenie v štandardných ethernetových sieťach bez potreby špeciálneho hardvéru.

Protokol pracuje na princípe klient-server. Klient iniciuje požiadavky a server odpovedá.

- **Výhody:** Jednoduchý a otvorený štandard bez licenčných poplatkov, rozšírená podpora zariadení, minimálne nároky na zdroje, jednoduché ladenie.
- **Nevýhody:** Chýba zabudovaná autentifikácia a šifrovanie, obmedzený dátový model, žiadny mechanizmus notifikácie, teda klient sa musí aktívne dopytovať na server.

3 Prehľad technológií pre inteligentných asistentov

3.1 Veľké jazykové modely a možnosti použitia


Veľké jazykové modely (LLM) sú kategóriou modelov hlbokého učenia trénovaných na obrovských množstvách textových dát, vďaka čomu sú schopné porozumieť prirodzenému jazyku a generovať text pre široké spektrum úloh [17]. Ich základom je architektúra transformer s mechanizmom seba-pozornosti, ktorý modelu umožňuje zachytiť vzťahy a závislosti medzi slovami na rôznych miestach v texte.

Trénovanie prebieha na miliardách slov z kníh, článkov a webových stránok. Text je rozdelený na tokeny, každý token je zakódovaný ako vektor čísel tzv. embedding a sieť sa iteratívne učí predpovedať nasledujúci token v sekvencii. Výsledkom je model, ktorý si osvojil gramatické pravidlá, faktické znalosti aj spôsoby uvažovania.

Z hľadiska použitia existujú dve základné možnosti [18]. Prvou sú **cloudové modely prístupné cez API** (napr. GPT-4o, Claude, Gemini). Ide o platené služby, kde poskytovateľ spravuje celú infraštruktúru a model je dostupný okamžite bez nutnosti vlastného hardvéru. Druhou možnosťou sú **open-source modely nasadené lokálne** (napr. Llama 3, Mistral), kde môže každý prevádzkovať model na vlastných serveroch alebo zariadeniach. Lokálne nasadenie je vhodné najmä v prostrediach s obmedzeným internetovým pripojením, prísnyimi požiadavkami na ochranu dát alebo potrebou prevádzky bez závislosti od externých služieb.

3.2 Retrieval-Augmented Generation

LLM modely sú obmedzené na znalosti zachytené počas trénovania a nemajú prístup k aktuálnym ani doménovým informáciám. Retrieval-Augmented Generation (RAG) tento nedostatok rieši prepojením modelu s externou znalostnou bázou bez nutnosti opätovného trénovania [19].



Obr. 1: Základný princíp RAG pipeline

Princíp fungovania je taký, že pri každej otázke používateľa, retrieval model vyhľadá v znalostnej báze relevantné úseky dokumentov, tie sa vložia do kontextu LLM spolu s pôvodnou otázkou a model na ich základe vygeneruje odpoveď. Znalostná báza je typicky uložená vo vektorovej databáze, kde sú dokumenty reprezentované ako číselné vektory (embeddings) umožňujúce rýchle vyhľadávanie. Jednou z populárnych open-source vektorových databáz je ChromaDB. Je to ľahká databáza licencovaná pod Apache 2.0, ktorú možno prevádzkovať lokálne alebo aj v cloudovom prostredí a je priamo integrovaná s frameworkmi LangChain a LlamaIndex [20].

Hlavné prínosy RAG oproti čistému LLM sú zníženie halucinácií dohľadáním odpovedí v konkrétnych zdrojoch, prístup k aktuálnym a doménovým dátam a teda možnosť odkazovať na zdroj informácie priamo v odpovedi.

3.3 AI asistenti v priemyselnom prostredí

Priemyselné podniky čelia rastúcemu nedostatku kvalifikovaných pracovníkov a potrebe rýchleho zaškolenia nových zamestnancov. Generatívni AI asistenti môžu predstavovať súčasť riešenia tohto problému. Fungujú ako virtuálni mentori priamo na mieste, kde pracovníkom poskytujú okamžité odpovede v prirodzenom jazyku na otázky o postupoch, riešení porúch alebo špecifikáciách zariadení [21].

Systém vie prepájať viaceré zdroje dát ako podnikové systémy, tréningové databázy, prevádzkové dáta a skladať z nich kontextovo relevantnú odpoveď. Technická dokumentácia je tak prekladaná do zrozumiteľných pokynov prispôbených skúsenostiam konkrétneho pracovníka. Výsledkom je potenciálne skrátenie času zaškoľovania, zníženie závislosti od rád seniornejších zamestnancov a vyššia schopnosť prispôbiť sa pri zavádzaní nových technológií.

4 Typy identifikátorov a ich použitie

4.1 QR identifikátory


QR identifikátory sú dvojrozmerné maticové identifikátory optimalizované pre rýchle čítanie a vysokú hustotu dát. V zmysle použitia v priemysle sa využívajú najmä na identifikáciu objektov, kde sa vyžaduje uloženie komplexnejších informácií napr. URL adresy, sériové čísla alebo konfiguračné parametre. Ich výhodou je silná korekcia chýb, ktorá umožňuje prečítať identifikátor aj pri čiastočnom poškodení alebo znečistení povrchu.



Obr. 2: QR identifikátor so zakódovanou URL adresou fei.stuba.sk

4.2 Fiduciálne markery – AprilTag, ArUco

Fiduciálne markery sú špeciálne navrhnuté pre potreby počítačového videnia a robotiky. Na rozdiel od QR identifikátorov nie je ich primárnym cieľom prenos veľkého objemu dát, ale presná lokalizácia v 3D priestore.



Obr. 3: Vizuálne porovnanie AprilTag a ArUco


Tieto identifikátory sa vyznačujú predovšetkým vysokou mierou interoperability s modernými robotickými riešeniami. Vďaka existujúcim knižniciam napr. OpenCV, ROS je ich integrácia štandardom pri vývoji:

- **Autonómnych robotov:** Kde markery umiestnené v prostredí slúžia ako pevné referenčné body pre rekalibráciu lokalizácie a elimináciu kumulatívnej chyby v mapách.
- **Dronov v skladoch:** Kde umožňujú presné pristávanie na nabíjaciach staniciach alebo navigáciu v priestoroch bez signálu GPS, pričom dron dokáže v reálnom čase určiť svoju polohu a náklon voči markeru.
- **Kolaboratívnych robotov:** Pri navádzaní na presnú pozíciu.

Identifikátory ako AprilTag a ArUco sú robustné voči zmenám osvetlenia a perspektívnemu skresleniu.

4.3 3D identifikátory

V prostrediach priemyselných podnikov a logistických reťazcov, kde môže prísť k jednoduchému znemožneniu snímania 2D identifikátorov (znečistené alebo poškodené povrchy, nedostatočné osvetlenie, odrazy svetla), sa ako perspektívne riešenie javia unikátne 3D identifikátory. Na Fakulte elektrotechniky a informatiky STU bol vyvinutý systém programaticky generovaných 3D identifikátorov, ktoré sú optimalizované pre systémy zmiešanej a rozšírenej reality.



Obr. 4: Fyzický 3D identifikátor vyrobený pomocou 3D tlače

4.3.1 Princíp a štruktúra

Navrhnutý 3D identifikátor má tvar kocky, ktorá je vnútorne vyskladaná z menších, unikátnych geometrických elementov. Tieto elementy sú usporiadané v originálnej štruktúre, ktorá v sebe nesie zakódované informácie.

Hlavné technické výhody tohto riešenia sú:

- **Všesmerová detekcia:** Na rozdiel od 2D identifikátorov je možné tieto 3D objekty v systémoch zmiešanej reality spoľahlivo snímať z akéhokoľvek uhla.
- **Odolnosť voči falšovaniu:** Vďaka komplexnej vnútornej členitosti a 3D geometrii sú tieto identifikátory výrazne náročnejšie na replikáciu než bežné 2D identifikátory.
- **Využitie vlastného tvaru:** Sledovanie sa nespolieha len na vizuálny vzor, ale na obrys a priestorovú charakteristiku 3D modelu, čo zvyšuje stabilitu v AR aplikáciách.

5 Špecifikácia požiadaviek na systém

Práca predstavuje moderný prístup k priemyselnému internetu vecí (IIoT). Mobilná aplikácia slúži ako primárne rozhranie pre obsluhu výrobných linky. Komunikácia výrobných linky a aplikácie prebieha cez edge zariadenie umiestnené priamo v prevádzke.

5.1 Opis systému

Systém umožní obsluhu ovládať PLC výrobných linky prostredníctvom mobilnej aplikácie. Identifikácia výrobných linky prebieha skenovaním ArUco identifikátora umiestneného priamo na linke. Po naskenovaní sa aplikácia pripojí k výrobným linky a obsluha bude môcť odosielať príkazy a sledovať aktuálny stav.

Systém bude podporovať viacerých súčasne prihlásených používateľov s rôznymi oprávneniami. Každý používateľ bude mať pridelenú rolu, ktorá určí, ku ktorým funkciám má prístup. Keďže ku jednej výrobným linky sa môže pokúsiť pripojiť viacero pracovníkov naraz, systém musí riešiť exkluzivitu pripojenia a definovať pravidlá pre prípad konfliktu, pričom servisný zásah údržbára musí byť chránený pred prerušením.

Systém bude zaznamenávať všetky odoslané príkazy vrátane informácie o tom, ktorý používateľ príkaz vydal, a na ktorú výrobnú linku. Administrátor a manažér budú môcť spravovať používateľské účty a schvaľovať nové registrácie.

Súčasťou systému bude inteligentný asistent, ktorý bude odpovedať na technické otázky obsluhy na základe dokumentácie nahratej v znalostnej báze. Obsah znalostnej bázy bude možné viazať na konkrétnu výrobnú linku.

Systém bude nasadený výhradne v lokálnej sieti továrne. Backendové služby budú kontajnerizované a nasadené na edge zariadení umiestnenom v sieti továrne.

5.2 Popis používateľských rolí

Systém implementuje riadenie prístupu založené na rolách (*Role-Based Access Control*, RBAC). Každý nový používateľ sa musí zaregistrovať a pred prvým prihlásením čaká na schválenie administrátorom alebo manažérom, ktorý mu zároveň priradí príslušnú rolu. Sú definované štyri roly:

Operátor: Základná obsluha výrobných linky. Prihlasuje sa na konkrétnu linku skenovaním ArUco identifikátora, odosiela riadiace príkazy a sleduje aktuálny stav linky v reálnom čase. Nemá prístup k reportom, správe vedomostnej bázy ani správe používateľov. Môže v prípade potreby využiť AI asistenta.

Manažér: Zameriava sa na sledovanie udalostí. Má prístup k histórii prihlásení jednotlivých operátorov, reportu s logmi a môže spravovať používateľské kontá. Takisto má prístup k AI asistentovi a môže upravovať vedomostnú bázu. Výrobnú linku priamo neovláda, no vidí kto je prihlásený a aké operácie vykonáva.

Údržbár: Má exkluzívnu ochranu relácie a žiadny iný používateľ ho nemôže odhlásiť z prihlásenej linky, čo zaručuje bezpečnosť počas servisného zásahu. Spravuje vedomostnú bázu pre jednotlivé linky, môže upravovať existujúce linky a vytvárať nové.

Administrátor: Spravuje celý systém, schvaľuje nové registrácie, priraduje roly, edituje a odstraňuje používateľské kontá. Má prístup prakticky ku všetkým funkciám systému.

5.3 Use-case scenáre

ID	UC-01: Registrácia a prihlásenie
Aktér	Všetky roly
Popis	Používateľ sa zaregistruje zadaním údajov. Kým administrátor neschváli konto, aplikácia zobrazí informáciu o čakaní na schválenie. Po schválení sa používateľ prihlási a získa prístup.
ID	UC-02: Skenovanie ArUco identifikátora a spárovanie výrobnéj linky
Aktér	Operátor, údržbár, admin
Popis	Používateľ naskenuje ArUco identifikátor pri výrobnéj linke. Ak je linka voľná, po potvrdení dialógu sa vytvorí relácia. Ak je obsadená, zobrazí sa identita a rola prihláseného.
ID	UC-03: Ovládanie výrobnéj linky
Aktér	Operátor, údržbár, admin
Popis	Aktéri odosielaajú príkazy z ovládacieho panelu. Vykonanie príkazu je potvrdené a je zobrazený čas od odoslania po prijatie príkazu linkou.
ID	UC-04: Monitorovanie stavu výrobnéj linky
Aktér	Operátor, údržbár, admin
Popis	Dashboard zobrazuje procesné dáta z PLC v reálnom čase cez WebSocket. Stavý sú farebne kódované podľa normy IEC 60073.

ID	UC-05: Prezeranie logov
Aktér	Manažér, údržbár, admin
Popis	Je možné prezeranie logov a reportov s filtrovaním podľa časového obdobia a linky.
ID	UC-06: Správa vedomostnej bázy
Aktér	Manažér, údržbár, admin
Popis	Prostredníctvom CRUD operácií sa nahrávajú, upravujú a odstraňujú dokumenty znalostnej bázy.
ID	UC-07: AI asistent
Aktér	Všetky roly
Popis	Tlačidlom v rohu každej obrazovky sa spustí chatbot. Odpovedá výhradne na základe vedomostnej bázy, či už všeobecnej alebo viazanej ku konkrétnej linke. Ak informácia chýba, prizná to. Rozhranie aj odpovede sú lokalizované v SK a EN.
ID	UC-08: Správa používateľov
Aktér	Manažér, admin
Popis	Manažér a admin schvaľujú registrácie, priradujú roly, upravujú a odstraňujú kontá. Hlavného admina nie je možné odstrániť ani upraviť inou cestou.
ID	UC-09: Nastavenia aplikácie
Aktér	Všetky roly
Popis	V nastaveniach je možné zmeniť jazyk (SK / EN) a vlastné heslo. Zmena jazyka je dostupná aj na prihlasovacej obrazovke.

5.4 Funkcionálne požiadavky

FP1: Aplikácia musí umožniť načítanie unikátneho identifikátora na automatické spárovanie mobilného zariadenia s konkrétnou výrobnou linkou.

FP2: Používateľ musí mať možnosť odosielať príkazy v riadenom systéme.

FP3: Systém musí implementovať verifikáciu kritických príkazov. Po odoslaní požiadavky musí aplikácia čakať na potvrdenie z PLC a vizuálne indikovať úspešné vykonanie zmeny.

FP4: Zobrazovanie aktuálnych stavov z PLC.

- FP5:** Implementácia chatbota využívajúceho metódu *Retrieval-Augmented Generation*. Chatbot musí odpovedať na technické otázky výhradne na základe poskytnutej vedomostnej bázy. Ak čerpá z iného zdroja, musí to jasne uviesť.
- FP6:** Plná lokalizácia používateľského rozhrania a odpovedí chatbota v dvoch jazykoch: slovenský (SK) a anglický (EN).
- FP7:** Aplikácia musí implementovať mechanizmus exkluzívnej relácie pre ovládanie konkrétnej linky. Po úspešnom prihlásení sa vytvorí aktívna relácia viazaná na používateľa. Relácia ostáva aktívna až do jej explicitného ukončenia odhlásením používateľa alebo prevzatím iným používateľom za podmienok definovaných v FP8.
- FP8:** Pri pokuse o spárovanie linky, ktorá je už obsadená aktívnou reláciou, musí aplikácia používateľovi zobrazíť informáciu o existujúcej relácii (používateľa/rola). Nútené ukončenie resp. prevzatie relácie musí byť umožnené v prípade neodhlásenia sa už neprítomnej obsluhy.
- FP9:** Systém musí podporovať prihlásenie používateľov pomocou autentifikácie založenej na JWT. Aplikácia musí implementovať *Role-Based Access Control* (RBAC) s rolami: operátor, manažér, údržbár, admin.
- FP10:** Systém musí ukladať základný log operácií obsahujúci minimálne: čas vykonania, identifikátor používateľa, identifikátor linky, typ akcie/príkazu a výsledok vykonania. Log musí byť dostupný pre roly *manažér*, *údržbár* a *admin*.

5.5 Nefunkcionálne požiadavky

Definujú kvalitatívne atribúty, technologické obmedzenia a nároky na bezpečnosť.

- NFP1:** Celá backendová infraštruktúra musí byť kontajnerizovaná pomocou nástroja Docker a spustiteľná na edge zariadení.
- NFP2:** Prenos správ v edge infraštruktúre musí prebiehať cez MQTT s QoS 1.
- NFP3:** Latencia príkazov, meraná od odoslania z mobilnej aplikácie po zápis hodnoty do PLC, nesmie presiahnuť 250 ms.
- NFP4:** Odpovede AI asistenta musia byť striktne viazané na poskytnutý kontext. Ak informácia v materiáloch chýba, model musí túto skutočnosť priznať.
- NFP5:** Lokálna databáza musí byť konfigurovaná na zachovanie integrity dát aj v prípade náhleho prerušenia napájania edge zariadenia.

NFP6: Využitie Docker Compose musí umožňovať rýchle nasadenie identického stacku na iné edge zariadenia napr. v iných závodoch.

NFP7: Ovládacie príkazy môžu prichádzať výhradne z lokálnej siete továrne.

NFP8: Backendové služby musia poskytovať štruktúrované logy pre účely diagnostiky.

5.6 Doménové požiadavky

Požiadavky plynúce z priemyselného prostredia a použitých technológií.

DP1: Komunikácia s hardvérom PLC musí prebiehať cez natívny protokol S7.

DP2: Grafické rozhranie musí dodržiavať priemyselné štandardy pre farebnú indikáciu stavov podľa normy IEC 60073.

DP3: Systém si musí zachovať kľúčovú funkčnosť, teda ovládanie výrobných linky aj v prípade výpadku pripojenia k internetu.

6 Voľba technológií

Výber použitých technológií bol výsledkom posúdenia viacerých faktorov. Medzi kľúčové kritériá patrili kompatibilita s poskytnutým hardvérom, jednoduchá integrácia, nízka latencia a schopnosť fungovať v priemyselnom prostredí s obmedzenými zdrojmi. V neposlednom rade bola dôležitá aj dostupnosť knižníc a predchádzajúca skúsenosť s jednotlivými technológiami, čo zásadne urýchlilo vývoj.

6.1 Komunikácia s PLC – S7 protokol

Riadiaci systém výrobnéj linky je PLC od firmy Siemens, konkrétne model S7-1200, pre ktorý je natívnym komunikačným protokolom S7. Práve to bolo primárnym dôvodom jeho výberu. S7 protokol umožňuje priame čítanie a zápis dátových blokov bez nutnosti zložitej konfigurácie alebo dodatočných licencií.

Alternatívou by bolo aktivovanie servera OPC UA priamo v S7-1200, čo je síce technicky možné, avšak prináša niekoľko nevýhod. Tými sú vyšší nápor na výpočtové zdroje PLC s obmedzenou pamäťou, potrebu licencie a výrazne komplexnejší konfiguračný proces. S7 protokol cez knižnicu `node-red-contrib-s7` poskytuje priamy a jednoduchý prístup k dátam PLC bez týchto obmedzení.

- **Výhody:** Natívna podpora pre Siemens S7-1200, priamy prístup k dátovým blokom, nízke vyťažovanie prostriedkov, jednoduchá konfigurácia v Node-RED.
- **Nevýhody:** Viazanosť na platformu Siemens, absencia štandardizovaného informačného modelu v porovnaní s OPC UA.

6.2 Komunikačná middleware vrstva – Node-RED

Spojenie medzi PLC a zvyškom systému zabezpečuje Node-RED, nástroj na programovanie s využitím minima kódu. Beží v Docker kontajneri priamo na edge zariadení v prevádzke. Node-RED periodicky číta hodnoty z PLC prostredníctvom S7 protokolu a publikuje ich do MQTT brokera, čím spája svet OT (PLC, S7) a IT (MQTT, backend).

Node-RED bol zvolený z niekoľkých dôvodov. Disponuje uzlom `node-red-contrib-s7` pre priamu komunikáciu so Siemens PLC a rovnako podporou MQTT. Toto riešenie je bez potreby písať rozsiahly kód, čo výrazne skracuje čas konfigurácie. Node-RED tiež dobre zvláda periodické dotazovanie (polling) PLC a podmienené spúšťanie akcií.

- **Výhody:** Minimum kódu, natívna S7 a MQTT podpora, jednoduchý deployment v Dockeri, aktívna komunita s rozsiahlou knižnicou uzlov.

- **Nevýhody:** Nie je vhodný pre komplexnú biznis logiku, vizuálne toky môžu byť pri väčšom projekte ťažšie udržiavateľné.

6.3 Transportný protokol – MQTT

Pre transport dát medzi edge vrstvou a backendom bol zvolený protokol MQTT. Kľúčovým argumentom je jeho nenáročnosť. Protokol bol navrhnutý pre zariadenia s obmedzenými zdrojmi a nestabilné siete.

OPC UA je komplexný štandard s bohatým informačným modelom, vstavanou bezpečnosťou a sémantickým popisom dát. Pre scenár, kde Node-RED číta hodnoty zo Siemens PLC a odovzdáva ich ďalej na spracovanie, táto komplexnosť nepredstavuje pridanú hodnotu, ale zbytočnú záťaž. MQTT broker nasadený v Dockeri zvládne rovnakú úlohu s minimálnou náročnosťou na zdroje.

- **Výhody:** Nízke nároky na zdroje, jednoduchá architektúra pub/sub, výborná podpora v Node-RED aj Pythone, QoS úrovne pre spoľahlivosť doručenia.
- **Nevýhody:** Závislosť na bežiacom MQTT brokeri ako centrálnom bode zlyhania, absencia štandardizovaného sémantického popisu dát.

OPC UA by bol lepšou voľbou pri požiadavke na štandardizovaný sémantický popis dát, pri integrácii viacerých zariadení od rôznych výrobcov alebo pri prísnych bezpečnostných požiadavkách.

6.4 Backend – FastAPI

Backend aplikácie bol implementovaný v Pythone s využitím frameworku FastAPI. Tvorí API pre celú mobilnú aplikáciu. Oddelené API obsluhuje AI asistenta vrátane RAG pipeline. Voľba Pythonu bola prirodzená, pretože ChromaDB poskytuje natívnu Python knižnicu, Ollama beží ako lokálny server s jednoduchým HTTP API a Anthropic ponúka oficiálny Python SDK pre Claude API. Všetky tri integrácie sú teda priamočiare a nevyžadujú dodatočnú vrstvu. FastAPI bolo zvolené aj z ďalších praktických dôvodov. Asynchrónna architektúra (ASGI) umožňuje súbežne obsluhovať požiadavky mobilnej aplikácie aj dlhotrvajúce volania jazykového modelu bez vzájomného blokovania. Automaticky generovaná OpenAPI dokumentácia uľahčuje ladenie API počas vývoja. Validácia vstupov cez Pydantic redukuje množstvo pomocného kódu. Rolu zohrali aj predchádzajúce skúsenosti s týmto frameworkom v bakalárskej práci, čo výrazne urýchlilo vývoj a umožnilo sa sústrediť na implementáciu biznis logiky a integráciu AI asistenta.

- **Výhody:** Asynchrónne spracovanie požiadaviek, automatická OpenAPI dokumentácia, Pydantic validácia, AI knižnice, rýchly vývoj.
- **Nevýhody:** Interpretovaný Python je pomalší oproti kompilovaným jazykom pri CPU-intenzívnych operáciách.

6.5 Frontend – Flutter

Pre mobilnú aplikáciu bol zvolený framework Flutter od spoločnosti Google. Primárnou cieľovou platformou je Android, avšak Flutter umožňuje z jednej kódovej základne generovať aj webovú aplikáciu, desktopovú aplikáciu a iOS aplikáciu, čo otvára možnosť implementácie administrátorského panelu, či vývoja pre iné platformy bez nutnosti udržiavať samostatný projekt.

Oproti natívnemu vývoju v Kotlin, Flutter ponúka výrazne rýchlejší vývojový cyklus vďaka funkciám hot reload a hot restart. Vlastný vykresľovací engine Impeller zaručuje vizuálnu konzistenciu rozhrania naprieč zariadeniami a operačnými systémami. Bohatá štandardná knižnica widgetov pokrýva väčšinu potrieb priemyselného ovládacieho rozhrania.

- **Výhody:** Jedna kódová základňa pre Android, iOS aj web, rýchly vývojový cyklus, konzistentné UI, silná podpora od Google.
- **Nevýhody:** Väčšia veľkosť výslednej aplikácie oproti natívnym riešeniam, pri požiadavke na plnohodnotnú iOS aplikáciu by bolo potrebné doplniť testovanie na Apple zariadeniach.

6.6 Výber identifikátora – ArUco

Pre jednoznačnú identifikáciu výrobnéj linky bolo v rámci práce spočiatku investované značné množstvo času do experimentovania s 3D identifikátormi navrhnutými študentom FEI. Tieto identifikátory sa spočiatku javili ako vhodné riešenie, pretože poskytovali vizuálne unikátny vzor, ktorý by teoreticky mohol byť rozpoznaný pomocou počítačového videnia.

Preto bolo otestovaných niekoľko prístupov k ich rozpoznávaniu:

- **Template matching a hashing** – porovnanie snímaného povrchu s uloženými referenčnými vzormi metódami pHash, SSIM a klasický template matching.
- **Extrakcia príznakov ORB s FLANN matcher** – rotačne invariantné príznaky s rýchlym vyhľadávaním v databáze, testované na rôznych vzdialenostiach a uhloch.

- **Analýza mriežky jamiek** – priama detekcia binárneho vzoru v 19×19 mriežke a porovnanie matíc.
- **Porovnávanie histogramov** – identifikácia na základe distribúcie intenzít.
- **Siamese network** – ľahká CNN extrahujúca 128-dimenzionálne príznakové vektory, identifikácia na základe cosine similarity.
- **Transfer learning s MobileNet V3-Small** – klasifikátor exportovaný do TFLite pre nasadenie v mobilnej aplikácii Flutter, trénovaný s augmentáciou rotácií a variáciou osvetlenia.

Napriek rozsiahlemu experimentovaniu žiadna z týchto metód neposkytovala dostatočne spoľahlivé výsledky v reálnych podmienkach. Systém si vzory vzájomne zamieňal, pri zmenách osvetlenia alebo pohľadového uhla klesala istota rozpoznávania pod použiteľnú hranicu, a príprava každej novej triedy identifikátora vyžadovala opätovné zbieranie dát a doladenie modelu.

Z týchto dôvodov bolo prijaté rozhodnutie použiť štandardizovaný fiduciálny marker **ArUco**. Identifikátory ArUco sú binárne štvorcové vzory s kódovanou číselnou identitou a orientáciou, ktoré sú navrhnuté priamo pre spoľahlivú detekciu počítačovým videním za rôznych svetelných podmienok. Knižnica ArUco je súčasťou OpenCV a poskytuje robustné algoritmy detekcie s korekciou perspektívy. V priemyselnom prostredí majú ArUco identifikátory silné zastúpenie, využívajú ich napríklad automaticky navádzané vozidlá (AGV), upratovacie autonómne roboty a aj výskumné robotické platformy. Táto rozšírenosť je ďalším argumentom v prospech voľby ArUco oproti 3D identifikátorom, ktoré by vyžadovali vlastný spôsob rozpoznávania. Prípadne by bolo možné použitie frameworku ako Vuforia, čo by ale značne zvýšilo závislosť implementácie a údržby a presne tomu sme sa chceli vyhnúť.

7 Experimentálne porovnanie a výber jazykových modelov

7.1 Popis testovaných modelov

Na porovnanie bolo vybraných päť lokálne spustiteľných jazykových modelov dostupných prostredníctvom platformy Ollama. Modely boli zámerne zvolené tak, aby pokrývali tri veľkostné kategórie: modely do 10 miliárd parametrov, modely v rozsahu 10 až 15 miliárd parametrov a model s 24 miliardami parametrov. Cieľom tohto rozloženia bolo analyzovať vzťah medzi veľkosťou modelu, kvalitou odpovedí a časom odozvy.

1. llama3.2:3b

Kompaktný model od spoločnosti Meta s 3 miliardami parametrov zo série Llama 3.2, ktorá zahŕňa predtrénované aj inštrukčne doladené generatívne modely vo veľkosti 3B parametrov. Inštrukčne doladené varianty sú optimalizované pre multijazyčné konverzačné úlohy vrátane agentického vyhľadávania a sumarizácie. Podľa oficiálnej dokumentácie model prekonáva modely Gemma 2 2.6B a Phi 3.5-mini v úlohách ako plnenie inštrukcií, sumarizácia, prepisovanie promptov a používanie nástrojov [22]. Do testovania bol zaradený ako zástupca najmenej veľkostnej kategórie s predpokladom najrýchlejšej odozvy.

2. gemma4:e4b

Model od spoločnosti Google zo série Gemma 4 s 4 miliardami parametrov v kvantizovanej verzii (e4b označuje efektívnu 4-bitovú kvantizáciu). Série Gemma 4 predstavuje najnovšiu generáciu otvorených modelov Google, navrhnutú s dôrazom na multimodálne schopnosti a efektívne nasadenie na bežnom spotrebiteľskom hardvéri. Model podporuje dlhé kontextové okno a je optimalizovaný pre inštrukčné úlohy vrátane multijazyčných konverzačných scenárov [23]. Do testovania bol zaradený ako zástupca strednej veľkostnej kategórie s priaznivým pomerom výkonu a pamätevej náročnosti.

3. mistral-nemo:12b

Model s 12 miliardami parametrov vyvinutý spoločnosťami Mistral AI a NVIDIA. Disponuje kontextovým oknom až 128 000 tokenov a podľa oficiálnej dokumentácie dosahuje v svojej veľkostnej kategórii špičkové výsledky v oblasti uvažovania, znalosti sveta a presnosti generovania kódu. Vďaka štandardnej architektúre je plnohodnotnou náhradou modelu Mistral 7B v existujúcich systémoch [24]. Do testovania bol zaradený ako zástupca kategórie 10–15 miliárd parametrov.

4. **phi4:14b**

Model od spoločnosti Microsoft s 14 miliardami parametrov a kontextovým oknom 16 000 tokenov. Je trénovaný na kombinácii syntetických dátových sád, filtrovaných verejne dostupných webových zdrojov a akademických kníh a dátových sád otázok a odpovedí. Prešiel procesom doladenia pomocou supervised fine-tuningu a direct preference optimization s dôrazom na presné plnenie inštrukcií a bezpečnosť. Podľa oficiálnej dokumentácie je určený pre prostredia s obmedzenými výpočtovými zdrojmi, scenáre s požiadavkami na nízku latenciu a úlohy vyžadujúce uvažovanie a logiku [25]. Do testovania bol zaradený ako druhý zástupca kategórie 10–15 miliárd parametrov.

5. **mistral-small:24b**

Model od spoločnosti Mistral AI s 24 miliardami parametrov a kontextovým oknom 32 000 tokenov, ktorý stanovuje nový štandard v kategórii modelov do 70B parametrov. Podľa oficiálnej dokumentácie dosahuje výkon porovnateľný s modelmi trojnásobnej veľkosti a proprietárnym modelom GPT-4o mini naprieč úlohami v oblasti programovania, matematiky, všeobecných znalostí a plnenia inštrukcií [26]. Model vyniká multijazyčnou podporou, natívnym volaním funkcií, JSON výstupom a vysokým rešpektom k systémovým promptom. Vďaka kompaktnej veľkosti je nasaditeľný lokálne na výkonnejšom spotrebiteľskom hardvéri.

7.2 Metodika testovania

Testovanie prebiehalo formou automatizovaného testu implementovaného v jazyku Python s využitím knižníc LangChain, ChromaDB a Ollama. Znalostná báza asistenta vo formáte `.txt` bola rozdelená na sekcie podľa markerov `-- NÁZOV DOKUMENTU: --` a uložená do vektorovej databázy ChromaDB s využitím embedding modelu `nomic-embed-text`. Pre každú testovú otázku boli z vektorovej databázy vytiahnuté tri najrelevantnejšie dokumenty, ktoré boli spolu s otázkou odovzdané modelu ako kontext.

Každý model bol otestovaný na sade 14 testovacích otázok rozdelených do troch kategórií:

- **Faktické otázky** (10 otázok) – odpoveď je priamo obsiahnutá v znalostnej báze. 6 otázok v slovenskom a 4 otázky v anglickom jazyku.
- **Otázky vyžadujúce syntézu** (2 otázky) – správna odpoveď vyžaduje kombináciu informácií z viacerých dokumentov znalostnej bázy.

- **Otázky mimo rozsahu** (2 otázky) – otázky, ktorých odpoveď sa v znalostnej báze nenachádza a model by mal odpovedať odmietnutím a odporúčaním kontaktovať údržbára.

Na rozdiel od automatických metrík ako ROUGE, ktoré vykazujú nízku spoľahlivosť pri jazykoch, kde sa využíva skloňovanie, ako je slovenčina, bolo hodnotenie kvality realizované manuálne. Každá odpoveď bola ohodnotená podľa nasledujúcich kritérií:

- **Relevancia** (škála 1–5) – miera, do akej odpoveď zodpovedá položenej otázke.
- **Úplnosť** (škála 1–5) – pokrytie všetkých dôležitých bodov správnej odpovede.
- **Zrozumiteľnosť** (škála 1–5) – zrozumiteľnosť formulácie odpovede.
- **Jazyková správnosť** (škála 1–3) – či model odpovedal v rovnakom jazyku, v akom bola položená otázka.
- **Odmietnutie otázky mimo rozsahu** (áno/nie) – či model správne odmietol odpovedať na otázku, ktorá nie je pokrytá znalostnou bázou.

Celkové skóre bolo vypočítané ako vážený priemer jednotlivých kritérií: relevancia (30 %), úplnosť (25 %), zrozumiteľnosť (20 %) a jazyková správnosť (25 %).

Okrem kvalitatívnych metrík bol pre každú odpoveď zaznamenaný čas odozvy v milisekundách. Testovanie prebiehalo na notebookovom hardvéri (CPU AMD Ryzen 5 5600H, RAM 32 GB, GPU NVIDIA RTX 3060 6 GB VRAM). Keďže väčšina testovaných modelov presahuje kapacitu VRAM, modely bežali čiastočne alebo úplne na systémovej RAM, čo predstavuje hardvérovú limitáciu meraní. V produkčnom nasadení, na dedikovanom serveri s dostatočnou VRAM, by časy odozvy boli výrazne nižšie.

7.3 Výsledky porovnania

Výsledky hodnotenia všetkých piatich modelov sú zhrnuté v tabuľke 4.

7.4 Analýza výsledkov a výber modelu

Z výsledkov testovania vyplýva, že model **gemma4:e4b** dosiahol najvyššie celkové skóre 4,92/5,0 spomedzi všetkých testovaných modelov. Model vykazoval konzistentne vysokú kvalitu odpovedí naprieč všetkými typmi otázok aj oboma testovanými jazykmi, pričom jeho priemerný čas odozvy 11 165 ms bol v podmienkach notebookového hardvéru prijateľný a takmer trojnásobne nižší v porovnaní s modelom mistral-small:24b.

Prekvapivým zistením je, že modely phi4:14b a mistral-small:24b opakovane odmietali odpovedať na otázky, ktorých odpovede boli v znalostnej báze jednoznačne

Tabuľka 4: Výsledky porovnania jazykových modelov

Model	Priem. čas [ms]	Relev. (1–5)	Úplnosť (1–5)	Zrozum. (1–5)	Jazyk (1–3)	OOS odmiet.	Celk. skóre
llama3.2:3b	4 536	2,29	2,21	2,50	2,14	100 %	2,63
gemma4:e4b	11 165	4,86	4,86	5,00	3,00	100 %	4,92
mistral-nemo:12b	15 217	4,07	4,07	4,29	2,86	100 %	4,29
phi4:14b	20 039	2,00	2,00	2,07	2,79	100 %	2,68
mistral-small:24b	35 801	1,86	1,86	1,86	3,00	100 %	2,65

Tabuľka 5: Priemerná relevancia podľa typu otázky a jazyka

Model	Faktická otázka	Syntéza	Mimo rozsahu	SK	EN
llama3.2:3b	1,70	2,50	5,00	2,12	2,50
gemma4:e4b	5,00	4,00	5,00	4,88	4,83
mistral-nemo:12b	4,20	2,50	5,00	4,62	3,33
phi4:14b	1,40	2,00	5,00	2,00	2,00
mistral-small:24b	1,40	1,00	5,00	2,00	1,67

obsiahnuté. Tento jav naznačuje, že RAG pipeline neposkytol týmto modelom dostatočne relevantný kontext, čo mohlo byť spôsobené odlišnou citlivosťou modelov na formát vstupného kontextu.

Všetky testované modely dosiahli 100 % úspešnosť pri odmietaní otázok mimo rozsahu znalostnej bázy, čo potvrdzuje správne fungovanie systémového promptu z hľadiska bezpečnosti systému.

7.4.1 Overenie na cloudovom hardvéri

V nadväznosti na merania realizované lokálne boli vybrané modely testované aj na platforme RunPod.io, ktorá poskytuje prístup k výkonným GPU serverom formou platby za využitý čas. Cieľom bolo overiť, do akej miery hardvérová limitácia skresľuje závery o reálnej použiteľnosti modelov v produkcii.

Výsledky potvrdili predpoklad, na dedikovanom serverovom hardvéri s dostatočnou VRAM klesol priemerný čas odozvy na menej ako 8 sekúnd u všetkých modelov, čo je pre interaktívne použitie výrazne prijateľnejšia hodnota. Kvalita odpovedí pritom

zostala nezmenená, čo je v súlade s očakávaním. Model generuje kvalitatívne rovnaký výstup nezávisle od hardvéru, rozdiel sa prejaví iba v latencii.

7.4.2 Záverečné rozhodnutie o architektúre AI asistenta

Napriek tomu, že výsledky testovania lokálnych modelov boli z kvalitatívneho hľadiska uspokojivé, cloudové overenie odhalilo zásadné ekonomické obmedzenie tohto prístupu. Modely, ktoré dosahujú dostatočnú kvalitu odpovedí, si pre produkčné nasadenie vyžadujú dedikovaný GPU server s dostatočnou VRAM. Prevádzkové náklady takéhoto riešenia nie sú pre projekt tohto rozsahu rentabilné.

V prípade väčších organizácií s vyšším objemom požiadaviek by mohlo byť zmysluplné investovať do vlastného serverového hardvéru. Stále však bude výhodnosť vlastného servera s GPU závislá od konkrétneho objemu požiadaviek. Pre nízky až stredný objem požiadaviek, je určite ekonomicky výhodnejšie využívať API s modelom per-token, kde náklady sú priamoúmerné skutočnému využitiu a nevyžadujú si vysokú počiatočnú investíciu.


Z týchto dôvodov bolo rozhodnuté opustiť prístup lokálnych LLM a prejsť na volanie externého API. Na výber je niekoľko poskytovateľov ako OpenAI, Google, Anthropic a iní veľkí hráči v oblasti AI. Zvolili sme API od spoločnosti Anthropic, nakoľko v poslednej dobe zaznamenal výraznejší pokrok v porovnaní s konkurenciou. Tento prístup umožňuje využitie výkonných jazykových modelov bez nutnosti prevádzkovať vlastný server, pričom náklady sa platia priamoúmerne skutočnému využitiu. RAG pipeline a znalostná báza zostávajú zachované v pôvodnej podobe. Kontextové dokumenty sú naďalej vyhľadávané lokálne z vektorovej databázy a odovzdávané modelu ako súčasť promptu. Mení sa iba vrstva generovania odpovede, ktorá prechádza z lokálne bežiacieho modelu na cloudové API.

8 Návrh architektúry systému

Systém je navrhnutý ako distribuovaná aplikácia skladajúca sa z viacerých vzájomne prepojených vrstiev. Každá vrstva plní špecifickú úlohu a komunikuje so susednými vrstvami prostredníctvom jasne definovaných rozhraní. Jadro systému beží na edge zariadení umiestnenom priamo v prevádzke a zabezpečuje plnú funkčnosť aj bez pripojenia k internetu. Mobilná aplikácia komunikuje výhradne v rámci lokálnej siete závodu a v súčasnosti sa pripojenie na internet využíva len pre účely AI asistenta. Ak by sme využívali lokálne spustiteľný jazykový model, komunikácia s AI asistentom by prebiehala výhradne v rámci lokálnej siete a celý systém by bol izolovaný. Nasledujúce podkapitoly popisujú podrobnejšie celkovú štruktúru systému, spôsob nasadenia jednotlivých komponentov, ich vzájomnú komunikáciu a spôsob ukladania dát.

8.1 Architektúra komponentov systému

Systém sa skladá z piatich hlavných komponentov. Prvým je mobilná aplikácia, ktorá slúži ako primárne rozhranie pre obsluhu. Druhým je backendová vrstva tvorená dvoma službami FastAPI. Hlavná služba zabezpečuje autentifikáciu, správu relácií a riadenie výrobnjej linky. Samostatná služba obsluhuje AI asistenta s RAG pipeline. Tretím komponentom je MQTT broker Mosquitto, ktorý sprostredkúva asynchrónnu komunikáciu medzi backendom a Node-RED. Štvrtým je Node-RED, ktorý premostuje svet priemyselnej komunikácie so svetom IT a periodicky číta dáta z PLC prostredníctvom S7 protokolu. Posledným komponentom je samotné PLC Siemens S7-1200, ktoré riadi prvky výrobnjej linky. Všetky tieto komponenty okrem mobilnej aplikácie a PLC bežia v Docker stacku na edge zariadení. Jediné externé volanie smeruje z AI služby na rozhranie Anthropic API.




Obr. 5: Diagram architektúry systému a komunikácia medzi komponentmi

Mobilná aplikácia komunikuje s hlavnou FastAPI službou cez REST API a prijíma aktualizácie stavu linky cez WebSocket. Príkazy odoslané z aplikácie putujú cez backend do MQTT brokera a ďalej do Node-RED, ktorý ich zapíše do PLC. Spätná väzba prechádza tou istou cestou v opačnom smere. Dáta zo senzorov PLC číta Node-RED periodicky a publikuje ich do príslušných MQTT tém, odkiaľ ich backend preposiela pripojeným klientom cez WebSocket.

8.2 Fyzická topológia systému

Fyzická topológia systému vychádza z požiadavky na lokálnu prevádzku bez závislosti od externej infraštruktúry. Celá komunikácia prebieha v rámci lokálnej siete medzi mobilnými zariadeniami, edge zariadením a riadiacimi systémami výrobných liniek. Schéma fyzickej architektúry je znázornená na obrázku 6.



Obr. 6: Fyzická topológia systému

Mobilné zariadenia sa pripájajú k edge zariadeniu bezdrôtovo cez WiFi. Voľba bezdrôtového pripojenia vychádza z charakteru práce operátora, ktorý sa pohybuje po výrobnjej hale a potrebuje mať prístup k systému kdekoľvek. Edge zariadenie je prepojené s Ethernet switchom, na ktorý sú napojené radiacie systémy výrobných liniek. Edge zariadenie plní úlohu centrálného uzla, na ktorom beží hlavný backend aj AI asistent a všetka logika spracovania príkazov sa vykonáva lokálne (okrem LLM, v práci sme zvolili externé API). Architektúra počíta s pripojením viacerých radiacích systémov, čo umožňuje rozšírenie na ďalšie výrobné linky bez zmeny základnej topológie. V súčasnej implementácii je na switch napojený jeden radiaci systém Siemens S7-1200.

8.3 Štruktúra MQTT tém

Komunikácia medzi backend službou, Node-RED a výrobnými linkami prebieha cez štruktúrované MQTT témy. Všetky témy zdieľajú spoločný prefix `plc`, za ktorým nasleduje identifikátor linky vo formáte `line_{id}`, kde `id` zodpovedá ArUco identifikátoru linky. Táto štruktúra umožňuje systému jednoznačne smerovať správy na konkrétne linky a zároveň odberateľom filtrovať témy.

```

plc/
├── device_{id}/
│   ├── data .....stav linky      Node-RED -> backend
│   ├── status ..... online/offline Node-RED -> backend
│   └── commands/
│       └── {prikaz} ..... radiaci prikaz  backend -> Node-RED
  
```

Tabuľka 6: Prehľad MQTT tém

Téma	Vydavateľ	Odberateľ	Popis
plc/device_{id}/data	Node-RED	Backend	Aktuálne hodnoty premen- ných linky
plc/device_{id}/status	Node-RED	Backend	Stav pripojenia linky (on- line/offline)
plc/device_{id}/commands/#	Backend	Node-RED	Riadiaci príkaz smerovaný na linku

Backend pri štarte subscribuje na tému `plc/#`, čím prijíma správy zo všetkých liniek naraz. Node-RED subscribuje selektívne len na témy `commands` pre linky, ktoré spravuje. Príkazy sú publikované s QoS 1, čím je zaručené doručenie aspoň raz.

9 Implementácia backendu

Backend systému tvorí dvojica nezávislých FastAPI služieb bežiacich v prostredí Docker, podrobnejšie opísaných v sekcii 8.1. V nasledujúcich podkapitolách popisujeme implementáciu autentifikácie a RBAC, REST endpointov, mechanizmu relácií, životného cyklu príkazu a generátora ArUco identifikátorov s exportom do formátu STL.

9.1 Autentifikácia a RBAC

Systém používa autentifikáciu pomocou JWT tokenov podľa štandardu OAuth2. Po úspešnom prihlásení server vygeneruje token podpísaný zdieľaným tajným kľúčom algoritmom HS256. Token obsahuje identifikátor používateľa a čas vypršania platnosti. Heslá sú uložené výhradne ako bcrypt hash.

Registrácia je verejne dostupná, avšak nový účet je predvolene neaktívny. Prístup do systému získa až po schválení administrátorom, ktorý zároveň priradí rolu. Táto dvojfázová registrácia zabraňuje neoprávnenému vstupu do systému.

Oprávnenia sú riadené štyrmi rolami. Každý chránený endpoint deklaruje požadovanú rolu ako FastAPI závislosť, čo umožňuje jednotnú kontrolu prístupu bez duplicitnej logiky.

```
async def get_line_operator(user: User = Depends(get_current_user)):  
    _ensure_role(user, {"operator", "admin", "maintenance"})  
    return user  
  
async def get_manager_or_admin(user: User = Depends(get_current_user)):  
    _ensure_role(user, {"manager", "admin"})  
    return user
```

Výpis kódu 1: Závislosti pre kontrolu rolí

9.2 API endpointy

Backend poskytuje REST API rozdelené do šiestich skupín podľa funkčnej oblasti. Endpointy pre AI asistenta sú dostupné na samostatnej službe počívajúcej na porte 8100, ostatné na porte 8000. Okrem REST komunikácie poskytuje backend WebSocket pre aktualizácie stavu linky.

Tabuľka 7: Prehľad API endpointov

Metóda	Endpoint	Popis	Rola
<i>Autentifikácia — /auth</i>			
POST	/auth/login	Prihlásenie, vracia JWT token	—
POST	/auth/register	Registrácia nového účtu	—
POST	/auth/logout	Odhlásenie	všetci
GET	/auth/me	Aktuálny prihlásený používateľ	všetci
PUT	/auth/me	Úprava mena a priezviska	všetci
POST	/auth/change-password	Zmena hesla	všetci
<i>Výrobné linky — /plc</i>			
GET	/plc/devices	Zoznam liniek	všetci
POST	/plc/devices	Vytvorenie linky	admin, údržbár
GET	/plc/devices/{aruco_id}	Detail linky	všetci
PUT	/plc/devices/{aruco_id}	Úprava linky	admin, údržbár
DELETE	/plc/devices/{aruco_id}	Vymazanie linky	admin, údržbár
POST	/plc/devices/{aruco_id}/command/{cmd}	Odoslanie príkazu	admin, údržbár, operátor
GET	/plc/stats	Dashboard štatistiky	všetci
WS	/plc/ws/{aruco_id}	Real-time stav + príkazy	všetci
<i>Relácie — /devices</i>			
GET	/devices/{aruco_id}/occupancy	Kto je prihlásený	všetci
POST	/devices/{aruco_id}/login	Prihlásenie na linku	admin, údržbár, operátor
POST	/devices/{aruco_id}/logout	Odhlásenie z linky	všetci
<i>Logy — /command-logs</i>			
GET	/command-logs	Logy s filtrami	admin, manažér, údržbár
GET	/command-logs/device/{aruco_id}	Logy linky	admin, manažér, údržbár
<i>Používatelia — /users</i>			
GET	/users	Zoznam používateľov	admin, manažér
POST	/users/{user_id}/approve	Schválenie + rola	admin, manažér
PUT	/users/{user_id}	Úprava účtu	admin, manažér
POST	/users/{user_id}/reset-password	Reset hesla	admin, manažér
DELETE	/users/{user_id}	Vymazanie účtu	admin, manažér
<i>ArÚco — /aruco</i>			
GET	/aruco/next-id	Nasledujúce voľné ID	všetci
GET	/aruco/preview/{aruco_id}	Náhľad identifikátora	všetci
GET	/aruco/png/{aruco_id}	Stiahnutie identifikátora ako PNG	všetci
GET	/aruco/stl/{aruco_id}	Stiahnutie identifikátora ako STL	všetci
<i>AI asistent — port 8100</i>			
POST	/chat	Správa AI asistentovi	všetci
GET	/kb	Zoznam záznamov znalostnej bázy	admin, manažér, údržbár
POST	/kb	Pridanie záznamu	admin, manažér, údržbár
POST	/kb/upload	Nahratie súboru do KB	admin, manažér, údržbár
PUT	/kb/{entry_id}	Úprava záznamu	admin, manažér, údržbár
DELETE	/kb/{entry_id}	Vymazanie záznamu	admin, manažér, údržbár

9.3 Mechanizmus relácií

Pred ovládaním linky sa musí používateľ na linku prihlásiť. Relácia je väzba medzi používateľom a linkou, ktorá zabráňuje súčasnému ovládaniu jednej linky viacerými používateľmi. Na každej linke môže byť aktívna práve jedna relácia.

Prihlásenie na linku prebieha volaním `POST /devices/{aruco_id}/login`. Backend overí, či je linka voľná. Ak áno, vytvorí novú reláciu. Ak je linka obsadená, správanie závisí od parametra `force` a od roly aktuálneho držiteľa relácie. Linka obsadená používateľom s rolou údržbára nemôže byť prebratá žiadnym iným používateľom. Táto ochrana zabráňuje prerušeniu servisného zásahu operátorom. Vlastnú reláciu môže ukončiť prihlásený používateľ odhlásením sa. Cudziu reláciu môže ukončiť každý, ak sa nejedná o reláciu údržbára. Je to z dôvodu, aby sa zabránilo situáciám, keď sa operátor zabudne odhlásiť a linka zostane zablokovaná. Každé prevzatie relácie je zaznamenané v logu príkazov, čo znamená dohľadateľnosť zodpovednosti. Pred prepísaním relácie systém informuje nového používateľa o tom, kto je aktuálne prihlásený. Následne je potrebné potvrdiť úmysel prevzatia, čím sa zabezpečí, že k prevzatiu nepríde náhodou.

```
if active.user.role == "maintenance":
    raise HTTPException(409, "maintenance_locked")
```

Výpis kódu 2: Ochrana relácie údržbára

9.4 Životný cyklus príkazu

Príkaz prechádza niekoľkými vrstvami systému, kým sa prejaví na linke.


Backend publikuje správu na MQTT tému `plc/device_{id}/commands/{cmd}`. Mosquitto broker správu doručí Node-RED, ktorý ju preloží do S7 protokolu a zapíše príslušnú premennú v PLC. Volajúci dostane späť potvrdenie `command_ack` s príznakom úspechu doručenia na broker. Skutočná zmena stavu je viditeľná v ďalšom cykle čítania, keď Node-RED publikuje aktualizované hodnoty na tému `plc/device_{id}/data` a backend ich pošle cez WebSocket do aplikácie.

Každý príkaz je bez ohľadu na výsledok zaznamenávaný do tabuľky `command_logs` s identifikátorom používateľa, linky, zdrojovým kanálom a príznakom úspechu doručenia.

9.5 Generátor ArUco identifikátorov a export do STL

Pre výrobu fyzických identifikátorov bola implementovaná vlastná Python trieda `ArucoSTLGeneratorVoxelOptimized`, ktorá generuje STL súbor určený na dvojfarebnú 3D tlač. Model je navrhnutý tak, aby farebné priradenie v sliceri bolo čo najjednoduchšie.

Povrch modelu je rozdelený do troch výškových úrovní. Čierne bunky identifikátora sú na základnej výške `base_height_mm`, ohraničovací rám je o `border_height_offset_mm` vyšší a biele bunky sú vyvýšené o `white_height_mm`. Pri predvolených hodnotách dosahujú čierne bunky výšku 1 mm a biele 3 mm.



Obr. 7: ArUco identifikátor tlačný z vygenerovaného STL modelu

10 Implementácia AI asistenta

Asistent je implementovaný ako samostatná FastAPI služba bežiaca na porte 8100 v rámci vlastného Docker stacku. Disponuje vlastnou PostgreSQL databázou pre záznamy znalostnej bázy a ChromaDB ako úložisko vektorov. Jediné externé sieťové volanie celej aplikácie smeruje na Anthropic API pre volanie jazykového modelu.

10.1 RAG pipeline

Spracovanie každej správy prebieha v niekoľkých krokoch. Najprv sa vykonajú dva vyhľadávacie dotazy do ChromaDB: s filtrom podľa `device_aruco_id` a všeobecný bez filtra, pričom každý vráti najviac tri najbližšie záznamy. Zo získaných kontextov, metadát relácie a histórie konverzácie sa zostaví systémový prompt, ktorý sa odošle na Claude API.

Volanie modelu sa vykonáva s aktivovaným nástrojom `web_search`, ktorý poskytuje samotný Anthropic na strane servera. Ak LLM vyhodnotí, že poskytnutý kontext nestačí na zodpovedanie otázky, sám zavolá tento nástroj. Vykoná sa vyhľadávanie a model pokračuje v generovaní odpovede s doplnenými výsledkami. Limit je nastavený na tri vyhľadávania na jednu správu. Tým, že o použití nástroja rozhoduje LLM, sa vyhľadávanie spustí len v prípadoch, keď je skutočne potrebné.

10.2 Embedovací model

Na generovanie vektorových reprezentácií textov sa používa model `nomic-embed-text`. Model beží v rámci Docker stacku na edge zariadení a nevyžaduje pripojenie na internet.

ChromaDB využíva kosínusovú podobnosť ako metriku vyhľadávania. Každý záznam znalostnej bázy sa indexuje ako reťazec `title + content` pri vytvorení aj aktualizácii.

10.3 Systémový prompt

Asistent vystupuje pod menom PLEXO. Systémový prompt existuje v slovenskej aj anglickej verzii podľa jazyka relácie. Pozostáva z dvoch častí. Prvou je sada pravidiel, ktorá určuje správanie asistenta, jazyk odpovede, formát, zákaz vymýšľania faktov a spôsob práce s kontextom. Druhú časť tvoria dynamicky dopĺňané sekcie, ktoré sa pred každým volaním modelu naplnia aktuálnymi údajmi:

- **AKTUÁLNA RELÁCIA** – meno a rola prihláseného používateľa, prípadne linka, na ktorú je prihlásený.
- **KONTEXT PRE LINKU** – výsledky vyhľadávania z ChromaDB filtrované podľa ID linky.
- **VŠEOBECNÝ KONTEXT** – výsledky vyhľadávania z ChromaDB bez filtra linky.

```
SYSTEM_PROMPT_SK = """Tvoje meno je PLEXO. Si priemyselný asistent aplikácie
    Scan2Control na riadenie výrobných liniek s využitím ArUco identifikátorov.
{intro_instruction}
PRAVIDLÁ:
1. Odpovedaj VÝHRADNE po slovensky.
2. Odpovedaj prednostne na základe informácií z kontextu nižšie. Ak tam odpoveď
    nie je, môžeš použiť nástroj na vyhľadávanie na internete.
3. Buď stručný a praktický. Používaj odrážky a krátke vety.
4. Nepoužívaj emotikony.
5. Ak sa používateľ pýta na svoje meno, rolu alebo linku, odpoveď nájdeš v sekcii
    AKTUÁLNA RELÁCIA.
6. Ak sa používateľ pýta na konkrétnu linku, prednostne použi informácie z
    KONTEXTU PRE LINKU.
7. Nikdy nevymýšľaj fakty, dátumy ani čísla. Ak niečo nevieš, priznaj to.
8. Ak odpovedáš na základe vyhľadávania na internete, jasne to v odpovedi označ.
    """
```

Výpis kódu 3: Základ systémového promptu AI asistenta PLEXO

Okrem pravidiel správania prompt obsahuje aj inštrukciu, aby sa asistent pri prvej správe konverzácie krátko predstavil. V ďalších správach sa toto predstavenie vynecháva.

10.4 Správa konverzácie

Server je bezstavový a história konverzácie sa neukladá na strane servera, ale je súčasťou každého požiadavku zo strany klienta. Služba prijíma pole správ vo formáte `{role, content}` a pri zostavovaní volania zahŕňa posledných desať správ. Tento prístup nevyžaduje žiadne serverové úložisko relácií a zjednodušuje škálovanie.

10.5 Správa znalostnej bázy

Znalostná báza je tvorená textovými záznamami uloženými v PostgreSQL. Každý záznam má názov, obsah a voliteľne priradené ID linky. Toto priradenie umožňuje vyhľadávanie obsahu filtrovaného pre konkrétnu linku, čo zvyšuje presnosť odpovedí pri otázkach viazaných na konkrétny stroj.

Pri každom vytvorení alebo úprave záznamu sa jeho vektorová reprezentácia synchronizuje do ChromaDB operáciou `upsert`. Mazanie záznamu odstráni aj príslušný vektor. Okrem manuálneho zadania textu API podporuje nahranie súboru vo formáte `.txt`, čo umožňuje import existujúcej technickej dokumentácie.

11 Implementácia frontendu

Frontend je implementovaný vo Flutter s podporou platformy Android ako primárneho cieľa a webového prehliadača pre administrátorský panel. Zdieľa takmer všetok kód medzi platformami s výnimkou ArUco skenovania, pretože v administrátorskom paneli táto funkcionality nie je potrebná.

11.1 Stavový manažment

Aplikácia používa knižnicu Riverpod so vzorcom `StateNotifier`. Centrálnym poskytovateľom je `AuthProvider`, ktorý uchováva JWT token, objekt prihláseného používateľa a príznaky stavu autentifikácie. Pri štarte aplikácie sa volá `tryRestoreSession`, ktorá overí uložený token volaním `/auth/me`. Ak je token platný, relácia sa obnoví.

11.2 ArUco skenovanie

Skenovanie prebieha v natívnom kóde prostredníctvom balíčka `opencv_dart`. Každý snímok z kamery dorazí vo formáte YUV420, z ktorého sa extrahuje kanál Y ako grayscale obraz. Samotná detekcia beží v Dart izolovanom vlákne pomocou `Isolate.run`, čím sa zabráni blokovaniu vykresľovacieho vlákna.

V izolovanom vlákne sa vytvorí detektor s preddefinovaným slovníkom `DICT_5X5_250` a zavolá sa `detectMarkers`. Pre každý detekovaný identifikátor sa vypočíta plocha Shoelaceovým vzorcom a stred ako relatívna poloha v obraze. Výstupom je zoznam detekovaných identifikátorov zoradených od najväčšieho po najmenší, kde väčšia plocha znamená bližší identifikátor. Príznak `_isProcessing` zabráňuje spusteniu ďalšej detekcie kým prebieha predchádzajúca.

11.3 WebSocket pripojenie

Po načítaní linky sa nadväzuje WebSocket spojenie cez balíček `web_socket_channel`. Server posiela tri typy správ: heartbeat, ktorý sa ignoruje, potvrdenie príkazu `command_ack` a aktualizáciu hodnôt premenných. Pri chybe alebo zatvorení spojenia sa po dvoch sekundách automaticky pokúsi o znovupripojenie.

Odosielanie príkazu funguje tak, že sa na WebSocket pošle JSON správa `{command, value}` a spustí sa päťsekundový časovač. Server najskôr vráti správu `command_ack`, ktorá potvrdzuje doručenie príkazu MQTT brokerovi. Ak je `success == false`, zobrazí sa chybové hlásenie okamžite. Ak je `success == true`, aplikácia čaká na skutočnú zmenu hodnoty premennej z linky. Keď táto zmena dorazí, zobrazí sa snackbar s po-

tvrdenou hodnotou a nameranou latenciou. Ak päťsekundový časovač vyprší skôr ako hodnota dorazí, zobrazí sa chybové hlásenie.

11.4 Používateľské rozhranie podľa roly

Viditeľnosť prvkov rozhrania je riadená pomocnými metódami triedy **AuthUser**. Každá metóda vracia booleovskú hodnotu na základe role prihláseného používateľa. Prehľad rolí je uvedený v tabuľke 8.

Tabuľka 8: Oprávnenia podľa roly používateľa

Oprávnenie	Operátor	Manažér	Údržbár	Administrátor
Ovládanie linky	✓	—	✓	✓
Zobrazenie zoznamu liniek	—	✓	✓	✓
Správa liniek	—	—	✓	✓
Správa používateľov	—	✓	—	✓
Správa znalostnej bázy	—	✓	✓	✓
Zobrazenie logov príkazov	—	✓	✓	✓
AI asistent	✓	✓	✓	✓

12 Opis funkcionalít aplikácie pre používateľa

12.1 Skener ArUco identifikátorov

Dostupné pre: operátor, údržbár, administrátor

Skener ArUco identifikátorov slúži ako primárny spôsob prihlásenia sa na konkrétnu linku. Používateľ namieri kameru mobilného zariadenia na ArUco identifikátor umiestnený priamo na linke a systém ho automaticky identifikuje. Po úspešnom naskenovaní je používateľ priradený k danej linke a získava prístup k jeho monitorovaniu a ovládaniu. Tento prístup eliminuje manuálne vyhľadávanie liniek a zabezpečuje, že používateľ pracuje s tou správnou linkou.

12.2 Generátor ArUco identifikátorov

Dostupné pre: údržbár, manažér, administrátor

Pri zakladaní novej linky v systéme aplikácia automaticky vygeneruje unikátny ArUco identifikátor, ktorý jednoznačne identifikuje danú linku. Identifikátor je možné exportovať vo formáte PNG pre bežnú tlač alebo vo formáte STL ako trojrozmerný model vhodný na 3D tlač, pričom biela časť identifikátora je vyvýšená nad čiernou základňou. Fyzická značka sa následne umiestni na linku, čím sa prepojí záznam v systéme s reálnou linkou v prevádzke.

12.3 Monitoring a ovládanie liniek

Dostupné pre: operátor, údržbár, administrátor

Monitoring a ovládanie liniek predstavuje hlavnú funkcionálnu aplikácie. Po prihlásení na linku má používateľ k dispozícii prehľad aktuálneho stavu linky. Môže sledovať stavy senzorov, aktuálny režim prevádzky, stav v ktorom sa linka nachádza, a iné prevádzkové parametre. Okrem sledovania stavu môže používateľ linku aj priamo ovládať, napríklad spustiť alebo zastaviť cyklus, zmeniť smer pohybu či vykonať reset. Všetky zmeny sa prejavujú rádo v desiatkach milisekúnd, čo umožňuje rýchlu reakciu na aktuálnu situáciu v prevádzke. Systém zároveň zaznamenáva históriu vykonaných príkazov pre potreby kontroly a auditu.

12.4 Virtuálny asistent PLE XO

Dostupné pre: operátor, údržbár, manažér, administrátor

Virtuálny asistent PLEXO je inteligentný pomocník dostupný priamo v aplikácii. Používatelia môžu kladať otázky prirodzeným jazykom, napríklad o aktuálnom stave linky, postupe pri riešení poruchy alebo pokynoch na údržbu. Asistent odpovedá na základe znalostnej bázy vytvorenej pre konkrétne linky a prevádzku. Vďaka tomu má operátor alebo údržbár potrebné informácie vždy po ruke, bez nutnosti listovať v technickej dokumentácii. Asistent komunikuje v jazyku nastavenom používateľom v nastaveniach aplikácie.

12.5 Správa používateľov

Dostupné pre: manažér, administrátor

Správa používateľov poskytuje oprávneným osobám nástroje na riadenie prístupu do systému. Manažér alebo administrátor môže vytvárať nové používateľské účty, upravovať existujúce, pridelať príslušné roly podľa pracovného zaradenia a v prípade potreby účty odstrániť resp. deaktivovať. Systém rolí zabezpečuje, že každý používateľ vidí a môže vykonávať iba tie akcie, ktoré zodpovedajú jeho pracovnej pozícii, čím sa minimalizuje riziko neoprávneného zásahu do prevádzky.

12.6 Správa liniek

Dostupné pre: údržbár, manažér, administrátor

Správa liniek umožňuje udržiavať databázu liniek aktuálnu a v súlade so skutočným stavom prevádzky. Oprávnený používateľ môže do systému pridať novú linku, nastaviť jej parametre a vygenerovať pre ňu ArUco identifikátor. Pri existujúcich linkách je možné upravovať, čo sa zobrazuje v ovládacom paneli linky a v akom poradí. Taktiež je možné ich zo systému odstrániť, ak boli vyradené z prevádzky. Vďaka tejto funkcionalite systém vždy odráža reálny stav liniek v prevádzke.

12.7 Správa znalostnej bázy

Dostupné pre: údržbár, manažér, administrátor

Znalostnú bázu tvorí súbor informácií, z ktorých čerpá virtuálny asistent PLEXO pri odpovedaní na otázky používateľov. Oprávnení používatelia môžu do znalostnej bázy priebežne pridávať nové dokumenty, upravovať existujúce záznamy alebo odstraňovať zastarané informácie. Kvalita a aktuálnosť znalostnej bázy priamo ovplyvňuje relevantnosť a presnosť odpovedí asistenta, preto je jej pravidelná údržba dôležitou súčasťou prevádzky systému.

12.8 Nastavenia

Dostupné pre: operátor, údržbár, manažér, administrátor

Každý používateľ má možnosť prispôbiť si aplikáciu podľa vlastných preferencií. V nastaveniach môže zmeniť jazyk rozhrania, ktorý sa automaticky uplatní aj na komunikáciu s virtuálnym asistentom PLEXO. Zároveň si môže zmeniť svoje prístupové heslo. Tieto nastavenia sú viazané na konkrétny používateľský účet a zostávajú zachované aj po opätovnom prihlásení.

13 Testovanie a meranie

Cieľom tejto kapitoly je overiť, či výsledná aplikácia spĺňa požiadavky definované v kapitole 5, a vyjadriť jej spoľahlivosť a efektivitu v laboratórnom a priemyselnom prostredí.

Testovanie prebiehalo na nasledujúcej zostave. Ako edge zariadenie poslužil notebook s 32 GB RAM a procesorom AMD Ryzen 5 5600H, na ktorom bežali Mosquitto, Node-RED, hlavný backend aj AI asistent v Docker kontajneroch. Výrobnú linku predstavoval model dopravníka Fischertechnik riadený PLC Siemens S7-1200. Mobilný klient bežal na zariadení Samsung Galaxy A54 s OS Android 14, pripojenom do tej istej WiFi siete ako edge počítač. Identifikátory boli vytlačené technológiou FDM na tlačiarňu Bambu Lab P1S s veľkosťou hrany 100 mm. Časť meraní detekcie bola vykonaná aj v skutočných priestoroch priemyselnej haly, čo umožnilo overenie systému v reálnych svetelných podmienkach.

Merania latencie a úspešnosti detekcie boli vykonané v sériách opakovaných pokusov a výsledky sú uvádzané formou priemernej hodnoty, minima, maxima. Kvalita odpovedí asistenta bola vyhodnotená na pevnej množine reprezentatívnych otázok podľa kritérií zavedených v kapitole 7.2.

13.1 Overenie splnenia špecifikácie

Prvá fáza testovania overovala, či implementácia pokrýva požiadavky stanovené v kapitole 5. Splnenie každej požiadavky bolo vyhodnotené jednou z troch možností: *splnené* pre požiadavku, ktorá bola implementovaná v plnej miere, *čiastočne splnené* pre požiadavku s istými obmedzeniami a *nesplnené* pre požiadavku, ktorá nebola implementovaná.

Tabuľka 9: Overenie funkčných požiadaviek

ID	Stručný popis	Stav
FP1	Načítanie unikátneho identifikátora a spárovanie s linkou	splnené
FP2	Odosielanie príkazov v riadenom systéme	splnené
FP3	Verifikácia príkazov a vizuálna indikácia vykonania	splnené
FP4	Zobrazovanie aktuálnych stavov z PLC	splnené
FP5	Chatbot s RAG a označenie iného zdroja informácií	splnené
FP6	Lokalizácia rozhrania a chatbota v SK a EN	splnené
FP7	Mechanizmus exkluzívnej relácie na linke	splnené
FP8	Informácia o obsadení linky a riadené prevzatie relácie	splnené
FP9	JWT autentifikácia a RBAC so štyrmi rolami	splnené
FP10	Log operácií dostupný pre manažéra, údržbára a admina	splnené

Tabuľka 10: Overenie nefunkčných požiadaviek

ID	Stručný popis	Stav
NFP1	Kontajnerizácia backendu pomocou Docker na edge zariadení	splnené
NFP2	Prenos správ v edge infraštruktúre cez MQTT s QoS 1	splnené
NFP3	Latencia príkazov pod 250 ms od odoslania po zápis do PLC	splnené
NFP4	Odpovede asistenta viazané na kontext, priznanie chýbajúcej informácie	splnené
NFP5	Integrita databázy pri náhlom prerušení napájania edge zariadenia	splnené
NFP6	Rýchle nasadenie identického stacku cez Docker Compose	splnené
NFP7	Ovládacie príkazy len z lokálnej siete továrne	splnené
NFP8	Štruktúrované logy backendu pre účely diagnostiky	splnené

Tabuľka 11: Overenie doménových požiadaviek

ID	Stručný popis	Stav
DP1	Komunikácia s PLC cez natívny protokol S7	splnené
DP2	Farebná indikácia stavov podľa normy IEC 60073	splnené
DP3	Zachovanie ovládania linky aj pri výpadku internetu	splnené

Všetky funkčné aj nefunkčné požiadavky boli vyhodnotené ako splnené. Doménová požiadavka DP3 bola overená odpojením edge zariadenia od WAN portu, pričom mobilná aplikácia naďalej úspešne odosiela príkazy aj prijímala stav linky. Jediný komponent,

ktorý je v takomto režime nedostupný, je AI asistent, čo zodpovedá architektonickému rozhodnutiu opísanému v kapitole 7.2.

13.2 Latencia vykonania príkazov

Latencia bola meraná pre kompletný reťazec od mobilu až po PLC a spätné prečítanie novej hodnoty späť do mobilu. Začiatok merania predstavuje stlačenie tlačidla v mobilnej aplikácii. Mobil zaznamená lokálnu časovú značku, odošle príkaz a ďalej iba čaká. Backend síce hneď po publikovaní príkazu na MQTT broker vráti potvrdenie `command_ack`, mobil ho však pri úspešnom doručení iba ticho prijme. Koncom merania je až moment, keď cez WebSocket dorazí aktualizovaná hodnota premennej, ktorú príkaz mal zmeniť. Toto meranie tak zahŕňa aj polling cyklus Node-RED a samotné vykonanie príkazu v PLC, čo predstavuje skutočnú latenciu vnímanú obsluhou. Vďaka lokálnej časovej značke nie je potrebná synchronizácia hodín medzi mobilom a serverom.

Pre každý typ príkazu bolo vykonaných 25 opakovaní. Testované boli tri príkazy. Výsledky sú uvedené v tabuľke 12.

Tabuľka 12: Štatistika latencie príkazov v milisekundách (n=25)

Príkaz	Priemer	Min	Max
Štart dopravníka	142	96	218
Stop dopravníka	138	91	207
Zmena smeru	156	102	234

Priemerná latencia naprieč všetkými príkazmi dosiahla 145 ms, čo s rezervou spĺňa požiadavku NFP3 na hornú hranicu 250 ms. Maximálne hodnoty sa v žiadnom z 25 opakovaní nepriblížili k stanovenému limitu.

13.3 Detekcia ArUco identifikátorov

Testovanie detekcie sledovalo úspešnosť rozpoznania identifikátora na mobilnom zariadení. Identifikátor s veľkosťou hrany 100 mm bol umiestnený na linke a kamera mobilu bola držaná v rôznych vzdialenostiach a uhloch. Pre každú kombináciu vzdialenosti a uhla bolo vyhodnotených 30 pokusov, z ktorých sa určil pomer úspešne určených identifikátorov.

Tabuľka 13: Úspešnosť detekcie podľa vzdialenosti a uhla (n=30)

Vzdialenosť	0°	15°	30°	45°
30 cm	100 %	100 %	100 %	97 %
60 cm	100 %	100 %	97 %	90 %
100 cm	100 %	97 %	93 %	80 %
150 cm	97 %	93 %	83 %	67 %

Z výsledkov vyplýva, že systém spoľahlivo pracuje do vzdialenosti jedného metra pri uhle do 30 stupňov. Pri väčších vzdialenostiach a šikmejších uhloch klesá rozlíšenie buniek identifikátora pod hranicu, ktorú knižnica OpenCV dokáže s istotou vyhodnotiť. Pre praktické nasadenie sa odporúča vzdialenosť do jedného metra a približne kolmé natočenie kamery na rovinu identifikátora.

Vplyv osvetlenia bol overený v troch prostrediach. Prvým bolo priemyselné osvetlenie výrobnjej haly so stropnými LED svetidlami, druhým bežné kancelárske osvetlenie a tretím tlmene osvetlená miestnosť. Merania v hale prebiehali priamo na mieste v priemyselnom podniku, do ktorého sme mali povolený vstup. Vzhľadom na absenciu kalibrovaného luxmetra nie sú uvádzané presné hodnoty svetelných podmienok. Výsledky sú v tabuľke 14.

Tabuľka 14: Úspešnosť detekcie podľa prostredia (vzdialenosť 60 cm, uhol 0°, n=30)

Prostredie	Úspešnosť
Priemyselná hala s LED svetidlami	100 %
Kancelársky priestor	100 %
Tlmene osvetlená miestnosť	93 %

Vďaka dvojfarebnému tlačnému prevedeniu identifikátora je kontrast dostatočný aj v priestoroch so slabším osvetlením.

13.4 Kvalita odpovedí AI asistenta

Asistent bol nasadený s modelom Claude Haiku 4.5 cez Anthropic API a vektorovou databázou ChromaDB, do ktorej bola vložená znalostná báza pripravená v rámci tejto práce. Pre vyhodnotenie bola použitá rovnaká metodika ako v kapitole 7.2, no aplikovaná na produkčné nasadenie cez Anthropic API namiesto lokálnych modelov. Sada obsahovala 15 testovacích otázok rozdelených do troch kategórií. Prvá kategória obsahuje otázky priamo pokryté v znalostnej báze, druhá otázky vyžadujúce kombináciu

informácií z viacerých záznamov a tretia otázka, ktoré v báze nie sú a očakáva sa použitie nástroja na vyhľadávanie na internete.

Každá odpoveď bola hodnotená v troch kritériách na škále 1 až 5: vecná správnosť, úplnosť a zrozumiteľnosť. Hodnotenie vykonal autor práce rovnako ako v kapitole 7.2. Výsledky sú v tabuľke 15.

Tabuľka 15: Kvalita odpovedí asistenta

Kategória otázok	Počet	Správnosť	Úplnosť	Zrozumiteľnosť
Priamo z bázy	5	4,9	4,7	4,9
Kombinácia záznamov	5	4,5	4,3	4,7
Mimo bázy (web search)	5	4,2	4,1	4,6

Pri otázkach pokrytých v báze asistent dosahoval takmer maximálne hodnotenie. Pri otázkach vyžadujúcich kombináciu informácií sa občas vyskytol problém s vynechaním jedného z relevantných záznamov, čo sa premietlo do nižšieho hodnotenia úplnosti. Pri otázkach mimo bázy asistent korektne identifikoval potrebu vyhľadávania, použil zabudovaný nástroj `web_search` a uviedol zdroj. Iba v jednom prípade z piatich uviedol mierne neaktuálnu informáciu, ktorú by bolo nutné overiť ručne. Priemerná dĺžka odpovede bola tri až päť viet, žiadna z odpovedí neobsahovala emotikony a prepínanie medzi slovenčinou a angličtinou podľa nastavenia funguje korektne.

Priemerný čas odpovede asistenta sa pohyboval okolo 4,1 sekundy pri otázkach bez vyhľadávania a okolo 9,5 sekundy pri otázkach, ktoré spustili `web_search`. Tieto hodnoty sú výrazne nižšie ako pri lokálnych modeloch testovaných v kapitole 7.2, čo potvrdzuje, že prechod na cloudové API odstránil hardvérovú limitáciu odhalenú počas predchádzajúcich meraní.

13.5 Zhrnutie výsledkov testovania

V laboratórnom aj priemyselnom prostredí sa podarilo overiť všetky funkčné, nefunkčné aj doménové požiadavky bez výhrad. Latencia vykonania príkazov sa pohybovala výrazne pod limitom 250 ms stanoveným v NFP3, čím systému ostáva dostatočná rezerva aj pre menej priaznivé sieťové podmienky. Detekcia ArUco identifikátorov je spoľahlivá v praktickom rozsahu vzdialeností a uhlov a obstála aj v hale s priemyselným osvetlením. Asistent poskytuje správne a stručné odpovede, pričom vyhľadávanie na internete dopĺňa znalostnú bázu pri otázkach mimo jej rozsah.

Identifikované obmedzenia sú menšieho charakteru. Mierny pokles spoľahlivosti detekcie pri šikmých uhloch nad 30 stupňov je riešiteľný pokynom pre operátora.

Vynechávanie jedného z relevantných záznamov pri otázkach vyžadujúcich syntézu sa dá riešiť rozšírením počtu kontextových dokumentov posielaých do modelu.

Na základe vykonaných meraní možno konštatovať, že aplikácia spĺňa kritériá stanovené v zadaní práce.

Záver

TODO: Napisat strucne co sme dosiahli, ze sme splnili ciele zadania a overili funkcnost

Literatúra

1. SIEMENS AG. *SIMATIC WinCC Unified PC* [online]. Siemens, 2025 [cit. 2026-04-07]. Dostupné z: <https://www.siemens.com/en-us/products/simatic-hmi/wincc-unified-software/>.
2. SIEMENS AG. *Engineering Copilot TIA Standard (Managed Service)* [online]. Siemens, 2025 [cit. 2026-04-07]. Dostupné z: <https://www.siemens.com/en-us/products/tia-portal/engineering-copilot-tia-standard/>.
3. INDUCTIVE AUTOMATION. *Ignition SCADA Software* [online]. Inductive Automation, 2026 [cit. 2026-04-07]. Dostupné z: <https://inductiveautomation.com/scada-software/>.
4. INDUCTIVE AUTOMATION. *Ignition Edge* [online]. Inductive Automation, 2026 [cit. 2026-04-07]. Dostupné z: <https://inductiveautomation.com/ignition/edge>.
5. TULIP INTERFACES. *Pricing and Plans* [online]. Tulip Interfaces, 2026 [cit. 2026-04-07]. Dostupné z: <https://tulip.co/plans/>.
6. TULIP INTERFACES. *Tulip Signs Strategic Collaboration Agreement With AWS to Build Generative AI Capabilities Empowering Frontline Workers* [online]. Tulip Interfaces, 2024-04-23 [cit. 2026-04-07]. Dostupné z: <https://tulip.co/press/tulip-signs-strategic-collaboration-agreement-with-aws-to-build-generative-ai-capabilities-empowering-frontline-workers/>.
7. AVEVA SOLUTIONS LIMITED. *AVEVA™ Edge* [online]. AVEVA, 2026 [cit. 2026-04-07]. Dostupné z: <https://www.aveva.com/en/products/edge/>.
8. AVEVA SOLUTIONS LIMITED. *Industrial AI for Operations* [online]. AVEVA, 2026 [cit. 2026-04-07]. Dostupné z: <https://www.aveva.com/en/solutions/digital-transformation/artificial-intelligence/industrial-ai-for-operations/>.
9. EITBIZ - EXTROVERT INFORMATION TECHNOLOGY. *Top App Development Frameworks to Build High-Performance Apps in 2026* [online]. Medium, 2025-12-23 [cit. 2026-04-07]. Dostupné z: <https://medium.com/@eitbiz/top-app-development-frameworks-for-high-performance-apps-in-2026-2db28c6c0a33>.
10. NADARAJAN, C. *How to Choose the Best Backend Frameworks in 2026 for AI-Powered Software: A Business Leader's Guide* [online]. ThinkPalm Technologies, 2025-12-01 [cit. 2026-04-07]. Dostupné z: <https://thinkpalm.com/blogs/how-t>

o-choose-the-right-backend-framework-for-ai-powered-software-a-business-leaders-guide/.

11. GARAI, K. *From Cloud to Edge: How Technology Is Redefining Data Processing* [online]. Medium, 2026-03-10 [cit. 2026-04-07]. Dostupné z: <https://medium.com/@kastab/from-cloud-to-edge-how-technology-is-redefining-data-processing-43b66acde782>.
12. DOCKER INC. *Docker Overview* [online]. Docker Documentation, 2026 [cit. 2026-04-07]. Dostupné z: <https://docs.docker.com/get-started/docker-overview/>.
13. OPC FOUNDATION. *OPC Unified Architecture* [online]. OPC Foundation, 2026 [cit. 2026-04-07]. Dostupné z: <https://opcfoundation.org/about/opc-technologies/opc-ua/>.
14. SIEMENS AG. *S7 Communication* [online]. Siemens TIA Portal Documentation, 2026 [cit. 2026-04-09]. Dostupné z: https://docs.tia.siemens.cloud/r/simatic_et_200clean_manual_collection_zhcn_20/function-manuals/communication-function-manuals/communication/s7-communication/s7-communication.
15. OASIS. *MQTT Version 5.0* [online]. OASIS, 2019-03-07 [cit. 2026-04-07]. Dostupné z: <https://docs.oasis-open.org/mqtt/mqtt/v5.0/mqtt-v5.0.html>.
16. MODBUS ORGANIZATION. *Modbus FAQ* [online]. Modbus Organization, 2026 [cit. 2026-04-07]. Dostupné z: <https://www.modbus.org/faq.php>.
17. STRYKER, C. *What are large language models (LLMs)?* [online]. IBM Think, 2025 [cit. 2026-04-11]. Dostupné z: <https://www.ibm.com/think/topics/large-language-models>.
18. ULLAH, I. *API vs. Self-Hosted LLM: Which Path Is Right for Your Enterprise?* [online]. Medium, 2025-08-28 [cit. 2026-04-11]. Dostupné z: <https://theirfan.medium.com/api-vs-self-hosted-llm-which-path-is-right-for-your-enterprise-82c60a7795fa>.
19. IBM. *What is retrieval augmented generation (RAG)?* [online]. IBM Think, 2025 [cit. 2026-04-11]. Dostupné z: <https://www.ibm.com/think/topics/retrieval-augmented-generation>.
20. RICADELA, A. *What Is Chroma? An Open Source Embedded Database* [online]. Oracle, 2024-04-15 [cit. 2026-04-11]. Dostupné z: <https://www.oracle.com/anz/database/vector-database/chromadb/>.

21. KUNTZ, C. *The New Industrial Evolution: How AI Assistants and Agents Are Transforming Manufacturing Knowledge* [online]. Training Industry, 2025-04-08 [cit. 2026-04-11]. Dostupné z: <https://trainingindustry.com/articles/work-force-development/the-new-industrial-evolution-how-ai-assistants-and-agents-are-transforming-manufacturing-knowledge/>.
22. META AI. *llama3.2* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/llama3.2>.
23. GOOGLE DEEPMIND. *gemma4* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/gemma4>.
24. MISTRAL AI; NVIDIA. *mistral-nemo* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/mistral-nemo>.
25. MICROSOFT. *phi4* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/phi4>.
26. MISTRAL AI. *mistral-small* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/mistral-small>.

Použitie nástrojov umelej inteligencie

Anthropic (2026), Claude Sonnet 4.6, kontrola gramatiky a štylistická úprava vlastných textov.

Anthropic (2026), Claude Opus 4.6, generovanie obsahu znalostnej bázy.

Anthropic (2026), Claude Opus 4.6, generovanie časti kódu na základe inštrukcií.

Anthropic (2026), Claude Opus 4.7, generovanie testovacích otázok pre AI asistenta.

Dodatok A: Súborová štruktúra

Suborova struktura

Dodatok B: Prílohy k testovaniu

Prílohy k testovaniu

Dodatok C: Návod na spustenie

Navod na spustenie

Dodatok D: Opis funkcionalít aplikácie

Opis funkcií aplikácie pre odborne neinteresovanú osobu, ktorá sa chce dozvedieť, čo aplikácia robí a ako jej môže pomôcť v práci.

Sem možno presunúť kapitolu 12