

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104378-115323

**Mobilná aplikácia na ovládanie výrobnéj linky s
využitím jedinečného identifikátora**

Diplomová práca

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104378-115323

Mobilná aplikácia na ovládanie výrobnéj linky s využitím jedinečného identifikátora

Diplomová práca

Študijný program:	Aplikovaná mechatronika a elektromobilita
Študijný odbor:	Kybernetika
Školiace pracovisko:	Ústav automobilovej mechatroniky (FEI)
Školiteľ:	Ing. Lukáš Beňo PhD.



ZADANIE BAKALÁRSKEJ PRÁCE

Študent: **Meno Priezvisko**
ID študenta: 012345
Študijný program: jadrové a fyzikálne inžinierstvo
Študijný odbor: elektrotechnika
Vedúci práce: tituly, Meno Priezvisko, tituly
Vedúci pracoviska: tituly Meno Priezvisko, tituly
Miesto vypracovania: Ústav jadrového a fyzikálneho inžinierstva

Názov práce: **Rozšírená šablóna záverečnej práce na FEI STU v Bratislave
v systéme LaTeX**

Jazyk, v ktorom sa práca vypracuje: slovenský jazyk

Špecifikácia zadania:

- Vytvorte šablónu záverečnej práce pre študentov bakalárskeho a inžinierskeho štúdia na FEI STU v Bratislave.
- Napište návod na písanie záverečnej práce s použitím vytvorenej šablóny.
- Vytvorte prehľad najpoužívanejších typov citovaných zdrojov a zdokumentujte ich tak, aby boli v súlade s normou ISO 690.

Zoznam odbornej literatúry:

- Zákon č. 131/2002 Z. z. z 21. februára 2002 o vysokých školách a o zmene a doplnení niektorých zákonov [online]. [cit. 2024-09-01]. Dostupné na https://www.slov-lex.sk/static/pdf/2002/131/ZZ_2002_131_20240901.pdf
- Vyhláška č. 233/2011 Z. z. Ministerstva školstva, vedy, výskumu a športu Slovenskej republiky z 1. júla 2011, ktorou sa vykonávajú niektoré ustanovenia zákona č. 131/2002 Z. z. o vysokých školách a o zmene a doplnení niektorých zákonov v znení neskorších predpisov [online]. [cit. 2024-09-01]. Dostupné na https://www.slov-lex.sk/static/pdf/2011/233/ZZ_2011_233_20201015.pdf

3. Metodické usmernenie Ministerstva školstva, vedy, výskumu a športu SR č. 56/2011 o náležitostiach záverečných prác, ich bibliografickej registrácii, kontrole originality, uchovávaní a sprístupňovaní č. 2011-11513/31015:4-071 [online]. [cit. 2024-09-24]. Dostupné na <http://www.minedu.sk/metodicke-usmernenie-c-562011-o-nalezitostiach-zaverecných-prac-ich-bibliografickej-registrácii-uchovavani-a-sprístupnovani/>.
4. STN ISO 214: 1998. Dokumentácia. Abstrakty (referáty) pre publikácie a dokumentáciu. Bratislava: Slovenský ústav technickej normalizácie. Bratislava. Úrad pre metrológiu a skúšobníctvo Slovenskej republiky.
5. STN ISO 690: 2022. Dokumentácia – Bibliografické odkazy – Obsah, forma a štruktúra. Bratislava. Úrad pre metrológiu a skúšobníctvo Slovenskej republiky.
6. STN 01 6910: 2023. Pravidlá písania a úpravy písomností. Bratislava. Úrad pre metrológiu a skúšobníctvo Slovenskej republiky.
7. STN ISO 2145: 1997. Dokumentácia. Číslovanie oddielov a pododdielov písaných dokumentov. Bratislava. Úrad pre metrológiu a skúšobníctvo Slovenskej republiky.
8. STN ISO EN 80 000-1: 2022. Veličiny a jednotky. Bratislava. Úrad pre metrológiu a skúšobníctvo Slovenskej republiky.
9. LICHNEROVÁ, L. a B. BELLÉROVÁ. Nové pravidlá citovania podľa ISO 690 z roku 2021. *ITlib. Informačné technológie a knižnice*, 3–4/2023, 10 – 22. [cit. 2024-09-06]. Dostupné na <http://doi.org/10.52036/1335793X.2023.3-4.10-22>.
10. HOFTICH, M. ISO 690 biblatex style [online]. [cit. 2024-09-30]. Dostupné na <https://mirrors.ibiblio.org/CTAN/macros/latex/contrib/biblatex-contrib/biblatex-iso690/biblatex-iso690.pdf>.

Termín odovzdania bakalárskej práce:	31. 05. 2025
Dátum schválenia zadania bakalárskej práce:	28. 02. 2025
Zadanie bakalárskej práce schválil:	tituly Meno Priezvisko, tituly – garant študijného programu

Podakovanie

Na tomto mieste by som sa rád poďakoval Ing. Lukášovi Beňovi PhD. za cenné rady a pomoc pri písaní diplomovej práce.

Abstrakt

Príručka pre študentov Fakulty elektrotechniky a informatiky STU v Bratislave obsahuje rady a návody, ako z formálneho hľadiska pristupovať k vypracovaniu záverečnej práce vysokoškolského štúdia. Dokument zároveň môže slúžiť ako šablóna práce v systéme na sadzbu textu $\text{\LaTeX}$. Detailne sa zaoberá pravidlami sadzby matematických rovníc, číslovania plávajúcich objektov a odkazovaním na ne. Podrobne sa venuje aj spôsobu citovania externých literárnych zdrojov.

Kľúčové slová

Ovládanie výrobnéj linky, mobilná aplikácia, jedinečný identifikátor, AI asistent

Abstract

The manual for students of the Faculty of Electrical Engineering and Information Technology at Slovak University of Technology in Bratislava provides advice and guidelines on how to approach the formal aspects of writing a final thesis for university studies. The document can also serve as a template for the thesis in the $\text{\LaTeX}$ typesetting system. It covers in detail the rules for typesetting mathematical equations, numbering floating objects, and referencing them. It also thoroughly addresses the method of citing external literary sources.

Keywords

Production line control, mobile application, unique identifier, AI assistant

Obsah

Úvod	1
1 Analýza existujúcich riešení	3
1.1 Siemens WinCC Unified	3
1.2 Ignition Perspective	4
1.3 Tulip	5
1.4 AVEVA InTouch Edge HMI	6
2 Prehľad technológií pre vývoj aplikácií a priemyselnú komunikáciu	8
2.1 Frontendové technológie	8
2.2 Backendové technológie	9
2.3 Kontajnerizácia a edge architektúra	9
2.3.1 Docker a Docker Compose	10
2.4 Priemyselné komunikačné protokoly	10
2.4.1 OPC UA	10
2.4.2 S7 Protokol	11
2.4.3 MQTT	11
2.4.4 Modbus TCP	12
3 Prehľad technológií pre inteligentných asistentov	13
3.1 Veľké jazykové modely a možnosti použitia	13
3.2 Retrieval-Augmented Generation	13
3.3 AI asistenti v priemyselnom prostredí	14
4 Typy identifikátorov a ich použitie	15
4.1 QR kódy	15
4.2 Fiduciálne markery – AprilTag, ArUco	15
4.3 3D identifikátory	16
4.3.1 Princíp a štruktúra	16
5 Špecifikácia požiadaviek na systém	18
5.1 Opis systému	18
5.2 Popis používateľských rolí	18
5.3 Use-case scenáre	19
5.4 Funkcionálne požiadavky	20
5.5 Nefunkcionálne požiadavky	21
5.6 Doménové požiadavky	22

6	Voľba technológií	23
6.1	Komunikácia s PLC – S7 protokol	23
6.2	Komunikačná middleware vrstva – Node-RED	23
6.3	Transportný protokol – MQTT	24
6.4	Backend – FastAPI	24
6.5	Frontend – Flutter	25
6.6	Výber identifikátora – ArUco	25
7	Experimentálne porovnanie a výber jazykových modelov	27
7.1	Popis testovaných modelov	27
7.2	Metodika testovania	28
7.3	Výsledky porovnania	29
7.4	Analýza výsledkov a výber modelu	30
7.4.1	Overenie na cloudovom hardvéri	30
7.4.2	Záverečné rozhodnutie o architektúre AI asistenta	31
8	Návrh architektúry systému	32
8.1	Architektúra komponentov systému	32
8.2	Fyzická topológia systému	33
8.3	Štruktúra MQTT tém	34
9	Implementácia backendu	36
9.1	Architektúra komponentov systému	36
9.2	Autentifikácia a RBAC	36
9.3	API endpointy	37
9.4	Mechanizmus relácií	38
9.5	Životný cyklus príkazu	39
9.6	Generátor ArUco markerov a export do STL	39
10	Implementácia AI asistenta	41
10.1	RAG pipeline	41
10.2	Embedovací model	41
10.3	Systémový prompt	41
10.4	Správa konverzácie	42
10.5	Správa znalostnej bázy	42
11	Implementácia frontendu	43
11.1	Stavový manažment	43
11.2	ArUco skenovanie	43

11.3	WebSocket pripojenie	43
11.4	Používateľské rozhranie podľa roly	44
12	Aplikácia a jej funkcionality	45
12.1	Skener ArUco identifikátorov	45
12.2	Generátor ArUco identifikátorov	45
12.3	Monitoring a ovládanie zariadení	45
12.4	Virtuálny asistent PLE XO	45
12.5	Správa používateľov	46
12.6	Správa zariadení	46
12.7	Správa znalostnej bázy	46
12.8	Nastavenia	46
13	Testovanie a meranie	48
13.1	Overenie splnenia špecifikácie	48
13.2	Latencia vykonania príkazov	48
13.3	ArUco detekcia	48
13.4	Kvalita odpovedí asistenta	48
	Záver	49
	Literatúra	51
	Použitie nástrojov umelej inteligencie	53
A	Algoritmus	54
B	Výpis dlhého kódu	55
C	Slovníček pojmov	59

Zoznam značiek a skratiek

AI	Artificial Intelligence (slovensky „umelá inteligencia“)
API	Application Programming Interface (slovensky „aplikačné programové rozhranie“)
ASGI	Asynchronous Server Gateway Interface (slovensky „asynchrónne rozhranie serverovej brány“)
CPU	Central Processing Unit (slovensky „centrálna procesorová jednotka“)
GPU	Graphics Processing Unit (slovensky „grafická procesorová jednotka“)
HMI	Human-Machine Interface (slovensky „rozhranie človek-stroj“)
HTML	HyperText Markup Language (slovensky „hypertextový značkovací jazyk“)
IIoT	Industrial Internet of Things (slovensky „priemyselný internet vecí“)
IoT	Internet of Things (slovensky „internet vecí“)
IT	Information Technology (slovensky „informačné technológie“)
JSON	JavaScript Object Notation (slovensky „JavaScriptová objektová notácia“)
KB	Knowledge Base (slovensky „znalostná báza“)
LLM	Large Language Model (slovensky „veľký jazykový model“)
ML	Machine Learning (slovensky „strojové učenie“)
MQTT	Message Queuing Telemetry Transport (slovensky „protokol na prenos telemetrických správ“)
OPC UA	Open Platform Communications Unified Architecture (slovensky „zjednotená architektúra otvorenej platformovej komunikácie“)
OT	Operational Technology (slovensky „prevádzkové technológie“)

PLC	Programmable Logic Controller (slovensky „programovateľný logický automat“)
Pub/Sub	Publish-Subscribe (slovensky „publikovanie-odberanie“)
QoS	Quality of Service (slovensky „kvalita služieb“)
QR	Quick Response (slovensky „rýchla odozva“)
RAG	Retrieval-Augmented Generation (slovensky „generovanie rozšírené o vyhľadávanie“)
RAM	Random Access Memory (slovensky „pamäť s náhodným prístupom“)
REST	Representational State Transfer (slovensky „reprezentačný prenos stavu“)
SaaS	Software as a Service (slovensky „softvér ako služba“)
SCADA	Supervisory Control and Data Acquisition (slovensky „dohľadové riadenie a zber dát“)
SQL	Structured Query Language (slovensky „štruktúrovaný dotazovací jazyk“)
TCP	Transmission Control Protocol (slovensky „protokol riadenia prenosu“)
UI	User Interface (slovensky „používateľské rozhranie“)
VRAM	Video Random Access Memory (slovensky „video pamäť s náhodným prístupom“)

Zoznam algoritmov

1	Vypočítaj $y = x^n$	54
---	-------------------------------	----

Zoznam výpisov kódov

1	Závislosti pre kontrolu rolí	36
2	Ochrana relácie údržbára	39
3	Ukážka výpisu kódu programu načítaného z externého súboru pomocou makra <code>\lstinputlisting</code>	55

Úvod

Písanie záverečnej práce je nevyhnutnou súčasťou štúdia na vysokej škole. Študenti sa s touto činnosťou často stretávajú po prvýkrát na konci bakalárskeho štúdia. Príprava obsiahlejšieho textu je náročná úloha, ktorá zväčša trvá niekoľko týždňov alebo mesiacov. Pri finalizácii a formátovaní do výslednej podoby často panuje neistota a medzi študentami sa šíria protichodné informácie. Tento dokument slúži ako odporúčaná šablóna pre všetkých študentov FEI STU. Môžu ju využiť v plnej miere, alebo len ako inšpiráciu vytvorenia vlastnej výslednej podoby. Zároveň obsahuje návody a rady, ako sa vysporiadať s problémami, ktoré sa môžu pri písaní práce vyskytnúť.

Dokument je vytvorený v systéme na sadzbu textu $\text{\LaTeX}$ použitím upravenej verzie obľúbenej šablóny `FEIstyle`, verzia 2.0.0. Príručka je po formálnej a vizuálnej stránke navrhnutá tak, aby zodpovedala požiadavkám kladeným na záverečnú prácu vrátane poradia jednotlivých častí. Niektoré časti sú povinné (napr. obálka, titulný list, abstrakt), iné sú voliteľné (zoznam obrázkov, tabuliek, poďakovanie). Odporúčame študentom prečítať si aspoň prvú kapitolu tejto príručky, aby získali istotu pri začatí práce.

Jedným zo zámerov tohto manuálu je, aby jeho zdrojové súbory slúžili ako šablóna, do ktorej študenti vložia obsah vlastnej práce. Okrem definície rozmerov, okrajov, číslovania strán, štýlov a znakov, šablóna `FEIstyle.cls` obsahuje množstvo makier a príkazov na generovanie zoznamov obrázkov, tabuliek, výpisov kódov, algoritmov alebo obsahu. Zoznam a opis všetkých funkcií šablóny nájdete v priloženom dokumente `tutorial.pdf`.

Je žiadúce, aby študenti ovládali prácu s $\text{\LaTeX}$ -om na pokročilej užívateľskej úrovni. Je vhodné, ak si pred začiatkom písania preštudujú základné príručky. Veľmi vhodná je kniha Jiřího Rybyčku $\text{\LaTeX}$ pro začátečníky z roku 2003 [**Rybicka2003Latex**]. Ide síce o staršiu publikáciu v českom jazyku, patrí však k vyhľadávaným didaktickým textom a je oceňovaná všetkými používateľmi $\text{\LaTeX}$ -u najmä pri zvládaní prvých krokov. Prehľadnou a príťažlivou formou je tiež spracovaný tutoriál pre používateľov internetovej služby Overleaf.¹ Je to bezplatný výkonný online kompilátor $\text{\LaTeX}$ -u podporovaný mnohými vedeckými vydavateľstvami.

V texte tejto rozšírenej šablóny nájdeme okrem iného aj poznámky k jazykovej stránke textu záverečných prác, písaniu matematických vzorcov, vytváraniu a formátovaniu grafov, tabuliek, či výpisu kódov programov.

V závere ?? kapitoly rozoberieme aktuálnu problematiku používania umelej inteligencie pri tvorbe akademických prác.

¹www.overleaf.com/learn

Citáciám a bibliografickým zdrojom venujeme celú kapitolu ??, pretože práca s externými zdrojmi je pri akademických textoch veľmi dôležitá. Záverečná práca má byť samostatné dielo študenta, ktorý čerpá poznatky z iných zdrojov, spracováva ich a spája do nových súvislostí, čím vytvára novú kvalitu. Veríme, že tento dokument študentom pomôže lepšie sa orientovať, dodá im istotu pri písaní, zabezpečí kvalitný výsledok, estetický vzhľad a hodnotný obsah. Táto príručka nie je komplexným nástrojom na všetky aspekty záverečnej práce, no poskytuje pevný základ úspešného písania a efektívnej práce s literatúrou.

Naším cieľom bolo vytvoriť materiál, ktorý vedie študenta pri hľadaní ďalších zdrojov v literatúre a na internete, aby sa vedel orientovať v terminológii a získal základný prehľad. Prajeme úspešné písanie a dosiahnutie všetkých stanovených cieľov.

1 Analýza existujúcich riešení

Trh s priemyselnými softvérovými platformami ponúka viacero riešení umožňujúcich vizualizáciu a ovládanie výrobných zariadení. Väčšina z nich vychádza z tradičného modelu SCADA/HMI a postupne sa rozširuje o mobilný prístup, cloudovú konektivitu a v niektorých prípadoch aj o prvky umelej inteligencie. Nasledujúci prehľad analyzuje štyri významné komerčné platformy. Posudzované sú nasledovné funkcionality: mobilný prístup k zariadeniam, identifikácia fyzických zariadení, nasadenie na edge, otvorenosť platformy a integrácia inteligentného asistenta schopného pracovať s technickou dokumentáciou.

1.1 Siemens WinCC Unified

SCADA systém *SIMATIC WinCC Unified PC* od spoločnosti Siemens je vizualizačná platforma integrovaná do prostredia TIA Portal, navrhnutá na zjednotenie OT a IT dát v rámci jedného konzistentného systému [1]. Platforma je škálovateľná od jedného stroja až po rozsiahle distribuované systémy s prakticky neobmedzeným počtom zariadení.

Prístup k prevádzkovým dátam je zabezpečený cez webové rozhranie HTML5, ktoré umožňuje vzdialené monitorovanie z prehliadača bez inštalácie klientskej aplikácie. Platforma obsahuje archív pre dlhodobé ukladanie dát a podporuje redundanciu pre vysokú dostupnosť systému.

Siemens v rámci TIA Portal ekosystému ponúka aj nástroj *Engineering Copilot TIA Standard* [2]. Ide o generatívneho AI asistenta pripojeného priamo k TIA Portal. Tento nástroj dokáže generovať kód PLC v jazyku SCL, vytvárať testy, konfigurovať HMI obrazovky a odpovedať na otázky na základe dokumentácie TIA Portal. Jeho zameranie je však výlučne na fázu návrhu a pomáha programátorom pri programovaní a konfigurácii, nie operátorovi počas prevádzky.

Z pohľadu našej práce sú kľúčové tieto body:

- **Mobilný prístup:** Webové rozhranie je dostupné cez prehliadač, nie je to natívna mobilná aplikácia. Interakcia nie je optimalizovaná pre dotykové ovládanie.
- **Identifikácia zariadení:** Platforma nepodporuje skenovanie unikátnych identifikátorov, operátor sa naviguje manuálne.
- **AI asistent pre obsluhu:** Engineering Copilot je nástroj pre programátorov, nie pre operátorov. Neposkytuje kontextovú pomoc na základe znalostnej bázy zariadení počas prevádzky.

- **Licenčný model:** Proprietárny, viazaný na ekosystém Siemens, vyžaduje TIA Portal licencie.

1.2 Ignition Perspective

Ignition SCADA od spoločnosti Inductive Automation je modulárna platforma postavená na otvorených IT štandardoch – SQL, Python, MQTT a OPC UA [3]. Jej kľúčovou vlastnosťou je licenčný model bez obmedzenia počtu tagov, klientov a pripojení, čo ju odlišuje od väčšiny konkurenčných riešení účtujúcich za každé zariadenie.

Platforma komunikuje s PLC od Allen-Bradley, Siemens, Mitsubishi, Modbus a ďalšími prostredníctvom vstavaných ovládačov a zabudovaného OPC UA servera. Ignition Gateway beží na štandardnom serveri a škálovateľnosť je riešená architektúrou hub-and-spoke, kde centrálny gateway koordinuje viaceré odľahčené inštancie.

Modul *Perspective* poskytuje plnohodnotné webové rozhranie na báze HTML5, prístupné z akéhokoľvek zariadenia bez inštalácie klientskej aplikácie. Vizualizačné komponenty sú responzívne a optimalizované pre dotykové ovládanie na tabletoch a smartfónoch. K dispozícii je aj mobilná aplikácia *Ignition Perspective App*.

Pre nasadenie na edge zariadeniach Inductive Automation ponúka *Ignition Edge* [4]. Odľahčenú verziu so archívom (35 dní lokálneho ukladania), podporou MQTT Sparkplug pre synchronizáciu dát na centrálny gateway a možnosťou tvorby REST API priamo na edge zariadení. Ignition Edge teda plní úlohu inteligentného premostenia medzi fyzickými zariadeniami a vyššími systémovými vrstvami.

Z pohľadu našej práce sú kľúčové tieto body:

- **Mobilný prístup:** Modul Perspective poskytuje responzívne webové rozhranie aj mobilnú aplikáciu a teda dotykové ovládanie je plne podporované.
- **Identifikácia zariadení:** Platforma natívne nepodporuje skenovanie unikátnych identifikátorov. Navigácia cez QR kódy je technicky realizovateľná vlastnými Pythonskými skriptmi, avšak nejde o štandardnú funkciu platformy.
- **Edge nasadenie:** Ignition Edge umožňuje distribuované nasadenie priamo na priemyselných zariadeniach s lokálnou archiváciou a synchronizáciou dát.
- **AI asistent:** Platforma neobsahuje vstavanú funkciu inteligentného asistenta ani správu znalostnej bázy. Skriptovacie rozhranie v Pythone by technicky umožnilo volanie externých LLM API, avšak bez natívnej podpory.
- **Licenčný model:** Licencia na Gateway bez obmedzenia počtu klientov. Jednotlivé moduly ako Perspective, Alarming, Reporting sa licencujú samostatne.

1.3 Tulip

Tulip je cloudová no-code platforma pre frontline operácie vo výrobnom sektore, ktorá umožňuje vytvárať priemyselné aplikácie prostredníctvom vizuálneho drag-and-drop editora bez nutnosti programovania [5]. Platforma je orientovaná na digitalizáciu manuálnych výrobných procesov – sledovanie výrobných krokov, zber dát z pracovísk, kontrolu kvality, vizuálne pracovné inštrukcie a sledovateľnosť výroby.

Licenčný model Tulip je účtovaný za interface (zariadenie spúšťajúce Tulip Player). Základný plán *Essentials* zahŕňa aplikácie na mobiloch, tabletoch, dotykových obrazovkách a nositeľných zariadeniach, pričom vyššie plány (*Professional*, *Enterprise*) pridávajú edge konektivitu či pokročilú správu rolí.

Pripojenie k priemyselným zariadeniam je realizované cez doplnkový modul *Machine Monitoring* s podporou OPC UA, MQTT a Node-RED. Aplikácia beží vo webovom prehliadači na tabletoch alebo iných zariadeniach umiestnených na pracoviskách.

V roku 2024 Tulip uzavrel strategickú spoluprácu s Amazon Web Services a predstavil funkciu *Frontline Copilot* [6], postavenú na platforme Amazon Bedrock. Frontline Copilot umožňuje operátorom diagnostikovať výrobné dáta, hľadať v nich vzory a vytvárať aplikácie bez kódu s pomocou generatívnej AI. Systém pracuje s reálnymi výrobnými dátami zozbieranými v rámci platformy.

Z pohľadu našej práce sú kľúčové tieto body:

- **Mobilný prístup:** Aplikácie sú webové a responzívne, spustiteľné na mobiloch, tabletoch aj dotykových obrazovkách.
- **Identifikácia zariadení:** Platforma podporuje skenovanie čiarových kódov a QR kódov pre identifikáciu materiálov a produktov, avšak nie pre priame spárovanie s konkrétnym zariadením výrobnéj linky.
- **Edge nasadenie:** Edge konektivita (OPC UA, MQTT, Node-RED) je dostupná ako platený doplnok, aplikačná logika a dáta sú hostované v cloude.
- **AI asistent:** Frontline Copilot poskytuje generatívnu AI na analýzu výrobných dát a asistenciu operátorom. Nejde však o asistenta s vlastnou znalostnou bázou technickej dokumentácie zariadení. Funkcia pracuje primárne s dátami nazbieranými v rámci platformy Tulip.
- **Licenčný model:** SaaS model účtovaný mesačne za interface, cloudová závislosť môže byť problematická v prostrediach s prísnyimi požiadavkami na lokalizáciu dát.

1.4 AVEVA InTouch Edge HMI

AVEVA Edge je HMI/SCADA platforma od spoločnosti AVEVA, člen skupiny Schneider Electric. Je navrhnutá pre nasadenie na priemyselných zariadeniach, priemyselných PC a edge zariadeniach s minimálnymi hardvérovými nárokmi [7]. Kľúčovým princípom platformy je heslo „develop once, deploy everywhere“. Aplikácia sa navrhne raz v prostredí AVEVA Edge Studio a nasadí na Windows alebo Linux, od malých embedded zariadení až po plnohodnotné SCADA systémy.

Platforma je interoperabilná s väčšinou priemyselných zariadení prostredníctvom vstavaných ovládačov a natívnej podpory OPC UA. Vzdialený prístup je zabezpečený webovým rozhraním na založeným na HTML5, čo umožňuje sledovanie a ovládanie zo smartfónov, tabletov a priemyselných panelov bez inštalácie klienta.

V oblasti priemyselnej AI AVEVA rozvíja samostatnú platformu *Industrial AI for Operations* [8], ktorá využíva aktuálne aj historické dáta naprieč prevádzkou, dodávateľským reťazcom a plánovaním na odhaľovanie skrytých nedostatkov v efektivite a predikciu výpadkov. Význam platformy bol uznaný v rebríčkoch Gartner a Verdantix v roku 2025. Táto AI vrstva je však cielená na podnikovú úroveň, optimalizáciu procesov a prediktívnu údržbu. Nie je cieľom poskytovať kontextovú asistenciu obsluhu priamo pri zariadení.

Z pohľadu našej práce sú kľúčové tieto body:

- **Mobilný prístup:** HTML5 webové rozhranie prístupné zo smartfónov a tabletov, nie je to natívna mobilná aplikácia.
- **Identifikácia zariadení:** Platforma nepodporuje skenovanie unikátnych identifikátorov pre spárovanie operátora so zariadením.
- **Edge nasadenie:** Natívna podpora, AVEVA Edge je priamo navrhnutý pre beh na edge zariadeniach vrátane Linux systémov s nižšími hardvérovými prostriedkami.
- **AI asistent:** Industrial AI for Operations je analytická platforma na podnikovej úrovni zameraná na prediktívnu údržbu a optimalizáciu procesov. Neposkytuje kontextovú asistenciu obsluhu na základe znalostnej bázy dokumentácie konkrétnych zariadení.
- **Licenčný model:** Proprietárny, licencie sa aktivujú cez AVEVA web portál na základe sériového čísla a hardvérového identifikátora.

Zhrnutie analýzy

Tabuľka 2 sumarizuje kľúčové vlastnosti porovnávaných platforiem vzhľadom na mobilný prístup, identifikáciu zariadení, edge nasadenie a integráciu AI asistenta s vlastnou znalostnou bázou.

Tabuľka 2: Porovnanie existujúcich riešení

Vlastnosť	WinCC Unified	Ignition Perspective	Tulip	AVEVA InTouch
Natívna mobilná aplikácia	Nie	Áno	Nie	Nie
Identifikácia zariadení	Nie	Nie	Čiastočne	Nie
Edge nasadenie	Áno	Áno	Čiastočne	Áno
AI asistent s vlastnou KB	Nie	Nie	Nie	Nie
Otvorená platforma	Nie	Čiastočne	Nie	Nie

Z porovnania vyplýva, že existujúce komerčné platformy poskytujú rôznu mieru mobilného prístupu k priemyselným systémom, avšak ani jedna z nich neintegruje inteligentného asistenta schopného odpovedať na otázky obsluhy na základe vlastnej znalostnej bázy technickej dokumentácie. Väčšina platforiem sa orientuje na vizualizáciu a vzdialený prístup k procesným dátam. Pričom podpora operátora, teda schopnosť systému aktívne pomáhať pri riešení prevádzkových situácií prostredníctvom práce s dokumentáciou, zostáva nepokrytou oblasťou.

Rovnako identifikácia fyzických zariadení prostredníctvom vizuálnych markerov s automatickým načítaním kontextu pre dané zariadenie nie je štandardnou funkciou žiadnej z analyzovaných platforiem. Operátori sú naďalej odkázaní na manuálnu navigáciu cez menu, čo spomaľuje prístup k informáciám a zvyšuje pravdepodobnosť interakcie s nesprávnym zariadením.

Tieto identifikované medzery v súčasnej ponuke komerčných riešení tvoria základ pre návrh systému prezentovaného v neskorších kapitolách tejto práce.

2 Prehľad technológií pre vývoj aplikácií a priemyselnú komunikáciu

Moderné priemyselné aplikácie nestoja na jednej technológii. Sú výsledkom starostlivo zvolenej skladačky nástrojov, kde každá vrstva plní svoju úlohu. Mobilné rozhranie reaguje na pokyny operátora, backendová vrstva spracúva množstvo súbežných udalostí z výrobnéj linky a pokyny prichádzajúce z mobilnej aplikácie.

Kľúčovou výzvou je pritom premostenie dvoch oddelených svetov. OT označuje svet priemyselného riadenia a teda PLC automaty, senzory, pohony a výrobné linky. IT je naopak svet softvéru, sietí a aplikácií určených na spracovanie a prenos informácií. Tieto dva svety dlho fungovali oddelene, každý s vlastnými protokolmi a prioritami. Priemyselné aplikácie v kontexte Industry 4.0 ich spájajú práve prostredníctvom komunikačnej vrstvy, napríklad pomocou protokolov MQTT alebo OPC UA.

Nasledujúci prehľad mapuje najpoužívanjšie technológie a ich typické uplatnenie.

2.1 Frontendové technológie

Výber frameworku pre mobilnú aplikáciu patrí k zásadným architektonickým rozhodnutiam. Z prehľadu moderných frameworkov vypláva, že voľba nie je len technická, ale priamo ovplyvňuje rýchlosť vývoja, výkon aplikácie, dlhodobé náklady na údržbu a dostupnosť vývojárov [9]. Nasledujúci prehľad stručne opisuje najrozšírenejšie spôsoby vývoja frontendu, resp. vybrané používané frameworky.

Natívny vývoj (Swift/SwiftUI pre iOS, Kotlin pre Android) poskytuje maximálny výkon a priamy prístup k hardvérovým funkciám zariadenia. Jeho nevýhodou je nutnosť paralelného vývoja a údržby dvoch samostatných kódových základní, čo zvyšuje celkové náklady na vývoj.

React Native od spoločnosti Meta umožňuje zdieľanie logiky aplikácie medzi platformami pomocou JavaScriptu, pričom UI vykresľuje cez natívne komponenty systému. React Native má silný ekosystém, avšak pri výkonnostne náročných operáciách môžu nastať obmedzenia spôsobené prechodom cez natívne rozhranie.

Flutter od spoločnosti Google využíva jednotnú kódovú základňu v jazyku Dart a vlastný vykresľovací engine, ktorý zaručuje konzistentné vizuálne výstupy na všetkých platformách bez závislosti na systémových komponentoch. Dosahuje výkon blízky natívnym aplikáciám vďaka AOT kompilácii.

Webové frameworky (React, Angular, Vue) umožňujú prístup z ľubovoľného zariadenia s prehliadačom bez inštalácie. Pre priemyselné aplikácie je ich hlavným

obmedzením bezpečnostný sandbox prehliadača, ktorý sťažuje priamu komunikáciu s lokálnym hardvérom a priemyselnými rozhraniami.

2.2 Backendové technológie

Backend tvorí jadro systému, spracúva požiadavky, komunikuje s databázami a sprostredkováva tok dát medzi PLC a klientskymi aplikáciami. Výber frameworku pre tvorbu backendu závisí od požiadaviek na výkon, dostupnosť AI/ML knižníc a dlhodobú udržateľnosť [10]. Pozrime sa na vybrané možnosti, ktoré sa často používajú pre ich jednoduchosť, výkon alebo ekosystém knižníc.

Django je framework s filozofiou „batteries included“ obsahuje vstavaný admin panel, správu relácií a ORM vrstvu. Je vhodný pre dátovo náročné aplikácie a rýchly vývoj, avšak jeho monolitická architektúra ho robí menej vhodným pre mikroslužby.

Node.js s Express/NestJS umožňuje použiť JavaScript aj pre backend. Node.js vyniká pri aplikáciách s vysokou frekvenciou krátkych I/O operácií, avšak nie je vhodný pre výpočtovo náročné úlohy blokujúce event loop. NestJS nadstavba pridáva štruktúru TypeScript pre väčšie projekty.

Python s frameworkmi Flask/FastAPI dominuje v oblasti AI a ML vďaka bohatému ekosystému knižníc ako PyTorch, Scikit-learn, LangChain. Flask je minimalistický a flexibilný, FastAPI využíva asynchrónne ASGI a automaticky generuje OpenAPI dokumentáciu na základe typových anotácií.

Go s Gin/Fiber je kompilovaný jazyk nízkymi nárokmi na RAM a CPU a predvídateľnou latenciou. Je vhodný pre mikroslužby, edge nasadenia a výkonnostne kritické systémy, avšak jeho ekosystém pre AI/ML je výrazne menší oproti Pythonu.

Tabuľka 3: Backendové frameworky podľa scenára nasadenia [10]

Scenár použitia	Odporúčaný framework
MVP/Startup	Node.js, Django, FastAPI
Podnikové mikroslužby	Spring Boot, Go, NestJS
Aplikácie s AI	Django, FastAPI, Node.js
Vysoká záťaž/real-time	Gin, Fiber, Node.js

2.3 Kontajnerizácia a edge architektúra

Cloudové spracovanie dát, kde sa všetky informácie odosielajú na vzdialené servery, čelí obmedzeniam v podobe latencie, zaťaženia siete a bezpečnostných rizík pri prenose citlivých dát [11]. Ako alternatíva sa presadzuje model *edge computing*, kde sa dáta

spracúvajú priamo pri zdroji a teda na lokálnom zariadení alebo v blízkosti výrobných linky. Edge zariadenia dokážu filtrovať a vyhodnocovať dáta lokálne, do cloudu sa odosielať len relevantné výsledky, čo znižuje spotrebu prenosového pásma a zvyšuje odolnosť systému pri výpadku pripojenia.

Edge computing a cloud sa navzájom nevylučujú, ale môžu spolupracovať v hybridnom modeli, kde edge zabezpečuje takmer real-time spracovanie a cloud poskytuje dlhodobé ukladanie dát, pokročilú analytiku alebo koordináciu v prípade viacerých edge uzlov.

2.3.1 Docker a Docker Compose

Docker je otvorená platforma pre vývoj, distribúciu a spúšťanie aplikácií [12]. Umožňuje baliť aplikáciu spolu so všetkými jej závislosťami do prenositeľného kontajnera, ktorý beží rovnako v každom prostredí – na vývojárskom počítači, v testovacom prostredí aj na priemyselnom PC v prevádzke. Kontajnery využívajú izoláciu na úrovni jadra Linuxu, sú výrazne viac odľahčené ako virtuálne stroje a umožňujú spúšťať viacero izolovaných aplikácií na jednom hostovskom systéme súčasne.

Zmena v kóde si vyžaduje prenos len zmenenej vrstvy obrazu, nie celého systému, čo môže byť kľúčové pri aktualizáciách cez obmedzené priemyselné pripojenia. Docker Compose rozširuje tento koncept na celý aplikačný stack: backend, MQTT broker, vektorová databáza a ďalšie služby môžu byť definované v jednom konfiguračnom súbore a môžu sa spúšťať jedným príkazom.

2.4 Priemyselné komunikačné protokoly

2.4.1 OPC UA

OPC UA je platformovo nezávislá architektúra orientovaná na služby, vydaná v roku 2008, ktorá integruje funkcionality predchádzajúcich OPC Classic špecifikácií do jedného rozšíriteľného frameworku. Štandard beží na rôznych hardvérových platformách, od priemyselných PC a PLC až po mikrokontroléry a cloudovú infraštruktúru. Podporuje operačné systémy Windows, Linux, Android a ďalšie [13].

Model OPC UA je objektovo orientovaný: dáta sú reprezentované hierarchicky ako uzly, objekty a premenné s plnou sémantickou popisnosťou. Prístup k dátam zahŕňa čítanie a zápis, odoberanie zmien, notifikácie na udalosti a volanie metód. Komunikácia je možná v modeli klient-server aj Pub/Sub.

Bezpečnosť je súčasťou návrhu: OPC UA podporuje šifrovanie správ, podpisovanie, X.509 certifikáty pre autentifikáciu, sekvenčné pakety proti replay útokom a auditný log aktivít.

- **Výhody:** Vstavaná kybernetická bezpečnosť, sémantický popis dát, podpora klient-server aj Pub/Sub komunikácie, spätná kompatibilita a platformová nezávislosť.
- **Nevýhody:** Vysoká komplexnosť a vyššie nároky na RAM/CPU limitujú nasadenie.

2.4.2 S7 Protokol

S7 komunikácia je proprietárny protokol spoločnosti Siemens určený na výmenu dát medzi PLC rady SIMATIC [14]. Ide o natívny komunikačný mechanizmus ekosystému TIA Portal, ktorý pracuje nad sieťami PROFINET alebo PROFIBUS DP. Na rozdiel od otvorených štandardov nie je S7 protokol verejne špecifikovaný a zariadenia tretích strán ho implementujú reverzným inžinierstvom.

Komunikácia prebieha na princípe klient-server s jednosmerne konfigurovanými alebo obojstranne konfigurovanými spojeniami.

- **Výhody:** Jednoduchá konfigurácia v prostredí TIA Portal, natívna podpora v celom ekosystéme, nízka latencia v homogénnych Siemens sieťach.
- **Nevýhody:** Uzavretý, neštandardizovaný protokol bez verejnej špecifikácie, obmedzená interoperabilita so zariadeniami iných výrobcov.

2.4.3 MQTT

MQTT je nenáročný a otvorený protokol typu klient-server s modelom publish/subscribe, navrhnutý pre jednoduché použitie v obmedzených prostrediach ako IoT a komunikácia medzi strojmi. Protokol beží nad TCP/IP a poskytuje obojsmerný tok správ s minimálnou réžiou [15].

Správy sa neposielajú priamo medzi zariadeniami. Klienti publikujú správy na témy (topics) na brokerovi, ostatní klienti sa môžu na tieto témy prihlásiť (subscribe) a dostávať správy bez potreby poznať ich pôvod.

Protokol definuje tri úrovne QoS pre doručenie správ:

- **QoS 0** – správa je doručená najviac raz, bez potvrdenia
- **QoS 1** – správa je doručená aspoň raz, môžu nastať duplikáty
- **QoS 2** – správa je doručená práve raz, s plným handshake protokolom

Ďalšou vlastnosťou je mechanizmus „Last Will and Testament“, správa, ktorú broker automaticky odošle ostatným klientom v prípade neštandardného odpojenia klienta. Verzia MQTT 5.0 pridáva rozšírené vlastnosti ako expirácia správ, aliasy tém a zlepšené hlásenie chýb.

- **Výhody:** Minimálna réžia, tri úrovne QoS, podpora „Last Will and Testament“, vhodnosť pre zariadenia s obmedzeným výkonom a sieťou.
- **Nevýhody:** Nutnosť udržiavať bežiaci broker čo môže byť centrálny bod zlyhania.

2.4.4 Modbus TCP

Modbus je komunikačný protokol vyvinutý spoločnosťou Modicon (dnes Schneider Electric) v roku 1979 pre potreby priemyselných programovateľných automatov. Dnes je de facto štandardom v priemyselnej automatizácii s odhadovaných 7 miliónmi nasadených uzlov [16]. Modbus TCP/IP prenáša správy protokolu Modbus zabalené do TCP/IP rámcov, čím umožňuje nasadenie v štandardných ethernetových sieťach bez potreby špeciálneho hardvéru.

Protokol pracuje na princípe klient-server. Klient iniciuje požiadavky a server odpovedá.

- **Výhody:** Jednoduchý a otvorený štandard bez licenčných poplatkov, rozšírená podpora zariadení, minimálne nároky na zdroje, jednoduché ladenie.
- **Nevýhody:** Chýba zabudovaná autentifikácia a šifrovanie, obmedzený dátový model, žiadny mechanizmus notifikácie, teda klient sa musí aktívne dopytovať na server.

3 Prehľad technológií pre inteligentných asistentov

3.1 Veľké jazykové modely a možnosti použitia


Veľké jazykové modely (LLM) sú kategóriou modelov hlbokého učenia trénovaných na obrovských množstvách textových dát, vďaka čomu sú schopné porozumieť prirodzenému jazyku a generovať text pre široké spektrum úloh [17]. Ich základom je architektúra transformer s mechanizmom seba-pozornosti, ktorý modelu umožňuje zachytiť vzťahy a závislosti medzi slovami na rôznych miestach v texte.

Trénovanie prebieha na miliardách slov z kníh, článkov a webových stránok. Text je rozdelený na tokeny, každý token je zakódovaný ako vektor čísel tzv. embedding a sieť sa iteratívne učí predpovedať nasledujúci token v sekvencii. Výsledkom je model, ktorý si osvojil gramatické pravidlá, faktické znalosti aj spôsoby uvažovania.

Z hľadiska použitia existujú dve základné možnosti [18]. Prvou sú **cloudové modely prístupné cez API** (napr. GPT-4o, Claude, Gemini). Ide o platené služby, kde poskytovateľ spravuje celú infraštruktúru a model je dostupný okamžite bez nutnosti vlastného hardvéru. Druhou možnosťou sú **open-source modely nasadené lokálne** (napr. Llama 3, Mistral), kde môže každý prevádzkovať model na vlastných serveroch alebo zariadeniach. Lokálne nasadenie je vhodné najmä v prostrediach s obmedzeným internetovým pripojením, prísnyimi požiadavkami na ochranu dát alebo potrebou prevádzky bez závislosti od externých služieb.

3.2 Retrieval-Augmented Generation

LLM modely sú obmedzené na znalosti zachytené počas tréningu a nemajú prístup k aktuálnym ani doménovým informáciám. Retrieval-Augmented Generation (RAG) tento nedostatok rieši prepojením modelu s externou znalostnou bázou bez nutnosti opätovného tréningu [19].



Obr. 1: Základný princíp RAG pipeline

Princíp fungovania je taký, že pri každej otázke používateľa, retrieval model vyhľadá v znalostnej báze relevantné úseky dokumentov, tie sa vložia do kontextu LLM spolu s pôvodnou otázkou a model na ich základe vygeneruje odpoveď. Znalostná báza je typicky uložená vo vektorovej databáze, kde sú dokumenty reprezentované ako číselné vektory (embeddings) umožňujúce rýchle vyhľadávanie. Jednou z populárnych open-source vektorových databáz je ChromaDB. Lhká databáza licencovaná pod Apache 2.0, ktorú možno prevádzkovať lokálne alebo aj v cloudovom prostredí a je priamo integrovaná s frameworkmi LangChain a LlamaIndex [20].

Hlavné prínosy RAG oproti čistému LLM sú zníženie halucinácií dohľadáním odpovedí v konkrétnych zdrojoch, prístup k aktuálnym a doménovým dátam a teda možnosť odkazovať na zdroj informácie priamo v odpovedi.

3.3 AI asistenti v priemyselnom prostredí

Priemyselné podniky čelia rastúcemu nedostatku kvalifikovaných pracovníkov a potrebe rýchleho zaškolenia nových zamestnancov. Generatívni AI asistenti môžu predstavovať súčasť riešenia tohto problému. Fungujú ako virtuálni mentori priamo na výrobnnej linke, kde pracovníkom poskytujú okamžité odpovede v prirodzenom jazyku na otázky o postupoch, riešení porúch alebo špecifikáciách zariadení [21].

Systém vie prepájať viaceré zdroje dát ako podnikové systémy, tréningové databázy, prevádzkové dáta a skladať z nich kontextovo relevantnú odpoveď. Technická dokumentácia je tak prekladaná do zrozumiteľných pokynov prispôbených skúsenostiam konkrétneho pracovníka. Výsledkom je potenciálne skrátenie času zaškoľovania, zníženie závislosti od rád seniornejších zamestnancov a vyššia schopnosť prispôbiť sa pri zavádzaní nových technológií.

4 Typy identifikátorov a ich použitie

4.1 QR kódy


QR kódy sú dvojrozmerné maticové identifikátory optimalizované pre rýchle čítanie a vysokú hustotu dát. V zmysle použitia v priemysle sa využívajú najmä na identifikáciu objektov, kde sa vyžaduje uloženie komplexnejších informácií napr. URL adresy, sériové čísla alebo konfiguračné parametre. Ich výhodou je silná korekcia chýba, ktorá umožňuje prečítať kód aj pri čiastočnom poškodení alebo znečistení povrchu.



Obr. 2: QR kód so zakódovanou URL adresou fei.stuba.sk

4.2 Fiduciálne markery – AprilTag, ArUco

Fiduciálne markery sú špeciálne navrhnuté pre potreby počítačového videnia a robotiky. Na rozdiel od QR kódov nie je ich primárnym cieľom prenos veľkého objemu dát, ale presná lokalizácia v 3D priestore.



Obr. 3: Vizuálne porovnanie AprilTag a ArUco


Tieto identifikátory sa vyznačujú predovšetkým vysokou mierou interoperability s modernými robotickými riešeniami. Vďaka existujúcim knižniciam napr. OpenCV, ROS je ich integrácia štandardom pri vývoji:

- **Autonómnych robotov:** Kde markery umiestnené v prostredí slúžia ako pevné referenčné body pre rekalibráciu lokalizácie a elimináciu kumulatívnej chyby v mapách.
- **Dronov v skladoch:** Kde umožňujú presné pristávanie na nabíjaciach staniciach alebo navigáciu v priestoroch bez signálu GPS, pričom dron dokáže v reálnom čase určiť svoju polohu a náklon voči markeru.
- **Kolaboratívnych robotov:** Pri navádzaní na presnú pozíciu.

Identifikátory ako AprilTag a ArUco sú robustné voči zmenám osvetlenia a perspektívnemu skresleniu.

4.3 3D identifikátory

V prostrediach priemyselných podnikov a logistických reťazcov, kde môže prísť k jednoduchému znemožneniu snímania 2D identifikátorov (špinavé, poškodené, nedostatočné osvetlenie, odrazy svetla), sa ako perspektívne riešenie javia unikátne 3D identifikátory. Na Fakulte elektrotechniky a informatiky STU bol vyvinutý systém programaticky generovaných 3D identifikátorov, ktoré sú optimalizované pre systémy zmiešanej a rozšírenej reality.



Obr. 4: Fyzický 3D identifikátor vyrobený pomocou 3D tlače

4.3.1 Princíp a štruktúra

Navrhnutý 3D identifikátor má tvar kocky, ktorá je vnútorne vyskladaná z menších, unikátnych geometrických elementov. Tieto elementy sú usporiadané v originálnej štruktúre, ktorá v sebe nesie zakódované informácie.

Hlavné technické výhody tohto riešenia sú:

- **Všesmerová detekcia:** Na rozdiel od 2D QR kódov je možné tieto 3D objekty v systémoch zmiešanej reality spoľahlivo snímať z akéhokoľvek uhla.
- **Odolnosť voči falšovaniu:** Vďaka komplexnej vnútornej členitosti a 3D geometrii sú tieto identifikátory výrazne náročnejšie na replikáciu než bežné 2D identifikátory.
- **Využitie vlastného tvaru:** Sledovanie sa nespolieha len na vizuálny vzor, ale na obrys a priestorovú charakteristiku 3D modelu, čo zvyšuje stabilitu v AR aplikáciách.

5 Špecifikácia požiadaviek na systém

Práca predstavuje moderný prístup k priemyselnému internetu vecí (IIoT), kde mobilná aplikácia slúži ako primárne rozhranie pre obsluhu výrobnnej linky, prepojené s riadiacim systémom prostredníctvom edge computing zariadenia umiestneného priamo v prevádzke.

5.1 Opis systému

Systém umožní obsluhu výrobnnej linky ovládať PLC zariadenia prostredníctvom mobilnej aplikácie. Identifikácia zariadenia prebieha skenovaním ArUco markera umiestneného priamo na zariadení. Po naskenovaní sa aplikácia pripojí k zariadeniu a obsluha bude môcť odosielať príkazy a sledovať aktuálny stav.

Systém bude podporovať viacerých súčasne prihlásených používateľov s rôznymi oprávneniami. Každý používateľ bude mať pridelenú rolu, ktorá určí, ku ktorým funkciám má prístup. Keďže ku jednému zariadeniu sa môže pokúsiť pripojiť viacero pracovníkov naraz, systém musí riešiť exkluzivitu pripojenia a definovať pravidlá pre prípad konfliktu, pričom servisný zásah údržbára musí byť chránený pred prerušením.

Systém bude zaznamenávať všetky odoslané príkazy vrátane informácie o tom, ktorý používateľ príkaz vydal a na ktoré zariadenie. Administrátor a manažér budú môcť spravovať používateľské účty a schvaľovať nové registrácie.

Súčastou systému bude inteligentný asistent, ktorý bude odpovedať na technické otázky obsluhy na základe dokumentácie nahratej v znalostnej báze. Obsah znalostnej bázy bude možné viazať na konkrétne zariadenie.

Systém bude nasadený výhradne v lokálnej sieti továrne. Backendové služby budú kontajnerizované a nasadené na edge zariadení umiestenom v sieti továrne.

5.2 Popis používateľských rolí

Systém implementuje riadenie prístupu založené na rolách (*Role-Based Access Control*, RBAC). Každý nový používateľ sa musí zaregistrovať a pred prvým prihlásením čaká na schválenie administrátorom alebo manažérom, ktorý mu zároveň priradí príslušnú rolu. Sú definované štyri roly:

Operátor: Základná obsluha výrobnnej linky. Prihlasuje sa na konkrétnu linku skenovaním ArUco kódu, odosiela riadiace príkazy a sleduje aktuálny stav zariadenia v reálnom čase. Nemá prístup k reportom, správe vedomostnej bázy ani správe používateľov. Môže v prípade potreby využiť AI asistenta.

Manažér: Zameriava sa na sledovanie udalostí. Má prístup k histórii prihlásení jednotlivých operátorov, reportu s logmi a môže spravovať používateľské kontá. Takisto má prístup k AI asistentovi a môže upravovať vedomostnú bázu. Linku priamo neovláda no vidí kto je prihlásený a aké operácie vykonáva.

Údržbár: Má exkluzívnu ochranu relácie a žiadny iný používateľ ho nemôže odhlásiť z prihláseného zariadenia, čo zaručuje bezpečnosť počas servisného zásahu. Spravuje vedomostnú bázu pre jednotlivé zariadenia, môže upravovať existujúce zariadenia a vytvárať nové.

Administrátor: Spravuje celý systém, schvaľuje nové registrácie, priraduje roly, edituje a odstraňuje používateľské kontá. Má prístup prakticky ku všetkým funkciám systému.

5.3 Use-case scenáre

ID	UC-01: Registrácia a prihlásenie
Aktér	Všetky roly
Popis	Používateľ sa zaregistruje zadaním údajov. Kým administrátor neschváli konto, aplikácia zobrazí informáciu o čakaní na schválenie. Po schválení sa používateľ prihlási a získa prístup.
ID	UC-02: Skenovanie ArUco kódu a spárovanie linky
Aktér	Operátor, údržbár, admin
Popis	Používateľ naskenuje ArUco kód pri zariadení. Ak je linka voľná, po potvrdení dialógu sa vytvorí relácia. Ak je obsadená, zobrazí sa identita a rola prihláseného. Reláciu neprítomného operátora je možné prevziať, reláciu údržbára prevziať nie je povolené.
ID	UC-03: Ovládanie linky
Aktér	Operátor, údržbár, admin
Popis	Aktéri odosielať príkazy z ovládacieho panelu. Vykonanie príkazu je potvrdené a je zobrazený čas od odoslania po prijatie príkazu zariadením.
ID	UC-04: Monitorovanie stavu linky
Aktér	Operátor, údržbár, admin
Popis	Dashboard zobrazuje procesné dáta z PLC v reálnom čase cez WebSocket. Stavý sú farebne kódované podľa normy IEC 60073.

ID	UC-05: Prezeranie logov
Aktér	Manažér, údržbár, admin
Popis	Je možné prezeranie logov a reportov s filtrovaním podľa časového obdobia a zariadenia.
ID	UC-06: Správa vedomostnej bázy
Aktér	Manažér, údržbár, admin
Popis	Prostredníctvom CRUD operácií sa nahrávajú, upravujú a odstraňujú dokumenty znalostnej bázy.
ID	UC-07: AI asistent
Aktér	Všetky roly
Popis	Tlačidlom v rohu každej obrazovky sa spustí chatbot. Odpovedá výhradne na základe vedomostnej bázy, či už všeobecnej alebo viazanej ku konkrétnemu zariadeniu. Ak informácia chýba, prizná to. Rozhranie aj odpovede sú lokalizované v SK a EN.
ID	UC-08: Správa používateľov
Aktér	Manažér, admin
Popis	Manažér a admin schvaľuje registrácie, priraduje roly, upravuje a odstraňuje kontá. Hlavného admina nie je možné odstrániť ani upraviť inou cestou.
ID	UC-09: Nastavenia aplikácie
Aktér	Všetky roly
Popis	V nastaveniach je možné zmeniť jazyk (SK / EN) a vlastné heslo. Zmena jazyka je dostupná aj na prihlasovacej obrazovke.

5.4 Funkcionálne požiadavky

FP1: Aplikácia musí umožniť načítanie unikátneho identifikátora na automatické spárovanie mobilného zariadenia s konkrétnou časťou výrobnéj linky.

FP2: Používateľ musí mať možnosť odosielať príkazy v riadenom systéme.

FP3: Systém musí implementovať verifikáciu kritických príkazov. Po odoslaní požiadavky musí aplikácia čakať na potvrdenie z PLC a vizuálne indikovať úspešné vykonanie zmeny.

FP4: Zobrazovanie aktuálnych stavov z PLC.

- FP5:** Implementácia chatbota využívajúceho metódu *Retrieval-Augmented Generation*. Chatbot musí odpovedať na technické otázky výhradne na základe poskytnutej vedomostnej bázy. Ak čerpá z iného zdroja, musí to jasne uviesť.
- FP6:** Plná lokalizácia používateľského rozhrania a odpovedí chatbota v dvoch jazykoch: slovenský (SK) a anglický (EN).
- FP7:** Aplikácia musí implementovať mechanizmus exkluzívnej relácie pre ovládanie konkrétnej výrobnjej linky. Po úspešnom prihlásení a spárovaní linky sa vytvorí aktívna relácia viazaná na používateľa. Relácia musí byť udržiavaná periodickým *heartbeat* signálom a automaticky ukončená pri odhlásení.
- FP8:** Pri pokuse o spárovanie linky, ktorá je už obsadená aktívnou reláciou, musí aplikácia používateľovi zobrazíť informáciu o existujúcej relácii (používateľa/rola). Nútené ukončenie resp. prevzatie relácie musí byť umožnené v prípade neodhlásenia sa už neprítomnej obsluhy.
- FP9:** Systém musí podporovať prihlásenie používateľov pomocou autentifikácie založenej na JWT. Aplikácia musí implementovať *Role-Based Access Control* (RBAC) s rolami: operátor, manažér, údržbár, admin.
- FP10:** Systém musí ukladať základný log operácií obsahujúci minimálne: čas vykonania, identifikátor používateľa, identifikátor linky, typ akcie/príkazu a výsledok vykonania. Log musí byť dostupný pre roly *manažér*, *údržbár* a *admin*.

5.5 Nefunkcionálne požiadavky

Definujú kvalitatívne atribúty, technologické obmedzenia a nároky na bezpečnosť.

- NFP1:** Celá backendová infraštruktúra musí byť kontajnerizovaná pomocou nástroja Docker a spustiteľná na edge zariadení.
- NFP2:** Prenos správ v edge infraštruktúre musí prebiehať cez MQTT s QoS 1.
- NFP3:** Latencia príkazov nesmie presiahnuť 250 ms.
- NFP4:** Odpovede AI asistenta musia byť striktné viazané na poskytnutý kontext. Ak informácia v materiáloch chýba, model musí túto skutočnosť priznať.
- NFP5:** Lokálna databáza musí byť konfigurovaná na zachovanie integrity dát aj v prípade náhleho prerušenia napájania edge zariadenia.

NFP6: Využitie Docker Compose musí umožňovať rýchle nasadenie identického stacku na iné edge zariadenia napr. v iných závodoch.

NFP9: Ovládacie príkazy z môžu prichádzať výhradne z lokálnej siete továrne.

NFP10: Backendové služby musia poskytovať štruktúrované logy pre účely diagnostiky.

5.6 Doménové požiadavky

Požiadavky plynúce z priemyselného prostredia a použitých technológií.

DP1: Komunikácia s hardvérom PLC musí prebiehať cez natívny protokol S7.

DP2: Grafické rozhranie musí dodržiavať priemyselné štandardy pre farebnú indikáciu stavov podľa normy IEC 60073.

DP3: Systém si musí zachovať kľúčovú funkcionálnu teda ovládanie linky aj v prípade výpadku pripojenia k internetu.

6 Voľba technológií

Výber použitých technológií bol výsledkom posúdenia viacerých faktorov. Medzi kľúčové kritériá patrili kompatibilita s poskytnutým hardvérom, jednoduchá integrácia, nízka latencia a schopnosť fungovať v priemyselnom prostredí s omezenými zdrojmi. V neposlednom rade bola dôležitá aj dostupnosť knižníc a predchádzajúca skúsenosť s jednotlivými technológiami, čo zásadne urýchlilo vývoj.

6.1 Komunikácia s PLC – S7 protokol

Riadiaci systém výrobnéj linky je PLC od firmy Siemens, konkrétne model S7-1200, pre ktorý je natívnym komunikačným protokolom S7. Práve to bolo primárnym dôvodom jeho výberu. S7 protokol umožňuje priame čítanie a zápis dátových blokov bez nutnosti zložitej konfigurácie alebo dodatočných licencií.

Alternatívou by bolo aktivovanie servera OPC UA priamo v S7-1200, čo je síce technicky možné, avšak prináša niekoľko nevýhod. Tými sú vyšší nápor na výpočtové zdroje PLC s obmedzenou pamäťou, potrebu licencie a výrazne komplexnejší konfiguračný proces. S7 protokol cez knižnicu `node-red-contrib-s7` poskytuje priamy a jednoduchý prístup k dátam PLC bez týchto obmedzení.

- **Výhody:** Natívna podpora pre Siemens S7-1200, priamy prístup k dátovým blokom, nízke vyťažovanie prostriedkov, jednoduchá konfigurácia v Node-RED.
- **Nevýhody:** Viazanosť na platformu Siemens, absencia štandardizovaného informačného modelu v porovnaní s OPC UA.

6.2 Komunikačná middleware vrstva – Node-RED

Spojenie medzi PLC a zvyškom systému zabezpečuje Node-RED, nástroj na programovanie s využitím minima kódu. Beží v Docker kontajneri priamo na edge zariadení v prevádzke. Node-RED periodicky číta hodnoty z PLC prostredníctvom S7 protokolu a publikuje ich do MQTT brokera, čím spája svet OT (PLC, S7) a IT (MQTT, backend).

Node-RED bol zvolený z niekoľkých dôvodov. Disponuje uzlom `node-red-contrib-s7` pre priamu komunikáciu so Siemens PLC a rovnako podporou MQTT. Toto riešenie je bez potreby písať rozsiahly kód, čo výrazne skracuje čas konfigurácie. Node-RED tiež dobre zvláda periodické dotazovanie (polling) PLC a podmienené spúšťanie akcií.

- **Výhody:** Minimum kódu, natívna S7 a MQTT podpora, jednoduchý deployment v Dockeri, aktívna komunita s rozsiahlou knižnicou uzlov.

- **Nevýhody:** Nie je vhodný pre komplexnú biznis logiku, vizuálne toky môžu byť pri väčšom projekte ťažšie udržiavateľné.

6.3 Transportný protokol – MQTT

Pre transport dát medzi edge vrstvou a backendom bol zvolený protokol MQTT. Kľúčovým argumentom je jeho nenáročnosť. Protokol bol navrhnutý pre zariadenia s obmedzenými zdrojmi a nestabilné siete.

OPC UA je komplexný štandard s bohatým informačným modelom, vstavanou bezpečnosťou a sémantickým popisom dát. Pre scenár, kde Node-RED číta hodnoty zo Siemens PLC a odovzdáva ich ďalej na spracovanie, táto komplexnosť nepredstavuje pridanú hodnotu, ale zbytočnú záťaž. MQTT broker nasadený v Dockeri zvládne rovnakú úlohu s minimálnou náročnosťou na zdroje.

- **Výhody MQTT:** Nízke nároky na zdroje, jednoduchá architektúra pub/sub, výborná podpora v Node-RED aj Pythone, QoS úrovne pre spoľahlivosť doručenia.
- **Kedy by bol OPC UA lepšou voľbou:** Pri požiadavke na štandardizovaný sémantický popis dát, pri integrácii viacerých zariadení od rôznych výrobcov alebo pri prísnych bezpečnostných požiadavkách.

6.4 Backend – FastAPI

Backend aplikácie bol implementovaný v Pythone s využitím frameworku FastAPI. Tvorí API pre celú mobilnú aplikáciu. Oddelené API obsluhuje AI asistenta vrátane RAG pipeline. Voľba Pythonu bola prirodzená, pretože knižnice LangChain, ChromaDB a Ollama sú súčasťou python ekosystému a ich integrácia je bezproblémová. FastAPI bolo zvolené ale aj z ďalších praktických dôvodov. Asynchrónna architektúra (ASGI) umožňuje súbežne obsluhovať požiadavky mobilnej aplikácie aj dlhotrvajúce volania jazykového modelu bez vzájomného blokovania. Automaticky generovaná OpenAPI dokumentácia uľahčuje ladenie API počas vývoja. Validácia vstupov cez Pydantic redukuje množstvo pomocného kódu. Rolu zohrali aj predchádzajúce skúsenosti s týmto frameworkom v bakalárskej práci, čo výrazne urýchlilo vývoj a umožnilo sa sústrediť na implementáciu biznis logiky a integráciu AI asistenta.

- **Výhody:** Asynchrónne spracovanie požiadaviek, automatická OpenAPI dokumentácia, Pydantic validácia, AI knižnice, rýchly vývoj.
- **Nevýhody:** Interpretovaný Python je pomalší oproti kompilovaným jazykom pri CPU-intenzívnych operáciách.

6.5 Frontend – Flutter

Pre mobilnú aplikáciu bol zvolený framework Flutter od spoločnosti Google. Primárnou cieľovou platformou je Android, avšak Flutter umožňuje z jednej kódovej základne generovať aj webovú aplikáciu, desktopovú aplikáciu a iOS aplikáciu, čo otvára možnosť implementácie administrátorského panelu, či vývoja pre iné platformy bez nutnosti udržiavať samostatný projekt.

Oproti natívnemu vývoju v Kotlin, Flutter ponúka výrazne rýchlejší vývojový cyklus vďaka funkciám hot reload a hot restart. Vlastný vykresľovací engine Impeller zaručuje vizuálnu konzistenciu rozhrania naprieč zariadeniami a operačnými systémami. Bohatá štandardná knižnica widgetov pokrýva väčšinu potrieb priemyselného ovládacieho rozhrania.

- **Výhody:** Jedna kódová základňa pre Android, iOS aj web, rýchly vývojový cyklus, konzistentné UI, silná podpora od Google.
- **Nevýhody:** Väčšia veľkosť výslednej aplikácie oproti natívnym riešeniam, pri požiadavke na plnohodnotnú iOS aplikáciu by bolo potrebné doplniť testovanie na Apple zariadeniach.

6.6 Výber identifikátora – ArUco

Pre jednoznačnú identifikáciu zariadení bolo v rámci práce spočiatku investované značné množstvo času do experimentovania s 3D identifikátormi navrhnutými študentom FEI. Tieto identifikátory sa spočiatku javili ako vhodné riešenie, pretože poskytovali vizuálne unikátny vzor, ktorý by teoreticky mohol byť rozpoznaný pomocou počítačového videnia.

Preto bolo otestovaných niekoľko prístupov k ich rozpoznávaniu:

- **Template matching a hashing** – porovnanie snímaného povrchu s uloženými referenčnými vzormi metódami pHash, SSIM a klasický template matching.
- **Extrakcia príznakov ORB s FLANN matcher** – rotačne invariantné príznaky s rýchlym vyhľadávaním v databáze, testované na rôznych vzdialenostiach a uhloch.
- **Analýza mriežky jamiek** – priama detekcia binárneho vzoru v 19×19 mriežke a porovnanie matíc.
- **Porovnávanie histogramov** – identifikácia na základe distribúcie intenzít.
- **Siamese network** – ľahká CNN extrahujúca 128-dimenzionálne príznakové vektory, identifikácia na základe cosine similarity.

- **Transfer learning s MobileNet V3-Small** – klasifikátor exportovaný do TFLite pre nasadenie v mobilnej aplikácii Flutter, trénovaný s augmentáciou rotácií a variáciou osvetlenia.

Napriek rozsiahlemu experimentovaniu žiadna z týchto metód neposkytovala dostatočne spoľahlivé výsledky v reálnych podmienkach. Systém si vzory vzájomne zamieňal, pri zmenách osvetlenia alebo pohľadového uhla klesala istota rozpoznávania pod použiteľnú hranicu, a príprava každej novej triedy identifikátora vyžadovala opätovné zbieranie dát a doladenie modelu.

Z týchto dôvodov bolo prijaté rozhodnutie použiť štandardizovaný fiduciálny marker **ArUco**. Markery ArUco sú binárne štvorcové vzory s kódovanou číselnou identitou a orientáciou, ktoré sú navrhnuté priamo pre spoľahlivú detekciu počítačovým videním za rôznych svetelných podmienok. Knížnica ArUco je súčasťou OpenCV a poskytuje robustné algoritmy detekcie s korekciou perspektívy. V priemyselnom prostredí majú ArUco markery silné zastúpenie, využívajú ich napríklad automaticky navádzané vozidlá (AGV), upratovacie autonómne roboty a aj výskumné robotické platformy. Táto rozšírenosť je ďalším argumentom v prospech voľby ArUco oproti 3D identifikátorom, ktoré by vyžadovali vlastný spôsob rozpoznávania. Prípadne by bolo možné použitie frameworku ako Vuforia, čo by ale značne zvýšilo závislosť implementácie a údržby a presne tomu sme sa chceli vyhnúť.

7 Experimentálne porovnanie a výber jazykových modelov

7.1 Popis testovaných modelov

Na porovnanie bolo vybraných päť lokálne spustiteľných jazykových modelov dostupných prostredníctvom platformy Ollama. Modely boli zámerne zvolené tak, aby pokrývali tri veľkostné kategórie: modely do 10 miliárd parametrov, modely v rozsahu 10 až 15 miliárd parametrov a model s 24 miliardami parametrov. Cieľom tohto rozloženia bolo analyzovať vzťah medzi veľkosťou modelu, kvalitou odpovedí a časom odozvy.

1. **llama3.2:3b**

Kompaktný model od spoločnosti Meta s 3 miliardami parametrov zo série Llama 3.2, ktorá zahŕňa predtrénované aj inštrukčne doladené generatívne modely vo veľkosti 3B parametrov. Inštrukčne doladené varianty sú optimalizované pre multijazyčné konverzačné úlohy vrátane agentického vyhľadávania a sumarizácie. Podľa oficiálnej dokumentácie model prekonáva modely Gemma 2 2.6B a Phi 3.5-mini v úlohách ako plnenie inštrukcií, sumarizácia, prepisovanie promptov a používanie nástrojov [22]. Do testovania bol zaradený ako zástupca najmenej veľkostnej kategórie s predpokladom najrýchlejšej odozvy.

2. **gemma4:e4b**

Model od spoločnosti Google zo série Gemma 4 s 4 miliardami parametrov v kvantizovanej verzii (e4b označuje efektívnu 4-bitovú kvantizáciu). Série Gemma 4 predstavuje najnovšiu generáciu otvorených modelov Google, navrhnutú s dôrazom na multimodálne schopnosti a efektívne nasadenie na bežnom spotrebiteľskom hardvéri. Model podporuje dlhé kontextové okno a je optimalizovaný pre inštrukčné úlohy vrátane multijazyčných konverzačných scenárov [23]. Do testovania bol zaradený ako zástupca strednej veľkostnej kategórie s priaznivým pomerom výkonu a pamätovej náročnosti.

3. **mistral-nemo:12b**

Model s 12 miliardami parametrov vyvinutý spoločnosťami Mistral AI a NVIDIA. Disponuje kontextovým oknom až 128 000 tokenov a podľa oficiálnej dokumentácie dosahuje v svojej veľkostnej kategórii špičkové výsledky v oblasti uvažovania, znalosti sveta a presnosti generovania kódu. Vďaka štandardnej architektúre je plnohodnotnou náhradou modelu Mistral 7B v existujúcich systémoch [24]. Do testovania bol zaradený ako zástupca kategórie 10–15 miliárd parametrov.

4. **phi4:14b**

Model od spoločnosti Microsoft s 14 miliardami parametrov a kontextovým oknom 16 000 tokenov. Je trénovaný na kombinácii syntetických dátových sád, filtrovaných verejne dostupných webových zdrojov a akademických kníh a dátových sád otázok a odpovedí. Prešiel procesom doladenia pomocou supervised fine-tuningu a direct preference optimization s dôrazom na presné plnenie inštrukcií a bezpečnosť. Podľa oficiálnej dokumentácie je určený pre prostredia s obmedzenými výpočtovými zdrojmi, scenáre s požiadavkami na nízku latenciu a úlohy vyžadujúce uvažovanie a logiku [25]. Do testovania bol zaradený ako druhý zástupca kategórie 10–15 miliárd parametrov.

5. **mistral-small:24b**

Model od spoločnosti Mistral AI s 24 miliardami parametrov a kontextovým oknom 32 000 tokenov, ktorý stanovuje nový štandard v kategórii modelov do 70B parametrov. Podľa oficiálnej dokumentácie dosahuje výkon porovnateľný s modelmi trojnásobnej veľkosti a proprietárnym modelom GPT-4o mini naprieč úlohami v oblasti programovania, matematiky, všeobecných znalostí a plnenia inštrukcií [26]. Model vyniká multijazyčnou podporou, natívnym volaním funkcií, JSON výstupom a vysokým rešpektom k systémovým promptom. Vďaka kompaktnej veľkosti je nasaditeľný lokálne na výkonnejšom spotrebiteľskom hardvéri.

7.2 Metodika testovania

Testovanie prebiehalo formou automatizovaného testu implementovaného v jazyku Python s využitím knižníc LangChain, ChromaDB a Ollama. Znalostná báza asistenta vo formáte `.txt` bola rozdelená na sekcie podľa markerov `-- NÁZOV DOKUMENTU: --` a uložená do vektorovej databázy ChromaDB s využitím embedding modelu `nomic-embed-text`. Pre každú testovú otázku boli z vektorovej databázy vytiahnuté tri najrelevantnejšie dokumenty, ktoré boli spolu s otázkou odovzdané modelu ako kontext.

Každý model bol otestovaný na sade 14 testovacích otázok rozdelených do troch kategórií:

- **Faktické otázky** (10 otázok) – odpoveď je priamo obsiahnutá v znalostnej báze. 6 otázok v slovenskom a 4 otázky v anglickom jazyku.
- **Otázky vyžadujúce syntézu** (2 otázky) – správna odpoveď vyžaduje kombináciu informácií z viacerých dokumentov znalostnej bázy.
- **Otázky mimo rozsahu** (2 otázky) – otázky, ktorých odpoveď sa v znalostnej báze nenachádza a model by mal odpovedať odmietnutím a odkazom na technika.

Na rozdiel od automatických metrík ako ROUGE, ktoré vykazujú nízku spoľahlivosť pri jazykoch, kde sa využíva skloňovanie, ako je slovenčina, bolo hodnotenie kvality realizované manuálne. Každá odpoveď bola ohodnotená podľa nasledujúcich kritérií:

- **Relevancia** (škála 1–5) – miera, do akej odpoveď zodpovedá položenej otázke.
- **Úplnosť** (škála 1–5) – pokrytie všetkých dôležitých bodov správnej odpovede.
- **Zrozumiteľnosť** (škála 1–5) – zrozumiteľnosť formulácie odpovede.
- **Jazyková správnosť** (škála 1–3) – či model odpovedal v rovnakom jazyku, v akom bola položená otázka.
- **Odmietnutie otázky mimo rozsahu** (áno/nie) – či model správne odmietol odpovedať na otázku, ktorá nie je pokrytá znalostnou bázou.

Celkové skóre bolo vypočítané ako vážený priemer jednotlivých kritérií: relevancia (30 %), úplnosť (25 %), zrozumiteľnosť (20 %) a jazyková správnosť (25 %).

Okrem kvalitatívnych metrík bol pre každú odpoveď zaznamenaný čas odozvy v milisekundách. Testovanie prebiehalo na notebookovom hardvéri (CPU AMD Ryzen 5 5600H, RAM 32 GB, GPU NVIDIA RTX 3060 6 GB VRAM). Keďže väčšina testovaných modelov presahuje kapacitu VRAM, modely bežali čiastočne alebo úplne na systémovej RAM, čo predstavuje hardvérovú limitáciu meraní. V produkčnom nasadení, na dedikovanom serveri s dostatočnou VRAM, by časy odozvy boli výrazne nižšie.

7.3 Výsledky porovnania

Výsledky hodnotenia všetkých piatich modelov sú zhrnuté v tabuľke 4.

Tabuľka 4: Výsledky porovnania jazykových modelov

Model	Priem. čas [ms]	Relev. (1–5)	Úplnosť (1–5)	Zrozum. (1–5)	Jazyk (1–3)	OOS odmiet.	Celk. skóre
llama3.2:3b	4 536	2,29	2,21	2,50	2,14	100 %	2,63
gemma4:e4b	11 165	4,86	4,86	5,00	3,00	100 %	4,92
mistral-nemo:12b	15 217	4,07	4,07	4,29	2,86	100 %	4,29
phi4:14b	20 039	2,00	2,00	2,07	2,79	100 %	2,68
mistral-small:24b	35 801	1,86	1,86	1,86	3,00	100 %	2,65

Tabuľka 5: Priemerná relevancia podľa typu otázky a jazyka

Model	Faktická otázka	Syntéza	Mimo rozsahu	SK	EN
llama3.2:3b	1,70	2,50	5,00	2,12	2,50
gemma4:e4b	5,00	4,00	5,00	4,88	4,83
mistral-nemo:12b	4,20	2,50	5,00	4,62	3,33
phi4:14b	1,40	2,00	5,00	2,00	2,00
mistral-small:24b	1,40	1,00	5,00	2,00	1,67

7.4 Analýza výsledkov a výber modelu

Z výsledkov testovania vyplýva, že model **gemma4:e4b** dosiahol najvyššie celkové skóre 4,92/5,0 spomedzi všetkých testovaných modelov. Model vykazoval konzistentne vysokú kvalitu odpovedí naprieč všetkými typmi otázok aj oboma testovanými jazykmi, pričom jeho priemerný čas odozvy 11 165 ms bol v podmienkach notebookového hardvéru prijateľný a takmer trojnásobne nižší v porovnaní s modelom mistral-small:24b.

Prekvapivým zistením je, že modely phi4:14b a mistral-small:24b opakovane odmietali odpovedať na otázky, ktorých odpovede boli v znalostnej báze jednoznačne obsiahnuté. Tento jav naznačuje, že RAG pipeline nepodal týmto modelom dostatočne relevantný kontext, čo mohlo byť spôsobené odlišnou citlivosťou modelov na formát vstupného kontextu.

Všetky testované modely dosiahli 100 % úspešnosť pri odmietaní otázok mimo rozsahu znalostnej bázy, čo potvrdzuje správne fungovanie systémového promptu z hľadiska bezpečnosti systému.

7.4.1 Overenie na cloudovom hardvéri

V nadväznosti na merania realizované lokálne boli vybrané modely testované aj na platforme RunPod.io, ktorá poskytuje prístup k výkonným GPU serverom formou platby za využitý čas. Cieľom bolo overiť, do akej miery hardvérová limitácia skresľuje závery o reálnej použiteľnosti modelov v produkcii.

Výsledky potvrdili predpoklad, na dedikovanom serverovom hardvéri s dostatočnou VRAM klesol priemerný čas odozvy na menej ako 8 sekúnd u všetkých modelov, čo je pre interaktívne použitie výrazne prijateľnejšia hodnota. Kvalita odpovedí pritom zostala nezmenená, čo je v súlade s očakávaním. Model generuje kvalitatívne rovnaký výstup nezávisle od hardvéru, rozdiel sa prejaví iba v latencii.

7.4.2 Závěrečné rozhodnutí o architektúre AI asistenta

Napriek tomu, že výsledky testovania lokálnych modelov boli z kvalitatívneho hľadiska uspokojivé, cloudové overenie odhalilo zásadné ekonomické obmedzenie tohto prístupu. Modely, ktoré dosahujú dostatočnú kvalitu odpovedí, si pre produkčné nasadenie vyžadujú dedikovaný GPU server s dostatočnou VRAM. Prevádzkové náklady takéhoto riešenia nie sú pre projekt tohto rozsahu rentabilné.

V prípade väčších organizácií s vyšším objemom požiadaviek by mohlo byť zmysluplné investovať do vlastného serverového hardvéru. Stále však bude výhodnosť vlastného servera s GPU závislá od konkrétneho objemu požiadaviek. Pre nízky až stredný objem požiadaviek, je určite ekonomicky výhodnejšie využívať API s modelom per-token, kde náklady sú priamoúmerné skutočnému využitiu a nevyžadujú si vysokú počiatočnú investíciu.


Z týchto dôvodov bolo rozhodnuté opustiť prístup lokálnych LLM a prejsť na volanie externého API. Na výber je niekoľko poskytovateľov ako OpenAI, Google, Anthropic a iní veľkí hráči v oblasti AI. My sme zvolili API od spoločnosti Anthropic, nakoľko v poslednej dobe zaznamenali výraznejší pokrok v porovnaní s konkurenciou. Tento prístup zabezpečuje prístup k výkonným jazykovým modelom bez nutnosti prevádzkovať vlastný server, pričom náklady sa platia priamoúmerne skutočnému využitiu. RAG pipeline a znalostná báza zostávajú zachované v pôvodnej podobe. Kontextové dokumenty sú naďalej vyhľadávané lokálne z vektorovej databázy a odovzdávané modelu ako súčasť promptu. Mení sa iba vrstva generovania odpovede, ktorá prechádza z lokálne bežiacieho modelu na cloudové API.

8 Návrh architektúry systému

Systém je navrhnutý ako distribuovaná aplikácia skladajúca sa z viacerých vzájomne prepojených vrstiev. Každá vrstva plní špecifickú úlohu a komunikuje so susednými vrstvami prostredníctvom jasne definovaných rozhraní. Jadro systému beží na edge zariadení umiestenom priamo v prevádzke a zabezpečuje plnú funkčnosť aj bez pripojenia k internetu. Mobilná aplikácia komunikuje výhradne v rámci lokálnej siete závodu a v súčasnosti sa pripojenie na internet využíva len pre účely AI asistenta. Ak by sme využívali lokálne spustiteľný jazykový model, komunikácia s AI asistentom by prebiehala výhradne v rámci lokálnej siete a celý systém by bol izolovaný. Nasledujúce podkapitoly popisujú podrobnejšie celkovú štruktúru systému, spôsob nasadenia jednotlivých komponentov, ich vzájomnú komunikáciu a spôsob ukladania dát.

8.1 Architektúra komponentov systému

Systém sa skladá z piatich hlavných komponentov. Prvým je mobilná aplikácia, ktorá slúži ako primárne rozhranie pre obsluhu. Druhým je backendová vrstva tvorená dvoma službami FastAPI. Hlavná služba zabezpečuje autentifikáciu, správu relácií, riadenie zariadení a samostatná služba rieši AI asistenta s RAG pipeline. Tretím komponentom je MQTT broker Mosquitto, ktorý sprostredkúva asynchrónnu komunikáciu medzi backendom a Node-RED. Štvrtým je Node-RED, ktorý premostuje svet priemyselnej komunikácie so svetom IT a periodicky číta dáta z PLC prostredníctvom S7 protokolu. Posledným komponentom je samotné PLC Siemens S7-1200, ktoré riadi prvky výrobnéj linky. Všetky tieto komponenty okrem mobilnej aplikácie a PLC bežia v Docker stacku na edge zariadení. Jediné externé volanie smeruje z AI služby na rozhranie Anthropic API.




Obr. 5: Diagram architektúry systému a komunikácia medzi komponentmi

Mobilná aplikácia komunikuje s hlavnou FastAPI službou cez REST API a prijíma aktualizácie stavu zariadení cez WebSocket. Príkazy odoslané z aplikácie putujú cez backend do MQTT brokera a ďalej do Node-RED, ktorý ich zapíše do PLC. Spätná väzba prechádza tou istou cestou v opačnom smere. Dáta zo senzorov PLC číta Node-RED periodicky a publikuje ich do príslušných MQTT tém, odkiaľ ich backend preposiela pripojeným klientom cez WebSocket.

8.2 Fyzická topológia systému

Fyzická topológia systému vychádza z požiadavky na lokálnu prevádzku bez závislosti od externej infraštruktúry. Celá komunikácia prebieha v rámci lokálnej siete medzi mobilnými zariadeniami, edge zariadením a riadiacimi systémami výrobných liniek. Schéma fyzickej architektúry je znázornená na obrázku 6.



Obr. 6: Fyzická topológia systému

Mobilné zariadenia sa pripájajú k edge zariadeniu bezdrôtovo cez WiFi. Voľba bezdrôtového pripojenia vychádza z charakteru práce operátora, ktorý sa pohybuje po výrobnjej hale a potrebuje mať prístup k systému kdekoľvek. Edge zariadenie je prepojené s Ethernet switchom, na ktorý sú napojené riadiace systémy výrobných liniek. Edge zariadenie plní úlohu centrálného uzla, beží na ňom hlavný backend aj AI asistent a všetka logika spracovania príkazov sa vykonáva lokálne (okrem LLM, v práci sme zvolili externé API). Architektúra počíta s pripojením viacerých riadiacich systémov, čo umožňuje rozšírenie na ďalšie výrobné linky bez zmeny základnej topológie. V súčasnej implementácii je na switch napojený jeden riadiaci systém Siemens S7-1200.

8.3 Štruktúra MQTT tém

Komunikácia medzi backend službou, Node-RED a zariadeniami prebieha cez štruktúrované MQTT témy. Všetky témy zdieľajú spoločný prefix `plc`, za ktorým nasleduje identifikátor zariadenia vo formáte `device_{id}`, kde `id` zodpovedá ArUco identifikátoru fyzického zariadenia. Táto štruktúra umožňuje systému jednoznačne smerovať správy na konkrétne zariadenie a zároveň odberateľom filtrovať témy.

```

plc/
├─ device_{id}/
│   ├── data .....stav zariadenia      Node-RED -> backend
│   ├── status ..... online/offline     Node-RED -> backend
│   └── commands/
│       └─ {prikaz} ..... riadiaci prikaz  backend -> Node-RED
  
```


Tabuľka 6: Prehľad MQTT tém

Téma	Vydavateľ	Odberateľ	Popis
plc/device_{id}/data	Node-RED	Backend	Aktuálne hodnoty premen- ných zariadenia
plc/device_{id}/status	Node-RED	Backend	Stav pripojenia zariadenia (online/offline)
plc/device_{id}/commands/#	Backend	Node-RED	Riadiaci príkaz smerovaný na zariadenie

Backend pri štarte subscribuje na tému `plc/#`, čím prijíma správy zo všetkých zariadení naraz. Node-RED subscribuje selektívne len na témy `commands` pre zariadenia, ktoré spravuje. Príkazy sú publikované s QoS 1, čím je zaručené doručenie aspoň raz.

9 Implementácia backendu

Backend systému tvorí dvojica nezávislých FastAPI služieb bežiacich v prostredí Docker, ako už bolo opísané v

9.1 Architektúra komponentov systému

. Asistent je nasadený oddelene predovšetkým z dôvodu možného budúceho prechodu na lokálne bežiaci jazykový model. V takom prípade by bolo možné presunúť tento stack na výkonnejší dedikovaný server bez akéhokoľvek zásahu do hlavného backendu. V nasledujúcich podkapitolách popisujeme implementáciu jednotlivých funkcionalít backendu, začínajúc autentifikáciou a RBAC, cez API endpointy, mechanizmus relácií, životný cyklus príkazov až po generátor ArUco identifikátorov a export identifikátorov vo formáte STL vhodnom pre 3D tlač.

9.2 Autentifikácia a RBAC

Systém používa autentifikáciu pomocou JWT tokenov podľa štandardu OAuth2. Po úspešnom prihlásení server vygeneruje token podpísaný zdieľaným tajným kľúčom algoritmom HS256. Token obsahuje identifikátor používateľa a čas vypršania platnosti. Heslá sú uložené výhradne ako bcrypt hash.

Registrácia je verejne dostupná, avšak nový účet je predvolene neaktívny. Prístup do systému získa až po schválení administrátorom, ktorý zároveň priradí rolu. Táto dvojfázová registrácia zabraňuje neoprávnenému vstupu do systému.

Oprávnenia sú riadené štyrmi rolami. Každý chránený endpoint deklaruje požadovanú rolu ako FastAPI závislosť, čo umožňuje jednotnú kontrolu prístupu bez duplicitnej logiky.

```
async def get_line_operator(user: User = Depends(get_current_user)):
    _ensure_role(user, {"operator", "admin", "maintenance"})
    return user

async def get_manager_or_admin(user: User = Depends(get_current_user)):
    _ensure_role(user, {"manager", "admin"})
    return user
```

Výpis kódu 1: Závislosti pre kontrolu rolí

Funkcia	Operátor	Manažér	Údržbár	Admin
Dashboard, nastavenia, AI asistent	✓	✓	✓	✓
ArUco skenovanie a ovládanie linky	✓		✓	✓
Zoznam a správa zariadení		✓	✓	✓
Log príkazov		✓	✓	✓
Znalostná báza		✓	✓	✓
Správa používateľov		✓		✓

9.3 API endpointy

Backend poskytuje REST API rozdelené do šiestich skupín podľa funkčnej oblasti. Endpointy pre AI asistenta sú dostupné na samostatnej službe počúvajúcej na porte 8100, ostatné na porte 8000. Okrem REST komunikácie poskytuje backend WebSocket pre aktualizácie stavu zariadenia.

Tabuľka 7: Prehľad API endpointov

Metóda	Endpoint	Popis	Rola
<i>Autentifikácia — /auth</i>			
POST	/auth/login	Prihlásenie, vracia JWT token	—
POST	/auth/register	Registrácia nového účtu	—
GET	/auth/me	Aktuálny prihlásený používateľ	všetci
PUT	/auth/me	Úprava mena a priezviska	všetci
POST	/auth/change-password	Zmena hesla	všetci
<i>Zariadenia — /plc</i>			
GET	/plc/devices	Zoznam zariadení	všetci
POST	/plc/devices	Vytvorenie zariadenia	admin, údržbár
GET	/plc/devices/{id}	Detail zariadenia	všetci
PUT	/plc/devices/{id}	Úprava zariadenia	admin, údržbár
DELETE	/plc/devices/{id}	Vymazanie zariadenia	admin, údržbár
POST	/plc/devices/{id}/command/{cmd}	Odoslanie príkazu	admin, údržbár, operátor
GET	/plc/stats	Dashboard štatistiky	všetci
WS	/plc/ws/{id}	Real-time stav + príkazy	všetci
<i>Relácie — /device-sessions</i>			
POST	/device-sessions/{id}/join	Prihlásenie na zariadenie	admin, údržbár, operátor
POST	/device-sessions/{id}/leave	Odhĺasenie zo zariadenia	všetci
<i>Logy — /command-logs</i>			
GET	/command-logs	Logy s filtrami	admin, manažér, údržbár
GET	/command-logs/device/{id}	Logy zariadenia	admin, manažér, údržbár
<i>Používatelia — /users</i>			
GET	/users	Zoznam používateľov	admin, manažér
POST	/users/{id}/approve	Schválenie + rola	admin, manažér
PUT	/users/{id}	Úprava účtu	admin, manažér
POST	/users/{id}/reset-password	Reset hesla	admin, manažér
DELETE	/users/{id}	Vymazanie účtu	admin, manažér
<i>ArUco — /aruco</i>			
GET	/aruco/next-id	Nasledujúce voľné ID	všetci
GET	/aruco/preview/{id}	Náhľad markera	všetci
GET	/aruco/png/{id}	Stiahnutie markera ako PNG	všetci
GET	/aruco/stl/{id}	Stiahnutie markera ako STL	všetci
<i>AI asistent — port 8100</i>			
POST	/chat	Správa AI asistentovi	všetci
GET	/kb	Zoznam záznamov znalostnej bázy	admin, manažér, údržbár
POST	/kb	Pridanie záznamu	admin, manažér, údržbár
POST	/kb/upload	Nahratie súboru do KB	admin, manažér, údržbár
DELETE	/kb/{id}	Vymazanie záznamu	admin, manažér, údržbár

9.4 Mechanizmus relácií

Pred ovládaním zariadenia sa musí používateľ na zariadenie prihlásiť. Relácia je väzba medzi používateľom a zariadením, ktorá zabráňuje súčasnému ovládaniu jedného zariadenia viacerými používateľmi. Na každom zariadení môže byť aktívna práve jedna relácia.

Prihlásenie na zariadenie prebieha volaním `POST /devices/{id}/login`. Backend overí, či je zariadenie voľné. Ak áno, vytvorí novú reláciu. Ak je zariadenie obsadené, správanie závisí od parametra `force` a od roly aktuálneho držiteľa relácie. Zariadenie obsadené používateľom s rolou údržbára nemôže byť prebraté žiadnym iným používateľom. Táto ochrana zabraňuje prerušeniu servisného zásahu operátorom. Vlastnú reláciu môže ukončiť prihlásený používateľ odhlásením sa. Cudziu reláciu môže ukončiť každý, ak sa nejedná o reláciu údržbára. Je to z dôvodu, aby sa zabránilo situáciám, keď sa operátor zabudne odhlásiť a zariadenie zostane zablokované. Každé prevzatie relácie je zaznamenané v logu príkazov, čo znamená dohľadateľnosť zodpovednosti. Pred prepísaním relácie systém informuje nového používateľa o tom, kto je aktuálne prihlásený. Následne je potrebné potvrdiť úmysel prevzatia, čím sa zabezpečí, že k prevzatiu nepríde náhodou.

```
if active.user.role == "maintenance":
    raise HTTPException(409, "maintenance_locked")
```

Výpis kódu 2: Ochrana relácie údržbára

9.5 Životný cyklus príkazu

Príkaz prechádza niekoľkými vrstvami systému, kým sa prejaví na fyzickom zariadení. Používateľ ho môže odoslať dvoma cestami: cez REST endpoint alebo cez WebSocket spojenie.


Backend publikuje správu na MQTT tému `plc/device_{id}/commands/{cmd}`. Mosquitto broker správu doručí Node-RED, ktorý ju preloží do S7 protokolu a zapíše príslušnú premennú v PLC. Volajúci dostane späť potvrdenie `command_ack` s príznakom úspechu doručenia na broker. Skutočná zmena stavu je viditeľná v ďalšom cykle čítania, keď Node-RED publikuje aktualizované hodnoty na tému `plc/device_{id}/data` a backend ich pošle cez WebSocket do aplikácie.

Každý príkaz je bez ohľadu na výsledok zaznamenávaný do tabuľky `command_logs` s identifikátorom používateľa, zariadenia, zdrojovým kanálom a príznakom úspechu doručenia.

9.6 Generátor ArUco markerov a export do STL

Pre výrobu fyzických markerov bola implementovaná vlastná Python trieda `ArucoSTLGeneratorVoxelOp`, ktorá generuje STL súbor určený na dvojfarebnú 3D tlač. Model je navrhnutý tak, aby farebné priradenie v sliceri bolo čo najjednoduchšie.

Povrch modelu je rozdelený do troch výškových úrovní. Čierne bunky markera sú na základnej výške `base_height_mm`, ohraničovací rám je o `border_height_offset_mm`



Obr. 7: ArUco marker tlačný z vygenerovaného STL modelu

vyšší a biele bunky sú vyvýšené o `white_height_mm`. Pri predvolených hodnotách dosahujú čierne bunky výšku 1 mm a biele 3 mm.

10 Implementácia AI asistenta

Asistent je implementovaný ako samostatná FastAPI služba bežiaca na porte 8100 v rámci vlastného Docker stacku. Disponuje vlastnou PostgreSQL databázou pre záznamy znalostnej bázy a ChromaDB ako úložisko vektorov. Jediné externé sieťové volanie celej aplikácie smeruje na Anthropic API pre volanie jazykového modelu.

10.1 RAG pipeline

Spracovanie každej správy prebieha v niekoľkých krokoch. Najprv sa vykonajú dva vyhľadávacie dotazy do ChromaDB: zariadenie-špecifický s filtrom podľa `device_aruco_id` a všeobecný bez filtra, pričom každý vráti najviac tri najbližšie záznamy. Zo získaných kontextov, metadát relácie a histórie konverzácie sa zostaví systémový prompt, ktorý sa odošle na Claude API.

10.2 Embedovací model

Na generovanie vektorových reprezentácií textov sa používa model `nomic-embed-text` spúšťaný lokálne cez Ollama. Model beží v rámci Docker stacku na edge zariadení a nevyžaduje pripojenie na internet. ChromaDB využíva kosínusovú podobnosť ako metriku vyhľadávania. Každý záznam znalostnej bázy sa indexuje ako reťazec `title + content` pri vytvorení aj aktualizácii.

10.3 Systémový prompt

Asistent vystupuje pod menom PLEXO. Systémový prompt existuje v slovenskej aj anglickej verzii podľa jazyka relácie a pred každým volaním modelu sa naplní nasledujúcimi sekciami:

- **AKTUÁLNA RELÁCIA** – meno a rola prihláseného používateľa, prípadne zariadenie na ktoré je prihlásený.
- **KONTEXT PRE ZARIADENIE** – výsledky vyhľadávania z ChromaDB filtrované podľa ArUco ID zariadenia.
- **VŠEOBECNÝ KONTEXT** – výsledky vyhľadávania bez filtra zariadenia.

Pravidlá v prompte zakazujú vymýšľanie faktov a nariaďujú asistentovi, aby sa pri prvej správe stručne predstavil. V ďalších správach konverzácie sa predstavenie preskakuje.

10.4 Správa konverzácie

Server je bezstavový. História konverzácie sa neukladá na strane servera, ale je súčasťou každého požiadavku zo strany klienta. Služba prijíma pole správ vo formáte `{role, content}` a pri zostavovaní volania zahŕňa posledných desať správ. Tento prístup nevyžaduje žiadne serverové úložisko relácií a zjednodušuje škálovanie.

10.5 Správa znalostnej bázy

Znalostná báza je tvorená textovými záznamami uloženými v PostgreSQL. Každý záznam má názov, obsah a voliteľne priradené ArUco ID zariadenia. Toto priradenie umožňuje vyhľadávanie obsahu filtrovaného pre konkrétne zariadenie, čo zvyšuje presnosť odpovedí pri otázkach viazaných na konkrétny stroj.

Pri každom vytvorení alebo úprave záznamu sa jeho vektorová reprezentácia synchronizuje do ChromaDB operáciou `upsert`. Mazanie záznamu zrkadlovo odstráni aj príslušný vektor. Okrem manuálneho zadania textu API podporuje nahranie súboru vo formáte `.txt`, čo umožňuje import existujúcej technickej dokumentácie.

11 Implementácia frontendu

Frontend je implementovaný vo Flutter s podporou platformy Android ako primárneho cieľa a webového prehliadača pre administrátorský panel. Zdieľa takmer všetok kód medzi platformami s výnimkou ArUco skenovania, kde sú použité platformovo špecifické implementácie.

11.1 Stavový manažment

Aplikácia používa knižnicu Riverpod so vzorcom `StateNotifier`. Centrálnym poskytovateľom je `authProvider`, ktorý uchováva JWT token, objekt prihláseného používateľa a príznaky stavu autentifikácie. Pri štarte aplikácie sa volá `tryRestoreSession`, ktorá overí uložený token volaním `/auth/me`. Ak je token platný, relácia sa obnoví. Pri chybe siete sa použijú záložné údaje z lokálneho úložiska, čo umožňuje obmedzený offline prístup.

Chatový asistent má vlastného poskytovateľa `chatProvider`, ktorý udržiava zoznam správ a informáciu o práve aktívnom zariadení. Táto informácia sa nastavuje pri otvorení stránky ovládania zariadenia a vymazáva pri odchode.

11.2 ArUco skenovanie

Skenovanie prebieha v natívnom kóde prostredníctvom balíčka `opencv_dart`. Každý snímok z kamery dorazí vo formáte YUV420, z ktorého sa extrahuje kanál Y ako grayscale obraz. Samotná detekcia beží v Dart izolovanom vlákne pomocou `Isolate.run`, čím sa zabráni blokovaniu vykresľovacieho vlákna.

V izolante sa vytvorí detektor s predefinovaným slovníkom `DICT_5X5_250` a zavolá sa `detectMarkers`. Pre každý detekovaný marker sa vypočíta plocha Shoelaceovým vzorcom a stred ako relatívna poloha v obraze. Výstupom je zoznam detegovaných markerov zoradených od najväčšieho po najmenší, kde väčšia plocha znamená bližší marker. Príznak `_isProcessing` zabraňuje spusteniu ďalšej detekcie kým prebieha predchádzajúca.

11.3 WebSocket pripojenie

Po načítaní zariadenia sa nadväzuje WebSocket spojenie cez balíček `web_socket_channel`. Server posiela tri typy správ: heartbeat, ktorý sa ignoruje, potvrdenie príkazu `command_ack` a aktualizáciu hodnôt premenných. Pri chybe alebo zatvorení spojenia sa po dvoch sekundách automaticky pokúsi o znovupripojenie.

Odosielanie príkazu funguje tak, že sa na WebSocket pošle JSON správa `{command, value}` a spustí sa päťsekundový časovač. Ak sa do tohto času zmení sledovaná premenná na zariadení, používateľovi sa zobrazí snackbar s potvrdenou hodnotou a nameranou latenciou. Ak časovač vyprší skôr, zobrazí sa chybové hlásenie.

11.4 Používateľské rozhranie podľa roly

Viditeľnosť prvkov rozhrania je riadená pomocnými metódami triedy `AuthUser`. Každá metóda vracia booleovskú hodnotu na základe role prihláseného používateľa. Prehľad priradenia je uvedený v tabuľke ??.

V bočnom paneli webového rozhrania sa položky navigácie filtrujú dynamicky. Napríklad položka správy zariadení sa zobrazí iba ak platí `canViewDevices`, tlačidlo konfigurácie zariadenia na stránke ovládania sa zobrazí iba ak platí `canManageDevices`. Týmto spôsobom sa rovnaká logika RBAC z backendu premietne aj do rozhrania bez potreby duplikovania podmienok na viacerých miestach.

12 Aplikácia a jej funkcionality

12.1 Skener ArUco identifikátorov

Dostupné pre: operátor, technik, manažér, administrátor

Skener ArUco identifikátorov slúži ako primárny spôsob prihlásenia sa na konkrétne zariadenie. Používateľ namieri kameru mobilného zariadenia na ArUco identifikátor umiestnený priamo na fyzickom zariadení a systém ho automaticky identifikuje. Po úspešnom naskenovaní je používateľ priradený k danému zariadeniu a získava prístup k jeho monitorovaniu a ovládaniu. Tento prístup eliminuje manuálne vyhľadávanie zariadení a zabezpečuje, že používateľ pracuje s tým správnym zariadením.

12.2 Generátor ArUco identifikátorov

Dostupné pre: technik, manažér, administrátor

Pri zakladaní nového zariadenia v systéme aplikácia automaticky vygeneruje unikátny ArUco identifikátor, ktorý jednoznačne identifikuje dané zariadenie. Identifikátor je možné exportovať vo formáte PNG pre bežnú tlač alebo vo formáte STL ako trojrozmerný model vhodný na 3D tlač, pričom biela časť kódu je vystúpená a čierna zapustená. Fyzická značka sa následne umiestni na zariadenie, čím sa prepojí záznam v systéme s reálnym zariadením v prevádzke.

12.3 Monitoring a ovládanie zariadení

Dostupné pre: operátor, technik, administrátor

Monitoring a ovládanie zariadení predstavuje hlavnú funkcionality aplikácie. Po prihlásení na zariadenie má používateľ k dispozícii prehľad aktuálneho stavu zariadenia v reálnom čase. Môže sledovať stavy senzorov, aktuálny režim prevádzky, stav v ktorom sa zariadenie nachádza, a iné. Okrem sledovania stavu môže používateľ zariadenie aj priamo ovládať, napríklad spustiť alebo zastaviť cyklus, zmeniť smer pohybu či vykonať reset. Všetky zmeny sa prejavia rádo vo desiatkach milisekúnd, čo umožňuje rýchlu reakciu na aktuálnu situáciu v prevádzke. Systém zároveň zaznamenáva históriu vykonaných príkazov pre potreby kontroly a auditu.

12.4 Virtuálny asistent PLE XO

Dostupné pre: operátor, technik, manažér, administrátor

Virtuálny asistent PLE XO je inteligentný pomocník dostupný priamo v aplikácii. Používatelia môžu klásť otázky prirodzeným jazykom, napríklad o aktuálnom stave

zariadenia, postupe pri riešení poruchy alebo pokynoch na údržbu. Asistent odpovedá na základe znalostnej bázy vytvorenej pre konkrétne zariadenia a prevádzku. Vďaka tomu má operátor alebo technik potrebné informácie vždy po ruke, bez nutnosti listovať v technickej dokumentácii. Asistent komunikuje v jazyku nastavenom používateľom v nastaveniach aplikácie.

12.5 Správa používateľov

Dostupné pre: manažér, administrátor

Správa používateľov poskytuje oprávneným osobám nástroje na riadenie prístupu do systému. Manažér alebo administrátor môže vytvárať nové používateľské účty, upravovať existujúce, prideliť príslušné roly podľa pracovného zaradenia a v prípade potreby účty odstrániť resp. deaktivovať. Systém rolí zabezpečuje, že každý používateľ vidí a môže vykonávať iba tie akcie, ktoré zodpovedajú jeho pracovnej pozícii, čím sa minimalizuje riziko neoprávneného zásahu do prevádzky.

12.6 Správa zariadení

Dostupné pre: technik, manažér, administrátor

Správa zariadení umožňuje udržiavať databázu zariadení aktuálnu a v súlade so skutočným stavom prevádzky. Oprávnený používateľ môže do systému pridať nové zariadenie, nastaviť jeho parametre a vygenerovať preň ArUco identifikátor. Existujúce zariadenia je možné upravovať, resp. meniť, čo sa zobrazuje v ovládacom paneli zariadenia. Taktiež je možné ich zo systému odstrániť, ak boli vyradené z prevádzky. Vďaka tejto funkcionalite systém vždy odráža reálny stav zariadení v podniku.

12.7 Správa znalostnej bázy

Dostupné pre: technik, manažér, administrátor

Znalostnú bázu tvorí súbor informácií, z ktorých čerpá virtuálny asistent PLEKO pri odpovedaní na otázky používateľov. Oprávnení používatelia môžu obsah znalostnej bázy priebežne pridávať nové dokumenty, upravovať existujúce záznamy alebo odstraňovať zastarané informácie. Kvalita a aktuálnosť znalostnej bázy priamo ovplyvňuje relevantnosť a presnosť odpovedí asistenta, preto je jej pravidelná údržba dôležitou súčasťou prevádzky systému.

12.8 Nastavenia

Dostupné pre: operátor, technik, manažér, administrátor

Každý používateľ má možnosť prispôbiť si aplikáciu podľa vlastných preferencií. V nastaveniach môže zmeniť jazyk rozhrania, ktorý sa automaticky uplatní aj na komunikáciu s virtuálnym asistentom PLEXO. Zároveň má možnosť zmeniť si svoje prístupové heslo. Tieto nastavenia sú viazané na konkrétny používateľský účet a zostávajú zachované aj po opätovnom prihlásení.

13 Testovanie a meranie

13.1 Overenie splnenia špecifikácie

13.2 Latencia vykonania príkazov

13.3 ArUco detekcia

13.4 Kvalita odpovedí asistenta

Záver

„V tejto príručke sme sa snažili poskytnúť praktické pokyny pre vypracovanie záverečných prác na Fakulte elektrotechniky a informatiky STU v Bratislave. Obsahuje dôležité informácie o formálnej stránke dokumentu, ktoré sú nevyhnutné pre zabezpečenie jasnej štruktúry a správneho formátovania práce. Naša príručka kladie dôraz na dodržiavanie základných pravidiel, ktoré pomáhajú minimalizovať chyby a zlepšujú celkovú kvalitu predkladaných dokumentov.

Rovnakú pozornosť venujeme aspektom, ako sú formátovanie textu, zarovnávanie, riadkovanie a použitie preddefinovaných štýlov, ktoré prispievajú k profesionálnemu vzhľadu dokumentu. Dôkladné spracovanie matematických rovníc a grafov je ďalším dôležitým prvkom, ktorý môže ovplyvniť hodnotenie práce. Práca s týmito aspektmi zaisťuje, že obsah je prehľadný a presne odráža zamýšľané myšlienky.

V neposlednom rade sa naša príručka zameriava na význam citovania externých zdrojov, čo je zásadné pre zachovanie integrity a etických štandardov pri písaní akademických textov. Správne citovanie nielenže posilňuje argumentáciu, ale tiež pomáha predchádzať plagiátorstvu, ktoré môže mať vážne následky na akademickú kariéru.

Dodržiavanie týchto pokynov umožňuje vyhnúť sa bežným chybám a zvyšuje kvalitu záverečných prác, čím sa zlepšuje celkový dojem z akademických schopností. Dobre vypracovaná práca môže viesť k pozitívnemu hodnoteniu a uznaniu zo strany hodnotiteľov, čo je cieľom každého študenta.

Celkovo je príručka navrhnutá ako cenný nástroj na podporu pri písaní záverečných prác. Poskytnuté informácie a odporúčania prispievajú k dosiahnutiu akademických cieľov a pomôžu vypracovať kvalitné a odborné dokumenty, ktoré budú spĺňať štandardy fakulty.“

(ChatGPT 3, 2024)

Poznámka autora: Časť záveru vygenerovala umelá inteligencia na základe analýzy obsahu verzie dokumentu pre práce písané v MS Word. Konkrétne išlo o aplikáciu ChatGPT 3 dňa 29. 9. 2024. Rukopis umelej inteligencie je z textu cítiť aj napriek tomu, že celá komunikácia vedúca k tejto forme záveru trvala približne 40 minút. Parafrázujúc ľudové príslovie konštatujeme, že umelá inteligencia je možno dobrý sluha, ale zlý pán. Používajme ju s rozumom.

Pripomíname, že takýto spôsob tvorby obsahu je v záverečnej práci, ako aj v iných akademických textoch, nepripustný. Autorské dielo nesmie obsahovať odseky vytvorené generatívnou umelou inteligenciou. Preto sme ho formátovali ako citovaný text.

Literatúra

1. SIEMENS AG. *SIMATIC WinCC Unified PC* [online]. Siemens, 2025 [cit. 2026-04-07]. Dostupné z: <https://www.siemens.com/en-us/products/simatic-hmi/wincc-unified-software/>.
2. SIEMENS AG. *Engineering Copilot TIA Standard (Managed Service)* [online]. Siemens, 2025 [cit. 2026-04-07]. Dostupné z: <https://www.siemens.com/en-us/products/tia-portal/engineering-copilot-tia-standard/>.
3. INDUCTIVE AUTOMATION. *Ignition SCADA Software* [online]. Inductive Automation, 2026 [cit. 2026-04-07]. Dostupné z: <https://inductiveautomation.com/scada-software/>.
4. INDUCTIVE AUTOMATION. *Ignition Edge* [online]. Inductive Automation, 2026 [cit. 2026-04-07]. Dostupné z: <https://inductiveautomation.com/ignition/edge>.
5. TULIP INTERFACES. *Pricing and Plans* [online]. Tulip Interfaces, 2026 [cit. 2026-04-07]. Dostupné z: <https://tulip.co/plans/>.
6. TULIP INTERFACES. *Tulip Signs Strategic Collaboration Agreement With AWS to Build Generative AI Capabilities Empowering Frontline Workers* [online]. Tulip Interfaces, 2024-04-23 [cit. 2026-04-07]. Dostupné z: <https://tulip.co/press/tulip-signs-strategic-collaboration-agreement-with-aws-to-build-generative-ai-capabilities-empowering-frontline-workers/>.
7. AVEVA SOLUTIONS LIMITED. *AVEVA™ Edge* [online]. AVEVA, 2026 [cit. 2026-04-07]. Dostupné z: <https://www.aveva.com/en/products/edge/>.
8. AVEVA SOLUTIONS LIMITED. *Industrial AI for Operations* [online]. AVEVA, 2026 [cit. 2026-04-07]. Dostupné z: <https://www.aveva.com/en/solutions/digital-transformation/artificial-intelligence/industrial-ai-for-operations/>.
9. EITBIZ - EXTROVERT INFORMATION TECHNOLOGY. *Top App Development Frameworks to Build High-Performance Apps in 2026* [online]. Medium, 2025-12-23 [cit. 2026-04-07]. Dostupné z: <https://medium.com/@eitbiz/top-app-development-frameworks-for-high-performance-apps-in-2026-2db28c6c0a33>.
10. NADARAJAN, C. *How to Choose the Best Backend Frameworks in 2026 for AI-Powered Software: A Business Leader's Guide* [online]. ThinkPalm Technologies, 2025-12-01 [cit. 2026-04-07]. Dostupné z: <https://thinkpalm.com/blogs/how-t>

o-choose-the-right-backend-framework-for-ai-powered-software-a-business-leaders-guide/.

11. GARAI, K. *From Cloud to Edge: How Technology Is Redefining Data Processing* [online]. Medium, 2026-03-10 [cit. 2026-04-07]. Dostupné z: <https://medium.com/@kastab/from-cloud-to-edge-how-technology-is-redefining-data-processing-43b66acde782>.
12. DOCKER INC. *Docker Overview* [online]. Docker Documentation, 2026 [cit. 2026-04-07]. Dostupné z: <https://docs.docker.com/get-started/docker-overview/>.
13. OPC FOUNDATION. *OPC Unified Architecture* [online]. OPC Foundation, 2026 [cit. 2026-04-07]. Dostupné z: <https://opcfoundation.org/about/opc-technologies/opc-ua/>.
14. SIEMENS AG. *S7 Communication* [online]. Siemens TIA Portal Documentation, 2026 [cit. 2026-04-09]. Dostupné z: https://docs.tia.siemens.cloud/r/simatic_et_200clean_manual_collection_zhcn_20/function-manuals/communication-function-manuals/communication/s7-communication/s7-communication.
15. OASIS. *MQTT Version 5.0* [online]. OASIS, 2019-03-07 [cit. 2026-04-07]. Dostupné z: <https://docs.oasis-open.org/mqtt/mqtt/v5.0/mqtt-v5.0.html>.
16. MODBUS ORGANIZATION. *Modbus FAQ* [online]. Modbus Organization, 2026 [cit. 2026-04-07]. Dostupné z: <https://www.modbus.org/faq.php>.
17. STRYKER, C. *What are large language models (LLMs)?* [online]. IBM Think, 2025 [cit. 2026-04-11]. Dostupné z: <https://www.ibm.com/think/topics/large-language-models>.
18. ULLAH, I. *API vs. Self-Hosted LLM: Which Path Is Right for Your Enterprise?* [online]. Medium, 2025-08-28 [cit. 2026-04-11]. Dostupné z: <https://theirfan.medium.com/api-vs-self-hosted-llm-which-path-is-right-for-your-enterprise-82c60a7795fa>.
19. IBM. *What is retrieval augmented generation (RAG)?* [online]. IBM Think, 2025 [cit. 2026-04-11]. Dostupné z: <https://www.ibm.com/think/topics/retrieval-augmented-generation>.
20. RICADELA, A. *What Is Chroma? An Open Source Embedded Database* [online]. Oracle, 2024-04-15 [cit. 2026-04-11]. Dostupné z: <https://www.oracle.com/anz/database/vector-database/chromadb/>.

21. KUNTZ, C. *The New Industrial Evolution: How AI Assistants and Agents Are Transforming Manufacturing Knowledge* [online]. Training Industry, 2025-04-08 [cit. 2026-04-11]. Dostupné z: <https://trainingindustry.com/articles/work-force-development/the-new-industrial-evolution-how-ai-assistants-and-agents-are-transforming-manufacturing-knowledge/>.
22. META AI. *llama3.2* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/llama3.2>.
23. GOOGLE DEEPMIND. *gemma4* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/gemma4>.
24. MISTRAL AI; NVIDIA. *mistral-nemo* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/mistral-nemo>.
25. MICROSOFT. *phi4* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/phi4>.
26. MISTRAL AI. *mistral-small* [online]. Ollama, 2026 [cit. 2026-04-12]. Dostupné z: <https://ollama.com/library/mistral-small>.

Použitie nástrojov umelej inteligencie

OpenAI (2025), ChatGPT 4o, časť ??, generovanie vzorca záznamu použitia AI.

OpenAI (2024), ChatGPT 3, Záver, generovanie textu.

OpenAI (2025), ChatGPT 4o, dodatok B, generovanie kódu programu.

OpenAI (2024), ChatGPT 3, dodatok C, generovanie zoznamu.

Anthropic (2026), Claude Sonnet 4.6, ?? kontrola gramatiky a štylistická úprava vlastných textov.

Dodatok A: Algoritmus

Algoritmus 1 Vypočítaj $y = x^n$

Require: $n \geq 0 \vee x \neq 0$

Ensure: $y = x^n$

$y \Leftarrow 1$

if $n < 0$ **then**

$X \Leftarrow 1/x$

$N \Leftarrow -n$

else

$X \Leftarrow x$

$N \Leftarrow n$

end if

while $N \neq 0$ **do**

if N is even **then**

$X \Leftarrow X \times X$

$N \Leftarrow N/2$

else $\{N \text{ is odd}\}$

$y \Leftarrow y \times X$

$N \Leftarrow N - 1$

end if

end while

Dodatok B: Výpis dlhého kódu

Dlhšie kódy, prípadne kompletne programy vypisujeme do dodatkov práce. Nasledujúci program v jazyku Python vygeneruje súbor `thesis.tex`, ktorý je funkčne totožný s hlavným súborom tohto dokumentu. Stačí vyplniť prehľadný formulár pri volaní funkcie `generate_thesis_tex` na konci kódu a získate hlavný súbor vašej práce.

```
def generate_thesis_tex(
    author,
    reg_nr,
    title,
    title_en,
    day,
    month,
    year,
    keywords,
    keywords_en,
    study_programme,
    study_programme_en,
    study_field,
    study_field_en,
    training_workplace,
    training_workplace_en,
    supervisor,
    consultant=None,
    thesis_type="bp",
    language="sk",
):

    tex_class_option = thesis_type if thesis_type in ["bp", "dp"] else "bp"
    tex_language_option = "en" if language == "en" else ""

    if tex_language_option:
        document_class = f"\\documentclass[{tex_class_option},{tex_language_option}]{FEIstyle}"
    else:
        document_class = f"\\documentclass[{tex_class_option}]{FEIstyle}"

    tex_content = f"""
{document_class}

% Author of the thesis
\\FEIauthor{{{author}}}
```

```

% Evidence number
\\FEIregNr{{{reg_nr}}}

% Title
\\FEItitle{{{title}}}
\\FEItitleEn{{{title_en}}}

% Date
\\FEIdate{{{day}}}{{{month}}}{{{year}}}

% Keywords
\\FEIkeywords{{{keywords}}}
\\FEIkeywordsEn{{{keywords_en}}}

% Further details
\\FEIstudyProgramme{{{study_programme}}}
\\FEIstudyProgrammeEn{{{study_programme_en}}}
\\FEIstudyField{{{study_field}}}
\\FEIstudyFieldEn{{{study_field_en}}}
\\FEItrainingWorkplace{{{training_workplace}}}
\\FEItrainingWorkplaceEn{{{training_workplace_en}}}

% Supervisor
\\FEIsupervisor{{{supervisor}}}
""

    if consultant:
        tex_content += f"\n\\FEIconsultant{{{consultant}}}\n"

    tex_content += f""

% Bibliography database file
\\bibliography{{includes/bibliography.bib}}

\\begin{{document}}

\\frontmatter
\\FEIpdfInfo
\\FEIcover
\\FEItitlePage
\\includepdf[pages=-]{{includes/assignment.pdf}}
\\FEIthanks{{includes/thanks}}
\\FEIabstract{{includes/abstract}}
\\FEIabstractEn{{includes/abstractEN}}

```

```

\\FEIcontent
\\FEImanualListOfGlossaries{{includes/manual_glossary}}
\\FEIlistOfAlgorithms
\\FEIlistOfListings

\\mainmatter
\\FEIintroduction{{includes/introduction}}
\\FEIcore{{includes/core}}
\\FEIconclusion{{includes/conclusion}}
\\FEIbibliography
\\FEIaiDeclaration{{includes/ai_declaration}}
\\backmatter
\\FEIappendix{{Algoritmus\\label{{att:algorithms}}}}{{includes/attachmentA}}
\\FEIappendix{{Výpis dlhého kódu\\label{{att:listings}}}}{{includes/attachmentB}}
\\FEIappendix{{Slovníček pojmov\\label{{att:dictionary}}}}{{includes/attachmentC}}

\\end{{document}}
"""

with open("thesis.tex", "w", encoding="utf-8") as file:
    file.write(tex_content)

print("Súbor thesis.tex bol úspešne vygenerovaný.")

# Testovacie volanie funkcie
generate_thesis_tex(
    author="RNDr. Juraj Chlpík, PhD.",
    reg_nr="FEI-xxxx-xxxx",
    title="Rozšírená šablóna záverečnej práce na FEI STU v Bratislave v systéme LaTeX",
    title_en="Extended thesis template at FEI STU in Bratislava in LaTeX system",
    day="31",
    month="12",
    year="2024",
    keywords="záverečná práca, šablóna, LaTeX, formátovanie textu, citácie",
    keywords_en="Final thesis, template, LaTeX, text formatting, citations",
    study_programme="názov študijného programu",
    study_programme_en="Study program in English",
    study_field="názov študijného odboru",
    study_field_en="Field of the study in English",
    training_workplace="Názov školiaceho pracoviska",
    training_workplace_en="Training Work place",
    supervisor="tituly Meno Priezvisko, tituly",
    consultant="",

```

```
thesis_type="bp", # Možnosti: "bp", "dp"  
language="sk", # Možnosti: "sk" (slovenčina - predvolená), "en" (angličtina)  
)
```

Výpis kódu 3: Ukážka výpisu kódu programu načítaného z externého súboru pomocou makra `\lstinputlisting`

Dodatok C: Slovníček pojmov

Abstrakt – Krátke zhrnutie hlavných bodov dokumentu, vrátane cieľov, metodológie a výsledkov.

Bod (pt) – Jednotka merania veľkosti písma; 1 bod sa rovná približne 0,352 mm.

Bold – Písmo, ktoré je tučné, používané na zvýraznenie dôležitých častí textu a v nadpisoch.

Citácia – Uvedenie zdroja informácií v texte, ktoré umožňuje identifikáciu pôvodného materiálu.

Font – Typ písma, ktorý sa používa na zobrazenie textu. Rôzne fonty majú odlišný štýl a vzhľad.

Graf – Vizualizácia údajov, ktorá zobrazuje vzťah medzi premennými.

Kapitola – Hlavná časť dokumentu, ktorá sa zaoberá konkrétnou témou a je zvyčajne označená číslom alebo názvom.

Korektúra – Proces revízie a opravy textu s cieľom odstrániť chyby.

Kurzíva – Typ písma, ktorý je sklonený doprava a používa sa na zvýraznenie textu, názvov alebo cudzích výrazov.

Metodológia – Opis metód a techník použitých pri výskume alebo analýze.

Normostrana – Základná jednotka pre meranie dĺžky textu, ktorá zvyčajne obsahuje 1 800 znakov vrátane medzier.

Obrázok – Grafický prvok alebo fotografia, ktorá ilustruje text.

Odsadenie – Vzdialenosť prvého riadku odseku od okraja stránky.

Odsek – Základná jednotka textu, ktorá obsahuje súvislé myšlienky. V L^AT_EX-u sa odseky oddeľujú prázdny riadkom v zdrojovom texte.

Plagiátorstvo – Prezenterovanie cudzej práce alebo myšlienok ako vlastných bez riadneho citovania.

Rez písma – Variant typu písma, ktorý určuje štýlové úpravy, ako sú normálny, tučný (bold), kurzíva (italic) alebo podčiarknutie.

Riadkovanie – Vzdialenosť medzi jednotlivými riadkami textu.

Sadzba – Proces usporiadania textu a grafiky na stránke.

Súbor – Elektronický dokument, ktorý obsahuje text alebo dáta.

Šablóna – Prednastavené formátovanie pre rôzne typy textu, ktoré zabezpečuje jednotný vzhľad.

Tabuľka – Usporiadanie údajov do riadkov a stĺpcov.

Titulný list – Prvá stránka dokumentu, ktorá obsahuje základné informácie, ako je názov práce a meno autora.

Typografia – Umenie a technika usporiadania textu tak, aby bol esteticky príťažlivý a čitateľný.

Úvod – Prvá časť dokumentu, ktorá predstavuje tému a ciele výskumu.

Vedecká práca – Akademický dokument, ktorý prezentuje výsledky výskumu, analýzy alebo diskusie o špecifickej téme.

Zdroje primárne a sekundárne – Primárne zdroje sú originálne dokumenty; sekundárne zdroje interpretujú alebo analyzujú primárne zdroje.